Sağlık Bilimleri Fakültesi

Öğretim Elemanları için Yapay Zekâ Eğitimi

MODÜL 2

Karar Destek Sistemleri ve Tahminleyici Modelleme

Katılımcı Ders Notu · Açıklayıcı Sürüm

Algoritma yazmadan, model çıktısını klinik gözle okumak: hemşirelik, ebelik, beslenme ve diyetetik ile diğer sağlık bilimleri için uygulamalı bir rehber.

Oturum 1	Oturum 2	Oturum 3	Oturum 4
Makine nasıl “öğrenir”?	Model çıktısını okumak	“Neden bu hasta?” Açıklanabilirlik	Klinik araştırmaya entegrasyon

12 saat · 4 oturum × 3 saat · Orange Data Mining ile kodsuz uygulama

Eğitmen

Ali AKDAĞLI

2026

Bu notta kullanılan sepsis, diyabetik ayak, malnütrisyon ve preeklampsi veri setleri sentetiktir; gerçek hasta içermez ve yalnızca öğretim amaçlıdır. Pima diyabet verisi açık erişimli gerçek bir veri setidir.

Bu notu nasıl kullanmalısınız?

Bu ders notu, dört oturumluk Modül 2 eğitiminde size eşlik etmek ve eğitimden sonra da başvuru kaynağı olarak masanızda kalmak için hazırlandı. Kod yazmanızı beklemiyoruz; amacımız bir tahmin modelinin ürettiği çıktıyı, yıllardır kullandığınız Braden skalasını, NEWS2'yi ya da bir tanı testinin duyarlılığını okur gibi **klinik gözle okuyabilmenizdir**. Notun her bölümü bir oturuma karşılık gelir ve her oturumdaki akışı izler: önce kavramlar, sonra Orange uygulaması, en sonda vaka ve tartışma.

Not boyunca aynı türden bilgiler aynı renkli kutularda karşınıza çıkar. Kutuların anlamını bir kez öğrenirseniz metni hızla tarayabilir, tekrar ederken yalnızca ilgilendiğiniz kutulara dönebilirsiniz.

Tablo G.1. Notta kullanılan kutular ve anlamları

Kutu	Ne içerir?	Nasıl kullanılır?
Öğrenme hedefleri	Bölümün sonunda neleri yapabileceğiniz	Okumaya başlamadan önce göz atın, bölüm sonunda kendinizi bunlarla sınayın.
Klinik Köşe (teal)	Kavramın serviste, doğumhanede ya da poliklinikte karşılığı	Kendi klinik deneyiminizle bağ kurun; öğrencilerinize örnek olarak aktarabilirsiniz.
Benzetme (açık lacivert)	Teknik bir kavramı tanıdık bir klinik durumla açıklayan kısa anlatım	Kavramı birine anlatmanız gerektiğinde bu benzetmeyi kullanın.
Dikkat! (mercan)	Sık yapılan yanılgılar, tuzaklar ve sınırlılıklar	Bir makale ya da sunum okurken bu uyarıları kontrol listesi gibi kullanın.
Orange'da Adım Adım (kehribar)	Uygulama oturumundaki numaralı adımlar; widget adları İngilizce ve kalın	Bilgisayar başında adımları sırayla izleyin.
Kendinizi Sınayın (gri)	Kısa sorular; kavram, kısaltma ve terim soruları	Cevapları Ek F'de bulabilirsiniz.
Bölüm özeti	Bölümün beş ana mesajı	Tekrar ederken yalnızca özetleri okumak bile yeterli bir hatırlatma sağlar.
KISALTMA KARTI (lacivert çerçeve, numaralı)	Bir kısaltmanın ya da kavramın açılımı, Türkçesi, tek cümlelik tanımı, üç benzetmesi (mühendislik, günlük hayat, klinik), bizim verimizden adım adım hesabı ve sık karışıklık	Kavram ilk geçtiği yerde karşınıza çıkar. Sonradan dönmek için Ek D'deki kart dizinini kullanın.
Benzetmeler (açık mor)	Aynı fikri birkaç farklı benzetmeyle anlatan kısa kutu	Öğrencilerinize anlatırken size en uygun gelen benzetmeyi seçin.
Başka bir alandan bakış (gri-mavi)	Kavramın mühendislik ve teknik dünyadaki karşılığı	İstatistikçi ya da mühendis meslektaşlarınızla ortak dil kurmak için.
Bu kelimeler ne demek? (açık teal)	Veri setlerinde ve vakalarda geçen tıbbi terimlerin kısa hatırlatması: ne demek, normal değer, model için neden önemli, benzetme	Bu terimleri büyük olasılıkla biliyorsunuz; kutular, veri setinin sütunlarını modelin gözüyle okumanız için hazırlandı.

Okuma önerileri

- **Oturumdan önce:** "Bu notun tek büyük fikri" bölümünü, ilgili bölümün öğrenme hedeflerini ve kısaltma kartlarının "Tek cümleyle" satırlarını okuyun (15–20 dakika).
- **Oturum sırasında:** Şekillerin üzerine not alın. Orange uygulamasında ilgili kutudaki adımları izleyin. Bir kısaltmaya takılırsanız Ek D.1'e bakın.

- **Oturumdan sonra:** Kartlardaki “Bizim verimizden” hesaplarını kâğıt üzerinde kendiniz yapın, Kendinizi Sınayın sorularını yanıtlayın, Dikkat! kutularını ve bölüm özetini yeniden okuyun.
- **Araştırma önerisi ve terimler için:** Bölüm 4'teki kontrol listesini, Ek C'deki formu, Ek D'deki sözlükleri ve Ek E'deki formüller kopya kâğıdını kullanın.

Şekil numaraları hakkında

Bölüm şekilleri bölüm numarasıyla (Şekil 2.4 gibi) numaralanmıştır. **A** ve **B** harfiyle başlayan şekiller (Şekil A1, B3 gibi) kavramları benzetmelerle anlatan **açıklayıcı şekillerdir**; numaraları eğitmen kılavuzu ve sunumlarla ortak tutulduğu için aralarında boşluk vardır. A şekilleri istatistik kavramlarını, B şekilleri tıbbi kavramları anlatır.

Rakamlar ve veri setleri hakkında

Notta yer alan model sonuçlarının tamamı (AUC değerleri, karışıklık matrisi, eşik tablosu, SHAP katkıları) eğitim için hazırlanan veri setleri üzerinde gerçekten çalıştırılmış modellerden alınmıştır. Ondalık ayırıcı olarak virgül kullanılmıştır. Sepsis, diyabetik ayak, malnütrisyon ve preeklampsi setleri klinik bilgiyle tasarlanmış **sentetik** verilerdir, gerçek hasta içermez. Bu nedenle buradaki sayılar, klinik uygulamaya doğrudan aktarılabilecek bulgular değil, **okuma becerisi kazandırmaya yönelik örneklerdir**. Pima diyabet seti ise açık erişimli gerçek bir veri setidir (Smith ve ark., 1988).

Son olarak, model bir **asistan**dır, karar veren değildir. Bu notun tamamı tek bir cümlenin açılımı olarak okunabilir: **“Model öneriyor, hemşire/ebe karar veriyor.”**

Ali AKDAĞLI

İçindekiler

Bu notu nasıl kullanmalısınız? 2
Okuma önerileri 2
Şekil numaraları hakkında 3
Rakamlar ve veri setleri hakkında 3
Bu notun tek büyük fikri: Model bir duman dedektörüdür 6
Kısaltma kartları nasıl okunur? 7
Modül 2'ye genel bakış 9
Modülün genel hedefleri 9
Bölüm 1. Makine nasıl “öğrenir”? 11
1.1 Karar destek sistemlerini zaten kullanıyorsunuz 11
1.2 Kural tabanlı sistem ve öğrenen sistem 13
1.3 Bir modelin yapı taşları 15
1.4 Makine öğrenmesinin altı adımı ve eğitim/test ayrımı 21
1.5 Dört algoritma, dört klinik benzetme 24
1.6 Orange ile ilk adımlar 29
1.7 Vaka ve tartışma: servisinizde hangi karar desteklenebilir? 31
Bölüm 2. Model çıktısını okumak 34
2.1 Karışıklık matrisi: modelin karnesi 34
2.2 ROC eğrisi ve AUC 39
2.3 Prevalans ve PPV: aynı model, farklı servis 43
2.4 Eşik bir klinik karardır 46
2.5 Kalibrasyon: model “%30” dediğinde gerçekten %30 mu? 47
2.6 Nadir olaylar: kesinlik-duyarlılık eğrisi 50
2.7 Karmaşık algoritma her zaman kazanmaz 53
2.8 Orange uygulaması: dört modeli yarıştırmak 54
2.9 Çözümlü hesap alıştırması 55
2.10 Vaka: Epic Sepsis Model 56
Bölüm 3. “Neden bu hasta?” Açıklanabilirlik ve vakalar 59
3.1 Kara kutu sorunu 59
3.2 Değişken önemi: model genelde neye bakıyor? 59
3.3 SHAP: riskin faturası 61
3.4 İyi bir karar destek ekranı neye benzer? 66
3.5 Orange uygulaması: Explain eklentisi 67

Ali AKDAĞLI

3.6 Vakalar ... 68
Bölüm 4. Klinik araştırmaya entegrasyon ... 80
4.1 Bir modelin yaşam döngüsü ... 80
4.2 Kanıt basamakları ... 81
4.3 Raporlama rehberleri ve yanlılık riski araçları ... 82
4.4 Eleştirel okuma için 10 soru ... 85
4.5 Veri kayması: dün iyi çalışan model yarın bozulabilir ... 87
4.6 Yanlılık ve hakkaniyet ... 88
4.7 Etik, hukuk ve sorumluluk ... 90
4.8 Açık veri kaynakları ... 91
4.9 Araştırma tasarım türleri ... 91
4.10 Atölye: kendi araştırma önerinizi yazın ... 92
Sık yapılan yanlış yorumlar ... 94
Ek A. Orange kurulumu ve Explain eklentisi ... 94
A.1 Windows'ta kurulum ... 94
A.2 macOS'ta kurulum ... 95
A.3 Explain eklentisinin kurulumu (SHAP için) ... 95
Ek B. Veri setleri sözlüğü ... 96
Ek C. Araştırma önerisi formu ... 99
Ek D. Sözlükler ... 100
D.1 Kısaltmalar sözlüğü ... 100
D.2 Kısaltma kartları dizini ... 102
D.3 Kavramlar sözlüğü ... 102
D.4 Tıbbi terimler sözlüğü ... 105
Ek E. Formüller kopya kâğıdı (tek sayfa) ... 107
Ek F. Kendinizi Sınayın: cevap anahtarı ... 108
Ek G. Kaynakça ... 110

ALİ AKDAĞLI

Bu notun tek büyük fikri: Model bir duman dedektörüdür

Modül 2'nin on iki saatlik içeriği tek bir soruya indirgenebilir:

“Bu alarm cihazı ne kadar iyi çalışıyor ve ne zaman ötmeli?”

Bir sepsis tahmin modeli, aslında hasta için bir **duman dedektörüdür**. Hastanın verilerine (nabız, ateş, tansiyon, laktat…) bakar ve ya “tehlike var” diye öter ya da susar. Bu notta geçen bütün ölçütler (duyarlılık, özgüllük, PPV, NPV, ROC, AUC, kalibrasyon…) bu alarmın **karnesindeki farklı derslerdir**. Dedektörün adı “yapay zekâ modeli”, yangının adı “sepsis” (ya da ülser, malnütrisyon, preeklampsi). Geri kalan her şey ayrıntıdır.



Şekil A1. *Dört durum: bir alarmın başına gelebilecek her şey. Sütunlar GERÇEĞİ, satırlar ALARMIN SÖYLEDİĞİNİ gösterir.*

Bir alarm cihazının başına yalnızca dört şey gelebilir. Aşağıdaki tablo, bu dört durumu dört farklı “cihazda” gösterir. Notun geri kalanında hangi kavrama gelirsek gelelim, hep bu dört kutuya döneceğiz.

Tablo 0.1. Dört durum, dört cihaz: bu notun omurgası

Durum	Duman dedektörü	Havalimanı metal dedektörü	E-posta spam filtresi	Sepsis modeli
Doğru pozitif (DP)	Yangın var, öttü	Silah var, öttü	Spam, spam klasörüne gitti	Sepsis gelişecek, model uyardı
Yanlış pozitif (YP)	Tost yandı, öttü	Kemer tokası, öttü	Patronun e-postası spam'e düştü	Sepsis yok, model uyardı (gereksiz alarm)
Yanlış negatif (YN)	Yangın var, SUSTU	Silah var, ötmedi	Dolandırıcı e-posta gelen kutusuna geldi	Sepsis gelişti, model sustu (KAÇIRDI)
Doğru negatif (DN)	Yangın yok, sessiz	Temiz yolcu, sessiz	Normal e-posta gelen kutusunda	Sepsis yok, model sessiz

■ Benzetmeler: Hafıza kancası

Dört harfi asla karıştırmamanın tek kuralı: **iki harfi ayrı ayrı okuyun.**

1. **İkinci harf = alarm ne dedi?** P (pozitif) = öttü, "var" dedi. N (negatif) = sustu, "yok" dedi.
2. **Birinci harf = alarm haklı mıydı?** D (doğru) = haklıydı. Y (yanlış) = yanıldı.

Örnek: **YN** = "negatif dedi (sustu)" + "yanlıştı" = yangın vardı ama sustu = **kaçırılan hasta**. **YP** = "pozitif dedi (öttü)" + "yanlıştı" = boşuna alarm. Orange İngilizce kısaltmaları kullanır: **TP** (true positive) = DP, **FP** = YP, **FN** = YN, **TN** = DN. Kural aynıdır.

■ Başka bir alandan bakış

Mühendislik dilinde bu bir **ikili sınıflandırıcıdır** (binary classifier): bir sensör (model, 0–1 arası "risk voltajı" üretir) ile bir **karşılaştırıcı** devresinin birleşimi. Karşılaştırıcının referans voltajına **eşik** denir: sinyal eşiği geçerse çıkış 1 (alarm), geçmezse 0 (sessiz). Bütün modül, bu devrenin iki hata türünü ölçmekten ibarettir: **kaçırma** (YN) ve **yanlış alarm** (YP). İstatistikçi ya da mühendis bir meslektaşla ortak proje yürütürken bu cümle ortak bir dil kurmanızı sağlar.

Karnedeki dersler. Notta göreceğiniz her kavram, dedektöre sorulan tek bir soruya cevap verir. Bu tablo bütün notun haritasıdır; her kavramın ayrıntısı, numarası verilen **kısaltma kartında**dır.

Tablo 0.2. Karnedeki dersler: her kavram dedektöre hangi soruyu soruyor?

Kavram	Dedektöre sorduğu soru	Kart	Bölüm
Eşik	Hassasiyet düğmesi hangi konumda?	5	1.3, 2.4
Duyarlılık	Gerçek yangınların yüzde kaçında öttü?	13	2.1
Özgüllük	Yangın yokken yüzde kaç kez sessiz kalabildi?	14	2.1
PPV	Öttüğünde gerçekten yangın var mıydı? (Koşmaya değer mi?)	15	2.1
NPV	Sustuğunda içimiz rahat uyuyabilir mi?	16	2.1
Doğruluk	Toplamda kaç gün "haklı" çıktı? (Dikkat: pili bitmiş dedektör de çoğu gün haklıdır!)	17	2.1
ROC / AUC	Düğmeyi her konuma getirsek genel kalitesi ne? Dumanlı havayı temiz havadan ayırabiliyor mu?	18–19	2.2
Prevalans	Bu evde yangın ne kadar sık çıkıyor? (Nadir mi?)	20	2.3
Alarm yorgunluğu	Çok sık boşuna öterse ev halkı pilini çıkarır mı?	21	2.4
Kalibrasyon / Brier	Göstergesi "%30 duman" dediğinde gerçekten o kadar mı?	22–23	2.5
PR / AP	Yangın çok nadirse, alarmlarının ne kadarı gerçek kalıyor?	24	2.6
Dış validasyon	Başka bir evde (başka hastanede) de çalışıyor mu?	26	2.10
SHAP	Neden öttü? Hangi sensör tetikledi?	28–29	3.3
Veri kayması	Yıllar geçince sensör yaşlandı mı, ayarı kaydı mı?	33	4.5
Yanlılık	Her odada (her hasta grubunda) aynı iyilikte çalışıyor mu?	34	4.6

Kısaltma kartları nasıl okunur?

İstatistik ve makine öğrenmesi kısaltmalarının (PPV, NPV, ROC, AUC, PR, AP, SHAP…) her biri, ilk geçtiği yerde lacivert çerçeveli bir **KISALTMA KARTI** ile açılır. Bütün kartlar aynı sırayla ilerler; sırayı bir kez öğrenince kartları birkaç saniyede tarayabilirsiniz.

Tablo 0.3. Kısaltma kartının satırları

Satır	Ne bulursunuz?
Açılımı	Kısaltmanın İngilizce açılımı ve harf harf anlamı
Türkçesi	Türkçe karşılığı ve kavramın sorduğu soru
Tek cümleyle	Kavramın tek cümlelik sade tanımı (kalın yazılır)
Formül	Varsa formül; DP, YP, YN, DN harfleriyle
Benzetmeler	En az üç benzetme: mühendislik, günlük hayat ve klinik
Bizim verimizden	Bu eğitimin gerçek sonuçlarıyla adım adım hesap (sepsis test grubu: 900 hasta, 89 sepsis)
Hafıza kancası	Varsa kavramı akılda tutmanın kısa yolu
Sık karışıklık	En sık yapılan yanlış yorum ve doğrusu
İlgili şekil	Kavramı gösteren şekil ve tablolar

■ Klinik Köşe: Dört sayıyı aklınızda tutun

Kartlardaki hesapların yarısı aynı dört sayıyla yapılır. Sepsis verisinde XGBoost modeli %20 eşiğiyle 900 test hastasına uygulandığında: **DP 54, YP 61, YN 35, DN 750.** Bu dört sayıyı bir kenara yazın; 54/89, 750/811, 54/115 ve 750/785 hesaplarını kartlarla birlikte kendiniz yapın.

Bu notu bitirdiğinizde şu beş cümleyi kimseye bakmadan söyleyebiliyor olmalısınız:

1. “Duyarlılık hastalardan başlar, PPV alarmlardan başlar.”
2. “Nadir olayda alarmların çoğu boştur; bu modelin değil, matematiğin kuralıdır.”
3. “AUC sıralama becerisidir; terazinin ayarı değildir.”
4. “Kalibrasyon, terazinin sıfır ayarıdır.”
5. “SHAP bir bordrodur: ortalamadan başla, katkıları ekle, sonuca var. Ama nedeni değil, modelin gerekçesini söyler.”

Ali AKDAĞ

Modül 2'ye genel bakış

Klinik karar destek sistemleri (KDS) sağlık profesyoneline doğru bilgiyi, doğru zamanda ve doğru biçimde sunarak karar vermesine yardım eden araçlardır. Bu modülde odaklandığımız tür, hasta verisinden bir olayın (sepsis, ülser, malnütrisyon, preeklampsi) gerçekleşme olasılığını hesaplayan **tahminleyici modellerdir**. Modülün felsefesi basittir: algoritma yazmak değil, **çıktıyı klinik olarak okumak**. Her teknik kavramı, zaten bildiğiniz bir klinik araca bağlayacağız.

Modülün genel hedefleri

Modülü tamamlayan bir öğretim üyesinin aşağıdakileri yapabilmesi beklenir:

1. Kural tabanlı karar destek araçları ile veriden öğrenen modelleri ayırt etmek ve dört temel algoritmayı birer klinik benzetmeyle anlatmak.
2. Bir modelin karışıklık matrisini, ROC eğrisini, AUC değerini ve kalibrasyon grafiğini yorumlamak; eşik seçimini klinik bedel üzerinden gerekçelendirmek.
3. Değişken önemi ve SHAP grafikleriyle “model bu hasta için neden böyle dedi?” sorusunu yanıtlamak ve açıklamanın nedensellik olmadığını ayırt etmek.
4. Bir tahmin modeli makalesini TRIPOD+AI ve PROBAST+AI mantığıyla eleştirel okumak; etik, KVKK ve yanlılık boyutlarını tartışmak.
5. Kendi alanında, uygulanabilir bir tahminleyici model araştırma önerisi taslağı hazırlamak.
6. Orange Data Mining'de kod yazmadan veri açmak, model kurmak, performansı değerlendirmek ve SHAP açıklamaları üretmek.

Tablo G.2. Modül 2'nin dört oturumluk akışı (toplam 12 saat)

Oturum	Ana soru	Kavramlar	Orange uygulaması	Vaka / ürün
1. Makine nasıl “öğrenir”? 3 saat	Kural yazmak ile kuralı veriden çıkarmak arasındaki fark nedir?	KDS tarihi, eğitim/test ayrımı, aşırı öğrenme, LR, karar ağacı, Random Forest, XGBoost	File, Data Table, Tree, Tree Viewer (sepsis ve Pima)	Servisinizde hangi karar desteklenebilir? (3 fikir)
2. Model çıktısını okumak 3 saat	Model ne kadar iyi ve hangi eşikte kullanılmalı?	Karışıklık matrisi, duyarlılık, özgüllük, PPV, NPV, ROC/AUC, prevalans, eşik, kalibrasyon	Test and Score, Confusion Matrix, ROC Analysis (sepsis ve preeklampsi)	Epic Sepsis Model vakası, hesap alıştırması
3. “Neden bu hasta?” 3 saat	Model bu kararı neye dayanarak verdi?	Global ve yerel açıklama, değişken önemi, SHAP (arı kovanı, şelale, bağımlılık), nedensellik uyarısı	Explain eklentisi: Explain Model, Explain Prediction	Sepsis, diyabetik ayak, malnütrisyon, preeklampsi, Pima
4. Klinik araştırmaya entegrasyon 3 saat	Bir modele nasıl güvenir, nasıl araştırırız?	Yaşam döngüsü, kanıt basamakları, TRIPOD+AI, PROBAST+AI, veri kayması, yanlılık, KVKK, etik	—	10 soruluk eleştirel okuma, araştırma önerisi formu ve 3 dakikalık sunum

TAKDAĞLI

Tablo G.3. Her oturumun iç akışı

Zaman	Etkinlik	Bu nottaki karşılığı
00:00–00:50	Kavramsal anlatım	Bölüm metni, şekiller, Benzetme ve Klinik Köşe kutuları
00:50–01:00	Ara	—
01:00–01:50	Orange uygulaması	Orange'da Adım Adım kutuları
01:50–02:00	Ara	—
02:00–03:00	Vaka, tartışma, özet ve çıkış kartı	Vaka bölümleri, Kendinizi Sınayın, Bölüm özeti

■ Klinik Köşe: Beş veri seti, beş meslek alanı

Oturumlar boyunca beş veri seti kullanacağız: sepsis (hemşirelik), diyabetik ayak (hemşirelik/podiatri), malnütrisyon (beslenme ve diyetetik/hemşirelik), preeklampsi (ebelik) ve gerçek açık veri olan Pima diyabet. Hangi alandan gelirseniz gelin, en az bir vakanın doğrudan kendi pratiğinize dokunduğunu göreceksiniz. Veri setlerinin değişken sözlüğü Ek B'dedir.

Tablo G.4. Eğitimde kullanılan veri setleri

Dosya	n	Hedef değişken	Prevalans	Kaynak
sepsis_sentetik.csv	3000	Sepsis (24 saat): Evet/Hayır	%9,9	Sentetik, servis hastası
diyabet_pima.csv	768	Diyabet: Var/Yok	%34,9	Gerçek açık veri (Smith ve ark., 1988)
diyabetik_ayak_sentetik.csv	2000	Ülser (12 ay): Evet/Hayır	%12	Sentetik
malnutrisyon_sentetik.csv	1500	Malnütrisyon (GLIM): Var/Yok	%27,7	Sentetik, ≥65 yaş yatan hasta
preeklampsi_sentetik.csv	4000	Preeklampsi: Gelişti/Gelişmedi	%5,5	Sentetik, 11–13. hafta taraması

Ali AYGÜL

Bölüm 1. Makine nasıl "öğrenir"?

Oturum 1 · 3 saat. Bu bölümde bir bilgisayarın "öğrenmesinin" ne anlama geldiğini, bildiğimiz klinik skorlardan yola çıkarak açacağız. Amacımız matematik öğrenmek değil; karşınıza bir model çıktığında onun **nasıl kurulduğunu, neye dayandığını ve nerede yanılabileceğini** sorgulayabilmektir.

■ Öğrenme hedefleri

Bu bölümü tamamladığınızda şunları yapabileceksiniz:

1. Kural tabanlı bir karar destek sistemi ile veriden öğrenen bir sistemi ayırt eder.
2. Verinin neden eğitim ve test olarak ikiye ayrıldığını, aşırı öğrenme (overfitting) kavramıyla açıklar.
3. Lojistik regresyon, karar ağacı, Random Forest ve XGBoost'u birer klinik benzetmeyle anlatır.
4. Orange'da bir veri setini açar, hedef değişkeni tanımlar ve bir karar ağacını okur.

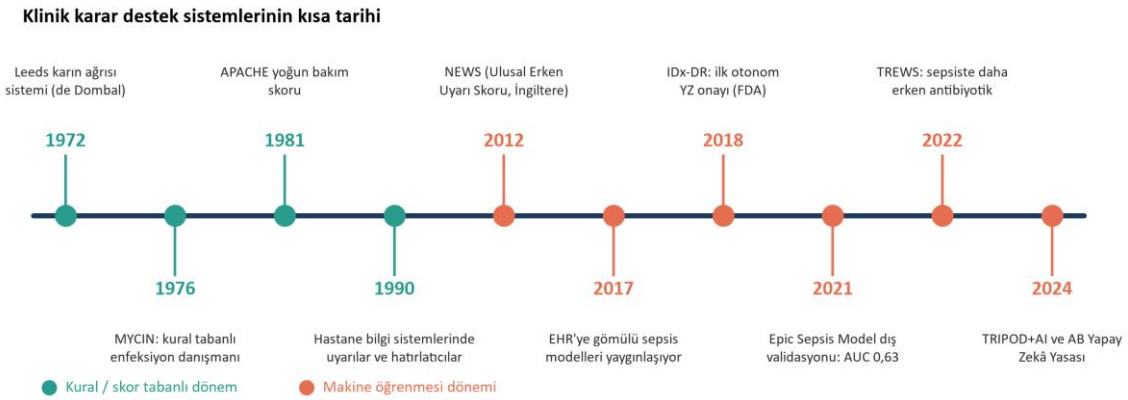
1.1 Karar destek sistemlerini zaten kullanıyorsunuz

Karar destek sistemi kulağa yeni ve teknolojik bir kavram gibi gelse de sağlık bilimlerinde onlarca yıldır kullanılıyor. Bası yarası riskini değerlendirmek için Braden ya da Norton skalasını, düşme riskini belirlemek için Morse düşme skalasını, yenidoğanı değerlendirmek için APGAR'ı, bilinç düzeyini izlemek için Glasgow Koma Skalasını (GKS) kullandığınızda aslında bir karar destek aracından yararlanırsınız. Bu araçların ortak özelliği şudur: **Kuralı bir uzman grubu yazmıştır.** Hangi bulgunun kaç puan alacağı, toplam puanın hangi eşikte "risk" sayılacağı önceden belirlenmiştir.

Tablo 1.1. Klinikte her gün kullandığımız kural tabanlı karar destek araçları

Araç	Ne için?	Kural nasıl çalışır?	Bu modüldeki karşılığı
Braden / Norton skalası	Bası yarası riski	Alt boyutlara puan verilir, toplam puan riske çevrilir.	Lojistik regresyonun "ağırlıklı toplam" mantığı
Morse düşme skalası	Düşme riski	Öykü ve gözlem maddeleri puanlanır, eşiğe göre önlem seçilir.	Eşik seçimi (Bölüm 2)
NEWS2 (Royal College of Physicians, 2017)	Klinik kötüleşmenin erken fark edilmesi	Vital bulgular puanlanır; toplam puan yanıt düzeyini belirler.	Erken uyarı modelleri, alarm yorgunluğu
qSOFA (Seymour ve ark., 2016)	Enfeksiyon şüphesinde kötü sonuç riski	Solunum sayısı ≥22, sistolik KB ≤100 mmHg, bilinç değişikliği: her biri 1 puan; ≥2 pozitif.	Sepsis vakası (Bölüm 3)
APGAR	Yenidoğanın doğum sonrası uyumu	Beş bulgu 0–2 arası puanlanır.	Basit, şeffaf skor örneği
Glasgow Koma Skalası	Bilinç düzeyi	Göz, sözel ve motor yanıt toplanır (3–15).	Karar ağacının ilk sorusu (Şekil 1.5)

Makine öğrenmesi (machine learning) bu tabloya yeni bir soru ekler: **Kuralı insan yazmak yerine, kural geçmiş hasta verisinden çıkarılabilir mi?** Karar destek sistemlerinin elli yılı aşkın tarihi bu sorunun etrafında şekillenmiştir (Şekil 1.1). 1972'de Leeds'te geliştirilen akut karın ağrısı sistemi bilgisayarla tanı desteğinin ilk örneklerindendir (de Dombal ve ark., 1972). 1970'lerde MYCIN, enfeksiyon tedavisinde yüzlerce "eğer–ise" kuralıyla çalışan bir danışman olarak tasarlandı (Shortliffe, 1976). 1981'de yoğun bakım hastalarının ağırlığını puanlayan APACHE geliştirildi (Knaus ve ark., 1981). Erken uyarı skorları hastane servislerine yayıldı ve NEWS2 ile standartlaştı (Royal College of Physicians, 2017).



Şekil 1.1. *Klinik karar destek sistemlerinin kısa tarihi: 1972 Leeds sisteminden 2024'te TRIPOD+AI ve AB Yapay Zekâ Yasası'na.*

2010'lardan sonra elektronik sağlık kayıtlarının yaygınlaşmasıyla veriden öğrenen modeller ön plana çıktı. 2018'de diyabetik retinopatiyi birinci basamakta hekim yorumu olmadan saptayan bir sistem, otonom çalışan ilk yapay zekâ tanı aracı olarak onay aldı (Abràmoff ve ark., 2018). Aynı dönemde elektronik kayıtlara gömülü sepsis modelleri yaygınlaştı; ancak bunlardan birinin bağımsız bir dış validasyonunda performansın beklenenden çok düşük çıkması, alanda önemli bir uyarı işlevi gördü (Wong ve ark., 2021). Buna karşılık iyi tasarlanmış ve klinisyen yanıtıyla birleştirilmiş bir sepsis uyarı sisteminin hasta sonuçlarını iyileştirebileceği de gösterildi (Adams ve ark., 2022). Bu iki vakayı Bölüm 2 ve 3'te ayrıntılı ele alacağız. 2024'te hem tahmin modeli çalışmalarının raporlanmasına yönelik TRIPOD+AI rehberi (Collins ve ark., 2024) hem de Avrupa Birliği Yapay Zekâ Yasası (Regulation (EU) 2024/1689, 2024) yayımlandı.

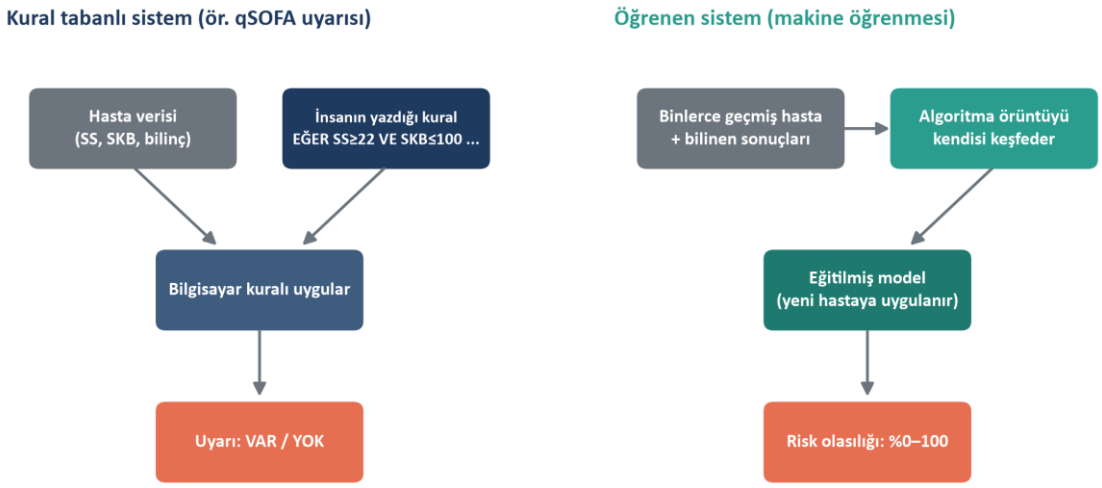
■ Bu kelimeler ne demek? · Tarihçede geçen adlar

Şekil 1.1'deki ve bu bölümdeki adların kısa açıklaması. Ayrıntılı kaynaklar Ek G'dedir.

Terim	Ne demek?	Benzetme / not	Bu eğitimde
Leeds sistemi (1972)	Akut karın ağrısında bilgisayar destekli olasılıksal (Bayes) tanı sistemi (de Dombal ve ark., 1972).	İlk "olasılık hesaplayan" tanı yazılımı.	Şekil 1.1
MYCIN (1976)	Stanford'da geliştirilen, kan enfeksiyonlarında antibiyotik öneren kural tabanlı uzman sistem.	Yüzlerce "eğer–ise" kuralı.	Şekil 1.1
APACHE (1981)	Yoğun bakım hastalarının hastalık ağırlığını puanlayan skor.	Ağırlık puanlama tablosu.	Şekil 1.1
IDx-DR (2018)	Göz dibi fotoğrafından diyabetik retinopatiyi hekim yorumu olmadan saptayan, FDA onaylı ilk otonom YZ tanı aracı (Abràmoff ve ark., 2018).	Görüntüden karar veren otomatik muayene istasyonu.	Bölüm 1.1, 4.2
FDA	Food and Drug Administration: ABD Gıda ve İlaç Dairesi; ilaç ve tıbbi cihazlara onay verir.	Sertifikasyon kurumu (CE gibi).	IDx-DR
EHR / EHK / HBYS	Electronic Health Record: elektronik hasta kaydı; Türkiye'de hastane bilgi yönetim sistemi (HBYS).	Hastanenin veritabanı.	Bölüm 1.1, 4
Epic Sepsis Model	ABD'de yaygın bir elektronik kayıt yazılımına gömülü ticari sepsis modeli; dış validasyonda AUC 0,63 (Wong ve ark., 2021).	Sahada başarısız olan ticari ürün.	Bölüm 2.10
TREWS	Targeted Real-time Early Warning System: Johns Hopkins'te geliştirilen sepsis erken uyarı sistemi (Adams ve ark., 2022).	Sahada işe yarayan örnek.	Bölüm 3, Vaka 1
AB YZ Yasası (2024/1689)	Avrupa Birliği Yapay Zekâ Yasası; tıbbi YZ'yi çoğunlukla "yüksek riskli" sınıfa koyar.	Ürün güvenliği mevzuatı.	Bölüm 4.7

1.2 Kural tabanlı sistem ve öğrenen sistem

Şekil 1.2 iki yaklaşımı yan yana gösterir. Kural tabanlı sistemde uzman kuralı yazar, bilgisayar yalnızca uygular. Öğrenen sistemde ise bilgisayara çok sayıda geçmiş hasta kaydı ve her hastanın sonucu (örneğin 24 saat içinde sepsis gelişip gelişmediği) verilir. Algoritma, bu kayıtlarda sonucu en iyi ayıran örüntüyü kendisi bulur. Ortaya çıkan "kural" çoğu zaman bir puan tablosu kadar yalın değildir; ama yeni bir hasta geldiğinde ona bir **risk olasılığı** verir.



Şekil 1.2. *Kural tabanlı sistem (örneğin qSOFA uyarısı) ile veriden öğrenen sistemin karşılaştırması.*

Tablo 1.2. Kural tabanlı ve öğrenen sistemlerin karşılaştırması

Özellik	Kural tabanlı sistem	Öğrenen sistem (makine öğrenmesi)
Kuralı kim koyar?	Uzman grubu, literatür, uzlaşı	Algoritma, geçmiş veriden
Şeffaflık	Yüksek: her puan görünür	Algoritmaya göre değişir; açıklama araçları gerekir (Bölüm 3)
Değişken sayısı	Genellikle az	Onlarca, hatta yüzlerce değişken olabilir
Etkileşimler	Çoğunlukla yok sayılır	Değişkenler arası etkileşimleri yakalayabilir
Yeni ortama uyum	Kural sabittir	Yeniden eğitilebilir; ama veri kaymasına açıktır (Bölüm 4)
Başlıca risk	Kaba ve genel kalabilir	Eğitildiği veriye özgü kalabilir, yanlılığı devralabilir
Örnek	Braden, Morse, NEWS2, qSOFA	Elektronik kayda gömülü sepsis modeli, preeklampsi risk algoritmaları

■ Benzetme: Öğrenmek, deneyim kazanmaktır

Yirmi yıllık bir yoğun bakım hemşiresi hastanın yanına gelir, monitöre ve yüzüne bakar ve "bu hasta iyi değil" der. Henüz hiçbir skor eşiği aşılmamıştır. Bu sezgi bir kural kitabından değil, **binlerce vakadan biriken deneyimden** gelir. Makine öğrenmesi modeli de binlerce kayıttan örüntü çıkarır. Ancak önemli bir fark vardır: model **yalnızca kendisine gösterilen vakalardan** öğrenir. Pediatri servisinde hiç çalışmamış bir hemşirenin çocuk hastadaki sezgisine ne kadar güvenirsek, yetişkin verisiyle eğitilmiş bir modele de çocuk hastada o kadar güvenebiliriz.

Bu bölümde sık geçecek ilk kısaltmalar KDS, YZ, ML ve XAI'dir; "model", "algoritma" ve "eğitim" sözcükleri de günlük dildekinden biraz farklı anlamlarda kullanılır. Aşağıdaki iki kart bu dili yerine oturtur.

KISALTMA KARTI 1	**KDS, YZ, ML, derin öğrenme, XAI**
Açılımı	KDS = Karar Destek Sistemi (CDSS, Clinical Decision Support System) · YZ = Yapay Zekâ (AI, Artificial Intelligence) · ML = Machine Learning · DL = Deep Learning · XAI = eXplainable Artificial Intelligence
Türkçesi	Karar destek sistemi · yapay zekâ · makine öğrenmesi · derin öğrenme · açıklanabilir yapay zekâ
Tek cümleyle	**KDS klinik karara yardım eden her araçtır; makine öğrenmesi, KDS'nin kurallarını insanın yazması yerine geçmiş veriden çıkarmasıdır.**
Benzetmeler	1. **Mühendislik:** Kural tabanlı KDS, elle yazılmış bir fabrika otomasyon programıdır ("sıcaklık 80'i geçerse alarm ver"). Makine öğrenmesi aynı mantığı geçmiş arıza kayıtlarından kendisi bulan bir sistemdir. 2. **Günlük hayat:** Annenizin tarif defteri kural tabanlıdır ("2 su bardağı un"). Usta aşçı ise yıllarca tadarak öğrenmiştir; tarif yazmaz ama tadı tutturur. Makine öğrenmesi usta aşçıdır. 3. **Klinik:** Braden, Morse, NEWS2 ve qSOFA birer kural tabanlı KDS'dir: kuralları uzman kurulu yazdı. Makine öğrenmesinde "kurul", binlerce hasta kaydıdır. 4. **Matruşka:** Yapay zekâ en büyük bebektir; içinde makine öğrenmesi, onun içinde derin öğrenme vardır. XAI bunların "neden böyle dedin?" sorusuna cevap veren açıklama araçlarıdır.
Bizim verimizden	Kural tabanlı: qSOFA'daki "solunum sayısı ≥22 ise 1 puan" kuralını insanlar yazdı. Öğrenen: Bizim karar ağacımız 3000 hastadan ilk soruyu kendisi buldu: "GKS ≤ 14,5 mi?", yani "bilinçte en ufak bir değişiklik var mı?" (Şekil 1.5).
Sık karışıklık	"Yapay zekâ kendi kendine düşünür." Hayır: model yalnızca kendisine gösterilen verideki örüntüyü öğrenir; hiç görmediği hasta tipini bilemez. Bu modülde derin öğrenme yoktur; tablo verisi ve klasik makine öğrenmesi vardır.
İlgili şekil	Şekil 1.1 (tarihçe), Şekil 1.2 (kural tabanlı ve öğrenen sistem)

KISALTMA KARTI 2	**Model, algoritma, eğitim**
Açılımı	Model · Algorithm (algoritma) · Training / fitting (eğitim, uydurma) · Parameter (parametre, modelin öğrendiği ayar)
Türkçesi	Algoritma = tarif · model = o tarifle pişmiş yemek · eğitim = pişirme süreci
Tek cümleyle	**Algoritma bir tariftir, model o tarifle pişmiş yemektir; eğitim, tarifin geçmiş verilerle pişirilmesi, yani modelin ayarlarının veriden öğrenilmesidir.**
Benzetmeler	1. **Mühendislik:** Ölçüm noktalarından en uygun eğriyi geçirmek (eğri uydurma). "En küçük kareler" yöntemi algoritmadır; bulunan katsayılarla kurulmuş denklem modeldir. 2. **Günlük hayat:** Tarif herkeste aynıdır; ama her aşçının eli farklı tat verir, çünkü farklı yemeklerden öğrenmiştir. Aynı algoritma farklı veriyle farklı model üretir. 3. **Klinik:** Yirmi yıllık yoğun bakım hemşiresinin hastaya bakıp "bu hasta kötüleşecek" demesi: binlerce hastadan öğrenilmiş bir sezgi.
Bizim verimizden	Aynı algoritma (Random Forest) iki farklı veriyle eğitilince iki farklı model çıkar: sepsis modeli ve Pima diyabet modeli. Bizim sepsis modelleri 2100 hastalık eğitim verisiyle "pişirildi", 900 hastada sınandı.
Sık karışıklık	"Model" ile "algoritma" günlük dilde birbirinin yerine kullanılır; sorun değildir. Ama "XGBoost algoritması" ile "bizim XGBoost modelimiz" farklıdır: ikincisi bizim verimizle eğitilmiş belirli bir üründür ve yalnızca o veriyi temsil eder.

1.3 Bir modelin yapı taşları

Orange'da bir veri setini açtığınızda karşınıza bir tablo gelir. Bu tablonun her parçasının klinik bir karşılığı vardır. Terimleri bir kez yerine oturttuğunuzda makalelerin yöntem bölümleri de çok daha kolay okunur.

Tablo 1.3. Veri tablosunun dili: terimler ve sepsis örneğindeki karşılıkları

Terim	Ne demek?	Sepsis veri setindeki karşılığı
Satır (gözlem, kayıt)	Bir hasta ya da bir yatış	3000 servis hastasından biri
Değişken, özellik (feature)	Modelin kullandığı bilgi; tahmin edici	Yaş, nabız, solunum sayısı, ateş, laktat, GKS vb. (15 değişken)
Hedef değişken (target)	Tahmin edilmek istenen sonuç	Sepsis (24 saat): Evet/Hayır
Prevalans	Hedef olayın veri setindeki sıklığı	%9,9 (yaklaşık her 10 hastadan 1'i)
Sınıflandırma	Hedefin kategorik olduğu tahmin görevi	Sepsis olacak mı, olmayacak mı?
Olasılık (risk skoru)	Modelin her hasta için verdiği 0–1 arası değer	Örneğin 0,68: "%68 olasılıkla sepsis"
Eşik (threshold)	Olasılığın "uyarı" sayılacağı sınır	Örneğin %20'nin üzeri uyarı üretir (Bölüm 2)

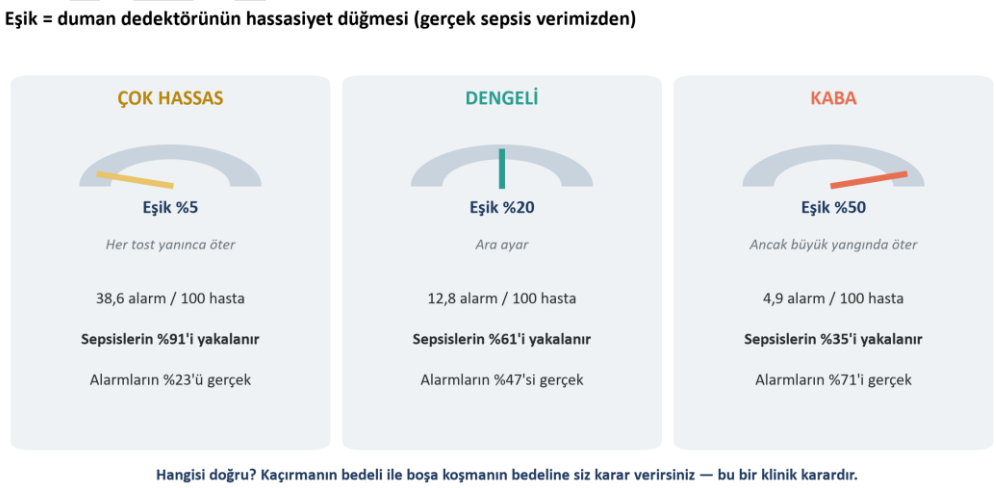
Tablodaki üç kavram, yani **değişken/hedef**, **olasılık** ve **eşik**, notun geri kalanının temelidir. Özellikle eşik, Bölüm 2'deki bütün hesapları belirler.

KISALTMA KARTI 3	**Değişken (özellik, feature) ve hedef (target)**
Açılımı	Feature = özellik, değişken, girdi, prediktör · Target = hedef, çıktı, sonuç (outcome), etiket (label)
Türkçesi	Değişken: modelin baktığı bilgi · Hedef: modelin tahmin etmeye çalıştığı sonuç
Tek cümleyle	**Değişkenler modelin girişleridir (nabız, ateş, laktat…); hedef, tahmin edilmek istenen sonuçtur (24 saat içinde sepsis var/yok).**
Benzetmeler	1. **Mühendislik:** Sensör kanalları ve sistem çıkışı: değişkenler giriş, hedef çıkıştır. 2. **Günlük hayat:** İkinci el araba alırken kilometre, model yılı ve hasar kaydı değişkenlerdir; "bu araba 2 yıl içinde arıza yapar mı?" sorusu hedeftir. 3. **Klinik:** Vital bulgular ve laboratuvar değerleri değişkenlerdir; "24 saat içinde sepsis gelişecek mi?" hedeftir. 4. **Excel:** Tablonun her sütunu bir değişkendir; en sağdaki "cevap sütunu" hedeftir. Her satır bir hastadır.
Bizim verimizden	Sepsis verisinde 15 değişken var: yaş, cinsiyet, nabız, solunum sayısı, ateş, sistolik KB, SpO2, GKS, laktat, lökosit, kreatinin, trombosit, diyabet, immünsupresyon, üriner kateter. Hedef son sütundur: "Sepsis (24 saat)" → Evet/Hayır. Orange'da bu sütun **Role = target** olarak işaretlenmezse model neyi tahmin edeceğini bilemez.
Sık karışıklık	Tahmin anında elde olmayan bir bilgiyi değişken yapmak (ör. sepsis tanısından sonra başlanan antibiyotik) veri sızıntısıdır (Kart 32). Değişken, kararın verildiği **anda** bilinen bir şey olmalıdır.

KISALTMA KARTI 4	**Olasılık (risk skoru, tahmin edilen risk)**
Açılımı	Probability = olasılık · Predicted risk = tahmin edilen risk · Score = puan
Türkçesi	Modelin "bu hasta için risk yüzde kaç?" cevabı
Tek cümleyle	**Model doğrudan "evet/hayır" demez; 0 ile 1 arasında bir sayı verir: 0,68 demek "%68 risk" demektir.**

Benzetmeler	1. **Mühendislik:** Analog sensör çıkışı: henüz bir karşılaştırıcıdan geçip dijital 0/1'e dönüşmemiş bir voltaj. Alarm kararı bu voltajdan sonra gelir. 2. **Günlük hayat:** Hava durumunun "yarın %70 yağmur" demesi. Meteoroloji "yağacak/yağmayacak" demez; şemsiyeyi alıp almamak sizin kararınızdır. 3. **Klinik:** "Bu hastanın 24 saat içinde sepsis olma olasılığı %68." Hemşire ve hekim bu sayıya, kendi değerlendirmesine ve bağlama göre eylem seçer.
Bizim verimizden	Örnek hastamız (57 yaşında erkek): modelin riski **%68**; ortalama servis hastasının riski **%6,7**. Laktata göre basit gösterim (Şekil 1.4): laktat 2 mmol/L → risk %14; laktat 4 mmol/L → risk %73.
Sık karışıklık	"Risk %68 ise hasta kesin sepsis." Hayır. %68, bu özellikteki 100 hastanın yaklaşık 68'inde olay beklendiği anlamına gelir (model iyi kalibre ise; Kart 22). Yaklaşık 32'sinde sepsis gelişmeyecektir.

KISALTMA KARTI 5	**Eşik (threshold, cut-off, kesim noktası)**
Açılımı	Threshold = eşik · Cut-off = kesim noktası · Operating point = çalışma noktası
Türkçesi	Riskin kaçın üzerinde alarm çalacağını belirleyen sınır
Tek cümleyle	**Eşik, olasılığı "alarm / sessiz" kararına çeviren sınırdır; eşiği model değil, biz seçeriz.**
Benzetmeler	1. **Mühendislik:** Termostat ayarı ya da sigorta amper değeri: 6 A'lık sigorta en ufak yükte atar (çok hassas), 32 A'lık sigorta çok geç atar (kablo yanabilir). 2. **Günlük hayat:** Duman dedektörünün hassasiyet düğmesi. Çok hassas: her tost yaktığınızda öter. Az hassas: gerçek yangını geç fark eder (Şekil A15). 3. **Klinik:** "Ateş 38 °C ve üzeriyse ateşli say" kuralı bir eşiktir. Ya da "riski %20'yi geçen hastayı başucunda yeniden değerlendir".
Bizim verimizden	XGBoost sepsis modeli, aynı model, üç düğme ayarı: • Eşik **%5**: 100 hastada **38,6** uyarı; sepsislerin **%91**'i yakalanır; alarmların **%23,3**'ü gerçek. • Eşik **%20**: 100 hastada **12,8** uyarı; sepsislerin **%60,7**'si yakalanır; alarmların **%47**'si gerçek. • Eşik **%50**: 100 hastada **4,9** uyarı; sepsislerin yalnızca **%34,8**'i yakalanır; alarmların **%70,5**'i gerçek. Modeli değiştirmedik; sadece düğmeyi çevirdik. Tam tablo: Tablo 2.6.
Sık karışıklık	"Model sepsis var dedi." Model bir olasılık verdi; "var" diyen sizin seçtiğiniz eşiktir. Orange varsayılan olarak 0,5 eşiğini kullanır; bu yüzden Orange'da duyarlılık bu nottakinden düşük görünür.
İlgili şekil	Şekil A15 (aşağıda), Şekil 2.5, Tablo 2.6



Şekil A15. *Eşik = duman dedektörünün hassasiyet düğmesi. Gerçek sepsis verimizden (XGBoost) üç ayar: %5, %20 ve %50.*

> ■ **Klinik Köşe: Hedefi kim, nasıl tanımladı?**
>
> Hedef değişkenin nasıl tanımlandığı modelin her şeyidir. "Sepsis" bir hastanede Sepsis-3 ölçütlerine göre (Singer ve ark., 2016), bir başkasında hekimin tanı koduna, bir üçüncüsünde kan kültürü istenmesine göre tanımlanmış olabilir. Bu üç model aynı adı taşısa da **farklı şeyleri** tahmin eder. Bir model makalesi okurken ilk sorunuz "sonuç nasıl ve ne zaman tanımlandı?" olmalıdır.

1.3.1 Sepsis veri setinin dili: bu kelimeler ne demek?

Sepsis veri seti modülün ana örneğidir ve dört oturumun hepsinde karşımıza çıkar. Sütunlarındaki terimlerin çoğunu klinikten biliyorsunuz. Aşağıdaki kutular bu bilgiyi **modelin gözüyle** tazeler: her terimin normal değerini, model için neden önemli olduğunu, öğrencilerinize anlatırken kullanabileceğiniz bir benzetmeyi ve bu eğitimde nerede karşımıza çıktığını bulacaksınız.

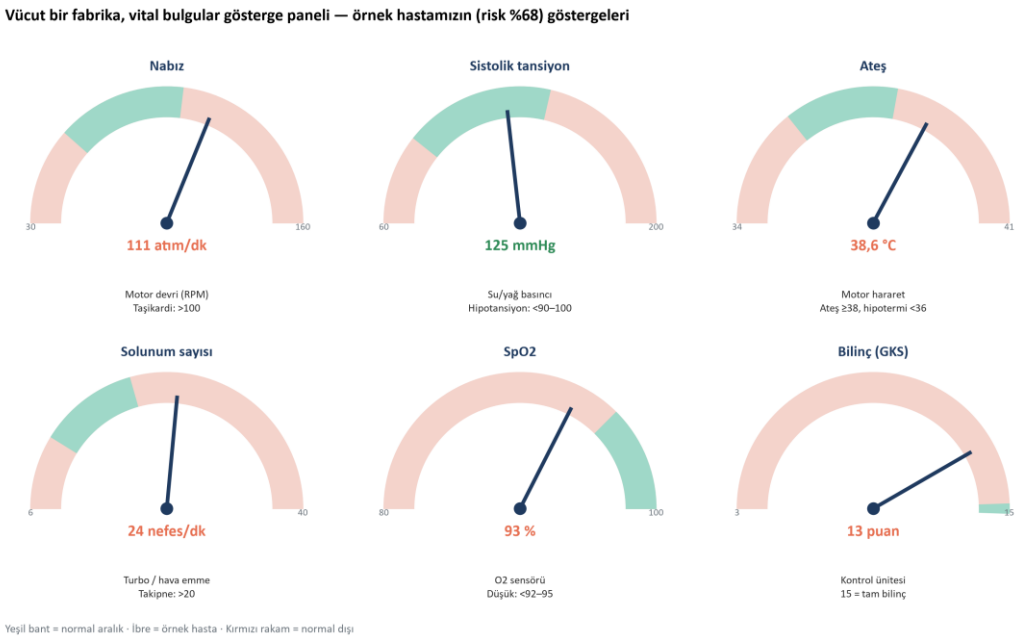
> ■ **Bu kelimeler ne demek? · Sepsis veri seti (sepsis_sentetik.csv)**
>
> 15 değişken ve 1 hedef sütun. Önce hastalığın kendisi, sonra vital bulgular, laboratuvar değerleri ve hasta özellikleri. Sütunların birim ve aralık listesi Ek B.1'dedir.

Sepsis	
Ne?	Vücudun bir enfeksiyona verdiği tepkinin kontrolden çıkması ve kendi organlarına zarar vermesi; güncel tanım Sepsis-3 (Singer ve ark., 2016). **Septik şok:** sepsisin, tansiyonun ilaçla bile zor yükseltildiği en ağır hâli.
Normal değer	Tek bir "normal değer" yoktur; tanı klinik ölçütlerle konur.
Model için neden önemli?	Erken fark edilip tedavi hızla başlarsa hayat kurtarır; her saatlik gecikme riski artırır. Erken uyarı modelinin (duman dedektörünün) değeri buradan gelir.
Benzetme	Eve hırsız girdi (mikrop). Alarm sistemi (bağışıklık) o kadar aşırı tepki verdi ki yangın söndürme sistemi bütün evi su bastı: hırsızdan çok savunmanın kendisi zarar verdi (Şekil B2).
Bu eğitimde	Modülün ana örneği: sepsis veri seti, 3000 servis hastası, hedef "Sepsis (24 saat)", prevalans %9,9.



Şekil B2. *Sepsis benzetmesi: hırsızdan (mikroptan) çok, alarm sisteminin (bağışıklığın) kendisinin zarar vermesi.*

Vital bulgular bir gösterge panelidir. Vücudu bir fabrika ya da araba motoru gibi düşünürsek, vital bulgular hemşirenin birkaç saatte bir okuduğu **gösterge panelidir** (Şekil B1). Sepsis modelinin girişlerinin yarısı bu göstergelerdir. Şekildeki ibreler örnek hastamızı (risk %68) gösterir.



Şekil B1. *Vital bulgular = gösterge paneli. Yeşil bant normal aralık, ibre örnek hastamızın değeri; kırmızı rakamlar normal dışı.*

Vital bulgu	Ne ölçer?	Normal	Araba / fabrika benzetmesi	Örnek hasta
Nabız (kalp hızı)	Kalbin dakikadaki atım sayısı	60–100 /dk	Motor devri (RPM)	111 → yüksek
Kan basıncı	Damarlardaki basınç	Sistolik ~90–120 mmHg	Su/yağ basıncı göstergesi	125 → normal
Ateş (vücut sıcaklığı)	Vücut ısısı	36,5–37,5 °C	Motor hararet göstergesi	38,6 → ateş
Solunum sayısı	Dakikadaki soluk sayısı	12–20 /dk	Hava emme / turbo devri	24 → hızlı
SpO2	Kandaki oksijen doygunluğu	%95–100	Yakıt-hava karışımı / O2 sensörü	%93 → düşük
Bilinç (GKS)	Beynin çalışması	15	Kontrol ünitesi: “sistem açık mı?”	13 → hafif bulanık

■ Başka bir alandan bakış: Sepsiste gösterge paneli

Sepsiste gösterge paneli şöyle kayar: motor hararet yapar (ateş) ya da soğur (düşük ısı); devir yükselir (nabız ↑); basınç düşer (tansiyon ↓); daha hızlı hava çeker (solunum ↑); oksijen göstergesi düşer (SpO2 ↓); kontrol ünitesi şaşırır (bilinç bulanıklaşır, GKS ↓); egzozdan kara duman çıkar (laktat ↑). Modelin yaptığı şey, bu göstergelerin **birlikte** nasıl kaydığını izlemektir; tek bir ibreye bakmak yetmez.

Nabız: taşikardi / bradikardi	
Ne?	**Taşikardi:** nabzın dakikada 100'ün üzerinde olması. **Bradikardi:** 60'ın altında olması (sporcularda normal olabilir).
Normal değer	60–100 atım/dk
Model için neden önemli?	Vücut daha fazla oksijen ve iş istiyor demektir (ateş, enfeksiyon, kanama, ağrı, korku).
Benzetme	Motor devri (RPM): taşikardi yüksek devir, bradikardi rölanti.
Bu eğitimde	Değişken “Nabız”. Örnek hasta 111 → taşikardi, SHAP +12. Karar ağacında “nabız ≤ 103,5 mi?”

Solunum sayısı / takipne	
Ne?	Dakikadaki soluk sayısı. **Takipne:** hızlı soluma (dakikada 20'nin üzeri).
Normal değer	12–20 soluk/dk
Model için neden önemli?	Kötüleşmenin en erken ve en çok gözden kaçan işaretlerindendir; qSOFA ölçütüdür (≥22).
Benzetme	Motor daha çok oksijen istediğinde turbo daha hızlı döner.
Bu eğitimde	Değişken "Solunum sayısı". Örnek hasta 24 → takipne, SHAP +11.

Ateş / hipotermi	
Ne?	**Ateş:** vücut sıcaklığının 38 °C ve üzeri olması. **Hipotermi:** 36 °C'nin altı.
Normal değer	36,5–37,5 °C
Model için neden önemli?	Sepsiste hem yüksek hem düşük ısı tehlikelidir (**U şekli**); bu yüzden "ateş" değişkeninin etkisi doğrusal değildir ve ağaç temelli modeller bu şekli kendiliğinden yakalayabilir.
Benzetme	Motorun ideal çalışma bandı vardır; iki yönde sapma da arızadır (hararet ya da soğuk motor).
Bu eğitimde	Değişken "Ateş": permütasyon öneminde 1. sıra; örnek hastada 38,6 °C → SHAP +19 (en büyük katkı).

Kan basıncı (KB): sistolik, diyastolik, hipotansiyon	
Ne?	**Sistolik (büyük tansiyon):** kalbin kasıldığı andaki en yüksek basınç. **Diyastolik (küçük tansiyon):** gevşeme anındaki en düşük basınç. **Hipotansiyon:** sistolik basıncın ~90–100 mmHg'nin altına inmesi. **Hipertansiyon (HT):** 140/90 mmHg ve üzeri.
Normal değer	Yaklaşık 90–120 / 60–80 mmHg (mmHg = milimetre cıva)
Model için neden önemli?	Hipotansiyon organlara yeterli kan gitmediğini gösterir; qSOFA ölçütüdür (sistolik ≤100 mmHg).
Benzetme	Pompalı su şebekesi: basınç düşerse üst katlara su çıkmaz; tansiyon düşerse beyin ve böbreğe kan gitmez.
Bu eğitimde	Sepsis verisinde "Sistolik KB", Pima'da "Diyastolik KB". Arı kovanında sistolik KB'nin **düşük** (mavi) değerleri sağda: düşük tansiyon riski artırır.

SpO2 (periferik oksijen satürasyonu)	
Ne?	Hemoglobinin yüzde kaçının oksijenle dolu olduğu; parmaktaki pulse oksimetre probuyla ölçülür. **Desatürasyon:** SpO2'nin düşmesi.
Normal değer	%95–100; %92'nin altı dikkat (bazı akciğer hastalarında hedef farklıdır)
Model için neden önemli?	Dokulara giden oksijenin dolaylı göstergesidir.
Benzetme	Fabrikaya hammadde taşıyan kamyonların doluluk oranı: %93, bazı kamyonların yarı boş gittiği demektir.
Bu eğitimde	Değişken "SpO2". Örnek hasta %93 → SHAP +5.

GKS (Glasgow Koma Skalası; GCS)	
Ne?	Bilinç düzeyini 3–15 arasında puanlayan ölçek: göz açma (1–4) + sözel yanıt (1–5) + motor yanıt (1–6).
Normal değer	15 = tam bilinçli · 13–14 hafif bulanıklık · ≤8 ağır
Model için neden önemli?	"Hasta bugün biraz tuhaf" gözlemi kötüleşmenin erken işaretidir; qSOFA ölçütüdür (GKS <15).
Benzetme	Sistemin durum kodu: 15 = "tüm sistemler normal", düştükçe "kontrol ünitesinde hata".
Bu eğitimde	Değişken "GKS". Karar ağacının kökü "GKS ≤ 14,5" (= 15 değil). Örnek hasta 13 → SHAP +9.

Laktat (laktik asit)	
Ne?	Hücreler yeterli oksijen alamayınca enerjiyi oksijensiz yoldan üretir; atık olarak laktat oluşur. Birimi mmol/L.
Normal değer	<2 mmol/L normal · 2–4 dikkat · >4 ciddi
Model için neden önemli?	Doku perfüzyonunun (kanlanmasının) bozulduğunu gösterir; Sepsis-3'te "laktat >2" bir ölçüttür.
Benzetme	Eksik yanma: motora yeterli hava gitmezse egzozdan kara duman çıkar. Laktat vücudun kara dumanıdır (Şekil B3). Ya da hızlı koşudan sonra bacaklardaki yanma.
Bu eğitimde	Değişken "Laktat": S eğrisinde laktat 2 → %14, 4 → %73; ağaçta "laktat ≤ 2,15 mi?"; bağımlılık grafiğinde 2'den sonra katkı artıyor. **Örnek hasta 1,6 (normal) ama risk %68.**



Şekil B3. *Laktat = vücudun kara dumanı: dokulara yeterli oksijen gitmeyince "eksik yanma" olur.*

Lökosit (beyaz kan hücresi; WBC)	
Ne?	Mikroplarla savaşan bağışıklık hücreleri.
Normal değer	4.000–11.000 /µL (verimizde $\times 10^3$/µL olarak 4–11)
Model için neden önemli?	Enfeksiyonda genelde artar; ağır sepsiste düşebilir de (yine U şekli).
Benzetme	Güvenlik ekibi: saldırıda takviye çağırır (yükselir); savaş uzarsa ekip tükenir (düşer).
Bu eğitimde	Değişken "Lökosit": permütasyon öneminde 6. sıra. Örnek hasta 6,7 (normal).

Kreatinin	
Ne?	Kas metabolizmasının atığı; böbrek süzer ve idrarla atar. Kanda yükselmesi böbrek işlevinin bozulduğunu gösterir.
Normal değer	Yaklaşık 0,6–1,2 mg/dL
Model için neden önemli?	Sepsiste böbrek etkilenebilir; kreatinin artışı organ etkilenmesinin işaretidir.
Benzetme	Su arıtma cihazında suyun kir ölçümü: kir artıyorsa filtre tıkanıyor.
Bu eğitimde	Değişken "Kreatinin". Örnek hasta 1,71 (yüksek) → SHAP +2.

Trombosit (PLT)	
Ne?	Kanamayı durduran, pıhtılaşmada görevli küçük hücreler.
Normal değer	150.000–400.000 /µL (verimizde 150–400 ×10³/µL)
Model için neden önemli?	Sepsiste düşebilir; pıhtılaşma sistemi her yerde aynı anda çalışırken tükenir.
Benzetme	Yol tamir ekibi: her yerde aynı anda tamir yapmaya çalışınca ekip tükenir.
Bu eğitimde	Değişken "Trombosit". Örnek hasta 132 (hafif düşük) → SHAP −2 (bu hastada riski hafifçe azaltmış görünüyor: model her zaman sezgimize uymaz).

İmmünsupresyon	
Ne?	Bağışıklık sisteminin ilaç ya da hastalıkla baskılanması (kemoterapi, organ nakli, yüksek doz kortikosteroid).
Model için neden önemli?	Enfeksiyon kolay gelişir, belirtiler geç ve silik ortaya çıkar.
Benzetme	Güvenlik görevlilerinin yarısı izinde: hırsız kolay girer, alarm geç çalar.
Bu eğitimde	Sepsis verisinde "İmmünsupresyon" (Var/Yok).

Üriner kateter (idrar sondası)	
Ne?	Mesaneye yerleştirilen kalıcı sonda.
Model için neden önemli?	Dış ortamdan vücuda açık bir kapıdır; kateterle ilişkili idrar yolu enfeksiyonu sepsis kaynağı olabilir.
Benzetme	Kale duvarında açık bırakılmış bir kapı.
Bu eğitimde	Sepsis verisinde "Üriner kateter". Örnek hastada var: olası enfeksiyon kaynağı.

1.4 Makine öğrenmesinin altı adımı ve eğitim/test ayrımı

Hangi algoritma kullanılırsa kullanılsın, bir tahmin modelinin yolculuğu benzer adımlardan geçer (Şekil 1.3). Önce hasta kayıtları toplanır. Sonra veri **eğitim** ve **test** olarak ikiye bölünür; bu eğitimde kullandığımız modellerde oran %70 eğitim, %30 testtir. Algoritma yalnızca eğitim verisinden öğrenir, ardından hiç görmediği test hastalarına risk hesaplar. Bu tahminler gerçek sonuçlarla karşılaştırılarak performans ölçülür. Son adım ise en önemlisidir: çıktıyı hemşire, ebe ya da diyetisyen klinik bağlam içinde yorumlar ve kararı verir.

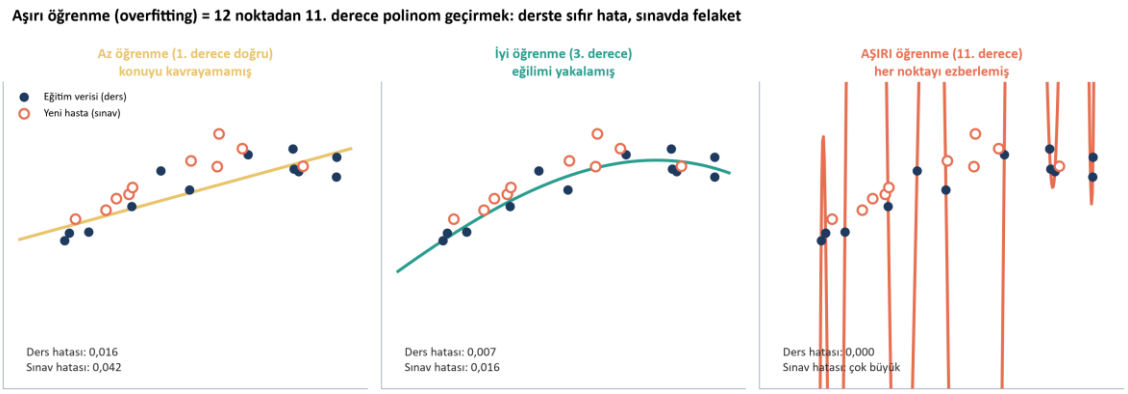


Şekil 1.3. *Makine öğrenmesinin altı adımı: veriden klinik yoruma.*

■ Benzetme: Sınav sorusunu önceden vermemek

Bir öğrenciye final sınavının sorularını önceden verirseniz büyük olasılıkla 100 alır. Ama bu not, konuyu öğrendiğini değil, **soruları ezberlediğini** gösterir. Model de böyledir: performansını eğitildiği hastalar üzerinde ölçerseniz gerçekte olduğundan çok daha iyi görünür. Bu nedenle bir kısım hasta "sınav sorusu" olarak saklanır ve model yalnızca onlarla sınanır. Eğitim verisini ezberleyen, ama yeni hastada başarısız olan modelin adı **aşırı öğrenme (overfitting)**dir.

KISALTMA KARTI 6	**Eğitim seti, test seti ve aşırı öğrenme (overfitting)**
Açılımı	Training set = eğitim seti · Test set (hold-out) = test seti · Overfitting = aşırı öğrenme, ezberleme · Underfitting = az öğrenme
Türkçesi	Ders kitabı (eğitim), kapalı zarftaki sınav (test), ezberci öğrenci (aşırı öğrenme)
Tek cümleyle	**Veri ikiye bölünür: model ilk parçadan öğrenir, hiç görmediği ikinci parçayla sınanır; aşırı öğrenme, modelin konuyu anlamak yerine eğitim verisini ezberlemesidir.**
Benzetmeler	1. **Mühendislik:** Gürültülü 12 ölçüm noktasından 11. dereceden bir eğri geçirmek: her noktadan tam geçer ama noktaların arasında çılgınca salınır; yeni ölçümde felakettir (Şekil A10). 2. **Günlük hayat:** Sınav sorularını önceden ezberleyen öğrenci 100 alır, ama soru biraz değişince takılır. Bu yüzden sınav soruları önceden verilmez. 3. **Klinik:** Yalnızca kendi servisinin hastalarını tanıyan, başka hastanede şaşıran hemşire.
Bizim verimizden	Sepsis verisi: 3000 hasta → **2100** eğitim (%70) + **900** test (%30). Test grubundaki 900 hastanın **89**'u sepsis oldu (%9,9). Bu nottaki bütün karne sayıları bu 900 hasta üzerinden hesaplandı. Uyarı işareti: eğitimde AUC 0,99, testte 0,70 ise model ezberlemiştir.
Sık karışıklık	"Eğitim verisinde AUC 0,99, model harika." Önemli olan, daha önce görmediği hastalardaki performanstır. Ayrıca test seti "kapalı zarf" kalmalıdır: modeli test sonucuna bakarak tekrar tekrar ayarlarsanız test seti de ezberlenir.
İlgili şekil	Şekil A10 (aşağıda), Şekil 1.3



Şekil A10. *Az öğrenme, iyi öğrenme ve aşırı öğrenme. Lacivert noktalar ders (eğitim), beyaz noktalar sınav (yeni hasta): en esnek eğri dersi ezberliyor, sınavda çöküyor.*

Tablo 1.4. Bir modelin performansını sınamanın yolları

Yöntem	Nasıl yapılır?	Klinik benzetme	Ne kadar güvenilir?
Eğitim verisinde ölçüm	Model öğrendiği hastalarla sınanır	Sınav sorularını önceden vermek	Yanıltıcı; aşırı iyimser
Test seti (hold-out)	Verinin bir kısmı (ör. %30) baştan ayrılır	Kapalı zarftaki sınav	Kabul edilebilir; tek bir bölmeye bağlıdır
Çapraz doğrulama (cross-validation)	Veri k parçaya bölünür (ör. 5 kat); her parça sırayla test olur	Beş farklı sınav kitapçığı	Daha kararlı bir iç validasyon
Dış validasyon	Başka hastane veya başka dönemden gelen hastalarda sınama	Başka okulun sınavına girmek	Klinik kullanım öncesi gerekli (Bölüm 4)

KISALTMA KARTI 7	**Çapraz doğrulama (cross-validation, CV)**
Açılımı	CV = Cross-Validation · k-fold = k katlı (Orange'da “Number of folds: 5”) · Stratified = tabakalı (her parçada hasta oranı aynı)
Türkçesi	Beş ayrı sınav yapıp ortalamasını almak
Tek cümleyle	**Veri 5 parçaya bölünür; her turda bir parça sınav, kalan dördü ders olur; beş sınavın ortalaması alınır.**
Benzetmeler	1. **Mühendislik:** Bir ölçümü tek seferde değil, 5 kez tekrarlayıp ortalamasını almak: tek ölçüme güvenmemek. 2. **Günlük hayat:** Pastayı 5 dilime bölün; her turda bir dilimi “tadım dilimi” ayırın, kalan dördüyle tarifi geliştirin. Beş turda her dilim bir kez tadılmış olur. 3. **Klinik:** Bir öğrenciyi tek bir uygulama gününe göre değil, beş farklı nöbetteki performansına göre değerlendirmek.
Bizim verimizden	Sepsis verisinin 3000 hastası 5 parçaya (600'er hasta) bölünür. 1. Tur 1: parça 1 sınav, parça 2–5 ders. 2. Tur 2: parça 2 sınav, diğerleri ders… ve böyle sürer. 3. Tur 5'in sonunda her hasta tam bir kez “sınava girmiş” olur; beş sonucun ortalaması bildirilir. Bu yüzden Orange'ın Confusion Matrix penceresinde 900 değil **3000** hasta (**296** sepsis) görürsünüz.
Sık karışıklık	Orange'daki sayılar (çapraz doğrulama, 0,5 eşiği) bu nottaki sayılardan (tek test seti, eşik %20) biraz farklı çıkar. Bu bir hata değildir; aynı hikâyenin farklı bir ölçümüdür. Çapraz doğrulama da bir **iç** validasyondur, dış validasyon değildir (Kart 26).

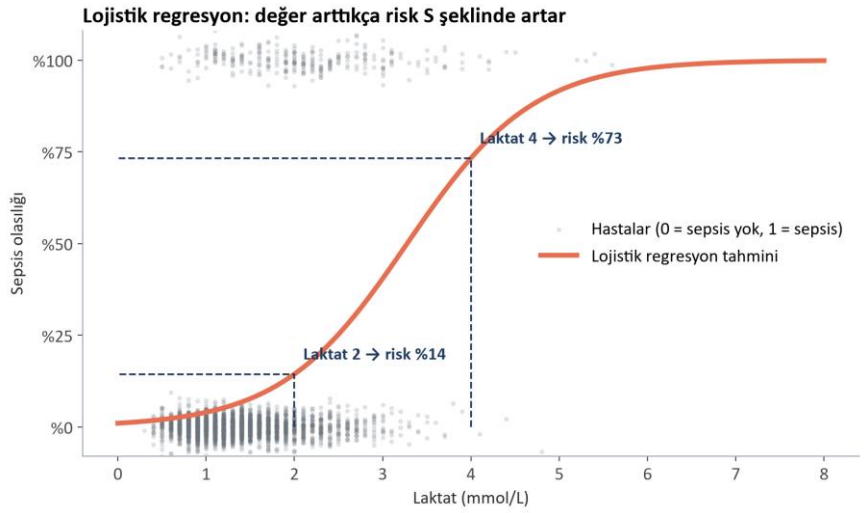
> ■ **Dikkat!**
>
> Bir makalede yalnızca eğitim verisindeki performans bildiriliyorsa ya da test hastaları model seçimi sırasında defalarca kullanılmışsa, bildirilen başarı büyük olasılıkla abartılıdır. Test seti, tıpkı kapalı zarftaki sınav gibi, **yalnızca en sonda bir kez** açılmalıdır.

1.5 Dört algoritma, dört klinik benzetme

Bu modülde dört algoritma ile çalışacağız. Her birinin matematiği farklıdır, ama klinik olarak tanıdık birer karşılıkları vardır. Hepsi aynı işi yapar: her hasta için **0 ile 1 arasında bir risk olasılığı** üretirler. Karar, sizin belirleyeceğiniz bir eşikte verilir.

1.5.1 Lojistik regresyon: Braden skalasının akrabası

Lojistik regresyon (logistic regression) her değişkene bir ağırlık verir, bu ağırlıklı değerleri toplar ve sonucu S biçimli bir eğriyle 0–1 arasındaki bir olasılığa çevirir. Şekil 1.4'te tek bir değişkenin, laktatın, sepsis riskiyle ilişkisi görülüyor: laktat 2 mmol/L iken tahmini risk yaklaşık %14, 4 mmol/L iken yaklaşık %73'tür. Eğrinin ortasında küçük bir laktat artışı riski hızla yükseltir, uçlarda ise eğri yataylaşır.



Şekil 1.4. *Laktata göre sepsis riski: lojistik regresyonun S eğrisi (laktat 2 mmol/L → yaklaşık %14, 4 mmol/L → yaklaşık %73).*

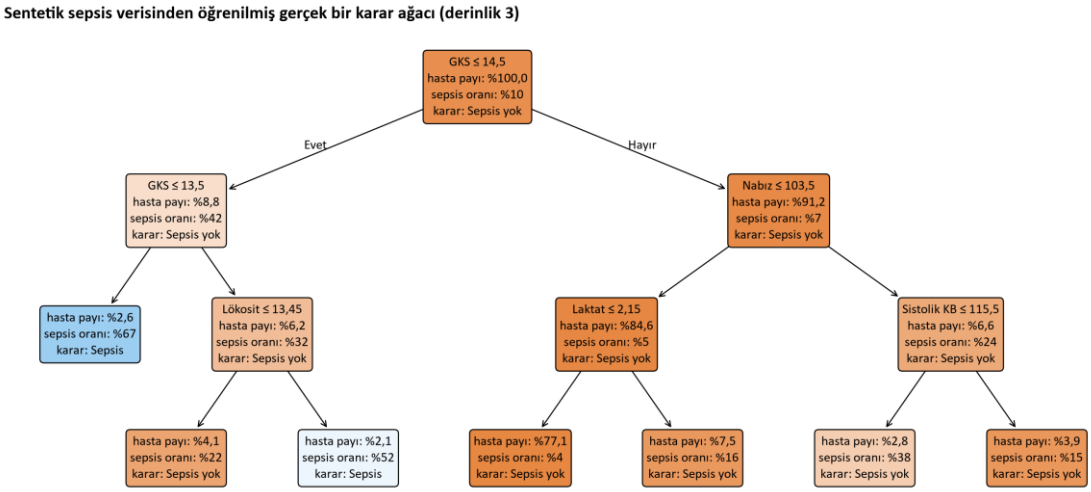
> ■ **Benzetme: Ağırlıklı toplam**
>
> Braden skalasında her alt boyuta bir puan verir ve toplarsınız. Lojistik regresyon da her etkene bir ağırlık verip toplar; tek farkı, toplamı S eğrisiyle doğrudan bir **olasılığa** çevirmesidir. Bu yüzden şeffaftır: hangi değişkenin riski ne yönde etkilediği katsayılardan okunabilir. Ayrıca genellikle iyi kalibre olur. Klinik tahmin çalışmalarında hâlâ **en güçlü kıyas noktasıdır** (Steyerberg, 2019).

KISALTMA KARTI 8	**Lojistik regresyon (LR, logistic regression)**
Açılımı	LR = Logistic Regression · Coefficient = katsayı (ağırlık) · Logit / log-odds = olasılığın S eğrisinden geçmeden önceki hâli
Türkçesi	Ağırlıklı toplam + S eğrisi
Tek cümleyle	**Her değişkene bir ağırlık verilir, bunlar toplanır ve toplam S biçimli bir eğriden geçirilerek 0–1 arası bir olasılığa çevrilir.**

Benzetmeler	1. **Mühendislik:** Işık dimmeri: düğmeyi çevirdikçe ışık önce yavaş, ortada hızlı, sonda yine yavaş artar; ne kadar çevirirseniz çevirin %100'ü geçmez, %0'ın altına inmez. 2. **Günlük hayat:** Kredi notu: gelir + puan, borç − puan; toplam puan onay olasılığına çevrilir. 3. **Klinik:** Braden skalası: her maddeye puan verip toplarsınız. LR de toplar; farkı, puanları veriden öğrenmesi ve sonucu olasılık diliyle vermesidir.
Bizim verimizden	Yalnızca laktatla kurulmuş basit gösterim (Şekil 1.4): laktat 2 → risk **%14**; laktat 4 → risk **%73**. Eğri ortada diktir: sınırdaki hastada küçük bir değişiklik riski çok oynatır; uçlarda eğri yataylaşır. Gerçek modelde 15 değişkenin hepsi birlikte toplanır: sepsiste AUC **0,86**; Pima'da **0,83** ile XGBoost'u (0,81) geçti.
Sık karışıklık	"Eski yöntem, makine öğrenmesi sayılmaz." LR şeffaftır, genellikle iyi kalibre olur ve klinik tahminde hâlâ en güçlü kıyas noktasıdır (Christodoulou ve ark., 2019). Adında "regresyon" geçse de burada bir sınıflandırma (var/yok) aracıdır.
İlgili şekil	Şekil 1.4

1.5.2 Karar ağacı: triaj akış şeması

Karar ağacı (decision tree) veriyi art arda sorulan evet/hayır sorularıyla gruplara ayırır. Şekil 1.5'teki ağaç, sepsis verisinden gerçekten öğrenilmiş ve derinliği 3 ile sınırlanmış bir ağaçtır. Algoritma ilk soruyu kendisi seçmiştir: **GKS ≤ 14,5**, yani "hastanın bilincinde herhangi bir değişiklik var mı?". Bilinci tam olan hastalarda ikinci soru **nabız ≤ 103,5**, ardından **laktat ≤ 2,15** gelir. Kutulardaki "hasta payı" o kutuya düşen hastaların oranını, "sepsis oranı" bu hastalar arasında sepsis gelişenlerin yüzdesini, "karar" ise ağacın o kutu için verdiği sınıfı gösterir. Örneğin GKS'si 13,5'in altında olan küçük grupta sepsis oranı %67'ye çıkar.



Şekil 1.5. *Sentetik sepsis verisinden öğrenilmiş gerçek bir karar ağacı (derinlik 3). Kök bölünme: GKS ≤ 14,5.*

> ■ **Benzetme: Triaj akış şeması**
>
> Acil serviste triaj hemşiresi bir akış şeması izler: "Hava yolu açık mı? Evet ise solunum nasıl?" Karar ağacı da tam olarak budur; tek fark, soruları ve kesim noktalarını veriden kendisinin bulmasıdır. Okunması çok kolaydır ve öğretimde mükemmel bir başlangıçtır. Ancak tek başına **kararsızdır**: veri biraz değişince ağacın dalları da değişebilir.

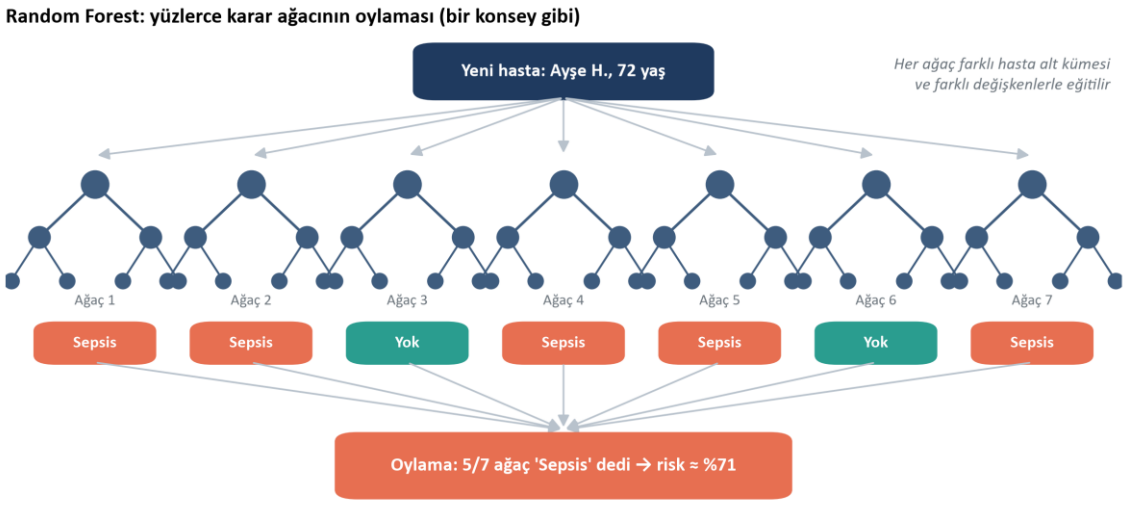
■ Klinik Köşe: Model klinisyen gibi düşünüyor mu?

Ağacın ilk sorusunun bilinç düzeyi olması tesadüf değildir. qSOFA'nın üç ölçütünden biri bilinç değişikliğidir (Seymour ve ark., 2016). Model, kimse söylemeden klinisyenlerin de önem verdiği bir bulguyu öne çıkarmıştır. Bu tür bir **klinik tutarlılık** kontrolü, bir modele güven duymanın ilk adımlarından biridir.

KISALTMA KARTI 9	**Karar ağacı (decision tree)**
Açılımı	Decision tree · Root = kök (ilk soru) · Branch = dal · Leaf = yaprak (son kutu, verilen risk) · Depth = derinlik (art arda soru sayısı)
Türkçesi	Evet/hayır soruları zinciri
Tek cümleyle	**Karar ağacı veriyi evet/hayır sorularıyla dallara ayırır ve en sonda her yaprakta bir risk verir.**
Benzetmeler	1. **Mühendislik:** Arıza teşhis akış şeması: "Güç ışığı yanıyor mu? Hayır → sigortayı kontrol et…" Bilgisayar dilinde iç içe "eğer–ise" blokları. 2. **Günlük hayat:** "20 soru" oyunu ya da beyaz eşya servisinin telefondaki soruları: "Cihaz hiç çalışmıyor mu, yoksa ısıtmıyor mu?" 3. **Klinik:** Acil serviste triaj akış şeması: "Bilinç değişikliği var mı? Evet → kırmızı alan."
Bizim verimizden	Bizim ağacın kökü: **GKS ≤ 14,5 mi?** GKS tam sayıdır; ağaç iki komşu değerin ortasından keser: "≤ 14,5" = "14 veya altı" = "15 değil". Sonraki sorular: **nabız ≤ 103,5 mi?** ve **laktat ≤ 2,15 mi?** Sepsis AUC **0,84**: dört model arasında en düşük.
Sık karışıklık	"Ağaç en kolay okunduğu için en iyisidir." Kolay okunur ama tek başına **kararsızdır**: veri biraz değişirse ağaç bambaşka olabilir. Tek bir uzmanın görüşü gibi oynaktır.
İlgili şekil	Şekil 1.5

1.5.3 Random Forest: konseyin oylaması

Random Forest (Breiman, 2001) yüzlerce karar ağacından oluşan bir "orman"dır. Her ağaç hastaların rastgele seçilmiş bir alt kümesini ve değişkenlerin rastgele bir kısmını görerek eğitilir. Yeni bir hasta geldiğinde her ağaç oy verir ve oyların oranı riski belirler. Şekil 1.6'daki basitleştirilmiş örnekte 7 ağaçtan 5'i "sepsis" demektedir; bu da yaklaşık %71'lik bir risk anlamına gelir. Bu yönteme **bagging** denir.



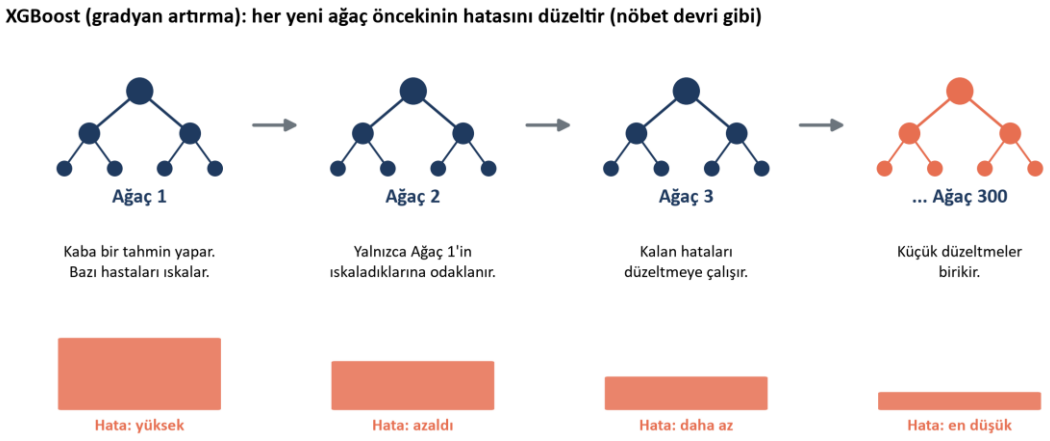
Şekil 1.6. *Random Forest oylaması: 7 ağaçtan 5'i "sepsis" diyor, risk ≈ %71.*

> ■ **Benzetme: Konsey**
>
> Zor bir vakada tek bir uzmana değil, bir konseye danışırız. Her üye hastayı biraz farklı bir açıdan görür, bazıları yanılır, ama **çoğunluğun görüşü** genellikle tek bir kişininkinden daha sağlamdır. Random Forest'ı 500 deneyimli hemşirenin oylaması gibi düşünebilirsiniz: kalabalığın bilgeliği.

KISALTMA KARTI 10	**Random Forest (RF, rastgele orman) ve bagging**
Açılımı	RF = Random Forest · Bagging = Bootstrap AGGregatING (tekrarlı rastgele örnekleme + birleştirme) · Bootstrap = veriden iadeli rastgele örnek çekmek
Türkçesi	Rastgele orman: yüzlerce ağacın oylaması
Tek cümleyle	**Yüzlerce karar ağacı eğitilir; her ağaç verinin farklı bir alt kümesini ve farklı değişkenleri görür; sonuç oylamayla belirlenir.**
Benzetmeler	1. **Mühendislik:** Yedekli sistemlerde çoğunluk oylaması: uçaklardaki üçlü yedekli sensörler. Biri saçmalarsa diğerleri onu bastırır. 2. **Günlük hayat:** Kavanozdaki şeker sayısını tahmin eden kalabalık: tek tek herkes yanılır, ama ortalama şaşırtıcı biçimde doğrudur (kalabalığın bilgeliği). Yarışmalardaki "seyirciye sorma" jokeri gibi. 3. **Klinik:** Zor bir hastada konsey kararı ya da 500 deneyimli hemşirenin oylaması.
Bizim verimizden	Şekil 1.6: 7 ağaçtan 5'i "sepsis" diyor → risk ≈ 5 / 7 ≈ **%71**. Sepsis AUC **0,885** (yuvarlamaya göre 0,88 ya da 0,89 yazılır; XGBoost'la başa baş).
Sık karışıklık	"Orman, ağacın büyüğüdür." Hayır; gücü tek büyük ağaçtan değil, birbirinden **farklı** çok sayıda ağacın hatalarının birbirini götürmesinden gelir. Hepsi aynı veriyi görseydi aynı hatayı yaparlardı.
İlgili şekil	Şekil 1.6

1.5.4 XGBoost: nöbet devri zinciri

XGBoost (Chen ve Guestrin, 2016) de ağaçlardan oluşur ama ağaçlar aynı anda değil, **sırayla** kurulur. Her yeni ağaç, kendinden önceki ağaçların hata yaptığı hastalara odaklanır ve küçük bir düzeltme ekler (Şekil 1.7). Bu yaklaşıma **boosting** denir. Tablo biçimindeki klinik verilerde çoğu zaman en güçlü algoritmalardan biridir; ama Bölüm 2'de göreceğimiz gibi her zaman değil.



Şekil 1.7. *XGBoost (boosting): ağaçlar sırayla eklenir, her biri öncekinin hatasını azaltır.*

■ Benzetme: Nöbet devri

Nöbet devrinde her ekip bir öncekinin kaçırdığı ya da yarım bıraktığı işlere odaklanır: "Yatak 7'nin idrar çıkışını takip edemedik, sen bak." Her devir küçük bir düzeltmedir ve bu düzeltmeler birikerek bakımı iyileştirir. XGBoost'ta her yeni ağaç, bir önceki ekibin kaçırdıklarını yakalamaya çalışan yeni bir vardiya gibidir: **hatadan öğrenme**.

KISALTMA KARTI 11	**XGBoost, boosting ve gradient boosting**
Açılımı	XGBoost = eXtreme Gradient Boosting (aşırı gradyan artırma) · Boosting = güçlendirme · Gradient = gradyan (hatanın eğimi) · Orange'daki adı: Gradient Boosting
Türkçesi	Ağaçları sırayla kurup her birinin öncekilerin hatasını düzelttiği model
Tek cümleyle	**Ağaçlar sırayla eğitilir; her yeni ağaç önceki ağaçların toplamının yaptığı HATAYI düzeltmeye çalışır; küçük düzeltmeler birikir.**
Benzetmeler	1. **Mühendislik:** Kapalı çevrim kontrol: her adımda hatayı ölç, ona göre düzelt. Hata adım adım küçülür (ardışık yaklaşım). 2. **Günlük hayat:** Golf: ilk vuruş topu yeşil alana getirir, sonraki vuruşlar deliğe adım adım yaklaştırır. Ya da ressamın önce kaba eskiz, sonra ayrıntı çizmesi. 3. **Klinik:** Nöbet devri zinciri: "Şu hastayı gözden kaçırdık, sen ona dikkat et." Her gelen ekip öncekinin kaçırdığına odaklanır.
Bizim verimizden	Sepsis AUC **0,89**: dört model içinde en yüksek. Ama Pima'da **0,81** (LR 0,83), preeklampside **0,75** (LR 0,77): her zaman kazanmıyor (Şekil 2.9).
Hafıza kancası	**RF = paralel + oylama (kalabalık). XGBoost = seri + düzeltme (zincir).**
Sık karışıklık	"XGBoost her zaman kazanır." Tablo verisinde çoğu zaman güçlüdür, ama klinik tahmin modellerinde makine öğrenmesinin lojistik regresyona genel bir üstünlüğü gösterilememiştir (Christodoulou ve ark., 2019).
İlgili şekil	Şekil 1.7, Şekil 2.9

Tablo 1.5. Dört algoritmanın özeti

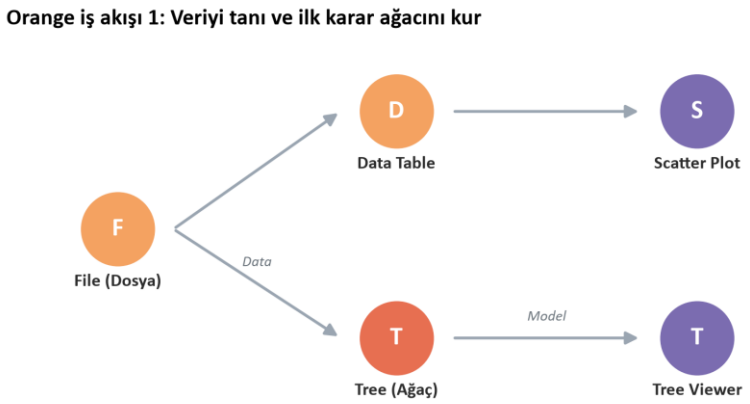
Algoritma	Klinik benzetme	Güçlü yanı	Zayıf yanı
Lojistik regresyon	Braden skalası: ağırlıklı toplam	Şeffaf, iyi kalibre, az veriyle de çalışır, güçlü kıyas noktası	Etkileşimleri ve doğrusal olmayan ilişkileri ancak elle eklenirse yakalar
Karar ağacı	Triaj akış şeması	Çok kolay okunur, öğretim için ideal	Kararsız; tek başına genellikle en düşük performans
Random Forest	Konsey / 500 hemşirenin oylaması (bagging)	Kararlı, güçlü, az ayarla iyi çalışır	Tek tek kuralları görmek zorlaşır; açıklama aracı gerekir
XGBoost	Nöbet devri zinciri (boosting)	Tablo verisinde çoğu zaman en güçlülerden	Ayar gerektirir; aşırı öğrenmeye ve kalibrasyon sorunlarına açık

■ Dikkat! Model risk verir, karar eşikte verilir

Dört algoritma da bir **olasılık** üretir, "sepsis var/yok" demez. "Var" ya da "yok" kararı, olasılığın sizin seçtiğiniz bir eşiği aşıp aşmadığına göre verilir. Eşiği değiştirmek modelin davranışını tamamen değiştirir. Bunu Bölüm 2'de ayrıntılı göreceğiz.

1.6 Orange ile ilk adımlar

Orange Data Mining, Ljubljana Üniversitesi'nde geliştirilen, ücretsiz ve açık kaynaklı bir veri madenciliği programıdır (Demšar ve ark., 2013). Kod yazmak yerine **widget** adı verilen kutucukları tuvale sürükleyip birbirine bağlarsınız. Veri, bağlantı çizgileri boyunca bir widget'tan diğerine akar. Kurulum adımları Ek A'dadır. Bu oturumda kuracağımız ilk iş akışı Şekil 1.8'de görülüyor.



Şekil 1.8. *Oturum 1 Orange iş akışı: File → Data Table / Scatter Plot ve File → Tree → Tree Viewer.*

Uygulamanın son adımında Pima diyabet verisini de açacağız. Pima, bu eğitimdeki tek **gerçek** veri setidir; sütunlarını tanımak için aşağıdaki kutuya göz atın.

> ■ **Bu kelimeler ne demek? · Pima diyabet veri seti (diyabet_pima.csv)**
>
> 768 Pima yerlisi kadın, 8 değişken ve hedef "Diyabet". Birim ve aralıklar Ek B.2'dedir.

Diyabet: Tip 1 ve Tip 2	
Ne?	Kan glukozunun kronik olarak yüksek seyretmesi. **Tip 1:** insülin üretilemez. **Tip 2:** insülin direnci; kilo, hareketsizlik ve yaşla ilişkilidir, en yaygın türdür.
Normal değer	Açlık plazma glukozu 70–99 mg/dL normal; ≥126 mg/dL diyabet
Model için neden önemli?	Uzun vadede damar ve sinirleri bozar: retinopati, nefropati, nöropati, ayak ülseri.
Benzetme	İnsülin, şeker kamyonlarının fabrikaya (hücreye) girmesi için kapıyı açan anahtardır. Tip 1'de anahtar yok, Tip 2'de kilit paslanmış; kamyonlar yolda (kanda) birikir.
Bu eğitimde	Pima verisinin hedefi (Diyabet); sepsis verisinde "Diyabet" değişkeni (örnek hastada SHAP +5); diyabetik ayak verisi.

Glukoz ve OGTT (oral glukoz tolerans testi)	
Ne?	**Glukoz:** anlık kan şekeri. **OGTT:** standart şekerli solüsyon içirildikten 2 saat sonra plazma glukozuna bakmak.
Normal değer	OGTT 2. saat: <140 mg/dL normal · 140–199 bozulmuş glukoz toleransı · ≥200 mg/dL diyabet
Model için neden önemli?	Vücudun şeker yükünü ne kadar hızlı temizlediğini gösterir.
Benzetme	Sisteme ani bir yük verip 2 saat sonra ne kadar toparlandığına bakmak: hızlı toparlanan sistem sağlıklıdır.
Bu eğitimde	Pima'da "Glukoz (OGTT 2. saat)": SHAP'ta açık ara 1. sıra.

BKİ (beden kitle indeksi; BMI)	
Ne?	Kilonun boya göre normalize edilmiş hâli: kilo (kg) / boy² (m²).
Normal değer	<18,5 zayıf · 18,5–24,9 normal · 25–29,9 fazla kilolu · ≥30 obez. Örnek: 70 kg, 1,75 m → 70 / 3,06 ≈ 22,9
Model için neden önemli?	Diyabet ve preeklampside risk etkeni; malnütrisyonda düşük BKİ bir GLIM ölçütü.
Benzetme	Farklı boyutlardaki yapıları karşılaştırabilmek için yükü boyuta bölmek.
Bu eğitimde	Pima (2. sıra), malnütrisyon (2. sıra), preeklampsi (4. sıra) ve diyabetik ayak verilerinde.

Pima veri seti	
Ne?	ABD'nin Arizona eyaletindeki Pima yerlisi kadınlardan toplanmış veri; diyabetin dünyada en sık görüldüğü topluluklardan biridir. 1988'den beri makine öğrenmesinin “ders kitabı” verisidir (Smith ve ark., 1988).
Normal değer	768 kadın; diyabet oranı %34,9
Model için neden önemli?	**Gerçek veridir** (diğer dört setimiz sentetiktir). Fizyolojik olarak imkânsız sıfırlar (ör. kan basıncı 0) eksik veri olarak kodlandı (Orange'da “?”).
Benzetme	Belli bir malzeme için yapılmış kalibrasyonun başka bir malzemede kullanılıp kullanılamayacağı sorusu: Pima kadınlarından öğrenilmiş model Mersinli bir kadın için geçerli mi? (genellenebilirlik)
Bu eğitimde	Bölüm 1.6 Orange uygulaması; Bölüm 3, Vaka 5. AUC: LR 0,83 · ağaç 0,74 · RF 0,84 · XGB 0,81.

Terim	Ne demek?	Benzetme / not	Bu eğitimde
İnsülin	Pankreas beta hücrelerinin salgıladığı, glukozun hücreye girişini sağlayan hormon. Pima'daki “İnsülin” sütunu 2. saat serum insülinidir; çok sayıda hücre eksiktir.	Kapı anahtarı.	Pima
Prediyabet	Glukozun normalden yüksek ama diyabet sınırının altında olması.	Sarı ışık.	OGTT, HbA1c
Aile öyküsü skoru	Ailedeki diyabet yükünü özetleyen puan (diabetes pedigree function).	Ürünün “seri geçmişi”: aynı partide arıza sık mı?	Pima, SHAP 3. sıra
Triseps deri kıvrımı	Kolun arka yüzündeki deri altı yağ dokusu kalınlığı (mm), kaliperle ölçülür.	Yalıtım tabakası kalınlığı.	Pima
Gebelik sayısı	Kadının toplam gebelik sayısı.	—	Pima, SHAP 5. sıra
Diyabetik retinopati	Diyabetin retina damarlarına verdiği hasar.	Kamera sensöründeki ince kabloların bozulması.	IDx-DR örneği

■ Orange'da Adım Adım

Bu adımlar Şekil 1.8'deki iş akışını kurar (yaklaşık 50 dakika).

1. Orange'ı açın. Sol paneldeki **Data** grubundan **File** widget'ını tuvale sürükleyin.
2. **File** widget'ına çift tıklayın ve klasör simgesinden *sepsis_sentetik.csv* dosyasını seçin.
3. Alttaki değişken listesinde *Sepsis (24 saat)* satırını bulun, **Role** sütununu **target** olarak değiştirin ve **Apply** düğmesine basın.
4. **Data Table** widget'ını tuvale ekleyin ve **File**'dan **Data Table**'a bir bağlantı çizin. Satırları ve değişkenleri inceleyin.
5. İsterseniz **Scatter Plot** ekleyin; örneğin x ekseni *Nabız*, y ekseni *Laktat* olsun ve renk olarak hedef değişkeni seçin.
6. **Model** grubundan **Tree** widget'ını ekleyin ve **File**'a bağlayın. Ayarlarda en fazla derinliği (**Limit the maximal tree depth**) 3 yapın.
7. **Visualize** grubundan **Tree Viewer** ekleyin ve **Tree**'ye bağlayın. Ağacın kökündeki soruyu bulun ve yorumlayın.
8. Aynı adımları *diyabet_pima.csv* ile tekrarlayın (hedef: *Diyabet*). Ağacın ilk sorusu hangi değişken?

İpucu: Bir widget'ı silmek için seçip Delete tuşuna basın. Bağlantıyı silmek için çizginin üzerine tıklayıp Delete'e basın.

Tablo 1.6. Oturum 1'de kullanılan Orange widget'ları

Widget	Grup	Ne işe yarar?
File	Data	CSV, Excel gibi dosyaları açar; değişkenlerin rolünü (feature, target, meta, skip) belirler.
Data Table	Data	Veriyi elektronik tablo gibi gösterir; hasta seçmeye olanak verir.
Scatter Plot	Visualize	İki değişkenin dağılımını, hedefe göre renklendirilmiş olarak gösterir.
Tree	Model	Karar ağacı öğrenicisi; derinlik ve yaprak büyüklüğü ayarlanabilir.
Tree Viewer	Visualize	Öğrenilen ağacı kutular ve dallar olarak çizer.

1.7 Vaka ve tartışma: servisinizde hangi karar desteklenebilir?

Oturumun son saatinde 3–4 kişilik gruplar hâlinde çalışacağız. Her grup kendi klinik alanından, bir modelin destekleyebileceği **üç karar** belirler. Aşağıdaki tablo bu tartışmayı yapılandırmanız için tasarlandı. Burada ürettiğiniz fikirler, Bölüm 4'teki araştırma önerisinin tohumu olacak.

Ali AKDAĞ

Tablo 1.7. Grup çalışması: "Servisinizde hangi kararı bir model destekleyebilirdi?"

	Klinik karar	Bugün nasıl veriliyor?	Model neyi, ne zaman tahmin eder?	Hangi veriler elimizde?
Fikir 1				
Fikir 2				
Fikir 3				

■ Klinik Köşe: Fikir üretmek için örnek alanlar

Hemşirelik: düşme, bası yarası, deliryum, planlanmamış yoğun bakım transferi, kateterle ilişkili enfeksiyon. Ebelik: preeklampsi, gestasyonel diyabet, erken doğum, doğum sonu kanama, emzirmenin erken bırakılması. Beslenme ve diyetetik: malnütrisyon, refeeding sendromu, sarkopeni, enteral beslenme intoleransı. Fizyoterapi ve diğer alanlar: taburculuk sonrası yeniden yatış, düşme sonrası işlev kaybı.

■ Kendinizi Sınayın

1. Braden skalası ile bası yarası riskini tahmin eden bir makine öğrenmesi modeli arasındaki temel fark nedir?
2. Bir model, eğitildiği hastalarda AUC 0,99, test hastalarında AUC 0,70 veriyor. Bu durumun adı nedir ve neyi gösterir?
3. Random Forest ile XGBoost'un her ikisi de karar ağaçlarından oluşur. Ağaçları bir araya getirme biçimleri nasıl farklılaşır?
4. Şekil 1.5'teki karar ağacına göre GKS'si 15, nabzı 98 ve laktatı 1,4 mmol/L olan bir hasta hangi yaprağa düşer? O yapraktaki sepsis oranı nedir?
5. Bir modelin "%35 risk" çıktısı, hastanın sepsis olup olmadığına dair bir karar mıdır? Neden?
6. **Kısaltma:** ML, XAI, RF, XGBoost ve CV kısaltmalarının açılımını ve Türkçesini yazın.
7. **Kısaltma:** Orange'da 5 katlı çapraz doğrulama (CV) sonuçlarında neden 900 değil 3000 hasta görürsünüz?
8. **Terim:** Örnek hastada GKS 13, laktat 1,6 mmol/L ve solunum sayısı 24/dk'dır. Her birinin normal sınırını yazın; hangisi normaldir?
9. **Terim:** Karar ağacının kökündeki "GKS ≤ 14,5" sorusu klinik olarak ne soruyor? Neden 14,5 gibi kesirli bir sayı kullanılmış?

Cevaplar Ek F'dedir. Önce kendiniz yanıtlamayı deneyin. Kısaltma ve terim soruları için ilgili kartlara ve Ek D'ye bakabilirsiniz.

■ **Bölüm özeti**

- Braden, Morse, NEWS2, qSOFA gibi araçlar insanın yazdığı kurallardır; makine öğrenmesi kuralı veriden çıkarır.
- Model yalnızca kendisine gösterilen vakalardan öğrenir; eğitim verisi kimi temsil ediyorsa model de onu temsil eder.
- Performans, modelin hiç görmediği test hastalarında ölçülmelidir; aksi hâlde aşırı öğrenme gizlenir.
- Lojistik regresyon = ağırlıklı toplam (Braden); karar ağacı = triaj şeması; Random Forest = konsey; XGBoost = nöbet devri.
- Tüm modeller bir risk olasılığı üretir; klinik karar, sizin seçtiğiniz eşikte ve sizin değerlendirmenizle verilir.

Ali AKDAĞLI

Bölüm 2. Model çıktısını okumak

Oturum 2 · 3 saat. Bir model "AUC 0,89" diye sunulduğunda ne anlamalıyız? Bu bölümde model performansını, zaten bildiğiniz tanı testi kavramlarıyla okuyacağız. Ardından iki kritik soruya geçeceğiz: **Hangi eşikte kullanalım?** ve **Modelin verdiği yüzdeye güvenebilir miyiz?**

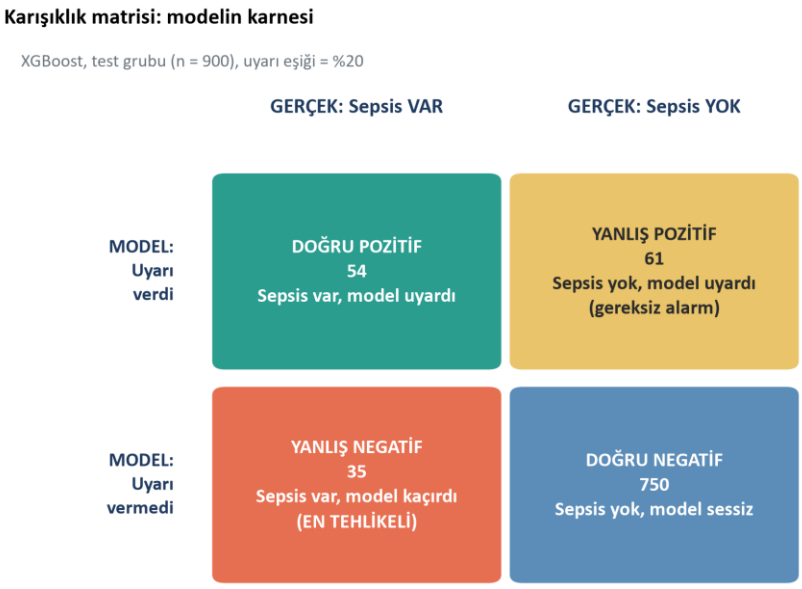
■ Öğrenme hedefleri

Bu bölümü tamamladığınızda şunları yapabileceksiniz:

1. Karışıklık matrisinden duyarlılık, özgüllük, PPV ve NPV hesaplar.
2. ROC eğrisini ve AUC değerini yorumlar, AUC'nin sınırlılıklarını bilir.
3. Prevalansın pozitif kestirim değeri (PPV) üzerindeki etkisini açıklar.
4. Eşik seçimini klinik bedel ve iş yükü üzerinden gerekçelendirir.
5. Kalibrasyonu tanımlar ve ayrım gücünden (AUC) farkını açıklar.

2.1 Karışıklık matrisi: modelin karnesi

Sepsis veri setinde modeller 2100 hastayla eğitildi ve hiç görmedikleri 900 test hastasında sınandı. Bu hastaların 89'unda 24 saat içinde sepsis gelişti. XGBoost modelini **%20 eşiğiyle** kullandığımızda, yani riski %20 ve üzerinde olan her hasta için uyarı ürettiğimizde, sonuçlar Şekil 2.1'deki karışıklık matrisinde (confusion matrix) özetlenir. Matrisin dört hücresi vardır ve her biri klinik olarak farklı bir anlam taşır.



Şekil 2.1. *XGBoost modelinin karışıklık matrisi (eşik %20, test grubu n=900): DP 54, YP 61, YN 35, DN 750.*

Tablo 2.1. Karışıklık matrisinin dört hücresi ve klinik anlamları

Hücre	Tanım	Sepsis örneği	Klinik anlamı
Doğru pozitif (DP)	Model uyardı, olay gerçekleşti	54	Erken yakalanan sepsis
Yanlış pozitif (YP)	Model uyardı, olay gerçekleşmedi	61	Gereksiz değerlendirme, alarm yükü
Yanlış negatif (YN)	Model uyarmadı, olay gerçekleşti	35	**Kaçırılan sepsis: en tehlikeli hücre**
Doğru negatif (DN)	Model uyarmadı, olay gerçekleşmedi	750	Doğru biçimde rahat bırakılan hasta

KISALTMA KARTI 12	**Karışıklık matrisi (confusion matrix): DP, YP, YN, DN**
Açılımı	Confusion matrix · TP / FP / FN / TN = True/False Positive/Negative · Türkçede DP / YP / YN / DN = Doğru/Yanlış Pozitif/Negatif
Türkçesi	Modelin karnesi: dört olası sonucu sayan 2×2 tablo
Tek cümleyle	**Karışıklık matrisi, modelin dört olası sonucunu (DP, YP, YN, DN) sayan 2×2'lik bir tablodur; adı, modelin hangi sınıfı hangisiyle "karıştırdığını" göstermesinden gelir.**
Benzetmeler	1. **Mühendislik:** Kalite kontrol kamerası: doğru ayıklanan kusurlu parça (DP), boşuna atılan sağlam parça (YP), kaçan kusurlu parça (YN), geçen sağlam parça (DN). 2. **Günlük hayat:** Futbol hakemi: penaltı vardı, verdi (DP); yoktu, verdi (YP); vardı, vermedi (YN); yoktu, vermedi (DN). VAR sistemi tam olarak YP ve YN'yi azaltmak için vardır. 3. **Klinik:** Gebelik testi: test pozitif ve gerçekten gebe (DP); test pozitif ama gebe değil (YP); test negatif ama gebe (YN); test negatif ve gebe değil (DN).
Bizim verimizden	Test grubu 900 hasta; XGBoost, eşik %20: • **DP = 54**: sepsis oldu, model uyardı. • **YN = 35**: sepsis oldu, model sustu (kaçırılan hasta). • **YP = 61**: sepsis olmadı, model uyardı (boşuna alarm). • **DN = 750**: sepsis olmadı, model sustu. Sağlama: 54 + 35 = **89** sepsis · 61 + 750 = **811** sağlam · 89 + 811 = **900** ✓ Satır toplamları: 54 + 61 = **115 alarm** · 35 + 750 = **785 sessizlik**.
Hafıza kancası	İki harfi ayrı okuyun: **ikinci harf** alarmın ne dediğini (P = öttü, N = sustu), **birinci harf** haklı olup olmadığını (D = haklı, Y = yanıldı) söyler. YN = "sustu ve yanıldı" = kaçırılan hasta.
Sık karışıklık	Tablonun yönü kaynağa göre değişir. Bu notta sütunlar GERÇEĞİ, satırlar MODELİN SÖYLEDİĞİNİ gösterir; Orange'ın Confusion Matrix penceresinde ise satırlar "Actual" (gerçek), sütunlar "Predicted" (tahmin) olur. Her tabloda önce eksen etiketlerini okuyun. En tehlikeli hücre **YN**'dir (35 kaçırılan sepsis).
İlgili şekil	Şekil A1, Şekil 2.1

■ Benzetme: Model bir tanı testidir

Duyarlılık ve özgüllüğü bir tanı testinden, örneğin bir gebelik testinden ya da mamografiden zaten biliyorsunuz. Tahmin modeli de **bir testtir**; tek farkı, sonucunu kan ya da görüntü yerine hastanın kayıtlı verilerinden üretmesidir. Bu nedenle bir modeli değerlendirirken tanı testlerine sorduğunuz soruların hepsini sorabilirsiniz.

Karışıklık matrisinden türetilen ölçütler Tablo 2.2'de özetlenmiştir. Formüllere takılmayın; her birinin yanındaki **klinik soru** asıl öğrenmeniz gereken şeydir.

Tablo 2.2. Karışıklık matrisinden türetilen ölçütler (XGBoost, eşik %20)

Ölçüt	Formül	Hesap	Sonuç	Yanıtladığı klinik soru
Duyarlılık (sensitivity)	DP / (DP + YN)	54 / 89	%60,7	Sepsis gelişen hastaların kaçını yakaladı?
Özgüllük (specificity)	DN / (DN + YP)	750 / 811	%92,5	Sepsis gelişmeyenlerin kaçını doğru biçimde rahat bıraktı?
Pozitif kestirim değeri (PPV)	DP / (DP + YP)	54 / 115	%47	Uyarı verdiğinde, hasta gerçekten sepsis olma olasılığı nedir?
Negatif kestirim değeri (NPV)	DN / (DN + YN)	750 / 785	%95,5	Uyarı vermediğinde, hastanın güvende olma olasılığı nedir?
Doğruluk (accuracy)	(DP + DN) / Toplam	804 / 900	%89,3	Tüm hastaların ne kadarı doğru sınıflandı? (Yanıltıcı olabilir!)
F1 skoru	2·DP / (2·DP + YP + YN)	108 / 204	0,53	Duyarlılık ile PPV'nin dengesi
Prevalans	(DP + YN) / Toplam	89 / 900	%9,9	Test grubunda olay ne kadar sık?

Doğruluk, F1 ve prevalans değerleri karışıklık matrisindeki sayılardan hesaplanmıştır. F1 ve Orange'daki diğer İngilizce kısaltmalar Kısaltma Kartı 25'te açıklanmıştır.

Tablodaki dört temel ölçütün her birini aşağıdaki kartlarda **adım adım** hesaplıyoruz. Hepsinde aynı tarifi izleyin: önce **paydayı** bulun ("neyden başlıyorum?"), sonra **payı**, sonra bölün.

KISALTMA KARTI 13	**Duyarlılık (sensitivity, recall, TPR)**
Açılımı	Sensitivity = duyarlılık · Recall = geri çağırma (Orange'da "Recall") · TPR = True Positive Rate = gerçek pozitif oranı
Türkçesi	"Hastaların yüzde kaçını yakaladım?"
Tek cümleyle	**Duyarlılık, gerçekten hasta olanların yüzde kaçını modelin yakaladığıdır.**
Formül	Duyarlılık = DP / (DP + YN) = yakalanan hasta / bütün gerçek hastalar
Benzetmeler	1. **Mühendislik:** Radarın gerçek uçakların yüzde kaçını ekranda gösterdiği (algılama olasılığı). 2. **Günlük hayat:** Balık ağı: gözleri küçük ağ (yüksek duyarlılık) neredeyse bütün balıkları yakalar, ama yosun ve çöp de toplar. 3. **Klinik:** Tarama testinden beklenen ilk özellik: kanser taramasında hastaları kaçırmamak.
Bizim verimizden	1. Paydayı bul: bütün gerçek sepsisler = DP + YN = 54 + 35 = **89**. 2. Payı bul: yakalananlar = DP = **54**. 3. Böl: 54 / 89 = 0,607 → **%60,7**. Yorum: her 10 sepsis hastasının yaklaşık 6'sı yakalandı, 4'ü kaçtı.
Hafıza kancası	**D**uyarlılık = "**D**oğru hastayı bulma". Paydada hep **gerçek hastalar** vardır.
Sık karışıklık	Duyarlılık modelin sabit bir özelliği değildir; eşiğe bağlıdır: eşik %5'te %91, %50'de %34,8. "Duyarlılık %61 düşük değil mi?" sorusunun cevabı: "Eşik %20'de öyle; düğmeyi çevirirsek artar, ama alarm sayısı da artar."

KISALTMA KARTI 14	**Özgüllük (specificity, TNR)**
Açılımı	Specificity = özgüllük · TNR = True Negative Rate = gerçek negatif oranı · FPR = False Positive Rate = 1 − özgüllük = yanlış alarm oranı
Türkçesi	"Sağlamların yüzde kaçını rahat bıraktım?"
Tek cümleyle	**Özgüllük, gerçekten sağlam olanların yüzde kaçına modelin "sorun yok" dediğidir.**
Formül	Özgüllük = DN / (DN + YP) = rahat bırakılan sağlam / bütün sağlamlar

Benzetmeler	1. **Mühendislik:** Radarın kuş sürüsüne "uçak" dememe becerisi (1 − yanlış alarm oranı). 2. **Günlük hayat:** Yalnızca hırsıza havlayan, postacıya ve komşuya havlamayan bekçi köpeği; ya da tost yaktığınızda susan akıllı duman dedektörü. 3. **Klinik:** Sağlam kişiyi boşuna korkutmamak, gereksiz tetkik ve girişim yaptırmamak.
Bizim verimizden	1. Paydayı bul: bütün sağlamlar = DN + YP = 750 + 61 = **811**. 2. Payı bul: rahat bırakılanlar = DN = **750**. 3. Böl: 750 / 811 = 0,925 → **%92,5**. Yanlış alarm oranı = 1 − 0,925 = %7,5 (61 / 811).
Hafıza kancası	**Ö**zgüllük = "**Ö**tmemesi gerekirken ötmemek". Paydada hep **gerçek sağlamlar** vardır.
Sık karışıklık	%92,5 kulağa çok iyi gelir; ama sağlam hasta çok olduğu için küçük bir yüzde bile çok sayıda boşuna alarm demektir (61 kişi). Bu yüzden PPV'ye de bakmak gerekir (Kart 15).

KISALTMA KARTI 15	**PPV — Pozitif Kestirim Değeri (precision, kesinlik)**
Açılımı	PPV = Positive Predictive Value · P = positive (pozitif) · P = predictive (kestirim, öngörü) · V = value (değer) · Orange'da "Precision" (Prec)
Türkçesi	Pozitif kestirim değeri, pozitif öngörü değeri, kesinlik. Kısaca: "Alarm çaldığında koşmaya değer mi?"
Tek cümleyle	**PPV, model "ALARM!" dediğinde hastanın gerçekten hasta olma olasılığıdır.**
Formül	PPV = DP / (DP + YP) = gerçek alarm / bütün alarmlar
Benzetmeler	1. **Mühendislik:** Arıza tespit sisteminin "arıza var" dediği durumların yüzde kaçında gerçekten arıza çıktığı; bakım ekibinin boşuna kaç kez sahaya gittiği. 2. **Günlük hayat:** "Kurt geldi!" diye bağıran çoban: 10 bağırışının 9'u yalansa köylüler artık koşmaz. Bu, PPV'si %10 olan bir alarmdır. Ya da spam klasörünüzdekilerin yüzde kaçının gerçekten spam olduğu. 3. **Klinik:** "Test pozitif çıktı; hasta gerçekten hasta mı?" Hastanın da klinisyenin de asıl merak ettiği soru budur.
Bizim verimizden	1. Paydayı bul: bütün alarmlar = DP + YP = 54 + 61 = **115**. 2. Payı bul: gerçek alarmlar = DP = **54**. 3. Böl: 54 / 115 = 0,47 → **%47**. Yorum: 100 alarmın 47'si gerçek, 53'ü boşa; yani her 2 uyarıdan yaklaşık 1'i gerçek sepsis.
Hafıza kancası	**P**PV = "**P**ozitif dediğinde haklı mı?" Paydada hep **alarmlar** vardır. **Duyarlılık hastalardan başlar, PPV alarmlardan başlar.**
Sık karışıklık	**Duyarlılıkla karıştırılır.** Duyarlılık hastalardan başlar (payda 89), PPV alarmlardan başlar (payda 115). Payları aynıdır (54), paydaları farklıdır: aynı pastanın iki farklı dilimi. PPV prevalansa bağlıdır (Kart 20): aynı model nadir hastalıkta ya da düşük riskli serviste düşük PPV verir.

KISALTMA KARTI 16	**NPV — Negatif Kestirim Değeri**
Açılımı	NPV = Negative Predictive Value = negatif kestirim (öngörü) değeri
Türkçesi	"Model 'sorun yok' dediğinde içimiz rahat mı?"
Tek cümleyle	**NPV, model "sorun yok" dediğinde gerçekten sorun olmama olasılığıdır.**
Formül	NPV = DN / (DN + YN) = gerçekten sağlam olan sessizlikler / bütün sessizlikler

Benzetmeler	1. **Mühendislik:** Kontrol paneli "tüm sistemler normal" dediğinde gerçekten normal olma oranı. 2. **Günlük hayat:** Duman dedektörü sessizken evde gerçekten yangın olmama olasılığı: gece rahat uyuyabilir miyiz? 3. **Klinik:** Hasta "temiz" çıktı; onu izlem sıklığını azaltıp rahat bırakabilir miyiz?
Bizim verimizden	1. Paydayı bul: bütün sessizlikler = DN + YN = 750 + 35 = **785**. 2. Payı bul: gerçekten sağlam olanlar = DN = **750**. 3. Böl: 750 / 785 = 0,955 → **%95,5**. Yorum: model sustuğunda hastaların %95,5'i gerçekten sağlam; ama 35 kişi "sessizlik içinde" sepsis oldu.
Sık karışıklık	NPV nadir hastalıklarda kendiliğinden yüksek çıkar, çünkü hasta zaten azdır. %95,5'i "mükemmel dışlama" diye okumadan önce, hiçbir şey yapmayan bir modelin NPV'sinin de %90,1 olacağını hatırlayın (811 / 900).

■ Benzetmeler: Payda nereden başlıyor?

Dört ölçütün farkı yalnızca **paydadadır**, yani "neyden başladığımızda":

- **Duyarlılık** hastalardan başlar (payda 89): "Hastaların kaçını yakaladım?" Balık ağı.
- **Özgüllük** sağlamlardan başlar (payda 811): "Sağlamların kaçını rahat bıraktım?" Postacıya havlamayan köpek.
- **PPV** alarmlardan başlar (payda 115): "Alarmlarımın kaçı haklıydı?" Kurt geldi çobanı.
- **NPV** sessizliklerden başlar (payda 785): "Sustuğumda içim rahat mı?" Gece sessiz dedektör.

Pastayı dört farklı yerden dilimlemek gibidir: pasta (karışıklık matrisi) aynıdır, dilimler farklıdır.

■ Klinik Köşe: Rakamları cümleye çevirmek

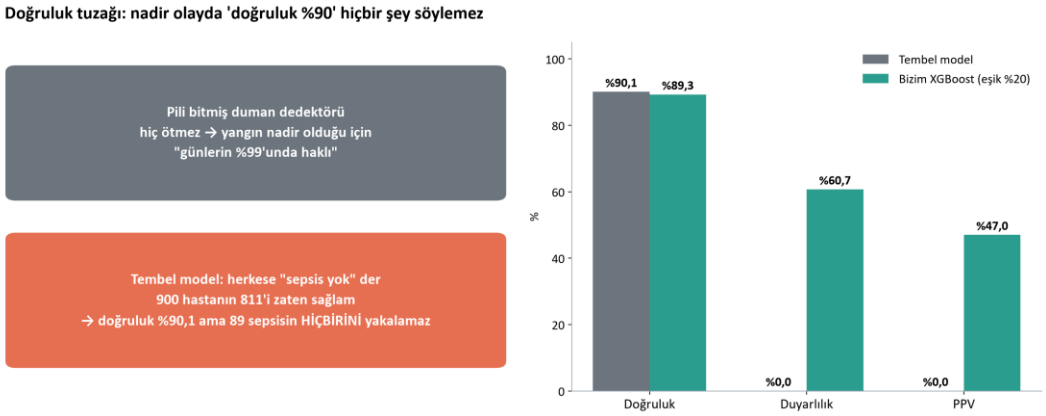
Tablodaki sonuçları serviste şöyle söyleyebilirsiniz: "Bu model %20 eşiğinde sepsis gelişecek her 10 hastanın yaklaşık 6'sını önceden yakalıyor. Verdiği her 2 uyarıdan yaklaşık 1'i gerçek sepsis. Uyarı vermediği hastaların %95,5'i gerçekten güvende." Aynı tablo, **35 sepsis hastasının uyarısız kaldığını** da söylüyor. Model, hemşirenin başucu değerlendirmesinin yerini alamaz.

■ Dikkat! Doğruluk tuzağı

Test grubunda 900 hastanın 811'inde sepsis gelişmemiştir. Hiçbir hastaya uyarı vermeyen, yani "herkes sağlam" diyen bir "model" 811/900 = **%90,1 doğruluk** elde eder. Bu, bizim XGBoost modelimizin doğruluğundan (%89,3) bile yüksektir; ama tek bir sepsis hastasını yakalamaz. Olayın nadir olduğu durumlarda **doğruluk (accuracy) tek başına anlamsızdır**. Duyarlılık, PPV ve kalibrasyon birlikte istenmelidir.

KISALTMA KARTI 17	**Doğruluk (accuracy, CA) ve doğruluk tuzağı**
Açılımı	Accuracy = doğruluk · Orange'da CA = Classification Accuracy (sınıflandırma doğruluğu) · Imbalanced data = dengesiz veri (bir sınıf çok nadir)
Türkçesi	Toplam doğru tahminlerin oranı; nadir olaylarda yanıltıcı bir vitrin sayısı
Tek cümleyle	**Doğruluk bütün tahminlerin yüzde kaçının doğru olduğudur; ama nadir olaylarda hiçbir şey yapmayan bir model de çok yüksek doğruluk alır.**
Formül	Doğruluk = (DP + DN) / toplam

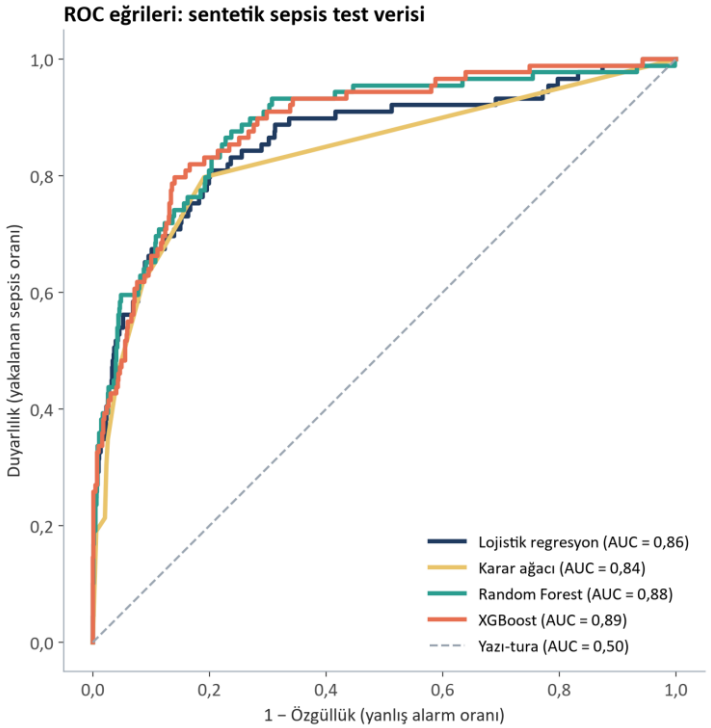
Benzetmeler	1. **Mühendislik:** 1000 parçada 2 kusur varsa “hepsi sağlam” diyen kamera %99,8 doğrudur; ama tek bir kusuru yakalamaz. 2. **Günlük hayat:** Pili bitmiş duman dedektörü, yangın nadir olduğu için “günlerin %99'unda haklı” görünür. Durmuş saat de günde iki kez doğruyu gösterir. 3. **Klinik:** Her hastaya “sepsis yok” diyen bir “uyarı sistemi” servisin %90'ında haklıdır; ama tek bir sepsis hastasını bile önceden haber vermez.
Bizim verimizden	1. Bizim model: (54 + 750) / 900 = 804 / 900 = **%89,3**. 2. Tembel model (herkese “sepsis yok”): DP 0, YN 89, YP 0, DN 811 → doğruluk 811 / 900 = **%90,1**. 3. Tembel modelin duyarlılığı **%0**: tek bir sepsisi bile yakalamıyor (Şekil A7). Tembel model bizim modelden daha “doğru” görünüyor!
Sık karışıklık	Orange'ın Test and Score tablosunda CA her modelde ≈ 0,90 çıkar; “hepsi harika” sanmayın. Nadir olayda “doğruluk %90” cümlesini duyunca hemen sorun: **Duyarlılık kaç? PPV kaç?**
İlgili şekil	Şekil A7 (aşağıda)



Şekil A7. *Doğruluk tuzağı: herkese “sepsis yok” diyen tembel model %90,1 doğruluk alır, ama duyarlılığı ve PPV'si sıfırdır.*

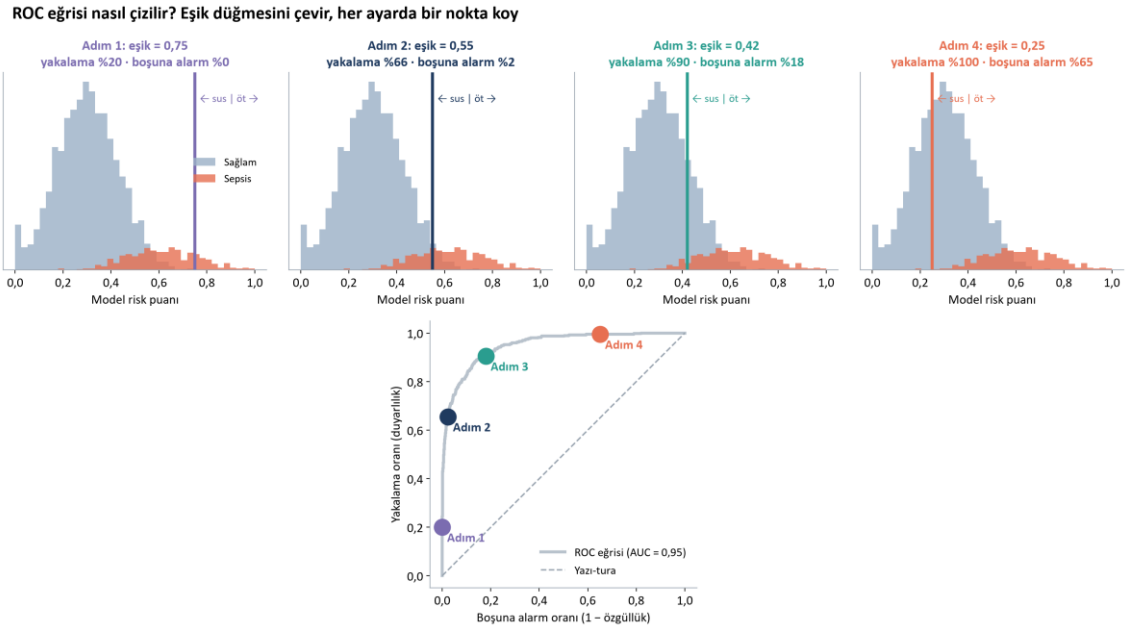
2.2 ROC eğrisi ve AUC

Karışıklık matrisi tek bir eşikteki performansı gösterir. Peki eşiği %1'den %99'a kadar kaydırırsak ne olur? Her eşik için duyarlılığı (y ekseni) ve 1 − özgüllüğü (x ekseni) işaretleyip noktaları birleştirdiğimizde **ROC eğrisi** (receiver operating characteristic) elde edilir. Eğrinin altında kalan alan da **AUC**'dir (area under the curve). Şekil 2.2, sepsis verisinde dört modelin ROC eğrisini gösterir. Köşegen çizgi yazı-tura atmaya karşılık gelir. Eğri sol üst köşeye ne kadar yaklaşırsa model o kadar iyi ayırır.



Şekil 2.2. *Sepsis test grubunda dört modelin ROC eğrileri.*

KISALTMA KARTI 18	**ROC eğrisi (Receiver Operating Characteristic)**
Açılımı	ROC = Receiver Operating Characteristic · receiver = alıcı (radar alıcısı ve operatörü) · operating characteristic = çalışma karakteristiği
Türkçesi	Alıcı işletim (çalışma) karakteristiği eğrisi
Tek cümleyle	**Eşik düğmesi en hassastan en kabaya çevrilir; her ayarda "kaç hastayı yakaladım" ile "kaç sağlama boşuna alarm verdim" bir nokta olarak işaretlenir; noktaları birleştiren çizgi ROC eğrisidir.**
Benzetmeler	1. **Mühendislik:** Adı İkinci Dünya Savaşı radar operatörlerinden gelir: ekrandaki nokta "düşman uçağı" mı "kuş sürüsü" mü? Hassasiyet düğmesi açıldıkça daha çok uçak, ama daha çok kuş da "uçak" olarak işaretlenir. ROC bu pazarlığın grafiğidir. 2. **Günlük hayat:** Balıkçı ağın göz büyüklüğünü değiştirir: göz küçüldükçe hem daha çok balık (iyi) hem daha çok çöp (kötü) gelir. ROC, her göz boyu için balık/çöp dengesini çizer. 3. **Klinik:** Bir tanı testinde kesim noktasını değiştirmek: kesim düştükçe daha çok hasta yakalanır ama daha çok sağlam kişi de "pozitif" çıkar.
Bizim verimizden	Dikey eksen = duyarlılık (yakalama oranı). Yatay eksen = 1 − özgüllük (boşuna alarm oranı). Eşik tablosundan noktalar: eşik %50 → (yanlış alarm %1,6; yakalama %34,8) · eşik %20 → (%7,5; %60,7) · eşik %5 → (%32,8; %91). Bu noktalar sol alttan sağ üste doğru bir eğri çizer. Sol üst köşe (0; 1) kusursuz dedektördür.
Hafıza kancası	Eğri sol üst köşeye ne kadar yakınsa o kadar iyi. Köşegen (kesikli çapraz çizgi) yazı-turadır. Köşegenin altına düşen model ters çalışıyordur.
Sık karışıklık	Yatay eksen "özgüllük" değil, **"1 – özgüllük"**tür (yanlış alarm oranı). Sağa gitmek "daha çok yanlış alarm" demektir.
İlgili şekil	Şekil A4 (aşağıda), Şekil 2.2, Şekil 2.3



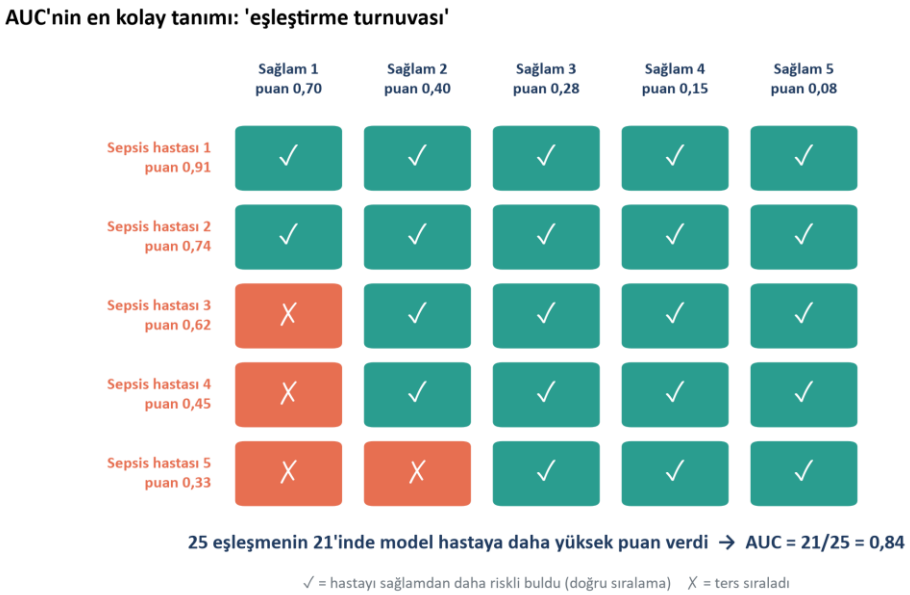
Şekil A4. *ROC eğrisi adım adım: her eşik (dikey çizgi) bir yakalama oranı ve bir boşuna alarm oranı verir; bu noktalar birleşince ROC eğrisi çıkar.*

■ Benzetme: İki hastayı sıralamak

Rastgele bir sepsis hastası ile rastgele bir sepsis gelişmeyen hastayı yan yana getirin. AUC, modelin **hastaya daha yüksek risk verme olasılığıdır**. AUC 0,89 ise bu karşılaştırmaların yaklaşık %89'unda model sıralamayı doğru yapar. Deneyimli bir hemşireye iki hasta dosyası verip "hangisi daha riskli?" diye sormak gibidir. AUC 0,5 ise model yazı-tura atmaktan farksızdır.

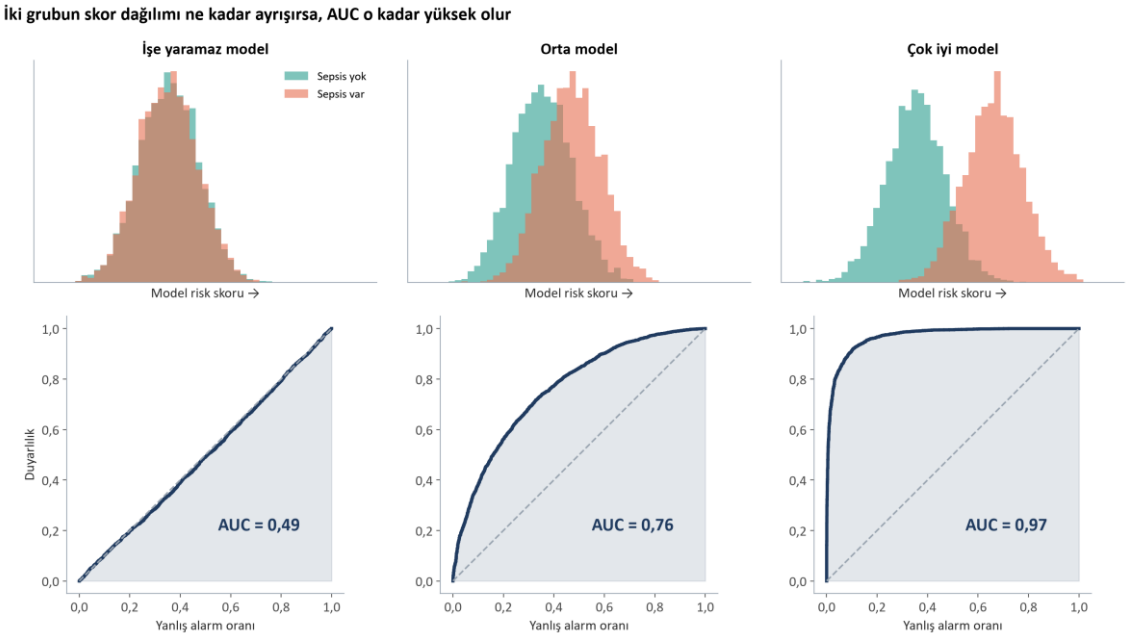
KISALTMA KARTI 19	**AUC (Area Under the Curve; ROC-AUC, C istatistiği)**
Açılımı	AUC = Area Under the Curve = eğri altındaki alan · ROC-AUC · C-statistic (C istatistiği; C = concordance, uyum)
Türkçesi	ROC eğrisinin altında kalan alan: modelin hastaları sağlamlardan ayırma (sıralama) becerisi
Tek cümleyle	**AUC, rastgele seçilen bir hastaya, rastgele seçilen bir sağlam kişiden daha yüksek risk puanı verme olasılığıdır.**
Benzetmeler	1. **Mühendislik:** Sınıflandırıcının sıralama kalitesi; eşikten bağımsızdır. Sistemleri eşik seçmeden önce karşılaştırmak için kullanılır (istatistikteki Mann–Whitney U ile aynı hesaptır). 2. **Günlük hayat:** Karpuza vurarak olgununu seçen manav: her "olgun–ham" çiftinde olgunu seçebiliyor mu? Bu "eşleştirme turnuvası" AUC'nin ta kendisidir (Şekil A5). 3. **Klinik:** Deneyimli bir hemşireye iki hasta dosyası verip "hangisi daha riskli?" diye sormak; doğru sıraladığı çiftlerin oranı.
Bizim verimizden	**Turnuva (Şekil A5):** 5 hasta ve 5 sağlam → 5 × 5 = 25 eşleşme. Model 21'inde hastaya daha yüksek puan verdi → AUC = 21 / 25 = **0,84**. Bizim sepsis modelleri: lojistik regresyon **0,86**, karar ağacı **0,84**, Random Forest **0,88**, XGBoost **0,89**. Yani XGBoost, rastgele bir sepsis hastası ile rastgele bir sağlam hastanın 100 eşleşmesinin yaklaşık 89'unda hastayı daha riskli sıralar. Kaba rehber: 0,5 yazı-tura · 0,6–0,7 zayıf · 0,7–0,8 kabul edilebilir · 0,8–0,9 iyi · 0,9 üstü mükemmel.

Sık karışıklık	**"AUC 0,90 = %90 doğru tahmin" YANLIŞTIR.** AUC sıralama becerisidir; doğruluk, PPV ya da kalibrasyon değildir. AUC eşikten bağımsızdır, ama klinik karar bir eşikte verilir. Bu yüzden AUC tek başına yetmez.
İlgili şekil	Şekil A5 (aşağıda), Şekil 2.3, Tablo 2.3



Şekil A5. *AUC = eşleştirme turnuvası. 5 hasta × 5 sağlam = 25 eşleşmenin 21'inde model hastaya daha yüksek puan verdi: AUC = 21 / 25 = 0,84.*

Şekil 2.3 AUC'nin ne ölçtüğünü sezgisel olarak gösterir. Hasta ve sağlam grupların aldığı risk skorlarının dağılımları birbirinin üzerine bindiğinde (AUC 0,49) model iki grubu ayıramaz. Dağılımlar kısmen ayrıştığında (AUC 0,76) ayrım orta düzeydedir. Dağılımlar neredeyse tamamen ayrıldığında (AUC 0,97) ayrım mükemmele yaklaşır.



Şekil 2.3. *Skor dağılımlarının örtüşmesi ve AUC: dağılımlar ayrıştıkça AUC yükselir (0,49 / 0,76 / 0,97).*

Tablo 2.3. AUC yorum rehberi (kaba kılavuz)

AUC	Yorum	Klinik anlamı	Dikkat edilecek nokta
0,50	Ayrım yok	Yazı-tura ile aynı	Modelin hiçbir bilgi taşımadığını gösterir
0,50–0,70	Zayıf	Sıralama sıklıkla yanlış	Tek başına klinik karar için genellikle yetersiz
0,70–0,80	Kabul edilebilir	Orta düzey ayrım	Klinik bağlama ve eşiğe göre değerlendirilmeli
0,80–0,90	İyi	Çoğu karşılaştırmada doğru sıralama	Kalibrasyon ve PPV yine ayrıca incelenmeli
> 0,90	Mükemmel	Grupların neredeyse tamamen ayrışması	Çok yüksekse veri sızıntısından şüphelenin

Sınırlar kaba bir rehberdir; aynı AUC farklı klinik bağlamlarda farklı değer taşır.

Tablo 2.4. Sepsis test grubunda dört modelin ayrım (AUC) ve genel doğruluk (Brier skoru) değerleri

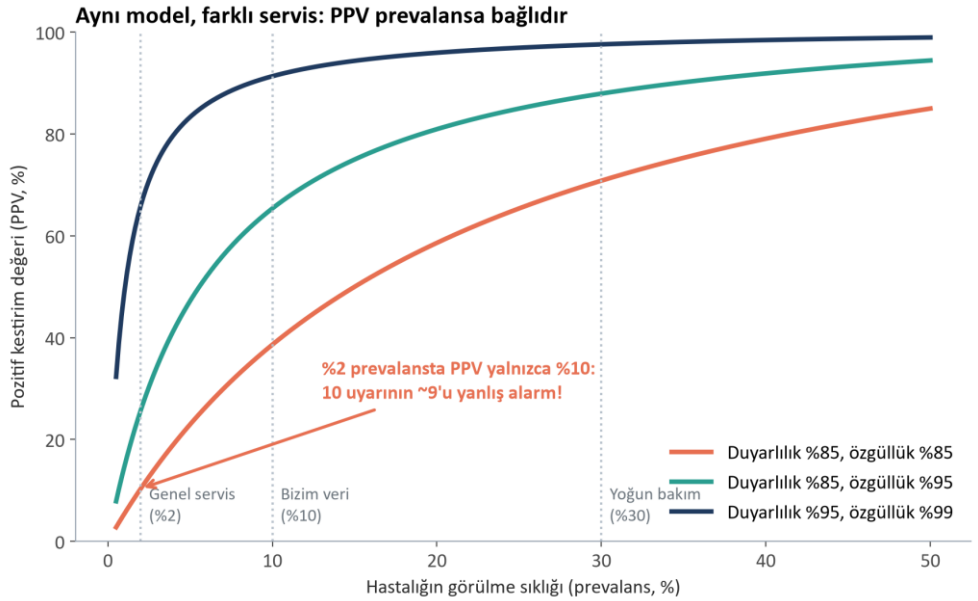
Model	AUC	Brier skoru	Yorum
Lojistik regresyon	0,860	0,061	Basit model, yakın performans
Karar ağacı (tek ağaç)	0,836	0,067	En düşük ayrım ve en yüksek Brier
Random Forest	0,885	0,061	XGBoost ile neredeyse aynı
XGBoost	0,886	0,061	En yüksek AUC, fark küçük

Brier skoru, tahmin edilen olasılık ile gerçekleşen sonuç arasındaki ortalama kare farktır; düşük olması iyidir. Adım adım hesabı Bölüm 2.5'teki Kısaltma Kartı 23'tedir.

> ■ **Dikkat! AUC ne değildir?**
>
> "AUC 0,90 ise model %90 doğru tahmin ediyor" **yanlıştır**. AUC bir sıralama başarısıdır, doğruluk oranı değildir. Ayrıca AUC **eşikten bağımsızdır**, oysa klinik karar her zaman bir eşikte verilir. AUC'si yüksek bir model, seçilen eşikte kabul edilemez sayıda hastayı kaçırabilir ya da çok fazla yanlış alarm üretebilir. AUC tek başına yeterli değildir.

2.3 Prevalans ve PPV: aynı model, farklı servis

Duyarlılık ve özgüllük bir testin (ya da modelin) kendine ait özellikleri gibi düşünülür. Ama klinisyen için asıl önemli soru genellikle şudur: **"Uyarı geldi; bu hasta gerçekten hasta mı?"** Bu sorunun cevabı PPV'dir ve PPV, olayın o ortamdaki sıklığına, yani **prevalansa** güçlü biçimde bağlıdır (Şekil 2.4).



Şekil 2.4. *PPV'nin prevalansa bağımlılığı: duyarlılık ve özgüllük aynı kalsa bile olay nadirleştikçe PPV hızla düşer.*

Bir örnekle somutlaştıralım. Duyarlılığı ve özgüllüğü %85 olan bir test, olayın %2 sıklıkta görüldüğü bir popülasyonda kullanılsın. 1000 kişilik bir grupta hesap Tablo 2.5'teki gibidir.

Tablo 2.5. Duyarlılık ve özgüllüğü %85 olan bir testin %2 prevalansta 1000 kişideki sonuçları

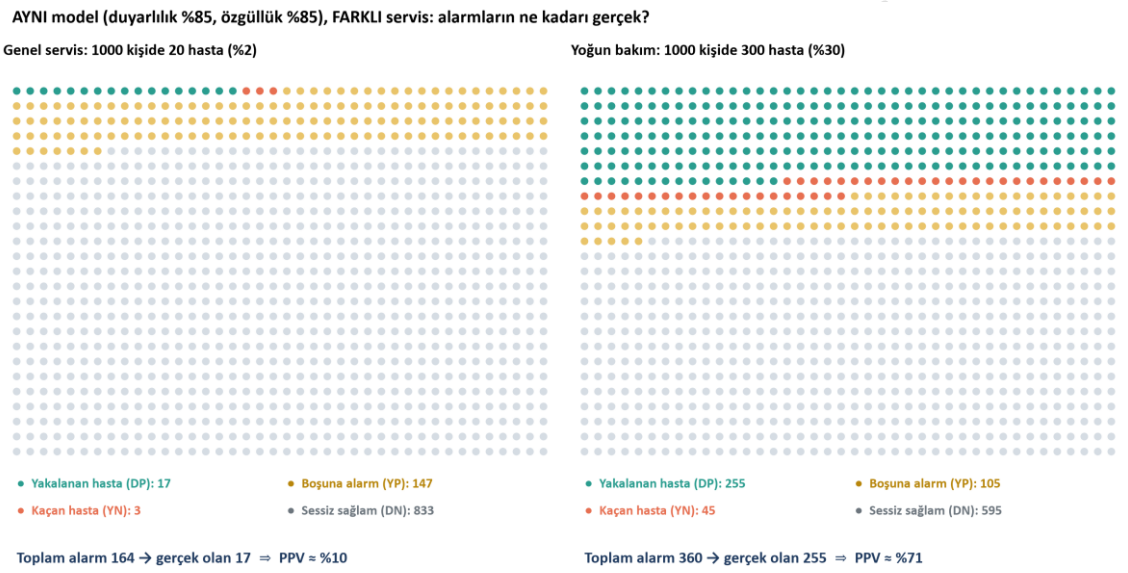
	Olay var (20)	Olay yok (980)	Toplam
Test pozitif	17 (DP)	147 (YP)	164
Test negatif	3 (YN)	833 (DN)	836
PPV	17 / 164 = **%10,4**		

Yani **10 uyarının yaklaşık 9'u yanlış alarmdır**, üstelik test kâğıt üzerinde "%85 duyarlı ve %85 özgül" görünmektedir. Aynı model, prevalansın yüksek olduğu bir yoğun bakımda iyi görünebilir, prevalansın düşük olduğu bir genel serviste ise sürekli yanlış alarm üretebilir. Aynı modeli **prevalansı %30 olan bir yoğun bakımda** kullandığımızda hesap şöyle değişir:

1. **Hasta sayısı:** 1000 × 0,30 = **300** hasta, **700** sağlam.
2. **Yakalanan:** 300 × 0,85 = **255** DP; kaçan 300 − 255 = **45** YN.
3. **Boşuna alarm:** 700 × 0,15 = **105** YP; rahat bırakılan 700 − 105 = **595** DN.
4. **PPV:** 255 / (255 + 105) = 255 / 360 ≈ **%71**. Aynı model, bu kez her 10 alarmın 7'sinde haklı.

KISALTMA KARTI 20	**Prevalans (görülme sıklığı, taban oranı)**
Açılımı	Prevalence = prevalans · Base rate = taban oranı · Base rate fallacy = taban oranı yanılgısı
Türkçesi	Bir toplulukta hastaların oranı
Tek cümleyle	**Prevalans bir topluluktaki hastaların oranıdır; aynı model, hastalığın nadir olduğu yerde alarmlarının çoğunda yanılır.**
Benzetmeler	1. **Mühendislik:** Arızanın taban oranı: üretim hattında 1000 parçada 2 kusur varsa kamera ne kadar iyi olursa olsun, "kusurlu" dediklerinin çoğu sağlam çıkar. 2. **Günlük hayat:** Havalimanında bomba çok nadirdir; bu yüzden x-ray cihazının "şüpheli" dediği bavulların neredeyse tamamından kemer tokası, ütü ya da konserve kutusu çıkar. 3. **Klinik:** Aynı sepsis modeli yoğun bakımda (hasta çok) iyi, genel serviste (hasta az) kötü görünür. Tarama testlerinin düşük riskli toplumda çok yanlış pozitif vermesi de budur.

Bizim verimizden	Bizim sepsis verisinde prevalans **%9,9** (100 hastadan ~10'u); preeklampside **%5,5**. **1000 kişi, prevalans %2, duyarlılık %85, özgüllük %85 (Şekil A2, sol):** 1. Hasta sayısı: 1000 × 0,02 = **20** hasta, **980** sağlam. 2. Yakalanan: 20 × 0,85 = **17 DP**; kaçan 3 YN. 3. Boşuna alarm: 980 × 0,15 = **147 YP**. 4. PPV = 17 / (17 + 147) = 17 / 164 = **%10,4**. Her 10 alarmın ~9'u boş! **Aynı model, prevalans %30 (Şekil A2, sağ):** 300 hastanın 255'i yakalanır; 700 sağlamın 105'ine boşuna alarm → PPV = 255 / 360 ≈ **%71**.
Sık karışıklık	"Duyarlılık ve özgüllük %85 ise pozitif sonuç %85 doğrudur." YANLIŞ. Duyarlılık ve özgüllük **modelin**, PPV ise modelin **kullanıldığı yerin** özelliğidir.
İlgili şekil	Şekil A2 (aşağıda), Şekil 2.4, Tablo 2.5



Şekil A2. *Aynı model (duyarlılık %85, özgüllük %85), iki farklı servis. Her nokta bir kişi. Solda (prevalans %2) alarmların yalnızca ~%10'u, sağda (prevalans %30) ~%71'i gerçek.*

■ Benzetmeler: Aynı model, farklı servis

- **Torba:** Torbada kırmızı bilye çok azsa, "kırmızı" diye çektiklerinizin çoğu aslında pembe çıkar.
- **Havalimanı:** Bomba çok nadir olduğu için "şüpheli" bavulların neredeyse hepsinden kemer tokası çıkar.
- **Kurt geldi çobanı:** Kurt nadiren gelirse, çobanın bağırışlarının çoğu boşa çıkar; köylüler koşmayı bırakır.

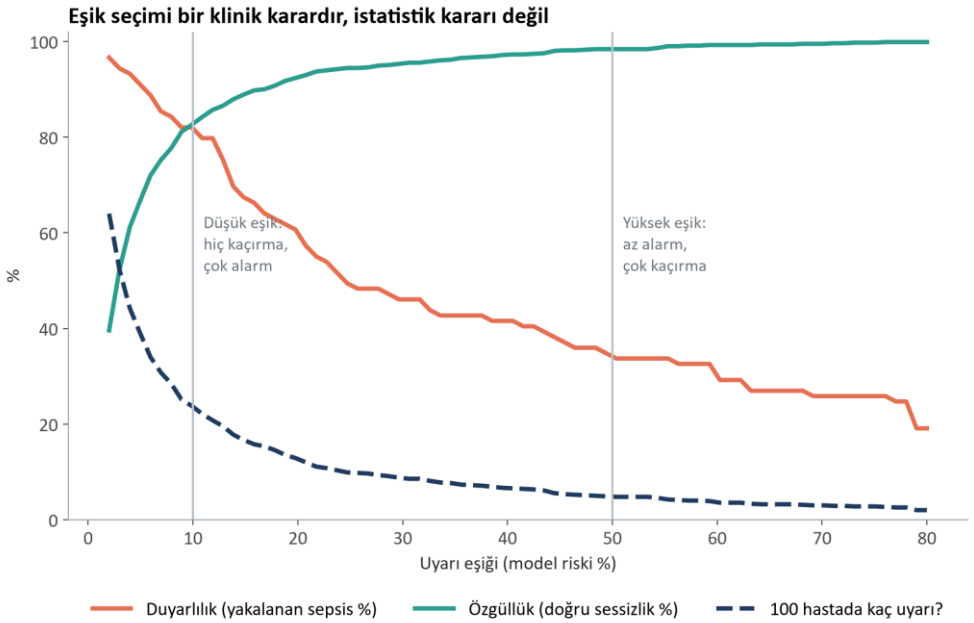
Ortak ders: **nadir olayda alarmların çoğu boştur; bu modelin değil, matematiğin kuralıdır.**

■ Klinik Köşe: PPV taşınamaz

Bir model makalesinde PPV bildirildiğinde, hangi prevalansta hesaplandığına bakın. Yoğun bakımda geliştirilen bir modelin PPV'si, sizin dahiliye servisinizde çok daha düşük olacaktır. Ebelikte de aynı durum geçerlidir: yüksek riskli gebe polikliniğinde iyi çalışan bir tarama modeli, düşük riskli toplum taramasında çok daha fazla yanlış pozitif üretir.

2.4 Eşik bir klinik karardır

Bir model 0 ile 1 arasında risk üretir. Hangi riskin üzerinde uyarı verileceğini, yani eşiği belirlemek istatistiksel değil **klinik bir karardır**. Şekil 2.5 ve Tablo 2.6, sepsis için XGBoost modelinin farklı eşiklerdeki davranışını gösteriyor.



Şekil 2.5. *Eşiğe göre duyarlılık, özgüllük ve 100 hastada üretilen uyarı sayısı (XGBoost, sepsis).*

Tablo 2.6. XGBoost sepsis modelinde eşik tablosu (test grubu n=900)

Eşik	Duyarlılık	Özgüllük	100 hastada uyarı	PPV
%5	%91	%67,2	38,6	%23,3
%10	%82	%83,1	23,3	%34,8
%20	%60,7	%92,5	12,8	%47
%30	%46,1	%95,4	8,7	%52,6
%50	%34,8	%98,4	4,9	%70,5

Tablo bir **değiş tokuşu** gösterir. Eşik %5'e indirildiğinde sepsis hastalarının %91'i yakalanır, ama her 100 hastada yaklaşık 39 uyarı üretilir ve uyarıların yalnızca %23,3'ü gerçek sepsistir. Eşik %50'ye çıkarıldığında uyarıların %70,5'i doğrudur, ancak sepsis hastalarının yalnızca %34,8'i yakalanır; yani üçte ikisi kaçırılır.

> ■ **Benzetme: Duman dedektörü**
>
> Mutfaktaki duman dedektörünü çok hassas ayarlarsanız her kızartmada öter; bir süre sonra kimse umursamaz, hatta pilini çıkarırsınız. Çok kaba ayarlarsanız gerçek yangını geç fark eder. Klinik uyarı sistemleri de böyledir. Düşük eşik az kaçırma ama **alarm yorgunluğu**, yüksek eşik az alarm ama **çok kaçırma** demektir. Alarm yorgunluğu gerçek bir hasta güvenliği sorunudur: sürekli öten bir uyarı, gerçek uyarının da göz ardı edilmesine yol açar (Şekil A15'teki üç düğme ayarını hatırlayın).

KISALTMA KARTI 21	**Alarm yorgunluğu (alarm fatigue)**
Açılımı	Alarm fatigue = alarm yorgunluğu · Alert burden = uyarı yükü · Alarm flood = alarm seli
Türkçesi	Çok fazla gereksiz alarmın insanları alarmları duymazdan gelmeye itmesi
Tek cümleyle	**Alarm yorgunluğu, çok sayıda (çoğu yanlış) uyarı nedeniyle uyarılara duyarlılığın azalması ve gerçek alarmın da kaçırılmasıdır.**
Benzetmeler	1. **Mühendislik:** Kontrol odasında "alarm seli": operatör yüzlerce gereksiz uyarı arasında kritik olanı kaçırır. 2. **Günlük hayat:** Sokakta çalan araba alarmına artık kimse bakmaz; her uygulamadan bildirim gelen telefonda önemli mesaj kaçar. "Kurt geldi" çobanına köylüler üçüncü kez gelmez; o gün kurt gerçekten gelmiştir. 3. **Klinik:** Monitör alarmlarının çoğu klinik olarak önemsizse, ekip alarm seslerine alışır ve gerçek aritmiye geç yanıt verir.
Bizim verimizden	Eşik %5: 100 hastada **38,6** uyarı; alarmların yalnızca **%23,3**'ü gerçek. 30 yataklı serviste eşik %5 → her risk hesaplama turunda yaklaşık 30 × 0,386 ≈ **11–12 uyarı**. Epic Sepsis Model yatışların **%18**'inde uyarı üretti; çoğu yanlış alarmdı (Bölüm 2.10).
Sık karışıklık	Alarm yorgunluğu "hemşirelerin dikkatsizliği" değildir; gerçek bir hasta güvenliği ve sistem tasarımı sorunudur. Eşik seçerken her alarmın gerçek bir hemşirenin gerçek bir koşusu olduğunu sayın.

■ Klinik Köşe: Eşik seçerken sorulacak sorular

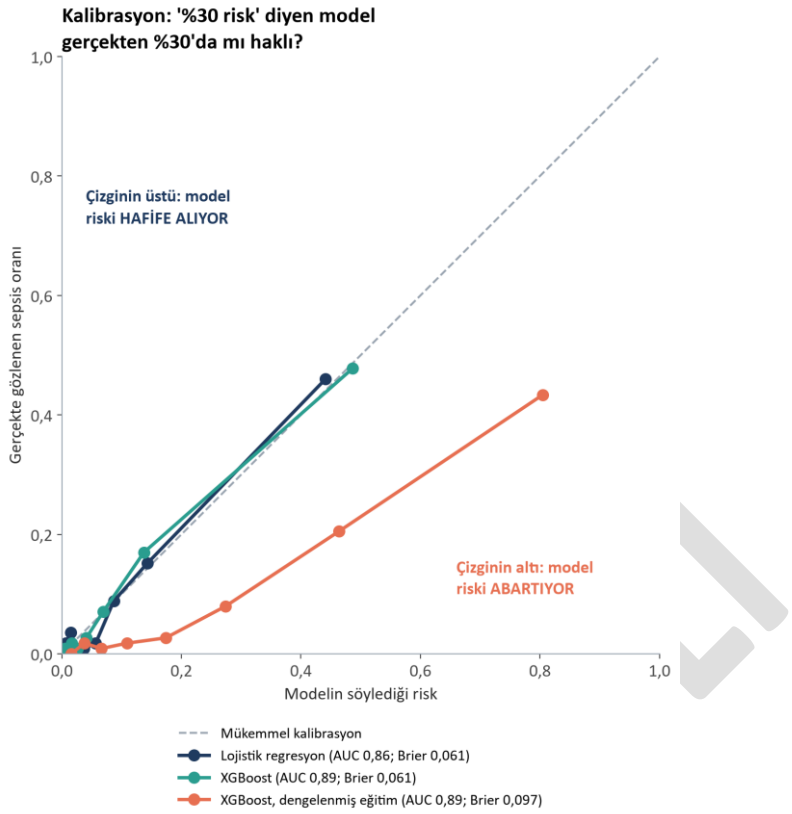
- **Kaçırmanın bedeli nedir?** Sepsiste bir hastayı kaçırmanın bedeli, gereksiz bir başucu değerlendirmesinin bedelinden çok yüksektir. Bu, görece düşük bir eşiği destekler.
- **Bir uyarının maliyeti nedir?** Uyarı yalnızca başucu değerlendirmesi mi gerektiriyor, yoksa invaziv bir girişim mi, gebeye ilaç başlanması mı?
- **Ekip kapasitesi nedir?** 30 yataklı bir serviste eşik %5 olursa her risk hesaplama turunda yaklaşık 11–12 uyarı (30 × 0,386) anlamına gelir. Bu iş yükü karşılanabilir mi?
- **Uyarıdan sonra ne yapılacak?** Eylemi tanımlanmamış bir uyarı yalnızca gürültüdür.
- **Karar eğrisi analizi** (decision curve analysis), farklı eşiklerde modelin net klinik yararını hesaplamaya yarayan bir yöntemdir (Vickers ve Elkin, 2006). Makalelerde görmeyi bekleyin.

■ Başka bir alandan bakış: Sigorta seçmek

Mühendislikte eşik seçimi bir **maliyet dengesi** problemidir: bir sigortanın amper değeri, "gereksiz atma" (yanlış alarm) ile "kabloyu yakma" (kaçırma) arasındaki bedel farkına göre seçilir. Kaçırmanın bedeli çok yüksekse daha hassas (düşük) bir değer, gereksiz atmanın bedeli yüksekse daha kaba (yüksek) bir değer seçilir. Klinikte de aynıdır: bir kaçırılan sepsisin bedeli ile bir gereksiz başucu değerlendirmesinin bedeli tartılır. Karar eğrisi analizi bu tartıyı grafiğe döker.

2.5 Kalibrasyon: model "%30" dediğinde gerçekten %30 mu?

AUC, modelin hastaları **doğru sıralayıp sıralamadığını** gösterir. Kalibrasyon ise modelin verdiği **yüzdelerin doğru olup olmadığını** sorar: Model "%30 risk" dediği hastaların gerçekten yaklaşık %30'unda olay gelişiyor mu? Kalibrasyon grafiğinde x ekseni tahmin edilen riski, y ekseni gözlenen oranı gösterir. İdeal model köşegen üzerindedir (Şekil 2.6).



Şekil 2.6. *Kalibrasyon eğrileri: "dengelenmiş" veriyle eğitilen XGBoost riski sistematik olarak abartır.*

Şekildeki öğretici örnekte XGBoost, sepsis hastaları ile sağlam hastaların sayısı yapay olarak eşitlenmiş ("dengelenmiş") bir veriyle eğitildi. Bu modelin AUC'si yine **0,89**'dur; yani sıralama gücü hiç bozulmamıştır. Ancak ortalama tahmini **%24,3** iken gerçek sepsis oranı **%9,9**'dur. Model riski yaklaşık **2,5 kat abartır** ve Brier skoru 0,061'den **0,097**'ye kötüleşir. Mesaj açıktır: **AUC aynı, kalibrasyon bozuk.**

Tablo 2.7. Ayrım (AUC) ile kalibrasyon arasındaki fark

	Ayrım (discrimination)	Kalibrasyon (calibration)
Sorduğu soru	Riskli hastayı risksizden daha yüksek sıraya koyuyor mu?	Verdiği yüzdeler gerçekleşen oranlarla uyumlu mu?
Tipik ölçüt	AUC (C istatistiği)	Kalibrasyon grafiği, kalibrasyon eğimi ve kesişimi, Brier skoru
Benzetme	Koşucuları doğru sırayla bitiş çizgisine dizmek	Her koşucunun süresini doğru tahmin etmek
Bozulursa ne olur?	Riskli hastalar gözden kaçar	Hasta ve gebeye yanlış risk bilgisi verilir; eşikler anlamsızlaşır
Bu eğitimdeki örnek	Dengelenmiş XGBoost: AUC 0,89 (değişmedi)	Ortalama tahmin %24,3, gerçek oran %9,9: riski ≈2,5 kat abartıyor

■ Benzetme: Hava durumu tahmini

Hava durumu "%30 yağmur olasılığı" dediği günlerin yaklaşık üçte birinde yağmur yağıyorsa, tahminler iyi kalibredir. Her gün "%80" diyen ama yağmurlu günleri doğru sıralayan bir meteorolog ise **iyi sıralar ama kötü kalibredir**. Bir gebeye "preeklampsi riskiniz %40" demek ile "%10" demek arasındaki fark, onun kaygısını ve kararlarını doğrudan etkiler.

KISALTMA KARTI 22	**Kalibrasyon (calibration)**
Açılımı	Calibration = kalibrasyon · Calibration plot / curve = kalibrasyon grafiği / eğrisi · Discrimination = ayrım (AUC'nin ölçtüğü şey) · Recalibration = yeniden kalibrasyon
Türkçesi	Modelin söylediği riskin gerçekleşen orana uyması
Tek cümleyle	**Kalibrasyon şunu sorar: model "%30 risk" dediğinde, bu hastaların gerçekten yaklaşık %30'u hastalanıyor mu?**
Benzetmeler	1. **Mühendislik:** Terazi ağır olanı ağır, hafifi hafif gösteriyor (sıralama doğru) ama her şeyi 2 kg fazla gösteriyorsa kalibrasyonu bozuktur. **Ayrım (AUC) = sıralama doğru mu? Kalibrasyon = sayının kendisi doğru mu?** 2. **Günlük hayat:** Hava durumu: "%30 yağmur" denen 100 günün yaklaşık 30'unda yağıyorsa tahminci iyi kalibredir (Şekil A6). Ya da gerçekte 90 giderken 100 gösteren hız göstergesi: hızlıyı yavaştan yine ayırır, ama sayısı yanlıştır. 3. **Klinik:** Bir gebeye "preeklampsi riskiniz %40" demek ile "%10" demek arasındaki fark, onun kaygısını ve kararlarını doğrudan etkiler. Sadece sıralama yetmez; sayı da doğru olmalı.
Bizim verimizden	Normal eğitilen modellerimiz iyi kalibre (Brier ≈ 0,061). "Dengelenmiş" eğitilen XGBoost: AUC yine **0,89** (sıralama aynı iyilikte). Ama ortalama tahmini **%24,3**, gerçek sepsis oranı **%9,9** → 24,3 / 9,9 ≈ **2,5 kat** abartı; Brier **0,097**. Sonuç: **AUC aynı, kalibrasyon bozuk.** Bu modelle hastaya "riskiniz %40" derseniz onu boş yere korkutursunuz.
Sık karışıklık	"AUC yüksekse kalibrasyon da iyidir." Hayır; ikisi farklı şeyleri ölçer. Kalibrasyona "tahmin modellerinin Aşil topuğu" denir (Van Calster ve ark., 2019). İyi haber: sıralaması iyi olan bir model yeniden kalibre edilebilir.
İlgili şekil	Şekil A6 (aşağıda), Şekil 2.6, Tablo 2.7



Şekil A6. *Kalibrasyon = hava durumunun dürüstlüğü. Sağdaki tahminci hangi günün daha yağışlı olacağını doğru sıralıyor (AUC iyi), ama her zaman abartıyor (kalibrasyon bozuk).*

KISALTMA KARTI 23	**Brier skoru (Brier score)**
Açılımı	Brier score: adını, 1950'de hava tahminlerini puanlamak için bu ölçütü öneren meteorolog Glenn Brier'den alır.
Türkçesi	Olasılık tahminlerinin ortalama kare hatası
Tek cümleyle	**Brier skoru, tahmin edilen olasılık ile gerçekleşen sonuç (1 = oldu, 0 = olmadı) arasındaki farkların karelerinin ortalamasıdır; küçük olan iyidir.**

Formül	Brier = ortalama [(tahmin − gerçek)²]
Benzetmeler	1. **Mühendislik:** Olasılıklar için ortalama kare hata: her tahminin hedeften sapmasının karesi alınıp ortalanır. 2. **Günlük hayat:** Dart: oklarınızın merkeze ortalama uzaklığı küçükse iyi nişancısınız. Golf skoru gibi: küçük olan kazanır. 3. **Klinik:** "%90 risk" deyip olay olmazsa büyük ceza (0,81), "%10 risk" deyip olay olmazsa küçük ceza (0,01): emin konuşup yanılan model daha çok cezalandırılır.
Bizim verimizden	1. Tek hasta: model %68 dedi, hasta sepsis oldu → (0,68 − 1)² = (−0,32)² = **0,1024**. 2. Aynı hasta sepsis olmasaydı → (0,68 − 0)² = **0,4624**. 3. Bütün hastaların cezaları ortalanır: bizim modellerimizde ≈ **0,061** (karar ağacı 0,067); dengelenmiş (abartan) modelde **0,097**.
Sık karışıklık	Brier hem ayrımı hem kalibrasyonu birlikte yansıtır; tek başına bir "kalibrasyon ölçütü" değildir. Sayının kendisi prevalansa bağlı olduğu için farklı hastalıklar arasında karşılaştırılmaz.
İlgili şekil	Tablo 2.4

■ **Dikkat!**

Kalibrasyon, tahmin modellerinin "Aşil topuğu" olarak nitelendirilir (Van Calster ve ark., 2019). Yayınların önemli bir kısmı yalnızca AUC bildirir. Bir model makalesinde **kalibrasyon grafiği yoksa** modelin verdiği yüzdelere güvenmek için yeterli kanıt yoktur.

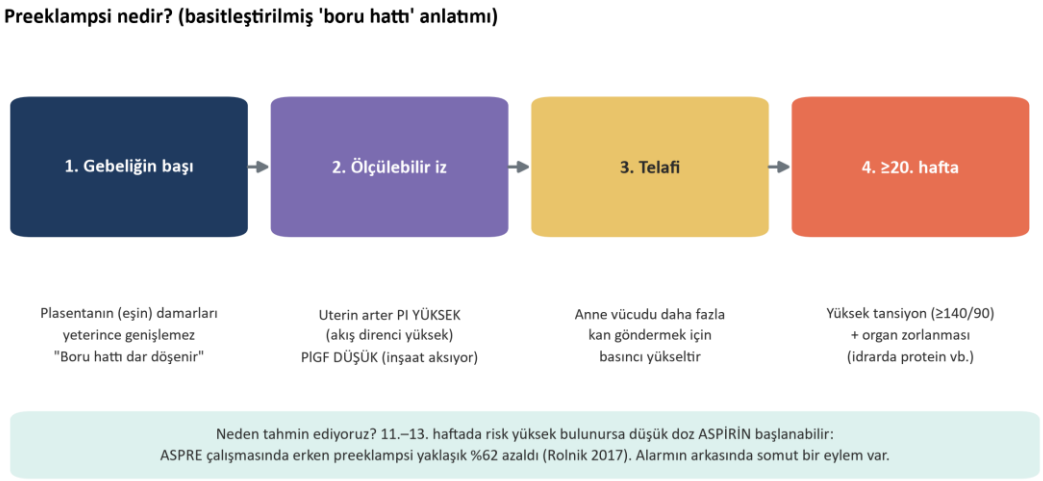
2.6 Nadir olaylar: kesinlik-duyarlılık eğrisi

Bu bölümde ikinci veri setimiz olan preeklampsi verisine geçiyoruz. Ebelikten gelen katılımcılar terimleri çok iyi bilir; diğer alanlardan gelenler için aşağıdaki kutu, sütunları modelin gözüyle okumaya yetecek kadar özet verir. Kalan terimler Bölüm 3, Vaka 4'te tamamlanır.

■ **Bu kelimeler ne demek? · Preeklampsi veri seti (preeklampsi_sentetik.csv)**

4000 gebe, 11–13. hafta taraması; hedef "Preeklampsi: Gelişti/Gelişmedi", prevalans %5,5. Birim ve aralıklar Ek B.5'tedir.

Preeklampsi	
Ne?	Gebeliğin 20. haftasından sonra ortaya çıkan yeni hipertansiyon (≥140/90 mmHg) ile birlikte proteinüri ya da organ etkilenmesi (karaciğer, böbrek, nörolojik ya da görme bulguları). **Eklampsi:** tabloya nöbet eklenmesi. Kesin tedavisi doğumdur.
Normal değer	Bizim verimizde prevalans %5,5 (4000 gebede 219)
Model için neden önemli?	11–13. haftada risk yüksek bulunursa **düşük doz aspirin** başlanabilir: ASPRE çalışmasında preterm preeklampsi yaklaşık %62 azaldı (Rolnik ve ark., 2017). Dedektör öttüğünde yapılacak somut bir eylem vardır.
Benzetme	Plasentanın damarları gebeliğin başında yeterince genişlemez: fabrikaya hammadde getiren boru hattı dar döşenmiştir. Anne basıncı artırarak (tansiyonu yükselterek) akışı sağlamaya çalışır; bu da annenin organlarını yorar (Şekil B4).
Bu eğitimde	Preeklampsi verisi; nadir olay ve PR eğrisi örneği (AUC 0,77, AP 0,21); Bölüm 3, Vaka 4.



Şekil B4. *Preeklampsi: basitleştirilmiş "boru hattı" anlatımı (plasenta damarlarının yetersiz genişlemesi ve annenin basıncı artırması).*

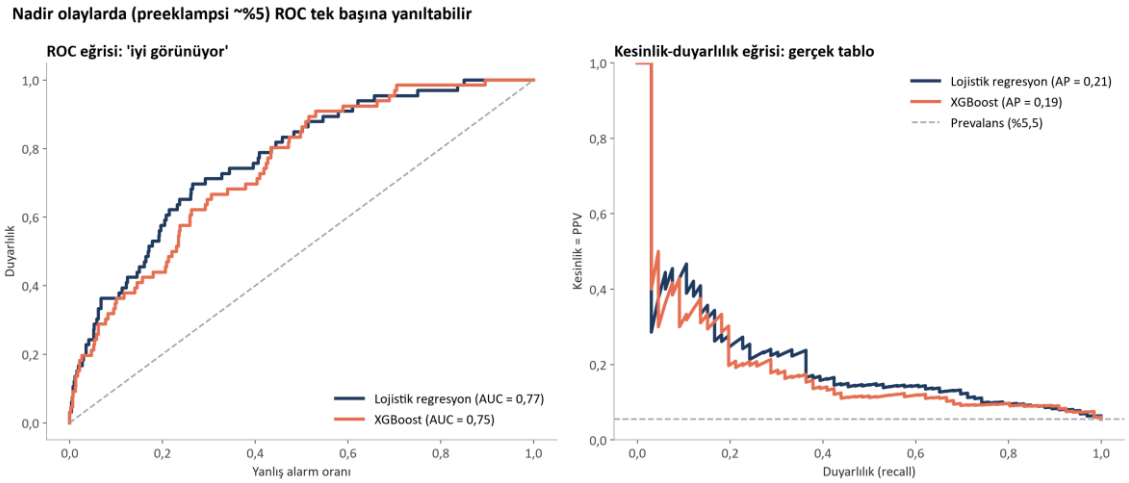
Uterin arter PI (pulsatilite indeksi)	
Ne?	Uterin artere Doppler ultrasonla bakılarak hesaplanan, akış direncini yansıtan indeks.
Normal değer	Verimizde MoM olarak (≈1,0 ortanca). **Yüksek PI** = yüksek direnç = risk
Model için neden önemli?	Plasentanın kanlanmasının dolaylı ölçüsüdür.
Benzetme	Dar boru: aynı pompayla daha dar bir borudan su geçirmeye çalışmak dalgalı ve dirençli bir akış yaratır.
Bu eğitimde	"Uterin arter PI (MoM)": SHAP'ta 3. sıra.

PlGF (plasental büyüme faktörü)	
Ne?	Plasentanın sağlıklı damar yapısı kurduğunu yansıtan anjiyojenik bir protein.
Normal değer	MoM olarak; **düşük PlGF** = risk
Model için neden önemli?	Bu değişkende riski artıran yüksek değil **düşük** değerdir; SHAP grafiğinde mavi noktalar sağdadır.
Benzetme	Şantiyeden gelen ilerleme raporu: rapor zayıfsa (düşük PlGF) inşaat aksıyor.
Bu eğitimde	"PlGF (MoM)": SHAP'ta 2. sıra (Şekil 3.8).

MoM (multiple of the median, ortancanın katı)	
Ne?	Ölçülen değerin, aynı gebelik haftasındaki (ve benzer özellikteki) gebelerin ortanca değerine bölünmesiyle elde edilen birimsiz sayı.
Normal değer	1,0 = tam ortanca · 0,5 = ortancanın yarısı · 2,0 = iki katı
Model için neden önemli?	Gebelik haftası ilerledikçe değerler doğal olarak değiştiği için MoM bu etkiyi temizler; farklı haftalarda ölçülen gebeler karşılaştırılabilir.
Benzetme	"Nominal değerin yüzdesi" gibi normalize edilmiş bir okuma: 0,5 MoM, "beklenenin yarısı" demektir.
Bu eğitimde	PI, PlGF ve PAPP-A sütunları MoM cinsindendir.

Olay nadir olduğunda ROC eğrisi iyimser bir tablo çizebilir, çünkü çok sayıdaki sağlam kişiyi doğru tanımak kolaydır. Preeklampsi veri setinde prevalans **%5,5**'tir. Lojistik regresyonun AUC'si **0,77**, XGBoost'unki **0,75**'tir; bunlar "kabul edilebilir" görünür. Oysa **kesinlik-duyarlılık eğrisi** (precision-recall curve) farklı bir hikâye anlatır (Şekil 2.7). Bu eğride y ekseni PPV'dir (kesinlik). Eğrinin altındaki alanı özetleyen **ortalama**

kesinlik (average precision, AP) lojistik regresyonda yalnızca **0,21**, XGBoost'ta **0,19**'dur. Yani modeller hangi eşikte kullanılırsa kullanılsın, uyarıların çoğu yanlış alarm olacaktır.



Şekil 2.7. *Preeklampsi (prevalans %5,5): ROC eğrisi iyi görünse de kesinlik-duyarlılık eğrisi düşük PPV'yi ortaya koyar.*

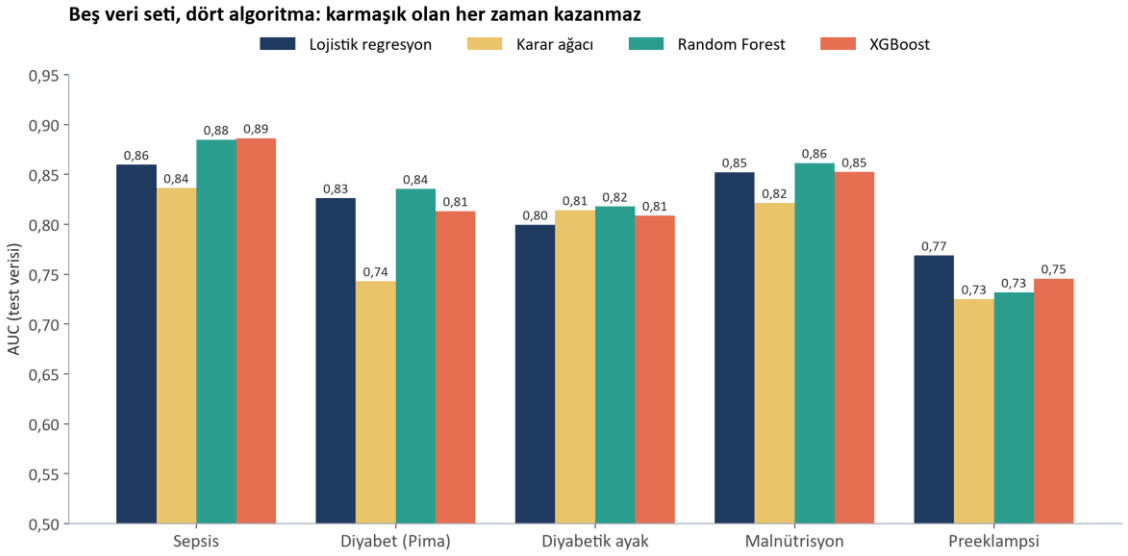
KISALTMA KARTI 24	**PR eğrisi (Precision–Recall) ve AP (Average Precision)**
Açılımı	PR = Precision–Recall (kesinlik–duyarlılık) · Precision = kesinlik = PPV · Recall = duyarlılık · AP = Average Precision = ortalama kesinlik (PR eğrisinin altındaki alan)
Türkçesi	Kesinlik–duyarlılık eğrisi; altındaki alan: ortalama kesinlik
Tek cümleyle	**PR eğrisi ROC'un nadir olaylar için daha dürüst kardeşidir: yatayda duyarlılık (hastaların kaçını yakaladım), dikeyde PPV (alarmlarımın kaçı haklı) vardır.**
Benzetmeler	1. **Mühendislik:** Arama motoru: 10 sonuç getirdi, kaçı alakalı (kesinlik)? Bütün alakalı sayfaların kaçını buldu (duyarlılık)? Bilgi erişiminde standart ölçüttür. 2. **Günlük hayat:** Samanlıkta iğne: 1000 samandan 50'sine yanlış alarm vermek "%5, ne güzel" görünür; ama yalnızca 10 iğne varsa 50 boş alarm 10 gerçek alarmı boğar. ROC samanlara, PR doğrudan iğnelere bakar. 3. **Klinik:** Düşük riskli gebe taramasında "yüksek risk" denen gebelerin kaçında gerçekten preeklampsi gelişti? İşte PR eğrisinin dikey ekseni budur.
Bizim verimizden	Preeklampsi verisi: prevalans **%5,5** (4000 gebede 219 preeklampsi). ROC'a göre AUC: lojistik regresyon **0,77**, XGBoost **0,75** → "fena değil". PR'ye göre AP: **0,21** ve **0,19** → tipik bir eşikte alarmların ancak beşte biri gerçek. Kıyas noktası 0,5 değil, **prevalanstır**: rastgele bir model AP ≈ 0,055 alır. 0,21 rastgeleden belirgin iyidir, ama yanlış pozitif yükü büyüktür.
Sık karışıklık	ROC'taki "0,5 = yazı-tura" kuralını PR'ye taşımak. PR'de yazı-tura çizgisi prevalans hizasındadır (preeklampside 0,055).
İlgili şekil	Şekil 2.7

■ Klinik Köşe: Gebeye ne söyleriz?

Rastgele tahmin yapan bir modelin ortalama kesinliği yaklaşık prevalansa (%5,5) eşittir. AP 0,21 bu düzeyin belirgin üzerindedir, yani model işe yarar bilgi taşır. Ama bir gebeye "yüksek risklisiniz" dendiğinde, bu gebelerin büyük çoğunluğunda preeklampsi gelişmeyecektir. **Danışmanlık dili** buna göre kurulmalıdır: "kesin olacak" değil, "daha yakından izleyeceğiz ve koruyucu önlem önereceğiz".

2.7 Karmaşık algoritma her zaman kazanmaz

Beş veri setinin tamamında dört algoritmayı aynı koşullarda karşılaştırdık (Şekil 2.9 ve Tablo 2.8). Sonuç, "en karmaşık algoritma en iyisidir" inancını sorgular. Pima diyabet verisinde en yüksek AUC Random Forest'a (0,835) aittir; lojistik regresyon (0,826) hemen arkasından gelir ve XGBoost'u (0,813) geride bırakır. Preeklampside en iyi sonucu lojistik regresyon verir. Sepsiste ise XGBoost ile Random Forest neredeyse aynıdır.



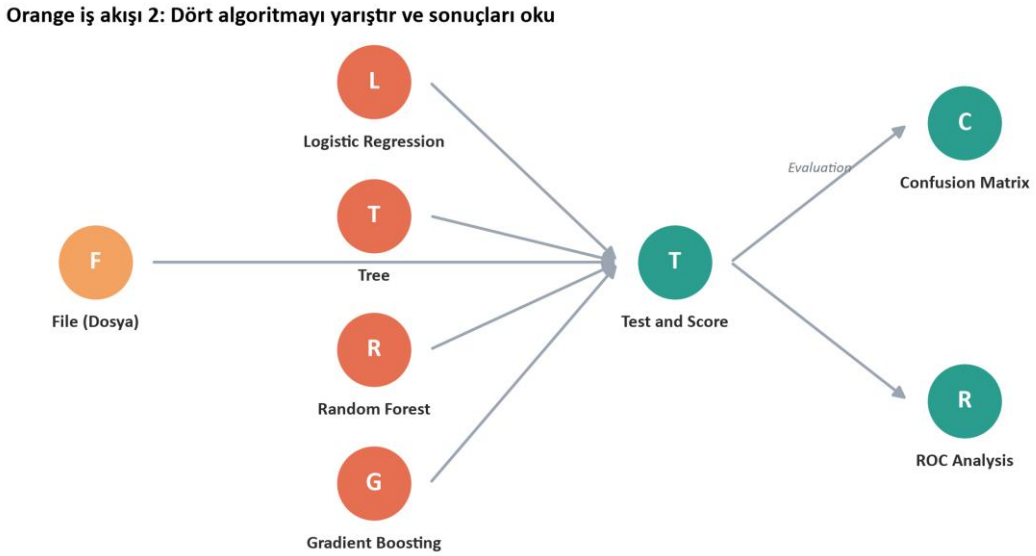
Şekil 2.9. *Beş veri seti × dört algoritma: AUC karşılaştırması.*

Tablo 2.8. Beş veri setinde dört algoritmanın AUC değerleri (her satırda en yüksek değer kalın)

Veri seti	Lojistik regresyon	Karar ağacı	Random Forest	XGBoost
Sepsis	0,860	0,836	0,885	**0,886**
Diyabet (Pima)	0,826	0,743	**0,835**	0,813
Diyabetik ayak	0,800	0,814	**0,818**	0,809
Malnütrisyon	0,852	0,821	**0,862**	0,852
Preeklampsi	**0,769**	0,725	0,732	0,746

Bu bulgu literatürle de uyumludur: klinik tahmin modellerini karşılaştıran sistematik bir derleme, makine öğrenmesinin lojistik regresyona göre ortalamada belirgin bir performans üstünlüğü göstermediğini bildirmiştir (Christodoulou ve ark., 2019). Basit ve şeffaf bir model, karmaşık bir modele yakın performans veriyorsa, klinik uygulamada çoğu zaman tercih edilmesi gereken odur.

2.8 Orange uygulaması: dört modeli yarıştırmak



Şekil 2.8. *Oturum 2 Orange iş akışı: dört öğrenici → Test and Score → Confusion Matrix ve ROC Analysis.*

Orange'da Adım Adım

1. **File** ile *sepsis_sentetik.csv* dosyasını açın, *Sepsis (24 saat)* değişkeninin rolünün **target** olduğunu kontrol edin.
2. **Model** grubundan **Logistic Regression**, **Tree**, **Random Forest** ve **Gradient Boosting** widget'larını tuvale ekleyin.
3. **Evaluate** grubundan **Test and Score** ekleyin. **File**'ı **Test and Score**'a, dört öğreniciyi de **Test and Score**'a bağlayın.
4. **Test and Score**'da **Cross validation** seçin, kat sayısını (**Number of folds**) 5 yapın. **Target class** olarak *Evet*'i seçin.
5. Tablodaki AUC, CA (doğruluk), Precision ve Recall sütunlarını karşılaştırın. Hangi model önde?
6. **Test and Score**'a **Confusion Matrix** bağlayın. Sol listeden bir model seçin ve dört hücreyi okuyun.
7. **Test and Score**'a **ROC Analysis** bağlayın. Eşiği değiştirmek için eğri üzerindeki noktayı izleyin; duyarlılık ve özgüllüğün nasıl değiştiğini gözleyin.
8. Aynı akışı *preeklampsi_sentetik.csv* ile tekrarlayın (**Target class**: *Gelişti*). Confusion Matrix'te PPV'nin ne kadar düştüğüne dikkat edin.

Orange'da XGBoost'a en yakın seçenek Gradient Boosting widget'ıdır; bilgisayarınızda xgboost kütüphanesi kuruluysa widget içinden XGBoost yöntemi de seçilebilir. Çapraz doğrulama sonuçları, bu notta bildirilen test seti sonuçlarından biraz farklı olabilir.

Test and Score tablosunun sütun başlıkları İngilizce kısaltmalardır. Aşağıdaki kart, ekranda göreceğiniz her kısaltmayı bu notta öğrendiğiniz Türkçe kavrama bağlar.

KISALTMA KARTI 25	**Orange ekranındaki kısaltmalar: CA, Prec, Recall, F1, AUC, MCC**
Açılımı	CA = Classification Accuracy · Prec = Precision · Recall · F1 = F1 score (F-ölçütü) · AUC = Area Under the Curve · MCC = Matthews Correlation Coefficient
Türkçesi	CA = doğruluk · Prec = PPV (kesinlik) · Recall = duyarlılık · F1 = PPV ile duyarlılığın dengeli ortalaması · AUC = ROC eğrisi altındaki alan · MCC = sürüme göre görülebilen ek bir özet ölçüt (bu eğitimde kullanmıyoruz)
Tek cümleyle	**Orange'ın Test and Score tablosu karnenin İngilizce özetidir; her sütun bu notta Türkçesini öğrendiğiniz bir kavramdır.**
Formül	F1 = 2 × PPV × Duyarlılık / (PPV + Duyarlılık) = 2DP / (2DP + YP + YN)
Benzetmeler	1. **Mühendislik:** F1 iki direncin paralel bağlanması gibidir: küçük olan sonucu aşağı çeker. PPV ya da duyarlılıktan biri kötüyse F1 de kötüdür (harmonik ortalama). 2. **Günlük hayat:** Hem hız hem güvenlik puanı olan bir araba: biri berbatsa "iyi araba" denmez. 3. **Klinik:** Hem kaçırmayan hem de boşuna alarm vermeyen bir triaj hemşiresi: iki özelliği tek notta birleştirmek.
Bizim verimizden	Bizim model (eşik %20): PPV 0,47, duyarlılık 0,607. F1 = 2 × 54 / (2 × 54 + 61 + 35) = 108 / 204 ≈ **0,53**. Orange'da sayılar 0,5 eşiği ve çapraz doğrulamayla hesaplandığı için farklı çıkar; mantık aynıdır.
Sık karışıklık	Orange'da **Target class** seçilmezse Prec ve Recall iki sınıfın ortalaması olarak gelir ve ikisi de yüksek görünür. Mutlaka **Target class: Evet** (preeklampside **Gelişti**) seçin.
İlgili şekil	Şekil 2.8

2.9 Çözümlü hesap alıştırması

1000 hastalık bir serviste bir modelin performansını hesaplayalım. Olayın prevalansı **%5**, modelin duyarlılığı **%80**, özgüllüğü **%90** olsun. Adım adım ilerleyelim:

1. **Hasta sayısı:** 1000 × 0,05 = **50** hastada olay gelişir, **950** hastada gelişmez.
2. **Doğru pozitif:** Duyarlılık %80 olduğuna göre 50 × 0,80 = **40** hasta yakalanır (DP = 40).
3. **Yanlış negatif:** Kalan 50 − 40 = **10** hasta kaçırılır (YN = 10).
4. **Doğru negatif:** Özgüllük %90 olduğuna göre 950 × 0,90 = **855** sağlam kişi doğru biçimde negatif bulunur (DN = 855).
5. **Yanlış pozitif:** Kalan 950 − 855 = **95** sağlam kişiye uyarı verilir (YP = 95).
6. **PPV:** 40 / (40 + 95) = 40 / 135 = **%29,6**. Uyarı alan her 10 hastadan yalnızca 3'ü gerçekten hastadır.
7. **NPV:** 855 / (855 + 10) = 855 / 865 = **%98,8**. Uyarı almayan hastalar büyük olasılıkla güvendedir.

Tablo 2.9. Hesap alıştırmasının karışıklık matrisi (n=1000, prevalans %5, duyarlılık %80, özgüllük %90)

	Olay var (50)	Olay yok (950)	Toplam	Kestirim değeri
Model pozitif	DP = 40	YP = 95	135	PPV = 40/135 = %29,6
Model negatif	YN = 10	DN = 855	865	NPV = 855/865 = %98,8
Toplam	50	950	1000	

> ■ **Klinik Köşe: Hesabın klinik yorumu**
>
> %80 duyarlılık ve %90 özgüllük kâğıt üzerinde etkileyici görünür. Ancak serviste karşılığı şudur: her gün uyarı alan 135 hastanın 95'i aslında olay yaşamayacaktır. Bu modelin değeri, uyarının ardından yapılacak eylemin ne kadar ucuz ve güvenli olduğuna bağlıdır. Basit bir başucu değerlendirmesi için kabul edilebilir; invaziv bir girişim için büyük olasılıkla kabul edilemez.

2.10 Vaka: Epic Sepsis Model

Bu vaka, bir modelin geliştiricisinin bildirdiği performans ile bağımsız bir hastanedeki gerçek performansı arasındaki farkın ne kadar büyük olabileceğini gösterir (Wong ve ark., 2021). Söz konusu model, yaygın kullanılan bir elektronik sağlık kaydı sistemine gömülü, ticari bir sepsis tahmin modelidir.

Tablo 2.10. Epic Sepsis Model: geliştirici beyanı ve dış validasyon

	Geliştiricinin bildirdiği	Michigan dış validasyonu (Wong ve ark., 2021)
Kapsam	Geliştirici verisi	27.697 hasta, 38.455 yatış
AUC	0,76–0,83	**0,63**
Sepsis vakalarını kaçırma	—	Vakaların **%67**'si kaçırıldı
Uyarı yükü	—	Yatışların **%18**'inde uyarı üretildi

Model sepsis vakalarının üçte ikisini kaçırırken, yatışların yaklaşık beşte birinde uyarı üretmiştir. Bu, hem güvenlik (kaçırılan vakalar) hem de iş yükü (alarm yorgunluğu) açısından ciddi bir sorundur.

KISALTMA KARTI 26 İç validasyon ve dış validasyon

Açılımı	Validation = geçerlilik sınaması, doğrulama · Internal validation = iç validasyon · External validation = dış validasyon
Türkçesi	İç: aynı veri setinin ayrılmış parçasında test · Dış: başka hastane, başka dönem ya da başka ülkede test
Tek cümleyle	**Dış validasyon, modeli geliştirildiği yerden FARKLI bir hastanede ya da farklı bir dönemde sınamaktır.**
Benzetmeler	1. **Mühendislik:** Rüzgâr tünelinde mükemmel olan uçağı gerçek fırtınada uçurmak; prototipi kendi laboratuvarınızda değil, başka bir fabrikanın sahasında test etmek. 2. **Günlük hayat:** Yalnızca kendi pistinde test edilmiş araba başka şehrin bozuk yollarında. 3. **Klinik:** Bir tedavinin tek merkezde değil, çok merkezli bir çalışmada sınanması.
Bizim verimizden	**Epic Sepsis Model (Wong ve ark., 2021):** geliştirici AUC'yi **0,76–0,83** bildirdi. Michigan'da 27.697 hasta ve 38.455 yatışta bağımsız dış validasyon: AUC **0,63**. Sepsis vakalarının **%67**'si kaçırıldı; yatışların **%18**'inde uyarı verildi. Bu eğitimdeki modellerde dış validasyon **yoktur**: hepsi iç validasyondur.
Sık karışıklık	Çapraz doğrulama dış validasyon değildir; aynı veri setinin içinde kalır (iç validasyon). “Başka hastanede iyi çalıştıysa bizde de çalışır” inancı Epic vakasıyla çürür.
İlgili şekil	Tablo 2.10, Şekil 4.4

■ Vaka tartışması: Neden böyle oldu? Siz olsaydınız ne sorardınız?

Grubunuzla aşağıdaki soruları tartışın:

1. Geliştiricinin bildirdiği AUC ile dış validasyondaki AUC neden bu kadar farklı olabilir? (İpucu: hasta profili, sepsis tanımı, verinin zamanlaması.)
2. Bu model sizin hastanenizde kullanıma alınmadan önce hangi soruları sorardınız?
3. Yatışların %18'inde uyarı üreten bir sistem, hemşirelik iş yükünü ve uyarılara verilen yanıtı nasıl etkiler?
4. Ticari ve kapalı (algoritması paylaşılmayan) bir modelin değerlendirilmesi neden daha zordur?
5. Bu vaka "başka hastanede iyi çalıştıysa bizde de çalışır" inancı hakkında ne söylüyor?

■ Dikkat!

Bir modelin başka bir hastanede ya da geliştirici verisinde iyi çalışması, **sizin hastanenizde de iyi çalışacağı anlamına gelmez**. Hasta profili, kayıt alışkanlıkları ve sonuç tanımları değiştikçe performans da değişir. Kullanım öncesinde yerel dış validasyon ve kullanım sırasında sürekli izleme gerekir (Bölüm 4).

■ Kendinizi Sınayın

1. Bir modelin karışıklık matrisi şöyledir: DP 30, YP 70, YN 10, DN 890. Duyarlılık ve PPV'yi hesaplayın.
2. "Bu modelin AUC'si 0,85, yani hastaların %85'ini doğru sınıflandırıyor." Bu cümledeki hata nedir?
3. Aynı sepsis modeli yoğun bakımda (prevalans yüksek) ve ortopedi servisinde (prevalans düşük) kullanılıyor. Hangi ortamda PPV daha düşük olur, neden?
4. Tablo 2.6'ya göre eşik %10'dan %30'a çıkarılırsa duyarlılık ve 100 hastadaki uyarı sayısı nasıl değişir? Klinik sonucu nedir?
5. AUC'si 0,89 olan bir model ortalama %24,3 risk tahmin ederken gerçek olay oranı %9,9'dur. Bu modelin sorunu nedir ve hangi grafikte görülür?
6. **Kısaltma:** PPV ve NPV'nin açılımını yazın. 54/115 ve 750/785 oranları hangi ölçütleri verir; paydaları neden farklıdır?
7. **Kısaltma:** ROC'un açılımı nedir? ROC grafiğinin x ve y eksenlerinde ne vardır?
8. **Kısaltma:** Preeklampside AP 0,21 bulunmuştur. AP'nin açılımı nedir ve rastgele bir modelin AP'si yaklaşık kaçtır? Neden?
9. **Kısaltma:** Model bir hastaya %10 risk verdi ve hastada sepsis gelişmedi. Bu hastanın Brier skoruna katkısı nedir? Model %90 deseydi ne olurdu?
10. **Kısaltma:** Orange Test and Score tablosundaki CA, Prec ve Recall sütunlarının Türkçe karşılıkları nedir?

Cevaplar Ek F'dedir. Önce kendiniz yanıtlamayı deneyin. Kısaltma ve terim soruları için ilgili kartlara ve Ek D'ye bakabilirsiniz.

■ **Bölüm özeti**

- Karışıklık matrisi modelin karnesidir; en tehlikeli hücre yanlış negatif, yani kaçırılan hastadır.
- AUC bir sıralama başarısıdır, doğruluk oranı değildir; eşikten bağımsızdır ve tek başına yeterli değildir.
- PPV prevalansa bağlıdır: aynı model nadir olayda veya düşük riskli serviste çok sayıda yanlış alarm üretir.
- Eşik bir klinik karardır: kaçırmanın bedeli, uyarının maliyeti ve ekip kapasitesi birlikte düşünülür.
- Ayrım ve kalibrasyon farklıdır; AUC aynı kalırken modelin verdiği yüzdeler yanlış olabilir. Karmaşık model her zaman kazanmaz.

Ali AKDAĞLI

Bölüm 3. “Neden bu hasta?” Açıklanabilirlik ve vakalar

Oturum 3 · 3 saat. Bir model “bu hastanın sepsis riski %68” dediğinde, bir hemşirenin ilk sorusu “neden?” olacaktır. Bu bölümde modellerin kararlarını açıklayan araçları, özellikle **SHAP** grafiklerini okumayı öğreneceğiz. Ardından dört klinik vaka ve bir gerçek veri seti üzerinde bu becerileri uygulayacağız.

■ Öğrenme hedefleri

Bu bölümü tamamladığınızda şunları yapabileceksiniz:

1. Global (modelin geneli) ve yerel (tek hasta) açıklamayı ayırt eder.
2. SHAP özet (arı kovanı), şelale ve bağımlılık grafiklerini yorumlar.
3. Bir açıklamanın nedensellik anlamına gelmediğini bilir ve klinik karar ile model açıklamasını ayırır.
4. Sepsis, diyabetik ayak, malnütrisyon ve preeklampsi vakalarında model çıktısını eleştirel okur.

3.1 Kara kutu sorunu

Lojistik regresyon ya da küçük bir karar ağacı kendini açıklar: katsayılara ya da dallara bakarak modelin neye dayandığını görebilirsiniz. Random Forest ve XGBoost ise yüzlerce ağacın birleşiminden oluşur ve tek tek incelenemez. Bu modellere **kara kutu** (black box) denir. Klinik ortamda kara kutu ciddi bir sorundur: gerekçesi görünmeyen bir uyarıya ne hemşire ne hekim ne de hasta güvenir. Açıklanabilir yapay zekâ (explainable AI, XAI) araçları bu kutunun içine pencere açmaya çalışır.

■ Klinik Köşe: “Neden?” sorusu bir meslek refleksidir

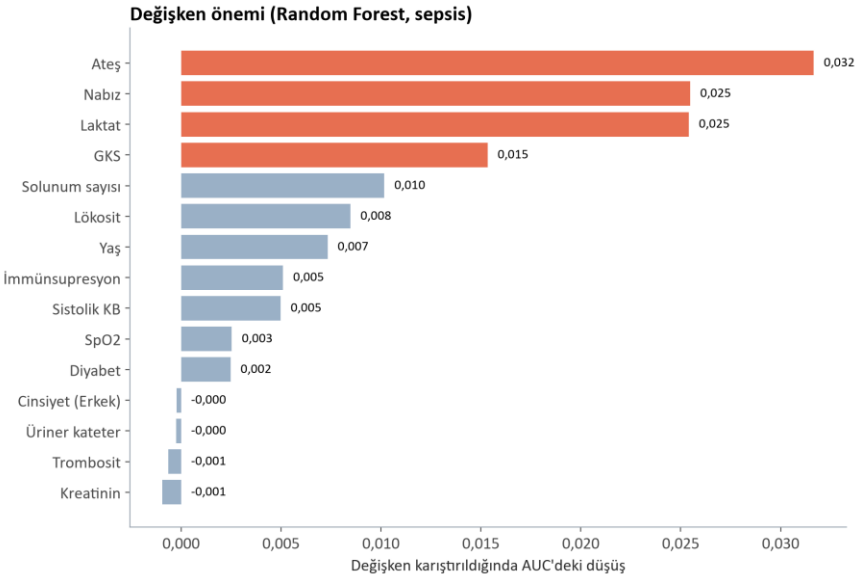
Deneyimli bir hemşire, monitörden gelen her alarma koşmaz; önce “neden ötüyor?” diye bakar: elektrot mu düştü, hasta mı hareket etti, yoksa gerçek bir aritmi mi var? Model uyarıları için de aynı tutum geçerlidir. Hemşire “neden?” diye sormadan alarma güvenmez, **güvenmemelidir de**. Açıklama, uyarıyı klinik tabloyla karşılaştırmanızı sağlar.

Tablo 3.1. Global ve yerel açıklama

	Global açıklama	Yerel açıklama
Sorduğu soru	Model genel olarak hangi değişkenlere bakıyor?	Model **bu hasta** için neden bu riski verdi?
Araçlar	Permütasyon önemi (Şekil 3.1), SHAP özet grafiği (Şekil 3.2), bağımlılık grafiği (Şekil 3.4)	SHAP şelale grafiği (Şekil 3.3), klinik ekran (Şekil 3.5)
Kim kullanır?	Araştırmacı, model geliştirici, kalite birimi, eğitimci	Başucundaki hemşire, ebe, hekim
Klinik benzetme	Bir servisin yıllık düşme raporu: düşmelerin en sık nedenleri	Tek bir hastanın düşme sonrası olay analizi

3.2 Değişken önemi: model genelde neye bakıyor?

En basit global açıklama **permütasyon önemidir** (permutation importance). Mantığı şöyledir: bir değişkenin değerleri hastalar arasında rastgele karıştırılır ve modelin performansının ne kadar düştüğüne bakılır. Performans çok düşüyorsa model o değişkene çok güveniyordur. Şekil 3.1, sepsis verisinde Random Forest modeli için ilk sıraları gösterir: **ateş, nabız, laktat, GKS, solunum sayısı ve lökosit**.



Şekil 3.1. *Permütasyon önemi (Random Forest, sepsis): bir değişken karıştırıldığında performans ne kadar düşüyor?*

■ Benzetme: Ekipten birini çıkarmak

Bir ameliyat ekibinden bir kişiyi çıkarıp yerine rastgele birini koyduğunuzu düşünün. Ameliyat aksıyorsa o kişi kritiktir. Hiçbir şey değişmiyorsa ya o kişinin rolü küçüktür ya da başka bir ekip üyesi onun işini zaten üstlenmektedir. Permütasyon önemi tam olarak bunu yapar.

■ Dikkat!

Birbiriyle ilişkili (korelasyonlu) değişkenler önemi **paylaşır**. Örneğin nabız ve solunum sayısı birlikte artma eğilimindeyse, biri karıştırıldığında model diğerine yaslanır ve her ikisi de olduğundan önemsiz görünebilir. Bu nedenle "değişken önemi düşükse o değişken klinik olarak önemsizdir" sonucu **çıkarılamaz**.

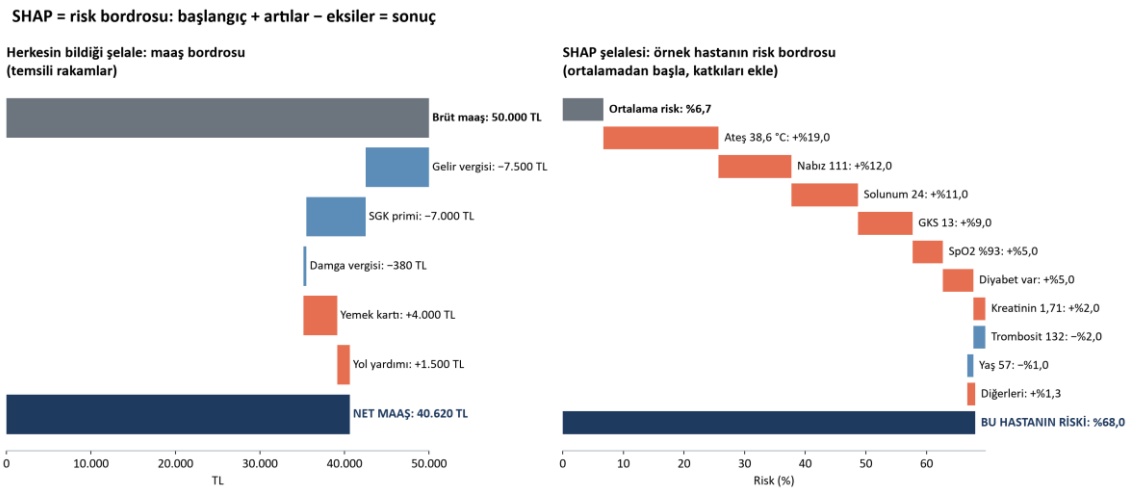
KISALTMA KARTI 27	**Değişken önemi (permütasyon önemi)**
Açılımı	Feature importance = değişken önemi · Permutation importance = permütasyon (karıştırma) önemi · Global explanation = global (genel) açıklama
Türkçesi	Modelin genel olarak hangi bilgiye yaslandığı
Tek cümleyle	**Bir değişkenin değerleri hastalar arasında karıştırılıp anlamsız hâle getirilir; modelin performansı ne kadar düşerse o değişken model için o kadar önemlidir.**
Benzetmeler	1. **Mühendislik:** Bir sensörün kablosunu çekip sistemin ne kadar bozulduğuna bakmak (duyarlılık analizi). 2. **Günlük hayat:** Bir futbolcuyu oyundan alıp takımın ne kadar kötü oynadığına bakmak; ya da yemekten tuzu çıkarıp tadın ne kadar bozulduğuna bakmak. 3. **Klinik:** Ameliyat ekibinden bir kişiyi çıkarıp yerine rastgele birini koymak: ameliyat aksıyorsa o kişi kritiktir.
Bizim verimizden	Random Forest, sepsis: ilk altı değişken **ateş, nabız, laktat, GKS, solunum sayısı, lökosit** (Şekil 3.1).
Sık karışıklık	"Değişken önemi düşükse o değişken klinik olarak önemsizdir." Hayır. İki değişken aynı bilgiyi taşıyorsa (korelasyon) model birine yaslanır, diğeri "önemsiz" görünür. Ayrıca bu "model için önem"dir, "hastalığın nedeni" değildir.
İlgili şekil	Şekil 3.1

3.3 SHAP: riskin faturası

SHAP (SHapley Additive exPlanations), oyun kuramındaki Shapley değerlerine dayanan bir açıklama yöntemidir (Lundberg ve Lee, 2017). Her hasta için şu soruyu yanıtlar: **"Ortalama riskten bu hastanın riskine nasıl gelindi ve her değişken bu yolculuğa ne kadar katkı yaptı?"** Her değişkenin katkısı artı (riski artıran) ya da eksi (riski azaltan) yönde bir sayıdır ve tüm katkıların toplamı, başlangıç riskini modelin bu hasta için verdiği riske taşır.

> ■ **Benzetme: Takım oyununda katkı payı**
>
> Maçı kazanan bir takımda golün ne kadarının forvete, ne kadarının pası veren orta sahaya, ne kadarının topu kazanan defansa ait olduğunu adil biçimde paylaştırmak istersiniz. SHAP da modelin verdiği riski değişkenler arasında adil biçimde paylaştırır. Ya da şöyle düşünün: SHAP, riskin **kalem kalem faturasıdır**. Fatura başlangıç tutarıyla (ortalama risk) açılır, her kalem bir tutar ekler ya da düşer, en altta toplam (modelin riski) yazar.

KISALTMA KARTI 28	**SHAP (SHapley Additive exPlanations) ve şelale grafiği**
Açılımı	SHAP = SHapley Additive exPlanations = Shapley toplamsal açıklamaları · Shapley: oyun kuramında "adil paylaştırma" fikri (Lloyd Shapley, 2012 Nobel ekonomi ödülü) · Waterfall plot = şelale grafiği · E[f(X)] = ortalama tahmin (başlangıç) · f(x) = bu hastanın tahmini
Türkçesi	Tek bir hastanın riskini, her değişkenin katkısına bölen açıklama yöntemi (yerel açıklama)
Tek cümleyle	**SHAP, "bu %68'lik riskin ne kadarı ateşten, ne kadarı nabızdan geldi?" sorusunu yanıtlar: ortalama riskten başlanır, her değişken riski + ya da − yönde iter, katkıların toplamı modelin riskini verir.**
Benzetmeler	1. **Mühendislik:** Hata bütçesi ya da tolerans yığılması: toplam sapma, her bileşenin katkılarının toplamıdır. 2. **Günlük hayat:** Maaş bordrosu: brüt maaştan başlarsınız; vergi (−), SGK (−), yemek kartı (+) eklenip çıkarılır; sonunda net maaş çıkar. SHAP şelalesi bir "risk bordrosu"dur (Şekil A9). Ya da dört arkadaşın 1000 TL'lik restoran hesabını herkesin yediğine göre adil paylaştırmak. 3. **Klinik:** Maçı kazanan takımda golün ne kadarının forvete, ne kadarının pası verene, ne kadarının topu kazanan defansa ait olduğunu adilce paylaştırmak gibi: her bulgunun riske "katkı payı".
Bizim verimizden	Örnek hasta: 57 yaşında erkek; ateş 38,6, nabız 111, solunum 24, GKS 13, SpO2 %93, laktat 1,6. 1. Başlangıç (ortalama risk, E[f(X)]): **%6,7**. 2. Kalemler (yüzde puan): ateş **+19**, nabız **+12**, solunum **+11**, GKS **+9**, SpO2 **+5**, diyabet **+5**, kreatinin **+2**, trombosit **−2**, yaş **−1**, diğerleri ≈ **+1**. 3. Topla: 6,7 + 19 + 12 + 11 + 9 + 5 + 5 + 2 − 2 − 1 + ≈1 ≈ **%68** = modelin riski f(x). ✓
Hafıza kancası	**SHAP bir bordrodur:** ortalamadan başla, katkıları ekle, sonuca var.
Sık karışıklık	SHAP "model neden böyle dedi?" sorusunu yanıtlar; "hastalık neden oldu?" sorusunu **yanıtlamaz**. Termometreyi soğutmak hastayı iyileştirmez (Kart 30).
İlgili şekil	Şekil A9 (aşağıda), Şekil 3.3, Tablo 3.3



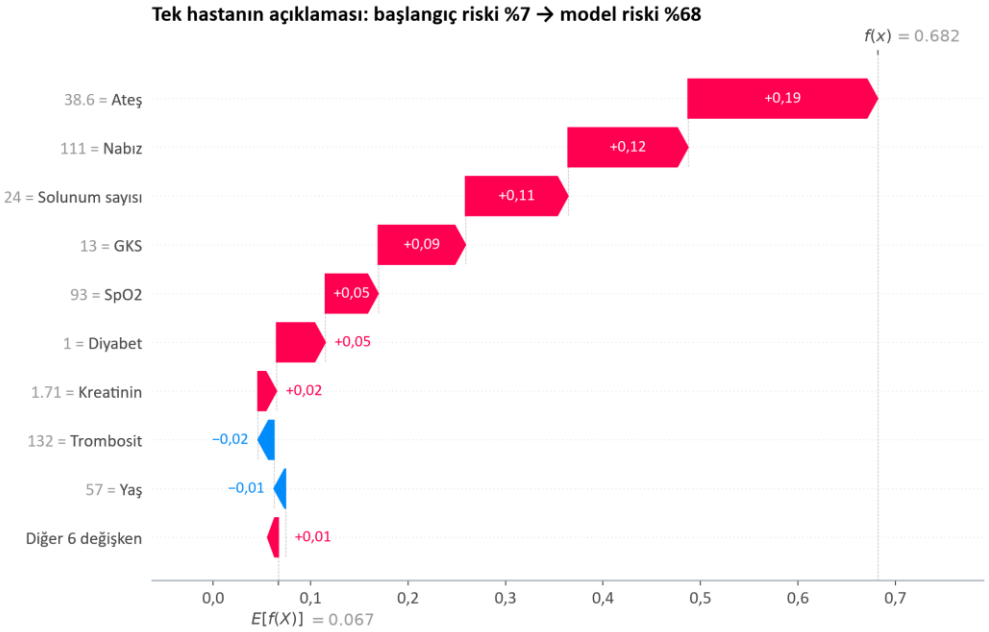
Şekil A9. *SHAP = risk bordrosu. Solda herkesin bildiği maaş bordrosu (temsili rakamlar), sağda örnek hastanın risk bordrosu: başlangıç %6,7, kalemler eklenir, sonuç %68.*

3.3.1 Şelale grafiği: tek hastanın faturası

Şekil 3.3, test grubundan seçilmiş bir örnek hastanın SHAP şelale (waterfall) grafiğidir. Hastanın bilgileri Tablo 3.2'de, değişkenlerin katkıları Tablo 3.3'te verilmiştir.

Tablo 3.2. Örnek hasta: 57 yaşında erkek, dahiliye servisi

Değişken	Değer	Değişken	Değer
Yaş	57	SpO2	%93
Ateş	38,6 °C	GKS	13
Nabız	111 /dk	Laktat	1,6 mmol/L (normal)
Solunum sayısı	24 /dk	Kreatinin	1,71 mg/dL
Sistolik KB	125 mmHg	Trombosit	132 ×10³/µL
Lökosit	6,7 ×10³/µL	Diyabet / üriner kateter	Var / Var



Şekil 3.3. *Örnek hasta için SHAP şelale grafiği: başlangıç riski %6,7'den modelin riski %68'e.*

Tablo 3.3. Örnek hastanın SHAP katkıları (riske etkisi, yüzde puan)

Sıra	Değişken (hastadaki değer)	Katkı	Klinik yorum
—	**Başlangıç: ortalama risk**	%6,7	Hiçbir bilgi yokken, bir servis hastası için modelin beklediği risk
1	Ateş (38,6 °C)	+19	Ateş en büyük artırıcı etken
2	Nabız (111/dk)	+12	Taşikardi
3	Solunum sayısı (24/dk)	+11	Takipne; qSOFA ölçütü
4	GKS (13)	+9	Bilinç değişikliği; qSOFA ölçütü
5	SpO2 (%93)	+5	Hafif düşük oksijen satürasyonu
6	Diyabet (var)	+5	Altta yatan risk etkeni
7	Kreatinin (1,71 mg/dL)	+2	Böbrek işlevinde bozulma
8	Trombosit (132)	−2	Riski hafifçe azaltıyor
9	Yaş (57)	−1	Görece genç yaş riski hafifçe azaltıyor
—	**Modelin riski**	**%68**	Listede olmayan değişkenlerin katkıları çok küçüktür; yuvarlamalarla toplam %68'e ulaşır

Şelale grafiğini okumak için şu adımları izleyin:

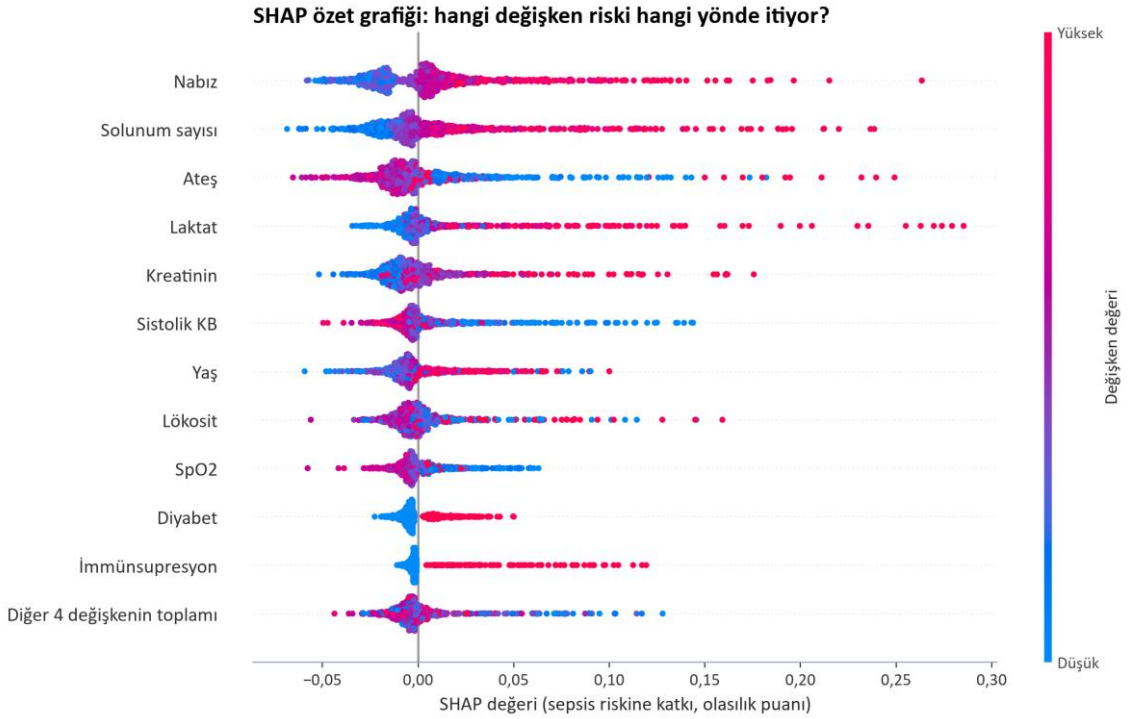
1. **Alttan başlayın:** Grafiğin altındaki E[f(x)] ya da "başlangıç" değeri, ortalama hastanın riskidir (%6,7).
2. **Okları izleyin:** Kırmızı (sağa giden) çubuklar riski artırır, mavi (sola giden) çubuklar riski azaltır. Çubuğun uzunluğu katkının büyüklüğüdür.
3. **Değerleri okuyun:** Her satırın yanında hastanın o değişkendeki değeri yazar (örneğin "Ateş = 38,6"). Katkı, değerin kendisi değil, o değerin riske etkisidir.
4. **Üste varın:** En üstteki f(x) değeri modelin bu hasta için verdiği risktir (%68).
5. **Klinik tabloyla karşılaştırın:** Katkılar hastanın klinik görünümüyle uyumlu mu? Beklenmedik bir değişken öne çıkıyorsa veri hatası ya da model sorunu olabilir.

> ■ **Dikkat! Laktat normal, risk yüksek**
>
> Bu hastanın **laktatı normaldir (1,6 mmol/L)**, buna karşın model %68 risk vermektedir. Ateş, taşikardi, takipne ve bilinç değişikliği birlikte riski yükseltmiştir. Bu tablo, klinikte sık duyulan "laktat normalse sepsis yoktur" yanılgısını tartışmak için iyi bir fırsattır. Tek bir bulguya değil, **bütün tabloya** bakılmalıdır.

3.3.2 Arı kovanı grafiği: bütün hastaların özeti

Şelale grafiği tek bir hastayı anlatır. SHAP özet grafiği ya da **arı kovanı (beeswarm) grafiği** ise test grubundaki bütün hastaların açıklamalarını tek bir resimde toplar (Şekil 3.2).

F. AKDAĞ



Şekil 3.2. *SHAP özet (arı kovanı) grafiği, sepsis: her nokta bir hasta; renk değişkenin değerini, yatay konum riske katkısını gösterir.*

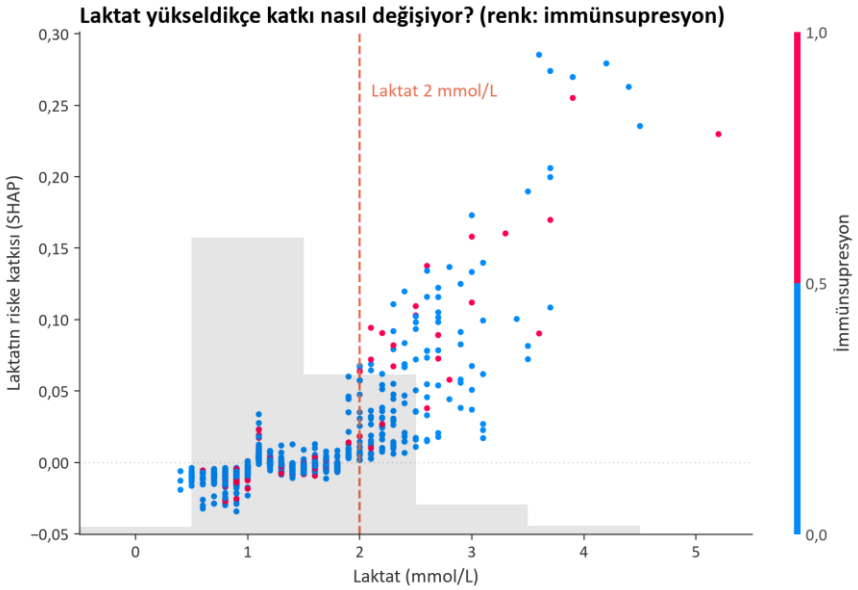
1. **Satırlar:** Değişkenler yukarıdan aşağıya ortalama etkilerine göre sıralanmıştır. En üstteki, model için en etkili değişkendir.
2. **Noktalar:** Her nokta bir hastadır. Noktalar üst üste geldiğinde dikey olarak yayılır; kalın bölgeler çok sayıda hastayı gösterir.
3. **Yatay konum:** Sıfırın sağındaki noktalar o hastada riski artıran, solundakiler riski azaltan katkılardır.
4. **Renk:** Kırmızı o değişkenin yüksek değerini, mavi düşük değerini gösterir.
5. **Örüntüyü okuyun:** Nabız satırında kırmızı noktalar sağdaysa, "yüksek nabız riski artırıyor" denir. Sistolik KB satırında ise **mavi** (düşük) noktalar sağdadır: düşük kan basıncı riski artırır.
6. **Klinik bilgiyle karşılaştırın:** Yön beklediğiniz gibi mi? Beklenmedik bir yön, veri sorununa ya da karıştırıcı bir etkene işaret edebilir.

KISALTMA KARTI 29	**SHAP arı kovanı (beeswarm) ve bağımlılık grafiği okuma**
Açılımı	Beeswarm plot = arı kovanı grafiği · Summary plot = özet grafik · Dependence plot = bağımlılık grafiği · Force plot = kuvvet grafiği (Orange'ın Explain Prediction penceresi) · |SHAP| = SHAP değerinin mutlak büyüklüğü
Türkçesi	Bütün hastaların SHAP katkılarını tek resimde gösteren grafik
Tek cümleyle	**Arı kovanı grafiğinde her satır bir değişken, her nokta bir hastadır; noktanın sağda olması o hastada riski artırdığını, rengi değişkenin değerini (kırmızı yüksek, mavi düşük) gösterir.**
Benzetmeler	1. **Mühendislik:** Her sensör için bir saçılım şeridi: sensör okuması yüksek (kırmızı) olduğunda çıkışı hangi yöne itiyor? Bir tür toplu duyarlılık haritası. 2. **Günlük hayat:** Seçim haritası: her ilçe bir nokta, renk partiyi, konum oy farkını gösterir; hangi bölgenin hangi yöne çektiği tek bakışta görülür. 3. **Klinik:** Bir servisin yıllık düşme raporu: hangi risk etkeni, hangi değerde, düşmeyi hangi yöne itiyor?

Bizim verimizden	**Dört okuma kuralı:** 1. Satırlar yukarıdan aşağı genel önem sırasına göre dizilir. 2. Her nokta bir hasta. Sağa = riski artırdı; sola = azalttı; ortadaki dikey çizgi = etkisiz. 3. Renk = o değişkenin o hastadaki değeri: kırmızı yüksek, mavi düşük. 4. Satırı cümleye çevirin: "Nabız satırında kırmızılar sağda → yüksek nabız riski artırıyor." "Sistolik KB satırında maviler sağda → düşük tansiyon riski artırıyor." "GKS satırında kırmızılar solda → GKS 15 (iyi) riski azaltıyor." **Bağımlılık grafiği** (Şekil 3.4): yatayda laktat değeri, dikeyde SHAP katkısı. Laktat **2 mmol/L**'yi geçince katkı belirgin artıyor; Sepsis-3'teki "laktat >2" eşiğiyle uyumlu. Model bu eşiği kendisi bulmuş.
Sık karışıklık	Renk ile konumu karıştırmak. Renk = değerin kendisi (yüksek/düşük); konum = riske etkisi (artırdı/azalttı). "Kırmızı = kötü" değildir: GKS'de kırmızı (yüksek puan) iyidir.
İlgili şekil	Şekil 3.2, Şekil 3.4

3.3.3 Bağımlılık grafiği: model eşiği kendisi buldu mu?

SHAP bağımlılık (dependence) grafiği tek bir değişkene odaklanır: x ekseninde değişkenin değeri, y ekseninde o değerin riske katkısı yer alır. Şekil 3.4'te laktatın katkısı görülüyor. Laktat **2 mmol/L'nin üzerine çıktığında katkı belirgin şekilde artar**. Bu, Sepsis-3 tanımındaki laktat >2 mmol/L ölçütüyle uyumludur (Singer ve ark., 2016). Modele hiç kimse "2'ye dikkat et" dememişti; **kuralı veriden kendisi bulmuştur**.



Şekil 3.4. *Laktatın SHAP bağımlılık grafiği: 2 mmol/L üzerinde riske katkı belirgin biçimde artıyor.*

Tablo 3.4. Üç SHAP grafiğini okuma rehberi

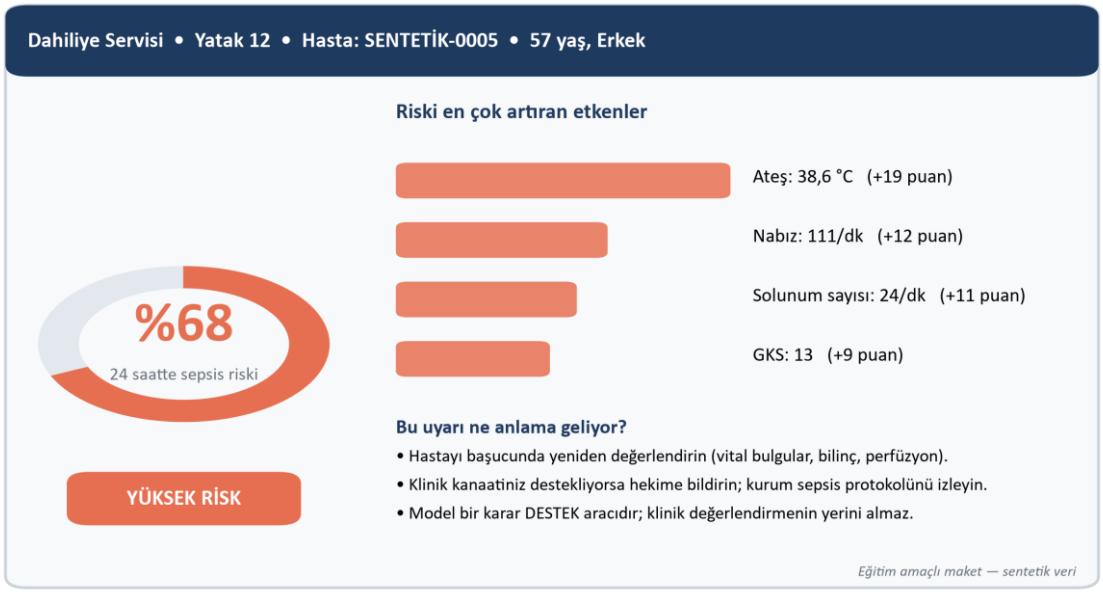
Grafik	Ne gösterir?	Nasıl okunur?	Sorulacak klinik soru
Şelale (waterfall)	Tek hastanın riskinin kalem kalem dökümü	Başlangıç riskten başla, kırmızı oklar artırır, mavi oklar azaltır, en üstte modelin riski	Bu hastadaki etkenler klinik tabloyla uyumlu mu?
Arı kovanı (beeswarm)	Tüm hastalarda değişkenlerin etkisi ve yönü	Üstteki değişken en etkili; kırmızı = yüksek değer, sağ = riski artırır	Etki yönleri fizyolojiyle tutarlı mı?
Bağımlılık (dependence)	Tek bir değişkenin değeri ile katkısı arasındaki ilişki	Eğrinin kırıldığı yerler modelin "eşikleri"dir	Model klinik eşikleri (ör. laktat >2) yakalamış mı?
Ortalama |SHAP| çubuk grafiği	Değişkenlerin ortalama etki büyüklüğü (yönsüz)	Uzun çubuk = model o değişkene çok dayanıyor	Önde gelen değişkenler klinik rehberlerle örtüşüyor mu?

> ■ **Dikkat! Açıklama nedensellik değildir**
>
> SHAP **"model neden böyle dedi?"** sorusunu yanıtlar; **"hastalık neden oldu?"** sorusunu yanıtlamaz. Örneğin ateş SHAP grafiğinde en önemli değişken olabilir, ama bu "ateşi düşürürsek sepsis riski azalır" anlamına gelmez. Ateş, altta yatan enfeksiyonun bir **belirtisidir**. İlişki nedensellik değildir. Müdahale kararı her zaman klinik bilgiyle verilir.

KISALTMA KARTI 30	**İlişki ≠ nedensellik; karıştırıcı (confounder)**
Açılımı	Correlation = ilişki (korelasyon) · Causation = nedensellik · Confounder = karıştırıcı değişken
Türkçesi	Birlikte görülmek, birinin diğerine yol açtığı anlamına gelmez
Tek cümleyle	**Model ve SHAP ilişkileri gösterir; "X'i değiştirirsek sonuç değişir" demek nedensellik iddiasıdır ve bunu ancak uygun bir tasarım (ör. randomize kontrollü çalışma) gösterebilir.**
Benzetmeler	1. **Mühendislik:** İki sensör aynı anda yükseliyor diye birinin diğerini sürdüğünü sanmak; oysa ikisi de aynı ısı kaynağından etkileniyor olabilir. 2. **Günlük hayat:** Yazın dondurma satışları ve boğulmalar birlikte artar; dondurma boğulmaya neden olmaz. İkisinin ortak nedeni (karıştırıcı) sıcak havadır. 3. **Klinik:** Termometreyi buzlu suya sokmak hastanın ateşini düşürmez; sadece göstergeyi değiştirir. SHAP'ta ateşin yüksek katkısı da "ateşi düşürün" demek değildir.
Bizim verimizden	Sepsis: "SHAP'ta ateş en önemli → antipiretik verirsek risk azalır" **yanlış** çıkarımdır. Ateşi düşürmek skoru düşürür, sepsisi tedavi etmez; üstelik modelin riski olduğundan düşük göstermesine yol açabilir. Diyabetik ayak: "ayak bakım eğitimi aldı" koruyucu çıktı; ama eğitim alanlar zaten kendine daha iyi bakan, daha uyumlu hastalar olabilir (karıştırıcı).
Sık karışıklık	"SHAP'ta X en önemli çıktı, X'i değiştirirsek sonuç değişir." Bu cümlede gizli bir nedensellik iddiası vardır.

3.4 İyi bir karar destek ekranı neye benzer?

Açıklamanın klinik değeri, başucundaki ekranda nasıl sunulduğuna bağlıdır. Şekil 3.5, örnek hastamız için tasarlanmış bir karar destek ekranı maketidir.



Şekil 3.5. *Klinik karar destek ekranı maketi: risk %68 (YÜKSEK), ana etkenler ve önerilen eylem (eğitim amaçlı, sentetik veri).*

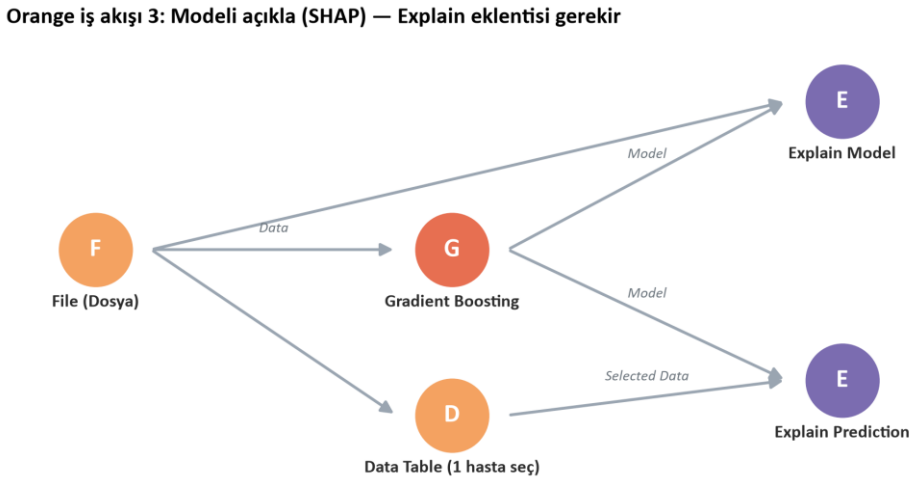
İyi tasarlanmış bir ekranda şu öğeler bulunur:

- **Risk ve kategorisi:** Hem sayı (%68) hem de anlaşılır bir kategori (YÜKSEK).
- **Riski artıran ana etkenler:** Hastanın kendi değerleriyle birlikte, en fazla 3–5 madde.
- **Önerilen eylem:** "Hastayı başucunda yeniden değerlendirin; klinik kanaatiniz destekliyorsa hekime bildirin; kurum protokolünü izleyin."
- **Sınırlılık uyarısı:** "Bu bir karar destek aracıdır; klinik değerlendirmenin yerini almaz."
- **Zaman bilgisi:** Riskin hangi verilerle ve ne zaman hesaplandığı.

> ■ **Klinik Köşe: Uyarı + açıklama + eylem**
>
> Bir uyarının yanında eylem önerisi yoksa, uyarı hemşireye yalnızca kaygı ve iş yükü getirir. Ekranda "ne yapmalıyım?" sorusunun yanıtı bulunmalıdır. Bu yanıt, kurumun mevcut protokolleriyle (sepsis paketi, hızlı yanıt ekibi çağırma ölçütleri) uyumlu olmalıdır.

3.5 Orange uygulaması: Explain eklentisi

Orange'da SHAP grafikleri **Explain** eklentisiyle üretilir. Eklentinin kurulumu Ek A'da anlatılmıştır. Bu oturumdaki iş akışı Şekil 3.10'da görülüyor.



Şekil 3.10. *Oturum 3 Orange iş akışı: Gradient Boosting → Explain Model (SHAP özeti) ve Data Table → Explain Prediction (tek hasta).*

Orange'da Adım Adım

1. **Options → Add-ons** menüsünü açın, listeden **Explain** eklentisini işaretleyin ve **OK** düğmesine basın. Kurulum bitince Orange'ı yeniden başlatın.
2. **File** ile *sepsis_sentetik.csv* dosyasını açın.
3. **Gradient Boosting** widget'ını ekleyin ve **File**'a bağlayın.
4. **Explain** grubundan **Explain Model** ekleyin. **File**'ı (veri) ve **Gradient Boosting**'i (model) **Explain Model**'e bağlayın. **Target class** olarak *Evet*'i seçin ve arı kovanı grafiğini inceleyin.
5. **Data Table** ekleyin ve **File**'a bağlayın. Tabloda tek bir hasta satırına tıklayarak seçin.
6. **Explain Prediction** ekleyin. **Gradient Boosting**'i (model), **File**'ı (arka plan verisi) ve **Data Table**'ın seçili satır çıkışını (**Selected Data**) bağlayın.
7. Grafikte kırmızı (riski artıran) ve mavi (riski azaltan) katkıları okuyun. Başka bir hasta seçerek grafiğin nasıl değiştiğini izleyin.
8. Grubunuzun vakasına ait veri setiyle (ayak, malnütrisyon, preeklampsi ya da Pima) adımları tekrarlayın.

Bağlantı kurarken Orange hangi çıkışın hangi girişe gideceğini sorarsa, bağlantı çizgisine çift tıklayarak düzenleyebilirsiniz.

3.6 Vakalar

Oturumun son saatinde dört grup oluşturulur; her grup bir veri seti ve bir SHAP grafiği alır. Pima diyabet verisi ek bir tartışma vakası olarak sunulur. Tablo 3.5 vakaları özetler.

Tablo 3.5. Vakalara genel bakış: SHAP'a göre ilk beş değişken ve klinik karşılığı

Vaka (alan)	Prevalans	SHAP'a göre ilk beş değişken	Klinik rehber karşılığı
Sepsis (hemşirelik)	%9,9	Ateş, nabız, solunum sayısı, GKS, SpO2 (örnek hastada)	Sepsis-3, qSOFA
Diyabetik ayak (hemşirelik/podiatri)	%12	Nöropati (monofilament), ABİ, Ayak deformitesi, Önceki ülser, Diyabet süresi (yıl)	IWGDF risk sınıflaması
Malnütrisyon (beslenme/hemşirelik)	%27,7	Kilo kaybı 3 ay (%), BKİ, Besin alımı azalması, Baldır çevresi (cm), Barthel indeksi	GLIM, NRS-2002
Preeklampsi (ebelik)	%5,5	OAB (mmHg), PlGF (MoM), Uterin arter PI (MoM), BKİ, Nullipar	İlk trimester tarama algoritmaları, ASPRE
Pima diyabet (gerçek veri)	%34,9	Glukoz (OGTT 2. saat), BKİ, Aile öyküsü skoru, Yaş, Gebelik sayısı	Genellenebilirlik tartışması

Vaka 1. Sepsis: laktat normal, risk yüksek (hemşirelik)

■ Bu kelimeler ne demek? · Sepsis vakası

Sepsis veri setinin sütunları Bölüm 1.3.1'de açıklandı. Bu vakada ek olarak yatak başı skorlar ve bildirim terimleri geçer.

qSOFA (quick Sequential Organ Failure Assessment)	
Ne?	Hızlı ardışık organ yetmezliği değerlendirmesi: yatak başında, laboratuvarsız 3 soru. 1. Solunum sayısı ≥22 /dk mı? 2. Sistolik KB ≤100 mmHg mi? 3. Bilinç değişikliği var mı (GKS <15)? Her "evet" 1 puandır; **2 ve üzeri yüksek risk** (Seymour ve ark., 2016).
Normal değer	0–3 puan; ≥2 pozitif
Model için neden önemli?	İnsanın yazdığı kural tabanlı bir alarmdır; makine öğrenmesi modelleriyle sık karşılaştırılır.
Benzetme	Arabada üç uyarı lambasından ikisi yanıyorsa servise git.
Bu eğitimde	**Örnek hasta:** SS 24 → 1 · SKB 125 → 0 · GKS 13 → 1 · **toplam 2 → qSOFA pozitif.** Model de %68 diyor: ikisi uyumlu (Tablo 3.6).

NEWS2 (National Early Warning Score 2) ve SIRS	
Ne?	**NEWS2:** İngiltere Ulusal Erken Uyarı Skoru, 2. sürüm; vital bulgulara puan verip toplam puana göre izlem sıklığı ve yanıt düzeyi belirler. **SIRS:** ateş/hipotermi, taşikardi, takipne ve anormal lökosite dayanan eski bir sistemik inflamatuvar yanıt tanımı.
Model için neden önemli?	İkisi de kural tabanlıdır. Modelimizin önde gelen değişkenleri (ateş, nabız, solunum, lökosit) SIRS bulgularıyla örtüşür.
Benzetme	Vardiya kontrol listesi: her göstergeye puan, toplam puana göre müdahale seviyesi.
Bu eğitimde	Tablo 1.1 (kural tabanlı KDS örnekleri); Bölüm 4.9 (tasarım c: NEWS2 ile ML karşılaştırması).

Terim	Ne demek?	Benzetme / not	Bu eğitimde
Sepsis-3 (2016)	Sepsisin güncel uluslararası tanımı (Singer ve ark., 2016); "laktat >2 mmol/L" ölçütü buradan.	Standardın son revizyonu.	Şekil 3.4
SBAR	Situation–Background–Assessment–Recommendation: Durum–Öykü–Değerlendirme–Öneri biçiminde yapılandırılmış bildirim.	Arıza bildirim şablonu.	Uyarıdan sonra hekime bildirim
Antipiretik	Ateş düşürücü ilaç (ör. parasetamol).	Göstergeyi soğutmak.	Kart 30 (nedensellik)
Perfüzyon	Dokuların kanla beslenmesi.	Fabrika bölümlerine hammadde akışı.	Laktat
Komorbidite	Eşlik eden başka hastalık (ör. diyabet).	Aynı makinedeki ikinci arıza.	Değişken "Diyabet"
Mortalite / morbidite	Ölüm oranı / hastalık ve komplikasyon oranı.	Toplam kayıp / arıza oranı.	TREWS
Hızlı yanıt ekibi	Kötüleşen servis hastasına çağrılan uzman ekip.	Acil müdahale timi.	Uyarı + eylem

■ Senaryo

Dahiliye servisinde yatan 57 yaşındaki erkek hasta diyabetiktir ve üriner kateteri vardır. Gece 02.00 vital bulgu ölçümünde ateş 38,6 °C, nabız 111/dk, solunum sayısı 24/dk, sistolik KB 125 mmHg, SpO2 %93'tür. Hasta uykuludur ve GKS 13'tür. Laktat 1,6 mmol/L, lökosit 6,7 ×10³/µL, kreatinin 1,71 mg/dL'dir. Sepsis tahmin modeli **%68 risk (YÜKSEK)** uyarısı vermiştir (Şekil 3.3 ve 3.5).

Modelin uyarısını, klinikte kullandığımız qSOFA skoruyla karşılaştıralım (Seymour ve ark., 2016).

Tablo 3.6. Örnek hastanın qSOFA hesabı

qSOFA ölçütü	Puan alma koşulu	Hastanın değeri	Puan
Solunum sayısı	≥ 22 /dk	24 /dk	1
Sistolik kan basıncı	≤ 100 mmHg	125 mmHg	0
Bilinç değişikliği	GKS < 15	GKS 13	1
Toplam	≥ 2 ise pozitif		**2 → pozitif**

Hem model hem de qSOFA bu hastayı riskli bulmaktadır; iki araç **uyumludur**. Modelin ek katkısı, ateş, nabız, SpO2, diyabet ve kreatinin gibi qSOFA'da yer almayan bilgileri de hesaba katması ve hangi etkenin ne kadar katkı yaptığını göstermesidir. Laktatın normal olması ise sepsisi dışlamaz.

■ Klinik Köşe: TREWS çalışması

TREWS adlı makine öğrenmesi tabanlı sepsis erken uyarı sisteminin çok merkezli prospektif çalışmasında, uyarı 3 saat içinde bir klinisyen tarafından değerlendirilip onaylandığında hastane mortalitesinde düzeltilmiş mutlak **%3,3**'lük bir azalma bulunmuştur (Adams ve ark., 2022). Buradaki kritik nokta, faydanın modelin kendisinden değil, **uyarıya zamanında verilen klinik yanıttan** gelmesidir. Modelin değeri, onu kullanan ekibin eylemiyle ortaya çıkar.

■ Tartışma soruları

1. qSOFA'ya göre bu hasta pozitif midir? Model ile skor uyumlu mu?
2. Laktatın normal olması sizi rahatlatır mı? Neden?
3. Bu uyarıdan sonra ilk 30 dakikada hemşirelik eylemleriniz neler olur?
4. Model aynı hasta için %15 risk verseydi, klinik kanaatiniz farklıysa ne yapardınız?

Vaka 2. Diyabetik ayak ülseri (hemşirelik/podiatri)

■ Bu kelimeler ne demek? · Diyabetik ayak veri seti (diyabetik_ayak_sentetik.csv)

Diyabetli hastada ayağı iki şey tehdit eder: **sinirler** bozulur (ayak acıyı hissetmez) ve **damarlar** daralır (yara iyileşmez). 2000 hasta; hedef "Ülser (12 ay)", prevalans %12. Birim ve aralıklar Ek B.3'tedir.

Diyabetik ayak ülseri	
Ne?	Diyabetli bireyin ayağında gelişen, kendiliğinden iyileşmeyen açık yara; çoğunlukla nöropati ve/veya periferik arter hastalığı zemininde gelişir.
Model için neden önemli?	Enfeksiyon ve ampütasyona kadar gidebilir; büyük bölümü önlenebilir.
Benzetme	Arabanın lastiğinde fark edilmeyen bir çivi: yavaş yavaş havası iner, fark ettiğinizde jant yere değmiştir.
Bu eğitimde	Diyabetik ayak verisi: 2000 hasta, hedef "Ülser (12 ay)", prevalans %12.

Nöropati ve monofilament testi	
Ne?	**Periferik nöropati:** yüksek glukozun sinirlere zarar vermesi; koruyucu duyu kaybolur. **Monofilament testi:** 10 g'lık naylon monofilamentle ayak tabanının belirli noktalarına dokunulur; hissedilmiyorsa koruyucu duyu kaybı vardır.
Normal değer	Verimizde "Hissediyor / Hissetmiyor"
Model için neden önemli?	Ülser riskinin en güçlü belirleyicisidir.
Benzetme	Sensör kablosu kopmuş: hasar var ama alarm gelmiyor. Monofilament, kablonun sağlam olup olmadığını kontrol eden süreklilik testidir.
Bu eğitimde	"Monofilament": SHAP'ta 1. sıra (Şekil 3.6).

ABİ (ayak bileği-kol indeksi; ABI)	
Ne?	Ayak bileği sistolik basıncının kol sistolik basıncına oranı.
Normal değer	0,9–1,3 normal · <0,9 periferik arter hastalığı · >1,3 damar sertliği (diyabette yanıltıcı yüksek değer)
Model için neden önemli?	Ayağa yeterli kan gitmezse yara iyileşmez.
Benzetme	Aynı pompaya bağlı iki musluk: uzaktakinin basıncı belirgin düşükse aradaki boru daralmış demektir.
Bu eğitimde	"ABİ": SHAP'ta 2. sıra.

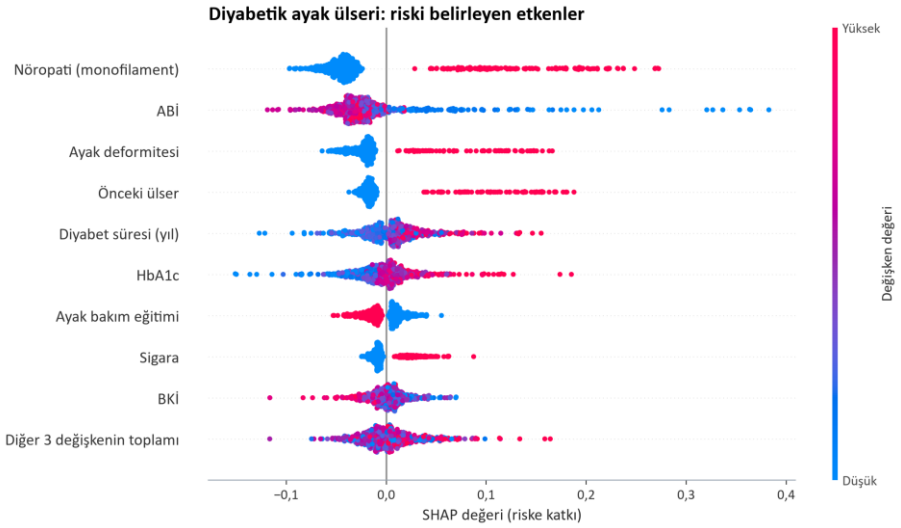
HbA1c (glikozile hemoglobin, "üç aylık şeker")	
Ne?	Glukozun hemoglobine bağlanmış oranı; eritrosit ömrü ~3 ay olduğundan son 2–3 ayın ortalama glisemisini yansıtır.
Normal değer	<%5,7 normal · %5,7–6,4 prediyabet · ≥%6,5 diyabet; tedavide çoğu hastada hedef <%7
Model için neden önemli?	Tek ölçümün dalgalanmasından etkilenmez; uzun dönem kontrolü gösterir.
Benzetme	Anlık glukoz hız göstergesidir, HbA1c son 3 ayın ortalama hızıdır. Ya da: glukoz bugünkü hava sıcaklığı, HbA1c mevsimin ortalaması.
Bu eğitimde	Diyabetik ayak verisinde "HbA1c".

eGFR (tahmini glomerüler filtrasyon hızı)	
Ne?	Böbreklerin dakikada süzdüğü plazma miktarının kreatinin, yaş ve cinsiyetten formülle tahmini (mL/dk/1,73 m²).
Normal değer	≥90 normal; <60 (3 aydan uzun) kronik böbrek hastalığını düşündürür
Model için neden önemli?	Diyabetin böbrek etkisini (nefropati) yansıtır; ayak ülseri riskiyle ilişkilidir.
Benzetme	Kreatinin "suyun kir ölçümü" ise eGFR "filtrenin debisidir".
Bu eğitimde	Diyabetik ayak verisinde "eGFR".

Terim	Ne demek?	Benzetme / not	Bu eğitimde
Wagner evresi (0–5)	Diyabetik ayak yarasının derinlik sınıflaması: 1 yüzeysel, 2 tendon/kapsüle uzanan, 3 kemik/apse, 4–5 kangren.	Hasar derecelendirme ölçeği.	Arka plan
Ayak deformitesi	Çekiç parmak, halluks valgus, Charcot ayağı gibi şekil bozuklukları; basınç noktası oluşturur.	Gerilme yığılması yaratan geometri.	SHAP 3. sıra
Önceki ülser	Daha önce ayak ülseri geçirmiş olmak; en güçlü yineleme risk etkenlerinden.	Daha önce arıza yapmış parça.	SHAP 4. sıra
Diyabet süresi	Tanıdan bu yana geçen yıl.	Sistemin çalışma saati.	SHAP 5. sıra
Periferik arter hastalığı (PAH)	Alt ekstremite arterlerinin daralması.	Tıkalı boru.	ABİ
Offloading	Yaralı bölgeden yükün alınması (özel ayakkabı, total kontakt alçı).	Gerilme yığılmasını gidermek.	Arka plan
IWGDF	International Working Group on the Diabetic Foot: risk sınıflaması ve rehber yayımlar (Schaper ve ark., 2024).	Sektör standardı kuruluşu.	Vaka 2
Ayak bakım eğitimi	Hastaya günlük ayak muayenesi, uygun ayakkabı ve bakımın öğretilmesi.	Kullanıcı eğitimi.	SHAP negatif (koruyucu görünüyor)
Podiatri	Ayak sağlığı ve hastalıklarıyla ilgilenen alan.	Ayak servisi.	Vaka 2

■ Senaryo

Diyabet polikliniğinde izlenen hastalar için 12 ay içinde ayak ülseri gelişme riskini tahmin eden bir model geliştirildi (prevalans %12). Değişkenler: monofilament testi (nöropati), ayak bileği-kol indeksi (ABİ), önceki ülser, ayak deformitesi, HbA1c, diyabet süresi, sigara, ayak bakım eğitimi, eGFR ve görme bozukluğu.



Şekil 3.6. *Diyabetik ayak ülseri: SHAP özet grafiği (XGBoost).*

Modelin ilk sıralarında **nöropati (monofilament), ABİ, ayak deformitesi, önceki ülser ve diyabet süresi** yer alır. Bu değişkenler Uluslararası Diyabetik Ayak Çalışma Grubu'nun (IWGDF) risk sınıflamasında kullanılan temel ögelerle örtüşür (Schaper ve ark., 2024). Dikkat çekici bir bulgu daha vardır: **ayak bakım eğitimi** almış hastalarda SHAP değerleri negatiftir, yani eğitim modelde **koruyucu** görünür. Bu, hemşirelik müdahalesinin bir tahmin modelinde görünür hâle gelmesidir.

■ Dikkat! Koruyucu görünmek, koruyucu olmak değildir

Ayak bakım eğitiminin koruyucu çıkması, "eğitim ülseri önler" şeklinde nedensel bir sonuç olarak yorumlanamaz. Eğitim alan hastalar, zaten sağlık hizmetine daha düzenli başvuran, öz bakımı daha iyi, tedaviye daha uyumlu hastalar olabilir. Bu durumda eğitim ile düşük risk arasındaki ilişkiyi bir **karıştırıcı etken** (uyum) açıklar. Eğitimin etkisini kanıtlamak için randomize kontrollü bir çalışma gerekir.

■ Tartışma soruları

1. Modelin ilk beş değişkeni IWGDF risk sınıflamasıyla ne ölçüde örtüşüyor?
2. Ayak bakım eğitiminin koruyucu görünmesini hangi karıştırıcı etkenler açıklayabilir?
3. Bu model poliklinikte hangi hastaların daha sık ayak muayenesine çağrılmasında kullanılabilir?
4. Bu bulgu üzerine nasıl bir hemşirelik araştırması tasarlardınız?

Vaka 3. Malnütrisyon (beslenme ve diyetetik/hemşirelik)

■ Bu kelimeler ne demek? · Malnütrisyon veri seti (malnutrisyon_sentetik.csv)

65 yaş ve üzeri 1500 yatan hasta; hedef "Malnütrisyon (GLIM)", prevalans %27,7. Birim ve aralıklar Ek B.4'tedir.

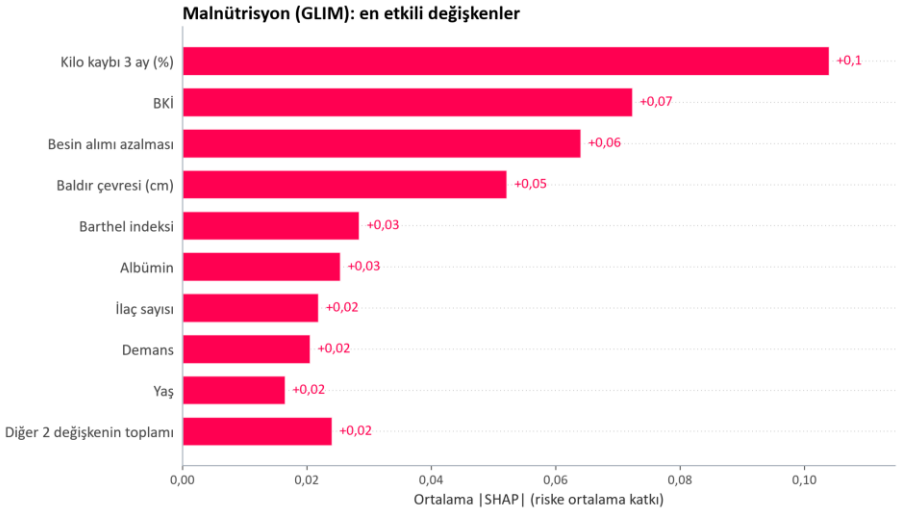
Malnütrisyon ve GLIM ölçütleri	
Ne?	**Malnütrisyon:** enerji ve besin ögesi alımının gereksinimi karşılamaması (ya da dengesizliği) sonucu vücut bileşimi ve işlevinin bozulması. **GLIM** (Global Leadership Initiative on Malnutrition): tanı için en az bir **fenotipik** ölçüt (istemsiz kilo kaybı, düşük BKİ, kas kütlesinde azalma) ile en az bir **etiyolojik** ölçütün (besin alımında azalma/emilim bozukluğu, hastalık yükü/inflamasyon) birlikte bulunması.
Model için neden önemli?	Tanının standart olması, modelin hedef değişkeninin tutarlı olması demektir.
Benzetme	Fenotipik = arızanın belirtisi (ses, titreşim); etiyolojik = arızanın nedeni (yağ eksikliği). Tanı için ikisinden de kanıt aranır.
Bu eğitimde	Malnütrisyon verisi: 1500 hasta (≥65 yaş), hedef "Malnütrisyon (GLIM)", prevalans %27,7 (Cederholm ve ark., 2019).

Albümin	
Ne?	Karaciğerde üretilen, plazmanın ana proteini.
Normal değer	Yaklaşık 3,5–5,0 g/dL
Model için neden önemli?	Eskiden beslenme göstergesi sayılırdı; bugün daha çok inflamasyonun (negatif akut faz) göstergesi olduğu biliniyor. Modelde geride kalması bununla uyumludur.
Benzetme	Yakıt göstergesi sandığınız lambanın aslında motor ısısını göstermesi.
Bu eğitimde	"Albümin" sütunu; SHAP sıralamasında geride (Vaka 3).

Terim	Ne demek?	Benzetme / not	Bu eğitimde
Kilo kaybı (3 ay, %)	Son 3 ayda istemsiz vücut ağırlığı kaybı yüzdesi (GLIM fenotipik ölçütü).	Depodaki stokun erimesi.	SHAP 1. sıra
Besin alımı azalması	Gereksinimin belirgin altında besin alımı (GLIM etiyolojik ölçütü).	Hammadde girişinin kısılması.	SHAP 3. sıra
Baldır çevresi (cm)	Kas kütlesinin pratik antropometrik göstergesi; yaşlılarda <31 cm düşük kası düşündürür.	Mezurayla kas ölçümü.	SHAP 4. sıra
Barthel indeksi (0–100)	Beslenme, giyinme, tuvalet gibi günlük yaşam aktivitelerinde bağımsızlık puanı; 100 = tam bağımsız.	Cihazın kaç fonksiyonu hâlâ çalışıyor?	SHAP 5. sıra
Disfaji	Yutma güçlüğü.	Besleme hattında daralma.	Değişken
Demans / depresyon	Bilişsel gerileme / süregen çökkünlük; ikisi de besin alımını azaltabilir.	—	Değişken
Polifarmasi	Çok sayıda ilacın birlikte kullanılması (genellikle ≥5).	Aynı anda çok yazılım çalıştırmak: yan etkiler çakışır.	"İlaç sayısı"
İnflamasyon	Vücudun iltihabi yanıtı; albümin gibi belirteçleri etkiler.	Alarm sisteminin sürekli açık kalması.	Albümin
Sarkopeni	Yaşa bağlı kas kütlesi ve gücü kaybı.	Motor gücünün azalması.	Baldır çevresi
NRS-2002, MUST	Hastanede kullanılan beslenme riski tarama araçları (Kondrup ve ark., 2003); kural tabanlı skorlar.	Elle yazılmış kontrol listeleri.	"Model bunlardan iyi mi?"

■ Senaryo

65 yaş ve üzeri yatan hastalarda GLIM ölçütlerine göre malnütrisyonu tahmin eden bir model geliştirildi (prevalans %27,7). Değişkenler: kilo kaybı, BKİ, besin alımında azalma, baldır çevresi, albümin, disfaji, demans, depresyon, ilaç sayısı ve Barthel indeksi.



Şekil 3.7. *Malnütrisyon (GLIM): ortalama |SHAP| değerlerine göre en etkili değişkenler.*

İlk sıralardaki değişkenler, GLIM'in **fenotipik ölçütleri** (istemsiz kilo kaybı, düşük BKİ ve kas kütlesinin bir göstergesi olarak baldır çevresi) ile **etiyolojik ölçütü** (besin alımında azalma) ile örtüşür (Cederholm ve ark., 2019). Barthel indeksi ile ölçülen işlevsel bağımlılık da öne çıkar. **Albüminin sıralamada geride kalması** güncel kanıtla uyumludur: albümin beslenme durumundan çok inflamasyonu yansıtan bir belirteçtir ve tek başına malnütrisyon göstergesi olarak kullanılmamalıdır.

■ Klinik Köşe: Model mi, tarama aracı mı?

Klinikte malnütrisyon taraması için NRS-2002 gibi doğrulanmış araçlar kullanılır (Kondrup ve ark., 2003). Bir makine öğrenmesi modelinin bu araçların yerini alabilmesi için yalnızca AUC'sinin yüksek olması yetmez. Aynı hastalarda NRS-2002 ile doğrudan karşılaştırılması, kalibrasyonunun gösterilmesi ve serviste kullanımının iş yükünü azalttığının kanıtlanması gerekir.

■ Tartışma soruları

1. Model NRS-2002 veya MUST'tan daha mı iyi? Bunu anlamak için nasıl bir çalışma gerekir?
2. Modelin performansını artırmak için hangi ek veriyi toplamak gerekir? (Örneğin kas gücü, biyoempedans.)
3. Albüminin geride kalması diyetisyen olarak sizi şaşırttı mı? Öğrencilerinize bunu nasıl anlatırsınız?
4. Model “malnütrisyon riski yüksek” dediğinde beslenme ekibinin ilk eylemi ne olmalı?

Vaka 4. Preeklampsi taraması (ebelik)

■ Bu kelimeler ne demek? · Preeklampsi vakası

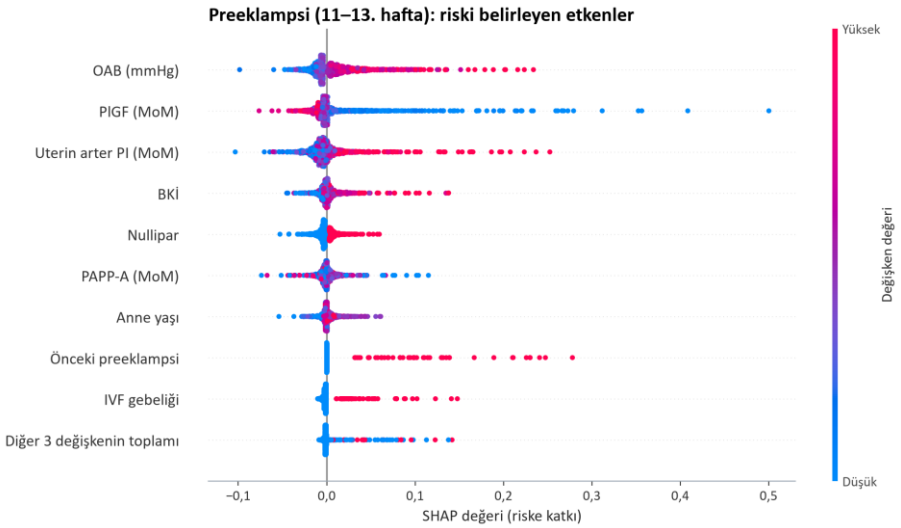
Preeklampsi, uterin arter PI, PlGF ve MoM Bölüm 2.6'da açıklandı (Şekil B4). Burada modelin kalan değişkenleri ve tarama terimleri yer alıyor.

OAB (ortalama arter basıncı; MAP)	
Ne?	Bir kalp döngüsü boyunca arterlerdeki ortalama basınç.
Normal değer	Yaklaşık 70–100 mmHg. Formül: OAB ≈ (sistolik + 2 × diyastolik) / 3 → 120/80 için (120 + 160) / 3 ≈ 93 mmHg
Model için neden önemli?	Organ perfüzyonunu tek sayıyla özetler; ilk trimester preeklampsi taramasında biyofiziksel belirteçtir.
Benzetme	Zaman ortalamalı basınç: diyastol daha uzun sürdüğü için ağırlığı iki kattır.
Bu eğitimde	Preeklampsi verisinde "OAB (mmHg)": SHAP'ta 1. sıra; yüksek OAB riski artırır.

Terim	Ne demek?	Benzetme / not	Bu eğitimde
Plasenta (eş)	Anne ile fetüs arasında besin ve gaz alışverişini sağlayan organ.	Bebeğin besleme istasyonu.	Arka plan
Nullipar	Daha önce hiç doğum yapmamış kadın; ilk gebelik preeklampsi riskini artırır. (Primipar: bir doğum; multipar: birden çok doğum.)	İlk kez çalışan sistem.	"Nullipar", SHAP 5. sıra
Önceki preeklampsi	Önceki gebelikte preeklampsi öyküsü.	Daha önce arıza yapmış parça.	Değişken
Kronik hipertansiyon	Gebelik öncesinden (ya da 20. haftadan önce) var olan hipertansiyon.	Zaten yüksek basınçlı şebeke.	Değişken
Pregestasyonel diyabet	Gebelikten önce var olan diyabet. (Gestasyonel diyabet: gebelikte ortaya çıkan glukoz intoleransı.)	—	Değişken
IVF	In vitro fertilizasyon: tüp bebek yöntemiyle elde edilen gebelik.	—	"IVF gebeliği"
Çoğul gebelik	İkiz ya da daha fazla fetüs.	Tek boru hattından iki fabrikayı beslemek.	Değişken
PAPP-A	Pregnancy-Associated Plasma Protein-A: ilk trimester taramasında bakılan plasenta proteini; düşük değer riskle ilişkili.	İkinci ilerleme raporu.	"PAPP-A (MoM)"
Trimester	Gebeliğin üç aylık dönemleri; 11–13. hafta birinci trimesterin sonu.	Proje fazları.	Tarama zamanı
FMF	Fetal Medicine Foundation: ilk trimester preeklampsi risk algoritmasının geliştiricisi.	Sektörün referans yazılımı.	Vaka 4
Preterm	37. gebelik haftasından önce (doğum ya da preeklampsinin erken başlaması).	Erken teslim.	ASPRE
Aspirin profilaksisi / ASPRE	Yüksek riskli gebelerde düşük doz aspirinle önleme; ASPRE'de preterm preeklampsi ~%62 azaldı (Rolnik ve ark., 2017).	Önleyici bakım.	Modelin eylemi

■ Senaryo

Gebeliğin 11–13. haftasında yapılan tarama sırasında toplanan verilerle preeklampsi gelişimini tahmin eden bir model geliştirildi (prevalans %5,5). Değişkenler: ortalama arter basıncı (OAB), uterin arter pulsatilite indeksi (PI), PlGF ve PAPP-A (MoM olarak), anne yaşı, BKİ, nulliparite, önceki preeklampsi, kronik hipertansiyon, pregestasyonel diyabet, IVF ve çoğul gebelik.



Şekil 3.8. *Preeklampsi: SHAP özet grafiği. Düşük PlGF (mavi) riski artırıyor.*

Modelin ilk sıralarında **OAB, PlGF, uterin arter PI, BKİ ve nulliparite** yer alır. Bu değişkenler, ilk trimester preeklampsi taramasında kullanılan biyofiziksel ve biyokimyasal belirteçlerle uyumludur. Dikkat: PlGF'de yüksek değil, **düşük değer** (mavi noktalar sağda) riski artırır. ASPRE çalışmasında ilk trimester taramasıyla yüksek riskli bulunan gebelerde düşük doz aspirin, preterm preeklampsiyi plaseboya göre yaklaşık **%62** azaltmıştır (Rolnik ve ark., 2017). Modelin çıktısının bir **eyleme** dönüştüğü yer burasıdır.

■ Dikkat! Yanlış pozitif yükü

Prevalans %5,5 olduğu için bu modelin PPV'si düşüktür (Bölüm 2.6, Şekil 2.7: ortalama kesinlik 0,21). "Yüksek riskli" olarak işaretlenen gebelerin büyük çoğunluğunda preeklampsi **gelişmeyecektir**. Bu durum gereksiz kaygıya, ek vizitlere ve iş yüküne yol açabilir.

■ Tartışma soruları

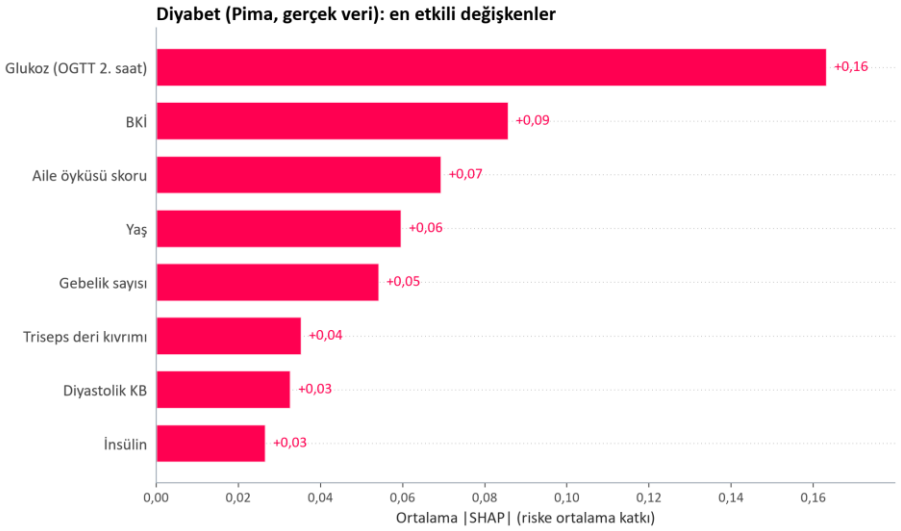
1. PlGF'nin düşük değerinin riski artırması fizyolojik olarak nasıl açıklanır?
2. "Yüksek riskli" sonucu alan bir gebeyle nasıl iletişim kurarsınız? Hangi kelimeleri seçersiniz?
3. Yanlış pozitif yükünü azaltmak için hangi eşik ve izlem stratejileri önerilebilir?
4. Ebelik öğrencilerine bu modelin çıktısını okumayı nasıl öğretirsiniz?

Vaka 5 (ek). Pima diyabet: gerçek veri ve genellenebilirlik

■ Bu kelimeler ne demek? · Pima vakası

Diyabet, glukoz ve OGTT, BKİ, insülin, aile öyküsü skoru ve triseps deri kıvrımı Bölüm 1.6'daki kutuda açıklandı. Akılda tutulacak üç nokta: **OGTT 2. saat glukozu <140 mg/dL normaldir**; **BKİ ≥30 obezitedir**; veride "?" görünen hücreler fizyolojik olarak imkânsız sıfırlardan dönüştürülmüş **eksik verilerdir**.

Pima verisi, ABD'deki Pima yerlisi kadınlardan toplanmış ve makine öğrenmesi eğitiminde sıkça kullanılan gerçek bir açık veri setidir (Smith ve ark., 1988). Veride fizyolojik olarak imkânsız sıfır değerleri (örneğin sıfır BKİ ya da sıfır kan basıncı) bulunduğundan, bu değerler eksik veri olarak kodlanmıştır. Şekil 3.9'da görüldüğü gibi **glukoz** açık ara baskın değişkendir; onu BKİ, aile öyküsü skoru, yaş ve gebelik sayısı izler.



Şekil 3.9. *Pima diyabet (gerçek veri): ortalama |SHAP| değerleri. Glukoz baskın değişken.*

■ Tartışma soruları: genellenebilirlik

1. Model yalnızca Pima yerlisi kadınlarda eğitildi. Mersinli bir gebe için kullanılabilir mi? Neden?
2. Veri setindeki "sıfır" değerleri eksik veri olarak kodlanmasaydı model nasıl etkilenirdi?
3. Glukozun bu kadar baskın olması, modelin klinik katkısı hakkında ne söylüyor? Glukozu zaten ölçüyorsak model bize ne kazandırır?

■ Kendinizi Sınayın

1. Global açıklama ile yerel açıklama arasındaki farkı birer örnekle açıklayın.
2. Bir şelale grafiğinde başlangıç değeri %6,7, modelin riski %68'dir. Bu iki değer ne anlama gelir?
3. Arı kovanı grafiğinde sistolik KB satırında mavi noktalar sağda toplanmışsa bunu nasıl yorumlarsınız?
4. "SHAP'a göre ateş en önemli değişken; o hâlde antipiretik verirsek sepsis riski azalır." Bu çıkarım neden yanlıştır?
5. Diyabetik ayak modelinde ayak bakım eğitiminin koruyucu görünmesini hangi karıştırıcı etken açıklayabilir?
6. **Kısaltma:** SHAP'ın açılımı nedir? Maaş bordrosu benzetmesinde "brüt maaş", "kalemler" ve "net maaş" şelale grafiğinde neye karşılık gelir?
7. **Kısaltma:** Arı kovanı grafiğinde GKS satırında kırmızı noktalar solda toplanmışsa bunu nasıl okursunuz? "Kırmızı = kötü" yorumu neden yanlıştır?
8. **Terim:** Bir gebenin PlGF değeri 0,5 MoM'dur. MoM ne demektir ve bu değer risk açısından nasıl yorumlanır?
9. **Terim:** Diyabetik ayak verisinde ABİ'si 0,7 olan bir hasta için bu değer neyi düşündürür? Normal aralık nedir?
10. **Terim:** GLIM'e göre malnütrisyon tanısı için hangi iki tür ölçüt birlikte aranır? Malnütrisyon modelinden birer örnek verin.

Cevaplar Ek F'dedir. Önce kendiniz yanıtlamayı deneyin. Kısaltma ve terim soruları için ilgili kartlara ve Ek D'ye bakabilirsiniz.

■ Bölüm özeti

- Kara kutu modellerin klinikte kabulü için açıklama gerekir; hemşire "neden?" diye sormalıdır.
- Global açıklama modelin genel olarak neye baktığını, yerel açıklama tek bir hastanın riskinin nedenini gösterir.
- SHAP riski kalem kalem faturalandırır: ortalama riskten başlar, her değişken riski artırır ya da azaltır.
- Açıklama nedensellik değildir; korelasyonlu değişkenler önemi paylaşır, karıştırıcılar ilişkiyi yanıltabilir.
- Vakalarda model değişkenleri klinik rehberlerle (Sepsis-3, IWGDF, GLIM, ilk trimester taraması) örtüşüyor; ama genellenebilirlik ve yanlış pozitif yükü ayrıca sorgulanmalı.

Bölüm 4. Klinik araştırmaya entegrasyon

Oturum 4 · 3 saat. Önceki üç bölümde bir modelin nasıl öğrendiğini, çıktısının nasıl okunduğunu ve kararlarının nasıl açıklandığını gördük. Bu son bölümde perspektifi genişletiyoruz: Bir modele ne zaman güvenebiliriz? Bir model makalesini nasıl eleştirel okuruz? Etik ve hukuki sorumluluklarımız nelerdir? Ve en önemlisi: **kendi alanımızda nasıl bir araştırma yapabiliriz?**

■ Öğrenme hedefleri

Bu bölümü tamamladığınızda şunları yapabileceksiniz:

1. Bir tahmin modelinin yaşam döngüsünü ve kanıt basamaklarını açıklar.
2. TRIPOD+AI, PROBAST(+AI), CONSORT-AI, SPIRIT-AI ve DECIDE-AI'nin hangi çalışma türü için kullanıldığını bilir.
3. Bir tahmin modeli makalesini 10 soruluk kontrol listesiyle eleştirel okur.
4. Veri kayması, yanlılık, KVKK, etik ve sorumluluk konularını tartışır.
5. Kendi alanında bir tahminleyici model araştırma önerisi taslağı yazar.

4.1 Bir modelin yaşam döngüsü

Bir tahmin modeli, bir makalede yayımlandığı anda tamamlanmış olmaz. Klinik sorudan başlayıp sürekli izlemeye uzanan sekiz evreli bir döngüden geçer (Şekil 4.1). Literatürdeki modellerin çok büyük bir kısmı dördüncü evrede, yani iç validasyonda kalır; klinik etkiye ulaşmanın önünde veri, iş akışı, düzenleme ve güven gibi pek çok engel vardır (Kelly ve ark., 2019).



Şekil 4.1. *Klinik tahmin modelinin sekiz evreli yaşam döngüsü. Literatürdeki modellerin çoğu dördüncü evrede kalır.*

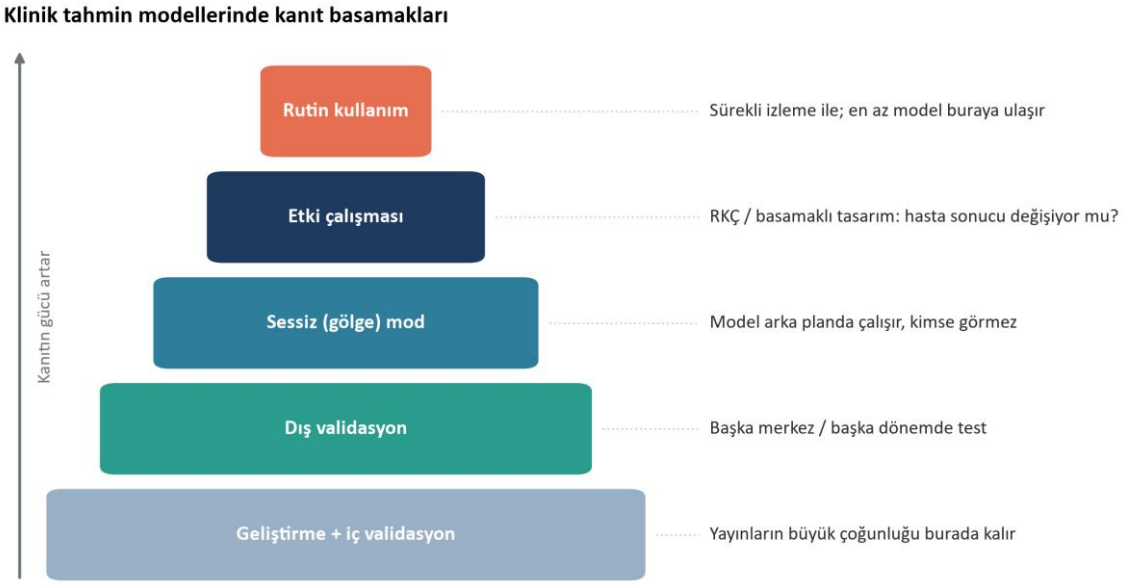
Tablo 4.1. Yaşam döngüsünün evreleri ve sağlık profesyonelinin rolü

Evre	Temel soru	Hemşire, ebe, diyetisyenin rolü
1. Klinik soru	Hangi karar iyileşecek?	Gerçek klinik gereksinimi tanımlamak; "model için model" yapılmasını önlemek
2. Veri	Veri temsili mi? Etik onay ve KVKK sağlandı mı?	Kayıtların nasıl tutulduğunu bilmek; ölçüm hatalarını ve eksikleri fark etmek
3. Geliştirme	Hangi algoritma, hangi değişkenler?	Değişkenlerin klinik anlamını ve tahmin anında elde olup olmadığını denetlemek
4. İç validasyon	Test seti veya çapraz doğrulamada performans nasıl?	AUC'nin yanında kalibrasyon ve eşik sonuçlarını istemek
5. Dış validasyon	Başka hastanede ve başka dönemde çalışıyor mu?	Kendi kurumunda dış validasyon çalışması yürütmek
6. Etki çalışması	Hasta sonucu değişiyor mu?	Uyarıya verilen yanıtı, iş yükünü ve hasta sonuçlarını ölçmek
7. Uygulama	İş akışına nasıl yerleşecek?	Ekran tasarımı, eylem protokolü ve eğitim süreçlerine katılmak
8. İzleme	Zamanla bozuluyor mu? Bazı gruplar için adil mi?	Kayma ve yanlılık belirtilerini bildirmek; geri bildirim vermek

> ■ **Başka bir alandan bakış: Ürün yaşam döngüsü**
>
> Mühendislikte hiçbir ürün "prototip laboratuvarda çalıştı" diye piyasaya çıkmaz: önce saha testi (dış validasyon), sonra pilot üretim (sessiz mod ve erken klinik değerlendirme), sonra seri üretim (rutin kullanım) ve ürün ömrü boyunca bakım ve kalibrasyon (izleme) gelir. Bir tahmin modelinin yaşam döngüsü de aynı mantıkla işler; farkı, "ürünün" hastanın güvenliğine doğrudan dokunmasıdır.

4.2 Kanıt basamakları

Bir modelin "iyi" olduğunu söyleyebilmek için hangi düzeyde kanıta sahip olduğumuzu bilmemiz gerekir. Şekil 4.4 bu kanıtı basamaklar hâlinde gösterir. Asıl soru, modelin AUC'sinin yüksek olup olmadığı değil, **hasta sonucunu değiştirip değiştirmediğidir** (Topol, 2019; Rajkomar ve ark., 2019).



Şekil 4.4. *Klinik tahmin modellerinde kanıt basamakları: iç validasyondan rutin kullanıma.*

Tablo 4.2. Kanıt basamakları ve bu notta karşılaştığımız örnekler

Basamak	Ne gösterir?	Bu nottaki örnek
Geliştirme + iç validasyon	Model kendi verisinde, ayrılmış hastalarda nasıl çalışıyor?	Bu eğitimdeki beş veri setindeki modeller (Bölüm 2)
Dış validasyon	Başka merkezde ya da başka dönemde de çalışıyor mu?	Epic Sepsis Model: Michigan'da AUC 0,63 (Wong ve ark., 2021)
Sessiz (gölge) mod	Model arka planda çalışır, klinisyene gösterilmez; gerçek zamanlı performans ölçülür	Uygulamaya geçmeden önce önerilen ara adım
Etki çalışması	Model kullanıldığında hasta sonucu değişiyor mu? (RKÇ, basamaklı tasarım, prospektif çalışma)	TREWS: zamanında yanıtla mortalitede azalma (Adams ve ark., 2022); otonom retinopati sistemi (Abràmoff ve ark., 2018)
Rutin kullanım	Sürekli izleme ile klinik uygulamada	En az sayıda model bu basamağa ulaşır

4.3 Raporlama rehberleri ve yanlılık riski araçları

Tahmin modeli ve yapay zekâ çalışmalarının nasıl raporlanacağını ve nasıl değerlendirileceğini tanımlayan uluslararası rehberler vardır. Bir makale yazarken raporlama rehberini, bir makaleyi değerlendirirken yanlılık riski aracını kullanırsınız. Hangi rehberin hangi çalışma için kullanıldığı Tablo 4.3'te eşleştirilmiştir.

Tablo 4.3. Rehber eşleştirme tablosu

Çalışma türü	Raporlama rehberi	Yanlılık riski aracı
Tahmin modeli geliştirme / validasyon	TRIPOD+AI (2024) (Collins ve ark., 2024)	PROBAST (Wolff ve ark., 2019) / PROBAST+AI (2025) (Moons ve ark., 2025)
Yapay zekâ müdahalesi içeren RKÇ protokolü	SPIRIT-AI (2020) (Cruz Rivera ve ark., 2020)	—
Yapay zekâ müdahalesi içeren RKÇ raporu	CONSORT-AI (2020) (Liu ve ark., 2020)	RoB 2
Erken evre klinik değerlendirme (canlı kullanım)	DECIDE-AI (2022) (Vasey ve ark., 2022)	—

■ Bu kelimeler ne demek? · Araştırma, raporlama ve mevzuat terimleri

Bu bölümde ve atölyede sık geçen kısaltmalar. Rehberlerin tam adları ve yılları burada; hangi çalışma için hangisinin kullanılacağı Tablo 4.3'te.

RKÇ (randomize kontrollü çalışma; RCT)	
Ne?	Katılımcıların kurayla gruplara ayrılıp yeni uygulama ile karşılaştırıcının sınandığı çalışma.
Model için neden önemli?	Nedenselliği gösterebilen en güçlü tasarımdır: “Bu model hasta sonucunu iyileştiriyor mu?” sorusunun altın standardı.
Benzetme	A/B testi: kullanıcıların yarısına yeni arayüz, yarısına eskisi; kura sayesinde iki grup diğer her şeyde benzer.
Bu eğitimde	Bölüm 4.2 kanıt basamakları; SPIRIT-AI ve CONSORT-AI.

TRIPOD+AI, PROBAST(+AI), SPIRIT-AI, CONSORT-AI, DECIDE-AI, RoB 2	
Ne?	Raporlama rehberleri ve yanlılık riski araçları: • **TRIPOD+AI** (Transparent Reporting of a multivariable prediction model for Individual Prognosis Or Diagnosis + AI, 2024): tahmin modeli geliştirme/validasyon makalesi raporlama listesi. • **PROBAST / PROBAST+AI** (Prediction model Risk Of Bias ASsessment Tool, 2019 / 2025): tahmin modeli çalışmasında yanlılık riskini değerlendirme aracı. • **SPIRIT-AI / CONSORT-AI** (2020): YZ müdahalesi içeren RKÇ'nin **protokolü / raporu**. • **DECIDE-AI** (2022): YZ destekli karar sisteminin canlı kullanımdaki erken evre klinik değerlendirmesi. • **RoB 2** (Risk of Bias 2): RKÇ'lerde yanlılık riski aracı.
Model için neden önemli?	Hakemler ve etik kurullar bu listeleri sorar; önerinizi yazarken baştan açık tutun.
Benzetme	Uçuş öncesi kontrol listesi ya da kalite standartları: “yazarken şu maddeleri unutma.”
Bu eğitimde	Tablo 4.3 (rehber eşleştirme), Tablo 4.4 (10 soruluk kontrol listesi).

%95 GA (güven aralığı; CI) ve p değeri	
Ne?	**%95 GA:** gerçek değerin büyük olasılıkla bulunduğu aralık. **p değeri:** gerçekte fark yokken en az bu kadar büyük bir farkı tesadüfen görme olasılığı; p <0,05 genelde "istatistiksel olarak anlamlı" kabul edilir.
Model için neden önemli?	Küçük alt gruplarda (ör. ≥80 yaş, n=18) güven aralığı çok geniştir; farkların güvenilmez olmasının nedeni budur.
Benzetme	Ölçüm belirsizliği (± tolerans): az ölçümle tolerans bandı geniş olur.
Bu eğitimde	Bölüm 4.6 alt grup analizi.

KVKK (6698 sayılı Kişisel Verilerin Korunması Kanunu)	
Ne?	Türkiye'nin kişisel veri koruma kanunu (2016). Sağlık verisi "özel nitelikli" kişisel veridir.
Model için neden önemli?	Hasta verisiyle model kurmak ya da doğrulamak için açık rıza veya kanuni istisna, anonimleştirme, veri minimizasyonu, etik kurul onayı ve kurum izni gerekir.
Benzetme	Bilgi güvenliğinde "gizli" etiketli veri ve "en az yetki" ilkesi.
Bu eğitimde	Bölüm 4.7 etik ve hukuk.

Terim	Ne demek?	Benzetme / not	Bu eğitimde
Kohort	Bir grubu zaman içinde izleyen çalışma.	Bir üretim partisini ömür boyu izlemek.	Tasarım
Retrospektif / prospektif	Geçmiş kayıtlardan geriye bakmak / bugünden ileriye izlemek.	Kayıt (log) analizi / canlı izleme.	Tasarım
Prevalans / insidans	Belli bir anda hasta olanların oranı / belli bir sürede yeni hastalananların oranı.	Stoktaki arızalı oranı / bu ay yeni arızalanan oranı.	Kart 20
Sessiz (gölge) mod	Modelin hesaplayıp klinisyene uyarı göstermediği deneme dönemi; sonuçlar gerçekleşenle karşılaştırılır.	Paralel çalıştırma.	Tablo 4.2
Genellenebilirlik	Bulgunun başka topluluk ve ortamlara taşınabilmesi.	Kalibrasyonun başka malzemede geçerliliği.	Pima, Epic
Etik kurul / açık rıza	Araştırmanın etik uygunluğunu onaylayan kurul / kişinin bilgilendirilerek özgür iradesiyle verdiği onay.	Proje onay komitesi / gerçekten okunmuş kullanıcı sözleşmesi.	Bölüm 4.7
Anonimleştirme / veri minimizasyonu	Verinin kişiyle ilişkilendirilemez hâle getirilmesi / yalnızca gerekli verinin işlenmesi.	Kimlik alanlarını geri döndürülemez silmek / en az yetki.	KVKK

■ Klinik Köşe: Önerinizi yazarken

Bu eğitimin sonunda yazacağınız araştırma önerisi büyük olasılıkla bir tahmin modeli geliştirme ya da dış validasyon çalışması olacaktır. Bu durumda yöntem bölümünüzü yazarken **TRIPOD+AI** kontrol listesini baştan açık tutun. Bir modelin geliştirilmesi için gereken örneklem büyüklüğü ve olay sayısı ise, değişken sayısı ve beklenen performansa göre hesaplanabilir (Riley ve ark., 2020). Kapsamlı bir yöntem kaynağı olarak Steyerberg'in kitabı önerilir (Steyerberg, 2019).

KISALTMA KARTI 31	**Hiperparametre, karar eğrisi analizi (DCA), örneklem ve olay sayısı (EPV)**
Açılımı	Hyperparameter = hiperparametre · DCA = Decision Curve Analysis = karar eğrisi analizi · EPV = Events Per Variable = değişken başına olay sayısı
Türkçesi	Ayar düğmeleri · net fayda grafiği · kaç hasta ve kaç olay gerekir?
Tek cümleyle	**Hiperparametre modelin ayar düğmesidir; karar eğrisi analizi modelin net klinik faydasını gösterir; örneklem büyüklüğünde belirleyici olan hasta sayısı değil, olay (ör. sepsis) sayısıdır.**
Benzetmeler	1. **Mühendislik:** Hiperparametre bir cihazın kalibrasyon vidası gibidir: ağaç derinliği, ağaç sayısı. Model bunları kendisi öğrenmez, biz seçeriz (Orange'da Tree → derinlik 3). Karar eğrisi ise bir maliyet-fayda analizidir. 2. **Günlük hayat:** Bir lokantayı 2 yorumla değil 200 yorumla değerlendirmek; 10 vakayla model kurmak, 10 ölçümle 50 bilinmeyenli denklem çözmeye benzer: ezber (aşırı öğrenme) garantidir. 3. **Klinik:** Karar eğrisi şu soruyu sorar: "Bu modeli kullanmak, hiç kimseye müdahale etmemekten ya da herkese müdahale etmekten daha fazla net fayda sağlıyor mu?" (Vickers ve Elkin, 2006).
Bizim verimizden	Sepsis verisi: 3000 hasta ama yalnızca **296** sepsis. Modelin asıl "öğrendiği" şey bu 296 olaydır. Gerekli örneklem Riley ve ark. (2020) yaklaşımıyla hesaplanır; eski "değişken başına 10 olay" kuralı tek başına yeterli kabul edilmez.
Sık karışıklık	"3000 hastamız var, yeterli." Belirleyici olan olay sayısıdır: %1 prevalanslı bir sonuçta 3000 hasta yalnızca 30 olay demektir.

4.4 Eleştirel okuma için 10 soru

Aşağıdaki kontrol listesi, bir tahmin modeli makalesini okurken sormanız gereken temel soruları içerir. Liste PROBAST+AI ve TRIPOD+AI'nin mantığına dayanan, sadeleştirilmiş bir öğretim aracıdır. Bir makaleyi okurken her soru için uygun kutuyu işaretleyin; "Hayır" ve "Belirsiz" yanıtları, makalenin zayıf noktalarını gösterir.

Tablo 4.4. Tahmin modeli makaleleri için eleştirel okuma kontrol listesi

No	Soru	Evet	Hayır	Belirsiz
1	Klinik soru ve modelin kullanım anı (kim, nerede, ne zaman kullanacak?) net mi?	☐	☐	☐
2	Veri kaynağı, veri dönemi ve hasta seçimi amaca uygun mu?	☐	☐	☐
3	Sonuç (hedef) nasıl ve ne zaman tanımlandı? (Örneğin sepsis tanımı neye göre?)	☐	☐	☐
4	Tahmin anında elde olmayan bir veri kullanılmış mı (veri sızıntısı)?	☐	☐	☐
5	Eksik veriler nasıl ele alındı?	☐	☐	☐
6	Örneklem büyüklüğü ve olay sayısı yeterli mi? (Riley ve ark., 2020)	☐	☐	☐
7	Ayrım (AUC) ve kalibrasyon birlikte raporlanmış mı?	☐	☐	☐
8	Dış validasyon yapılmış mı?	☐	☐	☐
9	Alt gruplarda (cinsiyet, yaş, etnik köken vb.) performans incelenmiş mi?	☐	☐	☐
10	Klinik fayda (örneğin karar eğrisi analizi) ve iş akışı tartışılmış mı?	☐	☐	☐

Tablo 4.5, her sorunun neden önemli olduğunu ve bir makalede nereye bakmanız gerektiğini özetler.

Tablo 4.5. Kontrol listesi sorularının gerekçeleri

No	Neden önemli?	Makalede nereye bakılır?
1	Kullanım anı belirsizse modelin hangi bilgiyle çalışacağı da belirsizdir.	Giriş, amaç, yöntemin başı
2	Model, eğitildiği popülasyonu temsil eder (Pima vakası).	Yöntem: veri kaynağı, dahil etme/dışlama ölçütleri
3	Aynı adı taşıyan sonuçlar farklı tanımlanmış olabilir.	Yöntem: sonuç tanımı ve zaman ufku
4	Örneğin sepsis tahmininde "antibiyotik başlandı" değişkenini kullanmak, cevabı soruya katmaktır; performans yapay olarak yükselir.	Yöntem: değişkenler ve ölçüm zamanları
5	Eksik verilerin silinmesi veya yanlış doldurulması yanlılık yaratabilir (Pima'daki sıfırlar).	Yöntem: eksik veri yaklaşımı
6	Az sayıda olayla geliştirilen model aşırı öğrenmeye çok açıktır.	Bulgular: olay sayısı; yöntem: örneklem hesabı
7	AUC yüksek ama kalibrasyon bozuk olabilir (Bölüm 2.5).	Bulgular: kalibrasyon grafiği, Brier skoru
8	Başka hastanede iyi çalışmak bizde de çalışacağı anlamına gelmez (Epic vakası).	Bulgular ve tartışma
9	Model bazı gruplar için sistematik olarak daha kötü çalışabilir (Bölüm 4.6).	Bulgular: alt grup tabloları, ekler
10	Yüksek AUC, hasta sonucunun iyileşeceği anlamına gelmez (Vickers ve Elkin, 2006).	Bulgular ve tartışma: karar eğrisi, uygulama planı

■ Benzetme: Cevap anahtarını görmek

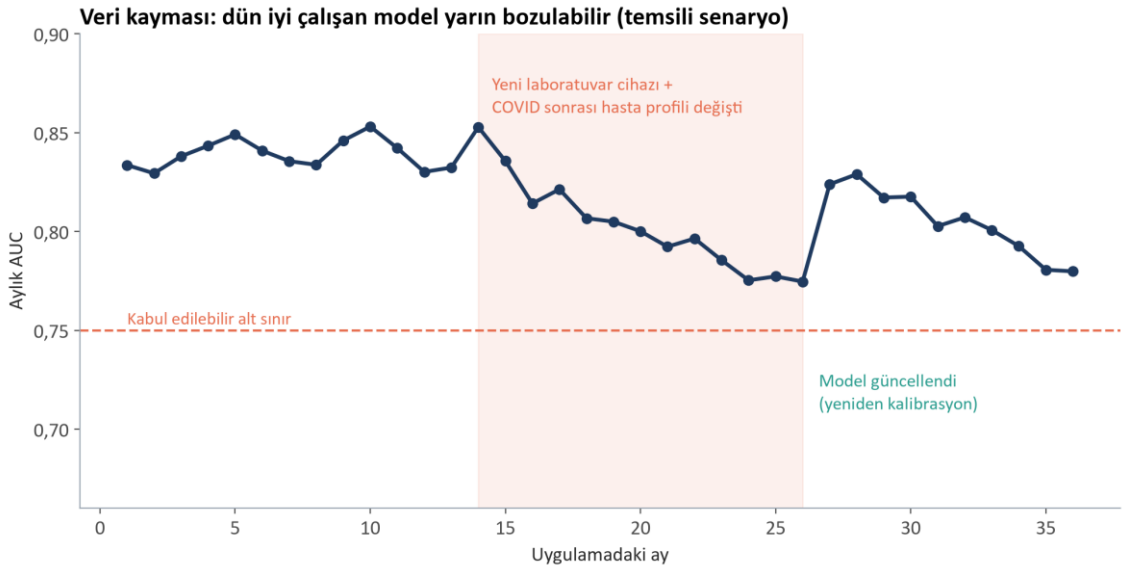
Bir öğrenci sınav sırasında cevap anahtarını görebiliyorsa notu ne kadar yüksek olursa olsun bir şey ifade etmez. **Veri sızıntısı** (data leakage) da budur: modelin, tahmin anında aslında bilinmeyen bir bilgiyi (örneğin sonuç belli olduktan sonra kaydedilen bir tetkiki) kullanmasıdır. AUC'si şaşırtıcı derecede yüksek bir model gördüğünüzde ilk şüpheniz bu olmalıdır.

KISALTMA KARTI 32 Veri sızıntısı (data leakage)

Açılımı	Data leakage = veri sızıntısı · Target leakage = hedef sızıntısı
Türkçesi	Modelin, tahmin anında aslında elde olmayan bir bilgiyi "kopya" olarak kullanması
Tek cümleyle	**Veri sızıntısı, modelin tahmin anında elde olmayacak bir bilgiyi girdi olarak kullanmasıdır; model çok iyi görünür ama gerçekte işe yaramaz.**
Benzetmeler	1. **Mühendislik:** Testte geleceğin verisini kullanan bir filtre: simülasyonda harika, gerçek zamanlı sistemde imkânsız. 2. **Günlük hayat:** Sınavdan önce cevap anahtarını görmek. Ya da "yarın şemsiye satışları arttıysa yağmur yağmıştır" diyen tahmin: doğru ama işe yaramaz, çünkü yarının satış verisi bugün yok. 3. **Klinik:** Sepsis tanısı konduktan sonra başlanan antibiyotiği ya da istenen kan kültürünü sepsisi tahmin etmek için değişken yapmak.
Bizim verimizden	Laktat çoğu zaman klinisyen sepsisten şüphelendiğinde istenir. Gerçek veride "laktat ölçülmüş olması" bile modele "klinisyen şüphelendi" bilgisini sızdırabilir. Belirti: beklenmedik derecede yüksek AUC (0,98 gibi). İlk şüphe: sızıntı (Tablo 2.3'teki "> 0,90" satırı).
Sık karışıklık	Sızıntı çoğu zaman kötü niyetten değil, zaman sırasının dikkatsizce kurulmasından doğar. Her değişken için sorun: "Bu bilgi tahmin **anında** elimde olur mu?"

4.5 Veri kayması: dün iyi çalışan model yarın bozulabilir

Bir model, eğitildiği dönemin hasta profilini, kayıt alışkanlıklarını ve klinik protokollerini "öğrenir". Bunlar değiştiğinde modelin performansı da değişir. Bu duruma **veri kayması** (dataset shift) denir. Şekil 4.2, temsili bir senaryoda aylar içinde AUC'nin nasıl düştüğünü ve modelin yeniden kalibre edilmesiyle nasıl toparlandığını gösterir.



Şekil 4.2. *Veri kayması: aylık AUC düşüşü ve yeniden kalibrasyon sonrası toparlanma (temsili senaryo, gerçek veri değildir).*

Veri kaymasının klinikteki tipik nedenleri şunlardır:

- **Yeni cihaz veya ölçüm yöntemi:** Laboratuvar analizörü ya da pulse oksimetre değişir, değerlerin dağılımı kayar.
- **Yeni protokol:** Sepsis paketi güncellenir; laktat artık her hastada istenir. Laktatı ölçülen hasta profili değişir.
- **Yeni hasta profili:** Hastane yeni bir bölüm açar, sevk örüntüsü değişir ya da salgın dönemleri yaşanır.
- **Kayıt alışkanlıkları:** Elektronik kayıt sistemi değişir, bazı alanlar artık zorunlu ya da isteğe bağlı olur.
- **Modelin kendi etkisi:** Model başarıyla kullanıldıkça erken müdahale artar ve olayların sıklığı değişir.

> ■ **Benzetme: Eski harita**
>
> On yıl önce çizilmiş bir şehir haritası, yeni açılan yolları ve kapanan sokakları göstermez. Harita çizildiği gün doğruydu; şehir değişti. Model de bir haritadır: **güncellenmesi ve sürekli izlenmesi** gerekir.

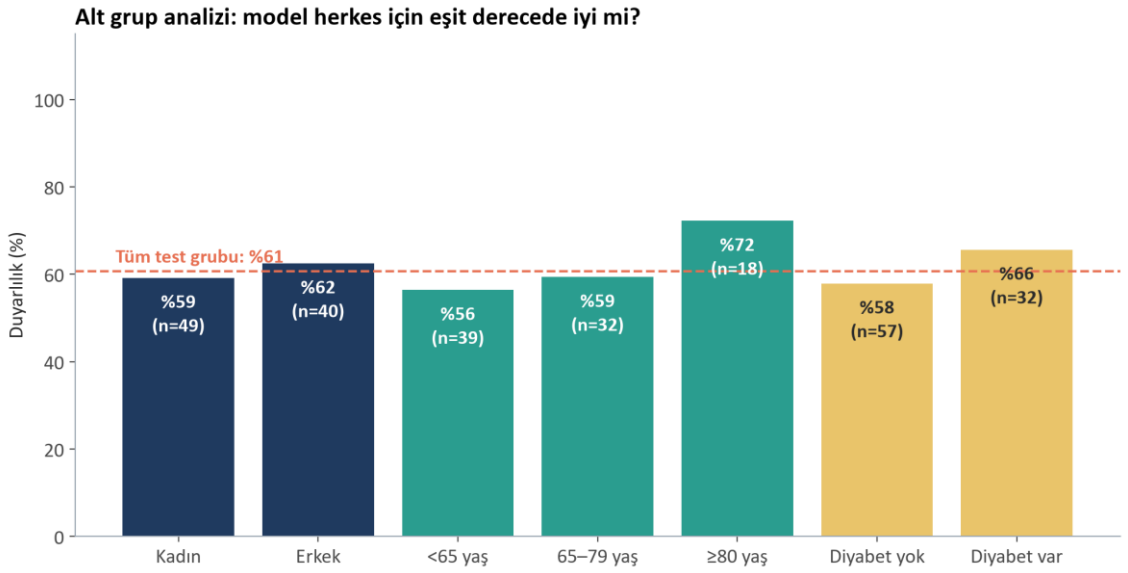
KISALTMA KARTI 33	**Veri kayması (dataset shift, drift)**
Açılımı	Dataset shift = veri seti kayması · Drift = kayma · Recalibration = yeniden kalibrasyon · Monitoring = izleme
Türkçesi	Model eğitildikten sonra koşullar değişince performansın bozulması
Tek cümleyle	**Veri kayması, modelin eğitildiği dönemdeki koşullar (cihaz, protokol, hasta profili, kayıt alışkanlığı) değişince performansının sessizce bozulmasıdır.**

Benzetmeler	1. **Mühendislik:** Sensör kayması: termokupl zamanla yaşlanır, okuma kayar; periyodik kalibrasyon gerekir. 2. **Günlük hayat:** Eski haritayla yeni açılmış bir otoyolda yol bulmaya çalışmak; ya da yazın ayarladığınız klimanın kışın işe yaramaması. 3. **Klinik:** Hastane yeni bir laboratuvar analizörü aldı, laktat değerleri biraz farklı ölçülmeye başladı; ya da salgın döneminde servisin hasta profili değişti.
Bizim verimizden	Şekil 4.2 (temsili senaryo): AUC aylar içinde düşüyor, yeniden kalibrasyonla toparlanıyor.
Sık karışıklık	"Model bir kez doğrulandı, artık sonsuza kadar iyidir." Hayır; model de bir cihaz gibi düzenli bakım ve sürekli izlem ister.
İlgili şekil	Şekil 4.2

4.6 Yanlılık ve hakkaniyet

Yapay zekâda yanlılığın en çok bilinen örneklerinden birinde, ABD'de milyonlarca hastanın bakım programlarına yönlendirilmesinde kullanılan bir algoritma, sağlık **gereksinimini** değil sağlık **harcamasını** hedef değişken olarak kullanmıştır. Sağlık hizmetine erişimleri daha kısıtlı olan Siyahi hastalar aynı hastalık yükünde daha az harcama yaptığı için, algoritma onların gereksinimini sistematik olarak düşük tahmin etmiştir (Obermeyer ve ark., 2019). Ders açıktır: **yanlış hedef değişken seçmek yanlılık doğurur.**

Yanlılığı saptamanın ilk adımı **alt grup analizidir**: model farklı hasta grupları için eşit derecede iyi mi? Şekil 4.3 ve Tablo 4.6, sepsis modelimizin (XGBoost, eşik %20) duyarlılığını alt gruplara göre gösterir.



Şekil 4.3. *Alt grup analizi: sepsis modelinin (XGBoost, eşik %20) cinsiyet, yaş ve diyabet gruplarına göre duyarlılığı.*

Tablo 4.6. Alt gruplara göre duyarlılık (test grubu, eşik %20)

Alt grup	Sepsis gelişen hasta sayısı (n)	Duyarlılık	Yorum
Kadın	49	%59	
Erkek	40	%62	
<65 yaş	39	%56	
65–79 yaş	32	%59	
≥80 yaş	18	%72	Küçük n: güvenilir değil
Diyabet yok	57	%58	
Diyabet var	32	%66	
Tüm test grubu	89	%61	Genel değer

■ Dikkat! Küçük n tuzağı

≥80 yaş grubunda duyarlılık %72 görünüyor; ama bu değer yalnızca **18** sepsis hastasına dayanıyor. Bu kadar küçük bir grupta birkaç hastanın farklı sınıflanması yüzdeyi büyük ölçüde değiştirir. Küçük alt gruplardaki farklar güvenilir değildir. **Yanlılık incelemesi büyük örneklem ister.** Yine de alt grup analizi yapılmalı ve sonuçları güven aralıklarıyla birlikte raporlanmalıdır.

KISALTMA KARTI 34	**Alt grup analizi ve yanlılık (bias)**
Açılımı	Subgroup analysis = alt grup analizi · Bias = yanlılık, sistematik hata · Fairness = hakkaniyet · n = gruptaki kişi (burada sepsis hastası) sayısı
Türkçesi	Modelin bazı gruplarda (yaşlılar, kadınlar, belli etnik gruplar) diğerlerinden kötü çalışması ve bunun grup grup incelenmesi
Tek cümleyle	**Yanlılık, modelin bazı gruplarda sistematik olarak daha kötü çalışmasıdır; alt grup analizi bunu ortaya çıkarmak için performansı grup grup ölçer.**
Benzetmeler	1. **Mühendislik:** Yalnızca belli bir sıcaklık aralığında kalibre edilmiş sensör: o aralığın dışında okumalar kayar. 2. **Günlük hayat:** Yüz tanıma sistemlerinin koyu tenli yüzlerde daha çok hata yapması: eğitim verisinde o yüzler azdı. Ya da yalnızca 42 numara ayakla tasarlanmış ayakkabı kalıbı. 3. **Klinik:** Obermeyer ve ark. (2019): sağlık harcamasını hedef alan algoritma, harcaması düşük kalmış grupların gerçek ihtiyacını düşük tahmin etti. Yanlış hedef değişken yanlılık doğurur.
Bizim verimizden	Bizim model, eşik %20, alt grup duyarlılığı: kadın **%59** (n=49), erkek **%62** (n=40), <65 yaş **%56** (n=39), 65–79 yaş **%59** (n=32), ≥80 yaş **%72** (n=18), diyabet yok **%58** (n=57), diyabet var **%66** (n=32). Genel **%61**. ≥80 yaşta %72 neden yüksek? Belki tesadüf: grupta yalnızca 18 sepsis hastası var. 18 kişide 1 hasta fazladan yakalanırsa oran 1 / 18 ≈ **5,6 puan** oynar.
Sık karışıklık	Küçük alt gruplardaki farkları "yanlılık kanıtı" saymak. Yanlılık incelemesi büyük örneklem ister; sonuçlar güven aralığıyla raporlanmalıdır.
İlgili şekil	Şekil 4.3, Tablo 4.6

4.7 Etik, hukuk ve sorumluluk

KVKK ve etik kurul

6698 sayılı Kişisel Verilerin Korunması Kanunu'na göre sağlık verisi **özel nitelikli kişisel veridir** (6698 sayılı KVKK, 2016). Sağlık verisiyle model geliştirmek ya da doğrulamak için açık rıza veya kanunda tanımlanan bir istisna, mümkün olduğunca **anonimleştirme** ve yalnızca gerekli verinin işlenmesi (**veri minimizasyonu**) gerekir. Geriye dönük kayıt çalışmaları dahil, tüm araştırmalar için **etik kurul onayı** ve kurum izni alınmalıdır.

AB Yapay Zekâ Yasası

2024'te yürürlüğe giren AB Yapay Zekâ Yasası (2024/1689), yapay zekâ sistemlerini risk düzeylerine göre sınıflandırır ve tıbbi yapay zekâ uygulamalarını çoğunlukla **"yüksek riskli"** sınıfa koyar (Regulation (EU) 2024/1689, 2024). Yüksek riskli sistemler için veri kalitesi, şeffaflık, insan gözetimi ve sürekli izleme gibi yükümlülükler tanımlanmıştır. Türkiye'de geliştirilen ve AB'de kullanılması hedeflenen sistemler de bu çerçeveden etkilenir.

Dünya Sağlık Örgütü'nün altı ilkesi

Dünya Sağlık Örgütü'nün 2021'de yayımladığı sağlıkta yapay zekâ etiği rehberi altı temel ilke tanımlar (World Health Organization, 2021). Tablo 4.7 bu ilkeleri sağlık bilimlerinden örneklerle özetler.

Tablo 4.7. DSÖ'nün sağlıkta yapay zekâ için altı etik ilkesi

İlke	Anlamı	Sağlık bilimlerinden örnek
Özerkliğin korunması	Kararlar insan denetiminde kalır; hasta bilgilendirilir	Gebe, risk skorunun anlamını ve seçeneklerini anlayarak karar verir
İyilik ve zarar vermeme	İnsan esenliği, güvenliği ve kamu yararı gözetilir	Yanlış alarm yükünün hasta güvenliğini tehdit etmemesi
Şeffaflık ve açıklanabilirlik	Sistemin nasıl çalıştığı anlaşılır olmalıdır	Uyarının yanında SHAP gibi açıklamaların sunulması
Sorumluluk ve hesap verebilirlik	Sistemin kullanımından kimin sorumlu olduğu bellidir	Model önerisine rağmen klinik karar hemşire/ebeye aittir
Kapsayıcılık ve hakkaniyet	Sistem tüm gruplar için adil çalışmalıdır	Alt grup analizlerinin yapılması (Şekil 4.3)
Duyarlılık ve sürdürülebilirlik	Sistem sürekli değerlendirilir ve güncellenir	Veri kaymasının izlenmesi (Şekil 4.2)

> ■ **Dikkat! "Model öyle dedi" bir gerekçe değildir**
>
> Sorumluluk **klinisyende kalır**. Modelin önerisini sorgulamak mesleki bir görevdir. Bir sistemin önerisine, kendi gözlemimiz farklı olsa bile körü körüne uyma eğilimine **otomasyon yanlılığı** (automation bias) denir. Model "düşük risk" dediğinde, kötüleştiğini gördüğünüz hastayı bekletmeyin; model "yüksek risk" dediğinde de klinik değerlendirmeyi atlamayın.

KISALTMA KARTI 35	Otomasyon yanlılığı (automation bias)
Açılımı	Automation bias = otomasyon yanlılığı · Human-in-the-loop = döngüdeki insan · Algorithm aversion = algoritma kaçınması (tersi)
Türkçesi	Makineye körü körüne güvenip kendi gözlemini bastırmak
Tek cümleyle	**Otomasyon yanlılığı, sistemin önerisine fazla güvenip kendi klinik gözlemini bastırmaktır.**

Benzetmeler	1. **Mühendislik:** Otomatik pilot varken pilotun dikkatinin dağılması ve otomasyon devreden çıkınca durumu geç fark etmesi. 2. **Günlük hayat:** GPS'e uyup göle ya da tek yönlü yola giren sürücü; yazım denetimi kırmızı çizmedi diye "hasta" yerine yazılmış "hata"yı gözden kaçırmak. 3. **Klinik:** Model "düşük risk" dediği için kötüleştiğini gördüğünüz hastayı bekletmek.
Bizim verimizden	Örnek hastamızda laktat normal (1,6). Yalnızca laktata ya da yalnızca modele bakıp karar vermek, ikisi de tek bir kaynağa körü körüne güvenmektir.
Sık karışıklık	Tersi de sorundur: modeli hiç dinlememek (algoritma kaçınması). Hedef, modeli bir meslektaş görüşü gibi tartmaktır. **Model öneriyor, hemşire/ebe karar veriyor.**

4.8 Açık veri kaynakları

Kendi kurumunuzun verisine erişim izni beklerken, açık veri kaynaklarıyla yöntem öğrenebilir, pilot analizler yapabilir ve öğrencilerinize uygulama yaptırabilirsiniz.

Tablo 4.8. Tahmin modeli çalışmaları için açık veri kaynakları

Kaynak	İçerik	Dikkat edilecek nokta
PhysioNet: MIMIC-IV (Johnson ve ark., 2023)	Yoğun bakım ve acil servis hastalarının elektronik kayıtları	Erişim için çevrim içi eğitim ve veri kullanım sözleşmesi gerekir
PhysioNet 2019 sepsis yarışması (Reyna ve ark., 2020)	Saatlik vital bulgu ve laboratuvar verisiyle erken sepsis tahmini	Sepsis tanımı ve zamanlamasını dikkatle okuyun
UCI Machine Learning Repository	Pima diyabet dahil çok sayıda klasik veri seti	Bazı setler eski ve küçüktür; eğitim için uygundur
OpenML	Standartlaştırılmış veri setleri ve karşılaştırmalı sonuçlar	Verinin klinik kaynağını ve tanımlarını kontrol edin
Kaggle	Çok sayıda kullanıcı tarafından yüklenmiş veri seti	**Dikkatli kullanılmalı:** kaynak, etik onay ve veri kalitesi belirsiz olabilir
Kurumsal veriler	Kendi hastanenizin kayıtları	Etik kurul onayı, kurum izni ve KVKK uyumu ile kullanılabilir

4.9 Araştırma tasarım türleri

Sağlık bilimleri öğretim elemanları için en uygulanabilir başlangıç noktası, sıfırdan model geliştirmek değil, var olan bir modelin kendi ortamında nasıl çalıştığını incelemektir. Tablo 4.9 beş temel tasarımı karşılaştırır.

Tablo 4.9. Tahminleyici model araştırmalarında tasarım türleri

Tasarım	Araştırma sorusu	Gerekenler	Rehber	Örnek fikir
(a) Dış validasyon	Yayımlanmış bir model bizim hastalarımızda çalışıyor mu?	Modelin formülü veya yazılımı, yerel veri	TRIPOD+AI	Bir düşme riski modelinin kendi servisimizde doğrulanması
(b) Yeni model geliştirme	Bizim hastalarımız için yeni bir model kurulabilir mi?	Yeterli olay sayısı, örneklem hesabı	TRIPOD+AI, PROBAST+AI	Doğum sonu kanama riskini tahmin eden model
(c) Model ile skorun karşılaştırılması	Makine öğrenmesi mevcut skordan daha mı iyi?	Aynı hastalarda iki aracın sonuçları	TRIPOD+AI	NEWS2 ile bir ML modelinin kötüleşme tahmininde karşılaştırılması
(d) Nitel / karma yöntem	Hemşire ve ebeler modelle birlikte nasıl çalışıyor?	Görüşme, gözlem, anket	DECIDE-AI	Uyarılara güven, kabul ve iş yükü algısı
(e) Eğitim araştırması	Öğrencilere model çıktısı okumayı nasıl öğretiriz?	Eğitim müdahalesi, ölçme aracı	—	Hemşirelik öğrencilerinde SHAP grafiği okuma becerisi

4.10 Atölye: kendi araştırma önerinizi yazın

Oturumun son saatinde her katılımcı tek sayfalık bir **"Tahminleyici Model Araştırma Önerisi"** doldurur. Form Ek C'dedir. Bölüm 1'de grubunuzla ürettiğiniz üç fikirden birini seçerek başlayabilirsiniz. Formu doldururken şu sırayı izleyin:

1. **Klinik problemi ve kararı** tek cümleyle yazın: "Hangi hastada, hangi karar, ne zaman?"
2. **Sonucu ve zaman ufkunu** tanımlayın: "72 saat içinde düşme", "12 ay içinde ülser" gibi.
3. **Tasarımı seçin:** Dış validasyon, yeni model ya da karşılaştırma (Tablo 4.9).
4. **Veri kaynağını ve olay sayısını** tahmin edin; olay sayısı azsa dış validasyonu tercih edin.
5. **Performans ölçütlerini** listeleyin: AUC, kalibrasyon, eşik, duyarlılık ve PPV.
6. **Açıklanabilirlik, etik/KVKK ve raporlama rehberi** satırlarını doldurun.
7. **Klinik etki planını** yazın: Model çalışırsa, uyarıdan sonra ne yapılacak?

> ■ **Klinik Köşe: 3 dakikalık sunum**
>
> Her katılımcı önerisini **3 dakikada** sunar: 1 dakika klinik problem, 1 dakika tasarım ve veri, 1 dakika beklenen klinik etki. Arkadaşlarınız 10 soruluk kontrol listesinden (Tablo 4.4) en az iki soruyu önerinize yöneltecektir.

> ■ **Kapanış**
>
> Dört oturum boyunca öğrendiklerimiz tek bir cümlede toplanabilir:
>
> **"Model öneriyor, hemşire/ebe karar veriyor."**

TAKDAĞLI

■ Kendinizi Sınayın

1. Bir tahmin modeli geliştirme makalesini değerlendirmek için hangi raporlama rehberini ve hangi yanlılık riski aracını kullanırsınız?
2. Bir sepsis modeli, “kan kültürü istendi” bilgisini değişken olarak kullanıyor. Kontrol listesinin hangi sorusu bu sorunu yakalar ve neden?
3. Bir modelin AUC'si iki yıl içinde 0,85'ten 0,72'ye düşmüş. Bunun olası nedenlerini ve çözümünü yazın.
4. Alt grup analizinde ≥80 yaş grubunun duyarlılığı %72 bulunmuş (n=18). Bu sonucu nasıl yorumlarsınız?
5. KVKK'ya göre sağlık verisi hangi veri kategorisindedir ve araştırmada hangi ilkeler gözetilmelidir?
6. **Kısaltma:** TRIPOD+AI ile PROBAST+AI arasındaki fark nedir? Hangisini kendi makalenizi yazarken, hangisini başkasının makalesini değerlendirirken kullanırsınız?
7. **Kısaltma:** EPV'nin açılımı nedir? Sepsis verimizde 3000 hasta olmasına karşın modelin asıl öğrendiği olay sayısı kaçtır ve bu neden önemlidir?
8. **Kısaltma:** RKÇ'nin açılımı nedir? Bir sepsis uyarı modelinin hasta sonucunu iyileştirdiğini göstermek için neden yüksek bir AUC yetmez?

Cevaplar Ek F'dedir. Önce kendiniz yanıtlamayı deneyin. Kısaltma ve terim soruları için ilgili kartlara ve Ek D'ye bakabilirsiniz.

■ Bölüm özeti

- Model yaşam döngüsü sekiz evreden oluşur; modellerin çoğu iç validasyonda kalır, asıl soru hasta sonucunun değişip değişmediğidir.
- Model geliştirme ve validasyon için TRIPOD+AI ile PROBAST/PROBAST+AI; RKÇ'ler için SPIRIT-AI ve CONSORT-AI; erken klinik değerlendirme için DECIDE-AI kullanılır.
- 10 soruluk kontrol listesi; sonuç tanımı, veri sızıntısı, kalibrasyon, dış validasyon ve alt grup analizini sorgular.
- Veri kayması ve yanlılık sürekli izleme gerektirir; yanlış hedef değişken yanlılık doğurur, küçük alt grup farkları güvenilir değildir.
- Sağlık verisi özel niteliklidir (KVKK); tıbbi YZ çoğunlukla yüksek risklidir (AB YZ Yasası); sorumluluk klinisyende kalır.

Sık yapılan yanlış yorumlar

Aşağıdaki tablo, eğitimler ve makale tartışmalarında en sık karşılaştığımız yanlış yorumları ve doğrularını bir araya getirir. Bir sunum hazırlarken ya da öğrencilerinize model çıktısı anlatırken bu tabloyu kontrol listesi olarak kullanabilirsiniz.

Tablo Y.1. Sık yapılan yanlış yorumlar ve doğruları

No	Yanlış inanış	Doğrusu	Bkz.
1	“AUC 0,90 ise model %90 doğru tahmin ediyor.”	AUC bir **sıralama** başarısıdır: rastgele bir hasta ile bir sağlam kişiden hastaya daha yüksek skor verme olasılığı. Doğruluk oranı değildir.	Bölüm 2.2
2	“Doğruluk (accuracy) %90, model harika.”	Prevalans %10 ise herkese “sepsis yok” diyen model de %90 doğruluk alır. Nadir olaylarda duyarlılık, PPV ve kalibrasyon gerekir.	Bölüm 2.1
3	“Risk %68 ise hasta kesin sepsis.”	Olasılık bir kesinlik değildir. Modelin kalibrasyonuna ve klinik bağlama bakılmalıdır.	Bölüm 2.5
4	“SHAP'ta ateş en önemliyse ateşi düşürünce risk azalır.”	Bu bir nedensellik iddiasıdır; model bunu söylemez. SHAP modelin gerekçesini açıklar, hastalığın nedenini değil.	Bölüm 3.3
5	“En karmaşık algoritma en iyisidir.”	Beş veri setinde lojistik regresyon çoğu zaman karmaşık modellere çok yakın, bazen daha iyidir (Şekil 2.9).	Bölüm 2.7
6	“Başka hastanede iyi çalıştıysa bizde de çalışır.”	Epic Sepsis Model'in dış validasyonunda AUC 0,63'e düştü. Yerel dış validasyon gerekir.	Bölüm 2.10
7	“Değişken önemi düşükse o değişken klinik olarak önemsizdir.”	Korelasyonlu değişkenler önemi paylaşır; düşük önem klinik önemsizlik anlamına gelmez.	Bölüm 3.2
8	“Model önerdiyse sorumluluk modelindir.”	Sorumluluk klinisyende kalır. Modelin önerisini sorgulamak mesleki görevdir (otomasyon yanlılığı).	Bölüm 4.7

Ek A. Orange kurulumu ve Explain eklentisi

Orange Data Mining ücretsizdir ve Windows, macOS ve Linux'ta çalışır (Demšar ve ark., 2013). Programı yalnızca resmî siteden indirin: **https://orangedatamining.com/download**. Kurulum ve eklenti indirme sırasında internet bağlantısı gerekir; kurum ağında güvenlik duvarı sorun çıkarırsa bilgi işlem biriminden destek isteyin.

A.1 Windows'ta kurulum

1. Tarayıcıda **https://orangedatamining.com/download** adresini açın ve **Windows** sekmesini seçin.
2. Önerilen Windows yükleyicisini (.exe) indirin.
3. İndirilen dosyaya çift tıklayın. Kullanıcı Hesabı Denetimi izin isterse onaylayın.
4. Kurulum sihirbazında varsayılan seçenekleri koruyarak **Next** ve **Install** düğmeleriyle ilerleyin. Kurulum birkaç dakika sürebilir.
5. Kurulum bitince Başlat menüsünden **Orange**'ı açın. İlk açılış diğerlerinden uzun sürebilir.
6. Açılış ekranındaki örnek iş akışlarını kapatarak boş bir tuvalle başlayın.

A.2 macOS'ta kurulum

1. **https://orangedatamining.com/download** adresinde **macOS** sekmesini seçin ve bilgisayarınızın işlemcisine uygun (Apple Silicon ya da Intel) .dmg dosyasını indirin.
2. İndirilen .dmg dosyasını açın ve **Orange** simgesini **Applications** (Uygulamalar) klasörüne sürükleyin.
3. Uygulamalar klasöründe Orange'ı ilk kez açarken güvenlik uyarısı çıkarsa, simgeye sağ tıklayıp **Open** (Aç) seçeneğini kullanın ve onaylayın.
4. Orange açıldığında boş bir tuvalle başlayın.

A.3 Explain eklentisinin kurulumu (SHAP için)

Orange'da Adım Adım: Explain eklentisi

1. Orange'ı açın ve üst menüden **Options → Add-ons** seçeneğine tıklayın.
2. Açılan listede **Explain** satırını bulun ve solundaki kutuyu işaretleyin.
3. **OK** düğmesine basın ve kurulumun tamamlanmasını bekleyin.
4. Orange'ı kapatıp yeniden açın. Sol panelde **Explain** adlı yeni bir grup görmelisiniz.
5. Grupta **Explain Model**, **Explain Prediction** ve **Explain Predictions** widget'larının bulunduğunu kontrol edin.

Tablo A.1. Sık karşılaşılan sorunlar ve çözümleri

Sorun	Olası neden	Çözüm
Türkçe karakterler bozuk görünüyor	Dosya farklı bir kodlamayla kaydedilmiş	Eğitim dosyaları UTF-8'dir; Excel'de açıp kaydetmeyin. Kendi verinizi “CSV UTF-8” olarak kaydedin.
Sayılar metin gibi algılanıyor	Ondalık ayırıcı virgül olarak kaydedilmiş	CSV dosyalarında ondalık ayırıcı nokta olmalıdır; **File** widget'ında değişken türünü (numeric) kontrol edin.
Hedef değişken seçilemiyor	Rol ataması yapılmamış	**File** widget'ında ilgili satırın **Role** sütununu **target** yapıp **Apply**'a basın.
Explain grubu görünmüyor	Eklenti kurulmamış ya da Orange yeniden başlatılmamış	**Options → Add-ons**'tan kurulumu kontrol edin ve Orange'ı yeniden başlatın.
Add-ons listesi boş geliyor	İnternet bağlantısı veya kurum güvenlik duvarı	Başka bir ağda deneyin ya da bilgi işlem biriminden destek isteyin.
Test and Score çok yavaş	Büyük veri, çok model, çok kat	Kat sayısını azaltın ya da Random Forest'ta ağaç sayısını düşürün.

Tablo A.2. Modül boyunca kullanılan Orange widget'larının özeti

Oturum	Widget'lar	Amaç
1	**File**, **Data Table**, **Scatter Plot**, **Tree**, **Tree Viewer**	Veriyi açmak, incelemek ve ilk modeli okumak
2	**Logistic Regression**, **Tree**, **Random Forest**, **Gradient Boosting**, **Test and Score**, **Confusion Matrix**, **ROC Analysis**	Modelleri karşılaştırmak, eşik ve performansı değerlendirmek
3	**Gradient Boosting**, **Explain Model**, **Data Table**, **Explain Prediction**	Global ve yerel SHAP açıklamaları üretmek

Ek B. Veri setleri sözlüğü

> ■ **Dikkat! Sentetik veri uyarısı**
>
> Sepsis, diyabetik ayak, malnütrisyon ve preeklampsi veri setleri **sentetiktir**: klinik bilgiyle tasarlanmış, bilgisayarda üretilmiş kayıtlardır ve **gerçek hasta içermez**. Yalnızca öğretim amaçlıdır; buradaki ilişkilerden klinik sonuç çıkarılmamalıdır. Pima diyabet seti ise açık erişimli **gerçek** bir veri setidir (Smith ve ark., 1988); fizyolojik olarak imkânsız sıfır değerleri eksik veri olarak kodlanmıştır.

Tüm dosyalar UTF-8 kodlamalı CSV biçimindedir ve Orange tarafından doğrudan açılır. Her dosyada **son sütun hedef değişkendir** (Orange'da Role = target). Her sütun için **ne demek** olduğu, **birimi**, kabaca **normal aralığı** ve dosyada **gözlenen aralık** (en küçük – en büyük değer ya da kategoriler) verilmiştir. Normal aralıklar laboratuvara, yaşa ve rehbere göre değişebilen yaklaşık değerlerdir; kavramı okumanız için verilmiştir. Terimlerin ayrıntılı açıklaması ilgili "Bu kelimeler ne demek?" kutularında ve Ek D.4'tedir.

B.1 sepsis_sentetik.csv

Tablo B.1. Sepsis (servis hastası, 24 saat içinde sepsis gelişimi): n = 3000

Değişken	Ne demek?	Birim / kategoriler	Normal aralık	Gözlenen aralık
Yaş	Hastanın yaşı	yıl	—	18 – 96
Cinsiyet	Biyolojik cinsiyet	Erkek / Kadın	—	Erkek / Kadın
Nabız	Kalp hızı; >100 taşikardi	atım/dk	60–100	25 – 133
Solunum sayısı	Dakikadaki soluk sayısı; >20 takipne, ≥22 qSOFA ölçütü	soluk/dk	12–20	10 – 31
Ateş	Vücut sıcaklığı; ≥38 ateş, <36 hipotermi	°C	36,5–37,5	34,5 – 39,5
Sistolik KB	Büyük tansiyon; ≤100 qSOFA ölçütü	mmHg	~90–120	65 – 185
SpO2	Periferik oksijen satürasyonu	%	95–100	89 – 100
GKS	Glasgow Koma Skalası; <15 bilinç değişikliği	puan (3–15)	15	9 – 15
Laktat	Oksijensiz metabolizma ürünü; >2 Sepsis-3 ölçütü	mmol/L	<2	0,3 – 5,6
Lökosit	Beyaz kan hücresi sayısı	$\times 10^3/\mu L$	4–11	0 – 19,8
Kreatinin	Böbrek işlevi göstergesi	mg/dL	~0,6–1,2	0,31 – 2,9
Trombosit	Pıhtılaşma hücresi sayısı	$\times 10^3/\mu L$	150–400	32 – 465
Diyabet	Diyabet tanısı (komorbidite)	Var / Yok	—	Var / Yok
İmmünsupresyon	Bağışıklığı baskılayan durum veya tedavi	Var / Yok	—	Var / Yok
Üriner kateter	Kalıcı idrar sondası	Var / Yok	—	Var / Yok
Sepsis (24 saat)	**Hedef değişken:** 24 saat içinde sepsis gelişimi	Evet / Hayır	Prevalans %9,9	Evet / Hayır

B.2 diyabet_pima.csv

Tablo B.2. Pima diyabet (GERÇEK açık veri; Smith ve ark., 1988): n = 768

Değişken	Ne demek?	Birim / kategoriler	Normal aralık	Gözlenen aralık
Gebelik sayısı	Toplam gebelik sayısı	sayı	—	0 – 17
Glukoz (OGTT 2. saat)	Oral glukoz tolerans testinde 2. saat plazma glukozu	mg/dL	<140	44 – 199 (eksik: 5)
Diyastolik KB	Küçük tansiyon	mmHg	~60–80	24 – 122 (eksik: 35)
Triseps deri kıvrımı	Kol arkası deri altı yağ kalınlığı	mm	—	7 – 99 (eksik: 227)
İnsülin	2. saat serum insülini (çok sayıda eksik)	µU/mL	—	14 – 846 (eksik: 374)
BKİ	Beden kütle indeksi	kg/m²	18,5–24,9	18,2 – 67,1 (eksik: 11)
Aile öyküsü skoru	Ailedeki diyabet yükünü özetleyen skor (pedigree function)	birimsiz	—	0,078 – 2,42
Yaş	Yaş	yıl	—	21 – 81
Diyabet	**Hedef değişken:** diyabet tanısı	Var / Yok	Oran %34,9	Var / Yok

B.3 diyabetik_ayak_sentetik.csv

Tablo B.3. Diyabetik ayak ülseri (12 ay içinde ülser gelişimi): n = 2000

Değişken	Ne demek?	Birim / kategoriler	Normal aralık	Gözlenen aralık
Yaş	Hastanın yaşı	yıl	—	30 – 90
Diyabet süresi (yıl)	Diyabet tanısından bu yana geçen süre	yıl	—	0,5 – 40
HbA1c	Son 2–3 ayın ortalama glisemisi	%	<5,7 (hedef <7)	5,2 – 13,5
Monofilament	10 g monofilamentle koruyucu duyu (nöropati göstergesi)	Hissediyor / Hissetmiyor	Hissediyor	Hissediyor / Hissetmiyor
ABİ	Ayak bileği / kol sistolik basınç oranı (PAH göstergesi)	oran	0,9–1,3	0,45 – 1,4
Önceki ülser	Ayak ülseri öyküsü	Var / Yok	—	Var / Yok
Ayak deformitesi	Çekiç parmak, halluks valgus, Charcot vb.	Var / Yok	—	Var / Yok
Sigara	Sigara kullanımı	Var / Yok	—	Var / Yok
BKİ	Beden kütle indeksi	kg/m²	18,5–24,9	18 – 47,1
eGFR	Tahmini glomerüler filtrasyon hızı	mL/dk/1,73 m²	≥90	11 – 130
Ayak bakım eğitimi	Yapılandırılmış ayak bakım eğitimi	Aldı / Almadı	—	Aldı / Almadı
Görme bozukluğu	Öz bakımı etkileyen görme sorunu	Var / Yok	—	Var / Yok
Ülser (12 ay)	**Hedef değişken:** 12 ay içinde ayak ülseri	Evet / Hayır	Prevalans %12	Evet / Hayır

TANITIM AMAÇLIDIR

B.4 malnutrisyon_sentetik.csv

Tablo B.4. Malnütrisyon (≥65 yaş yatan hasta, GLIM ölçütleri): n = 1500

Değişken	Ne demek?	Birim / kategoriler	Normal aralık	Gözlenen aralık
Yaş	Hastanın yaşı	yıl	≥65 (seçim ölçütü)	65 – 99
BKİ	Beden kütle indeksi (düşük BKİ GLIM fenotipik ölçütü)	kg/m²	18,5–24,9	14 – 38,3
Kilo kaybı 3 ay (%)	Son 3 ayda istemsiz kilo kaybı (GLIM fenotipik ölçütü)	%	~0	0 – 21,8
Besin alımı azalması	Besin alımında belirgin azalma (GLIM etiyolojik ölçütü)	Var / Yok	Yok	Ciddi / Orta / Yok
Baldır çevresi (cm)	Kas kütlesinin dolaylı göstergesi	cm	≥31 (yaşlı)	22 – 45
Albümin	Plazma albümini (inflamasyondan etkilenir)	g/dL	3,5–5,0	2,1 – 5
Disfaji	Yutma güçlüğü	Var / Yok	Yok	Var / Yok
Demans	Demans tanısı	Var / Yok	Yok	Var / Yok
Depresyon	Depresyon tanısı	Var / Yok	Yok	Var / Yok
İlaç sayısı	Düzenli kullanılan ilaç sayısı (polifarmasi)	sayı	—	0 – 15
Barthel indeksi	Günlük yaşam aktivitelerinde bağımsızlık	puan (0–100)	100	0 – 100
Malnütrisyon (GLIM)	**Hedef değişken:** GLIM'e göre malnütrisyon	Var / Yok	Prevalans %27,7	Var / Yok

B.5 preeklampsi_sentetik.csv

Tablo B.5. Preeklampsi (11–13. hafta taraması): n = 4000

Değişken	Ne demek?	Birim / kategoriler	Normal aralık	Gözlenen aralık
Anne yaşı	Gebenin yaşı	yıl	—	17 – 47
BKİ	Gebelik başı beden kütle indeksi	kg/m²	18,5–24,9	16 – 46,6
Nullipar	Daha önce doğum yapmamış olma	Evet / Hayır	—	Evet / Hayır
Önceki preeklampsi	Önceki gebelikte preeklampsi öyküsü	Var / Yok	—	Var / Yok
Kronik hipertansiyon	Gebelik öncesi hipertansiyon	Var / Yok	—	Var / Yok
Pregestasyonel diyabet	Gebelik öncesi diyabet	Var / Yok	—	Var / Yok
IVF gebeliği	Yardımcı üreme teknikleriyle (tüp bebek) gebelik	Evet / Hayır	—	Evet / Hayır
Çoğul gebelik	İkiz veya daha fazla	Evet / Hayır	—	Evet / Hayır
OAB (mmHg)	Ortalama arter basıncı ≈ (S + 2D) / 3	mmHg	~70–100	60 – 114
Uterin arter PI (MoM)	Uterin arter pulsatilite indeksi; yüksek = risk	MoM	≈1,0	0,48 – 2,26
PlGF (MoM)	Plasental büyüme faktörü; düşük = risk	MoM	≈1,0	0,26 – 2,85
PAPP-A (MoM)	Gebelikle ilişkili plazma proteini A; düşük = risk	MoM	≈1,0	0,24 – 4,61
Preeklampsi	**Hedef değişken:** preeklampsi gelişimi	Gelişti / Gelişmedi	Prevalans %5,5	Gelişmedi / Gelişti

Ek C. Araştırma önerisi formu

Bu form Oturum 4'teki atölyede doldurulur. Bölüm 4.10'daki adımları izleyin ve Tablo 4.4'teki kontrol listesiyle önerinizi sınayın. Form tek sayfaya sığacak biçimde tasarlanmıştır; Word dosyasında doğrudan boş hücrelere yazabilirsiniz.

Ad Soyad: ..... **Bölüm / alan:** .....

Tablo C.1. Tahminleyici Model Araştırma Önerisi

Alan	Yanıtınız
1. Başlık *Kısa ve açıklayıcı: popülasyon + sonuç + tasarım*	
2. Klinik problem *Hangi karar iyileşecek? Bugün nasıl veriliyor?*	
3. Hedef popülasyon ve ortam *Kimler, hangi birimde, hangi dönemde?*	
4. Tahmin edilecek sonuç ve zaman ufku *Sonuç tanımı (ör. Sepsis-3, GLIM) ve süre (ör. 72 saat, 12 ay)*	
5. Aday değişkenler ve veri kaynağı *Tahmin anında elde olan değişkenler; elektronik kayıt, form, ölçüm*	
6. Tasarım *☐ Dış validasyon ☐ Yeni model geliştirme ☐ Model–skor karşılaştırması ☐ Nitel/karma ☐ Eğitim araştırması*	
7. Örneklem ve olay sayısı *Beklenen hasta ve olay sayısı; örneklem gerekçesi (Riley ve ark., 2020)*	
8. Performans ölçütleri *AUC, kalibrasyon grafiği, duyarlılık/PPV ve seçilecek eşik*	
9. Açıklanabilirlik planı *Değişken önemi, SHAP; klinik tutarlılık kontrolü*	
10. Etik / KVKK *Etik kurul, kurum izni, anonimleştirme, veri minimizasyonu*	
11. Kullanılacak rehber *TRIPOD+AI, PROBAST+AI, DECIDE-AI ...*	
12. Klinik etki planı *Model çalışırsa uyarıdan sonra ne yapılacak? Hasta sonucu nasıl ölçülecek?*	

3 dakikalık sunum için: 1 dakika klinik problem, 1 dakika tasarım ve veri, 1 dakika beklenen klinik etki.

AKDAĞLI

Ek D. Sözlükler

Bu ek dört parçadan oluşur: **D.1** istatistik ve makine öğrenmesi kısaltmaları, **D.2** kısaltma kartlarının dizini, **D.3** kavramlar sözlüğü ve **D.4** tıbbi terimler sözlüğü. Her kısaltmanın ve kavramın ayrıntısı, "Kart" sütununda numarası ve sayfası verilen kısaltma kartındadır.

D.1 Kısaltmalar sözlüğü

Tablo D.1. İstatistik, makine öğrenmesi ve araştırma kısaltmaları

Kısaltma	Açılımı	Türkçesi	Tek benzetme	Kart
KDS (CDSS)	*Clinical Decision Support System*	Klinik karar destek sistemi	Braden gibi her yardımcı araç	1 · s. 14
YZ (AI)	*Artificial Intelligence*	Yapay zekâ	Matruşkanın en büyüğü	1 · s. 14
ML	*Machine Learning*	Makine öğrenmesi	Tarifsiz, tadarak öğrenen usta aşçı	1 · s. 14
DL	*Deep Learning*	Derin öğrenme	Matruşkanın en içteki bebeği	1 · s. 14
XAI	*eXplainable AI*	Açıklanabilir yapay zekâ	"Neden öttün?" sorusunun cevabı	1 · s. 14
CV	*Cross-Validation*	Çapraz doğrulama	Beş ayrı sınavın ortalaması	7 · s. 23
LR	*Logistic Regression*	Lojistik regresyon	Braden: topla, S eğrisine koy	8 · s. 24
RF	*Random Forest*	Rastgele orman	Konsey / kalabalığın bilgeliği	10 · s. 27
Bagging	*Bootstrap AGGregatING*	Önyükleme ile birleştirme	Seyirciye sorma jokeri	10 · s. 27
XGBoost	*eXtreme Gradient Boosting*	Aşırı gradyan artırma	Nöbet devri zinciri; golf vuruşları	11 · s. 28
DP / TP	*True Positive*	Doğru pozitif	Yangın var, öttü	12 · s. 35
YP / FP	*False Positive*	Yanlış pozitif	Tost yandı, öttü	12 · s. 35
YN / FN	*False Negative*	Yanlış negatif	Yangın var, SUSTU (en tehlikeli)	12 · s. 35
DN / TN	*True Negative*	Doğru negatif	Yangın yok, sessiz	12 · s. 35
Se / TPR / Recall	*Sensitivity / True Positive Rate*	Duyarlılık	Balık ağı: balıkların kaçını yakaladım?	13 · s. 36
Sp / TNR	*Specificity / True Negative Rate*	Özgüllük	Postacıya havlamayan köpek	14 · s. 36
FPR	*False Positive Rate (1 − Sp)*	Yanlış alarm oranı	Kuşa "uçak" diyen radar	14 · s. 36
PPV / Prec	*Positive Predictive Value / Precision*	Pozitif kestirim değeri, kesinlik	Kurt geldi çobanı: bağırışların kaçı gerçek?	15 · s. 37
NPV	*Negative Predictive Value*	Negatif kestirim değeri	Dedektör sessizken rahat uyumak	16 · s. 37
CA	*Classification Accuracy*	Doğruluk	Durmuş saat de günde iki kez doğru	17 · s. 38
F1	*F1 score (F-measure)*	F1 skoru	Paralel dirençler: küçük olan belirler	25 · s. 55
MCC	*Matthews Correlation Coefficient*	Matthews korelasyon katsayısı	Orange'da görülebilen ek özet ölçüt	25 · s. 55
ROC	*Receiver Operating Characteristic*	Alıcı işletim karakteristiği	Radar operatörünün hassasiyet düğmesi	18 · s. 40
AUC / C	*Area Under the Curve / Concordance statistic*	Eğri altındaki alan / C istatistiği	Eşleştirme turnuvası; karpuz seçen manav	19 · s. 41
PR	*Precision–Recall curve*	Kesinlik–duyarlılık eğrisi	Samanlıkta iğne	24 · s. 52

Kısaltma	Açılımı	Türkçesi	Tek benzetme	Kart
AP	*Average Precision*	Ortalama kesinlik	PR eğrisinin altı; kıyas noktası = prevalans	24 · s. 52
Brier	*Brier score*	Brier skoru	Olasılıkların golf skoru: küçük olan kazanır	23 · s. 49
SHAP	*SHapley Additive exPlanations*	Shapley toplamsal açıklamaları	Maaş bordrosu; restoran hesabı	28 · s. 61
E[f(X)] / f(x)	*Expected value of model output / model output*	Ortalama tahmin / bu hastanın tahmini	Brüt maaş / net maaş	28 · s. 61
|SHAP|	*Mean absolute SHAP value*	Ortalama mutlak SHAP değeri	Yönsüz etki büyüklüğü	29 · s. 64
DCA	*Decision Curve Analysis*	Karar eğrisi analizi	Maliyet-fayda grafiği	31 · s. 85
EPV	*Events Per Variable*	Değişken başına olay sayısı	10 ölçümle 50 bilinmeyen çözülmez	31 · s. 85
RKÇ (RCT)	*Randomized Controlled Trial*	Randomize kontrollü çalışma	A/B testi	—
GA (CI)	*Confidence Interval*	Güven aralığı	± ölçüm toleransı	—
TRIPOD+AI	*Transparent Reporting of a multivariable prediction model for Individual Prognosis Or Diagnosis + AI*	Tahmin modeli raporlama rehberi	Uçuş öncesi kontrol listesi	—
PROBAST(+AI)	*Prediction model Risk Of Bias ASsessment Tool*	Tahmin modeli yanlılık riski aracı	Muayene istasyonu	—
SPIRIT-AI / CONSORT-AI	*Protokol / rapor rehberleri (YZ müdahaleli RKÇ)*	RKÇ protokol / rapor listesi	Uçuş planı / uçuş raporu	—
DECIDE-AI	*Developmental and Exploratory Clinical Investigations of DEcision support systems driven by AI*	Erken evre canlı kullanım rehberi	Pilot üretim denetimi	—
RoB 2	*Risk of Bias 2*	RKÇ yanlılık riski aracı	Deney düzeneği denetimi	—
KVKK	*Kişisel Verilerin Korunması Kanunu (6698)*	—	“Gizli” etiketli veri	—
EHR / HBYS	*Electronic Health Record*	Elektronik hasta kaydı / hastane bilgi yönetim sistemi	Hastanenin veritabanı	—
FDA / DSÖ (WHO)	*Food and Drug Administration / World Health Organization*	ABD Gıda ve İlaç Dairesi / Dünya Sağlık Örgütü	Sertifikasyon / standart kurumu	—

D.2 Kısaltma kartları dizini

Kartlar notta ilk geçtikleri sırayla numaralanmıştır. Sayfa numaraları Word'de alanlar güncellendiğinde yenilenir.

Tablo D.2. Kısaltma kartları ve sayfaları

No	Kart	Sayfa	No	Kart	Sayfa
1	KDS, YZ, ML, derin öğrenme, XAI	14	**19**	AUC (Area Under the Curve; ROC-AUC, C istatistiği)	41
2	Model, algoritma, eğitim	14	**20**	Prevalans (görülme sıklığı, taban oranı)	44
3	Değişken (özellik, feature) ve hedef (target)	15	**21**	Alarm yorgunluğu (alarm fatigue)	47
4	Olasılık (risk skoru, tahmin edilen risk)	15	**22**	Kalibrasyon (calibration)	49
5	Eşik (threshold, cut-off, kesim noktası)	16	**23**	Brier skoru (Brier score)	49
6	Eğitim seti, test seti ve aşırı öğrenme (overfitting)	22	**24**	PR eğrisi (Precision–Recall) ve AP (Average Precision)	52
7	Çapraz doğrulama (cross-validation, CV)	23	**25**	Orange ekranındaki kısaltmalar: CA, Prec, Recall, F1, AUC, MCC	55
8	Lojistik regresyon (LR, logistic regression)	24	**26**	İç validasyon ve dış validasyon	56
9	Karar ağacı (decision tree)	26	**27**	Değişken önemi (permütasyon önemi)	60
10	Random Forest (RF, rastgele orman) ve bagging	27	**28**	SHAP (SHapley Additive exPlanations) ve şelale grafiği	61
11	XGBoost, boosting ve gradient boosting	28	**29**	SHAP arı kovanı (beeswarm) ve bağımlılık grafiği okuma	64
12	Karışıklık matrisi (confusion matrix): DP, YP, YN, DN	35	**30**	İlişki ≠ nedensellik; karıştırıcı (confounder)	66
13	Duyarlılık (sensitivity, recall, TPR)	36	**31**	Hiperparametre, karar eğrisi analizi (DCA), örneklem ve olay sayısı (EPV)	85
14	Özgüllük (specificity, TNR)	36	**32**	Veri sızıntısı (data leakage)	86
15	PPV — Pozitif Kestirim Değeri (precision, kesinlik)	37	**33**	Veri kayması (dataset shift, drift)	87
16	NPV — Negatif Kestirim Değeri	37	**34**	Alt grup analizi ve yanlılık (bias)	89
17	Doğruluk (accuracy, CA) ve doğruluk tuzağı	38	**35**	Otomasyon yanlılığı (automation bias)	90
18	ROC eğrisi (Receiver Operating Characteristic)	40			

D.3 Kavramlar sözlüğü

Terimler, notta ilk geçtikleri bağlamla uyumlu, sade tanımlarla verilmiştir.

Tablo D.3. Temel kavramlar sözlüğü

Terim	İngilizcesi	Sade tanım	Kart
Algoritma	*Algorithm*	Veriden bir model üretmek için izlenen hesaplama yöntemi; tarif.	2
Model	*Model*	Algoritmanın veriden öğrendiği, yeni hastaya risk hesaplayan sonuç; tarifle pişmiş yemek.	2
Eğitim seti	*Training set*	Modelin öğrendiği hastalar; ders kitabı.	6
Test seti	*Test set*	Modelin hiç görmediği, performansın ölçüldüğü hastalar; kapalı zarftaki sınav.	6
Çapraz doğrulama	*Cross-validation*	Verinin k parçaya bölünüp her parçanın sırayla test olarak kullanılması.	7
Aşırı öğrenme	*Overfitting*	Modelin eğitim verisini ezberleyip yeni hastada başarısız olması.	6
Özellik / değişken	*Feature*	Modelin kullandığı bilgi (yaş, nabız, laktat vb.).	3
Hedef değişken	*Target*	Tahmin edilmek istenen sonuç (ör. 24 saatte sepsis).	3
Sınıflandırma	*Classification*	Hedefin kategorik olduğu tahmin görevi (var/yok).	3

Terim	İngilizcesi	Sade tanım	Kart
Olasılık	*Probability*	Modelin hasta için verdiği 0–1 arası risk değeri.	4
Eşik	*Threshold*	Olasılığın uyarı sayılacağı sınır; klinik bir karardır.	5
Hiperparametre	*Hyperparameter*	Modelin bizim seçtiğimiz ayar düğmeleri (ağaç derinliği, ağaç sayısı).	31
Karışıklık matrisi	*Confusion matrix*	DP, YP, YN ve DN hücrelerinden oluşan 2×2 performans tablosu.	12
Duyarlılık	*Sensitivity, recall*	Olay yaşayanların ne kadarının yakalandığı: DP / (DP + YN).	13
Özgüllük	*Specificity*	Olay yaşamayanların ne kadarının doğru biçimde negatif bulunduğu: DN / (DN + YP).	14
Pozitif kestirim değeri	*PPV, precision*	Uyarı alanların gerçekten olay yaşama oranı; prevalansa bağlıdır.	15
Negatif kestirim değeri	*NPV*	Uyarı almayanların gerçekten güvende olma oranı.	16
Prevalans	*Prevalence*	Olayın toplulukta (veri setinde) görülme sıklığı; taban oranı.	20
Doğruluk	*Accuracy*	Doğru sınıflanan hastaların oranı; nadir olaylarda yanıltıcıdır.	17
F1 skoru	*F1 score*	Duyarlılık ile PPV'nin harmonik ortalaması.	25
ROC eğrisi	*ROC curve*	Tüm eşiklerde duyarlılık ile 1 − özgüllüğün çizimi.	18
AUC	*Area under the curve*	ROC eğrisinin altındaki alan; rastgele bir hastaya sağlamdan yüksek skor verme olasılığı.	19
Kesinlik-duyarlılık eğrisi	*Precision-recall curve*	Tüm eşiklerde PPV ile duyarlılığın çizimi; nadir olaylarda yol gösterir.	24
Ortalama kesinlik	*Average precision (AP)*	PR eğrisinin altındaki alan; kıyas noktası prevalanstır.	24
Kalibrasyon	*Calibration*	Modelin verdiği yüzdelerin gerçekleşen oranlarla uyumu.	22
Ayrım	*Discrimination*	Riskli hastayı risksizden daha yüksek sıraya koyabilme; AUC ile ölçülür.	22
Brier skoru	*Brier score*	Tahmin edilen olasılık ile gerçek sonuç arasındaki ortalama kare fark; düşük olması iyidir.	23
Bagging	*Bootstrap aggregating*	Çok sayıda modelin farklı alt örneklemlerle eğitilip oylanması.	10
Boosting	*Boosting*	Modellerin sırayla, her birinin öncekinin hatasını düzeltecek biçimde eklenmesi.	11
Random Forest	*Random forest*	Bagging ile kurulan karar ağaçları topluluğu.	10
XGBoost	*Extreme gradient boosting*	Boosting ile kurulan, hızlı ve güçlü ağaç topluluğu.	11
Global / yerel açıklama	*Global / local explanation*	Modelin genel davranışının / tek bir hastanın riskinin açıklanması.	27
Değişken önemi	*Feature importance*	Modelin genel olarak hangi değişkenlere dayandığının ölçüsü.	27
SHAP	*SHapley Additive exPlanations*	Riskin değişkenlere adil biçimde paylaştırılmasıyla yapılan açıklama.	28
Karıştırıcı	*Confounder*	Hem maruziyeti hem sonucu etkileyerek ilişkiyi yanıltan üçüncü değişken.	30
Veri sızıntısı	*Data leakage*	Tahmin anında bilinmeyen bilginin modele girmesi; performansı yapay olarak yükseltir.	32
Veri kayması	*Dataset shift*	Zamanla hasta profili, ölçüm ya da kayıt değiştiği için performansın bozulması.	33
İç / dış validasyon	*Internal / external validation*	Modelin aynı verinin ayrılmış parçasında / başka merkez ya da dönemde sınanması.	26
Alt grup analizi	*Subgroup analysis*	Performansın cinsiyet, yaş gibi gruplarda ayrı ayrı ölçülmesi.	34
Yanlılık	*Bias*	Modelin bazı gruplarda sistematik olarak daha kötü çalışması.	34
Alarm yorgunluğu	*Alarm fatigue*	Çok sayıda (çoğu yanlış) uyarı nedeniyle uyarılara duyarlılığın azalması.	21

Terim	İngilizcesi	Sade tanım	Kart
Otomasyon yanlılığı	*Automation bias*	Kendi gözlemi farklı olsa bile sistemin önerisine körü körüne uyma eğilimi.	35
Açıklanabilir YZ	*Explainable AI (XAI)*	Modelin kararlarını insanın anlayabileceği biçimde sunan yöntemler.	1
Karar eğrisi analizi	*Decision curve analysis*	Farklı eşiklerde modelin net klinik yararını gösteren yöntem.	31

Ali AKDAĞLI

D.4 Tıbbi terimler sözlüğü

Veri setlerinde ve vakalarda geçen tıbbi terimlerin tek satırlık hatırlatması. Normal değerler laboratuvara, yaşa ve rehbere göre değişebilen yaklaşık aralıklardır. Ayrıntı için ilgili bölümdeki "Bu kelimeler ne demek?" kutularına bakın.

Tablo D.4. Tıbbi terimler sözlüğü

Terim	Ne demek?	Normal / eşik	Benzetme
Sepsis / septik şok	Enfeksiyona kontrolden çıkmış konak yanıtı ve organ işlev bozukluğu / en ağır hâli	—	Hırsız için evi su basan alarm
Taşikardi / bradikardi	Nabız >100 / <60 atım/dk	60–100 /dk	Motor devri yüksek / rölanti
Takipne	Hızlı soluma (>20 /dk)	12–20 /dk	Turbo hızlı dönüyor
Ateş / hipotermi	≥38 °C / <36 °C	36,5–37,5 °C	Hararet / soğuk motor (U şekli)
Sistolik / diyastolik KB	Büyük / küçük tansiyon	~90–120 / 60–80 mmHg	Pompa tepe / taban basıncı
Hipotansiyon / HT	Düşük / yüksek tansiyon	HT ≥140/90 mmHg	Üst kata su çıkmıyor / borular zorlanıyor
OAB (MAP)	Ortalama arter basıncı ≈ (S + 2D) / 3	~70–100 mmHg	Zaman ortalamalı basınç
SpO2	Periferik oksijen satürasyonu	%95–100	Kamyonların doluluk oranı
GKS (GCS)	Glasgow Koma Skalası, 3–15	15	Sistem durum kodu
Laktat	Oksijensiz metabolizma ürünü	<2 mmol/L	Egzozdan kara duman
Lökosit (WBC)	Beyaz kan hücresi	4–11 ×10³/µL	Güvenlik ekibi
Kreatinin	Kas metabolizması atığı; böbrek işlevi	~0,6–1,2 mg/dL	Filtre kiri
eGFR	Tahmini glomerüler filtrasyon hızı	≥90 mL/dk/1,73 m²	Filtre debisi
Trombosit (PLT)	Pıhtılaşma hücresi	150–400 ×10³/µL	Yol tamir ekibi
İmmünsupresyon	Bağışıklığın baskılanması	—	Güvenliğin yarısı izinde
Üriner kateter	Kalıcı idrar sondası	—	Kale duvarında açık kapı
qSOFA	SS ≥22, SKB ≤100, GKS <15 → her biri 1 puan	≥2 = yüksek risk	3 lambadan 2'si yanıyorsa servise
NEWS2 / SIRS	Vital bulgu puanlama skoru / eski inflamatuvar yanıt ölçütleri	—	Vardiya kontrol listesi
Perfüzyon	Dokuların kanla beslenmesi	—	Hammadde akışı
Diyabet tip 1 / tip 2	İnsülin yok / insülin direnci	Açlık glukozu 70–99 mg/dL	Anahtar yok / kilit paslı
OGTT	75 g glukoz sonrası 2. saat plazma glukozu	<140 mg/dL	Yük sonrası toparlanma testi
HbA1c	Son 2–3 ayın ortalama glisemisi	<%5,7 (tedavi hedefi çoğunlukla <%7)	Mevsimin ortalama sıcaklığı
BKİ (BMI)	kg / m²	18,5–24,9	Boyuta göre normalize yük
Nöropati / monofilament	Sinir hasarı / koruyucu duyu testi	Hissediyor	Kopuk sensör kablosu / süreklilik testi
ABİ	Ayak bileği / kol sistolik basınç oranı	0,9–1,3	İki musluk basınç oranı
Ülser / Wagner	Açık yara / derinlik evresi 0–5	—	Lastikteki fark edilmeyen çivi
PAH	Periferik arter hastalığı	ABİ ≥0,9	Tıkalı boru
Malnütrisyon / GLIM	Yetersiz beslenme / fenotipik + etiyolojik tanı ölçütleri	—	Belirti + neden kanıtı
Albümin	Plazma proteini (inflamasyondan etkilenir)	3,5–5,0 g/dL	Yanlış okunan gösterge

Terim	Ne demek?	Normal / eşik	Benzetme
Baldır çevresi	Kas kütlesi göstergesi	≥31 cm (yaşlı)	Mezurayla kas ölçümü
Barthel indeksi	Günlük yaşam aktivitelerinde bağımsızlık	100 = tam bağımsız	Çalışan fonksiyon sayısı
Disfaji / demans	Yutma güçlüğü / bilişsel gerileme	—	Daralan besleme hattı
Polifarmasi	Çok sayıda ilacın birlikte kullanımı	—	Aynı anda çok yazılım
Preeklampsi / eklampsi	≥20. hafta yeni HT + organ etkilenmesi / nöbet eklenmesi	Verimizde %5,5	Dar döşenmiş boru hattı
Nullipar / multipar	Hiç doğum yapmamış / birden çok doğum yapmış	—	İlk kez çalışan sistem
Uterin arter PI	Uterin arter akış direnci (Doppler)	≈1,0 MoM	Boru direnci
PlGF / PAPP-A	Plasenta kaynaklı proteinler	≈1,0 MoM (düşük = risk)	İnşaat ilerleme raporu
MoM	Ölçüm / aynı haftanın ortancası	1,0	Nominal değerin yüzdesi
Trimester / preterm	Üç aylık gebelik dönemi / 37. haftadan önce	—	Proje fazı / erken teslim
Aspirin / ASPRE	Düşük doz aspirin profilaksisi / preterm PE ~%62 azalma	—	Önleyici bakım
Mortalite / morbidite	Ölüm oranı / hastalık ve komplikasyon oranı	—	Toplam kayıp / arıza oranı

Ali AKDAĞ

Ek E. Formüller kopya kâğıdı (tek sayfa)

1. Karışıklık matrisi (sütun = gerçek, satır = alarm)

	Gerçek hasta	Gerçek sağlam	Toplam
Alarm	DP = 54	YP = 61	115
Sessiz	YN = 35	DN = 750	785
Toplam	89	811	900

2. Dört temel ölçüt (payda = neyden başlıyorum?)

Duyarlılık = DP / (DP + YN) = 54 / 89 = **%60,7** (hastalardan)
Özgüllük = DN / (DN + YP) = 750 / 811 = **%92,5** (sağlamlardan)
PPV = DP / (DP + YP) = 54 / 115 = **%47** (alarmlardan)
NPV = DN / (DN + YN) = 750 / 785 = **%95,5** (sessizliklerden)
Doğruluk = (DP + DN) / N = 804 / 900 = %89,3 · tembel model 811 / 900 = %90,1
F1 = 2DP / (2DP + YP + YN) = 108 / 204 ≈ 0,53
Yanlış alarm oranı = 1 − özgüllük = 61 / 811 = %7,5
Prevalans = (DP + YN) / N = 89 / 900 = %9,9

3. Prevalans → PPV (2×2 tarifi)

Hasta = N × prevalans · DP = hasta × duyarlılık · DN = sağlam × özgüllük
%2, Se = Sp = %85, N = 1000 → 17 DP, 147 YP → PPV 17/164 = **%10,4**
%30, aynı model → 255 DP, 105 YP → PPV 255/360 ≈ **%71**
%5, Se %80, Sp %90 → 40 DP, 95 YP, 10 YN, 855 DN → PPV 40/135 = **%29,6**, NPV 855/865 = **%98,8**

4. Eşik tablosu (XGBoost, sepsis)

%5: Se %91 · Sp %67,2 · 38,6 uyarı/100 · PPV %23,3
%10: Se %82 · Sp %83,1 · 23,3 uyarı/100 · PPV %34,8
%20: Se %60,7 · Sp %92,5 · 12,8 uyarı/100 · PPV %47
%30: Se %46,1 · Sp %95,4 · 8,7 uyarı/100 · PPV %52,6
%50: Se %34,8 · Sp %98,4 · 4,9 uyarı/100 · PPV %70,5

5. ROC ve AUC

ROC: x = 1 − özgüllük, y = duyarlılık; her eşik bir nokta
AUC = hastanın önde olduğu eşleşme / toplam eşleşme
Turnuva: 21 / 25 = 0,84 · Sepsis: LR 0,86 · ağaç 0,84 · RF 0,88 · XGB 0,89
0,5 yazı-tura · 0,7–0,8 kabul · 0,8–0,9 iyi · >0,9 mükemmel (>0,9'da sızıntıdan şüphelen)

6. PR ve AP

x = duyarlılık, y = PPV · AP'nin kıyas noktası = prevalans
Preeklampsi (%5,5): AUC 0,77 / 0,75 · AP 0,21 / 0,19 · rastgele AP ≈ 0,055

7. Kalibrasyon ve Brier

Brier = ortalama (tahmin − gerçek)² · küçük = iyi
Tek hasta: (0,68 − 1)² = 0,1024 · olay olmasaydı (0,68 − 0)² = 0,4624
Modeller ≈ 0,061 · dengelenmiş XGB 0,097
Abartı oranı = ortalama tahmin / gerçek oran = 24,3 / 9,9 ≈ 2,5

8. SHAP ve oylama

Başlangıç %6,7 + 19 + 12 + 11 + 9 + 5 + 5 + 2 − 2 − 1 + ≈1 ≈ **%68**
Random Forest oyu: 5 / 7 ≈ %71

9. Klinik hesaplar

qSOFA: SS ≥22 (1) + SKB ≤100 (1) + GKS <15 (1); ≥2 pozitif · örnek: 1 + 0 + 1 = 2
OAB ≈ (sistolik + 2 × diyastolik) / 3 · 120/80 → ≈93 mmHg
BKİ = kg / m² · 70 / 1,75² ≈ 22,9
MoM = ölçülen değer / o gebelik haftasının ortancası
ABİ = ayak bileği sistolik KB / kol sistolik KB (normal 0,9–1,3)
Alt grup çözünürlüğü = 1 / n (≥80 yaş: 1 / 18 ≈ 5,6 puan)

10. Beş cümle

Duyarlılık hastalardan, PPV alarmlardan başlar.
Nadir olayda alarmların çoğu boştur.
AUC sıralamadır; kalibrasyon terazinin sıfır ayarıdır.
SHAP bir bordrodur; nedeni değil, modelin gerekçesini söyler.
Model öneriyor, hemşire/ebe karar veriyor.

Ek F. Kendinizi Sınayın: cevap anahtarı

Bölüm 1

1. Braden skalasında kuralı (maddeler, puanlar, eşik) uzmanlar yazar ve kural sabittir. Makine öğrenmesi modelinde kural geçmiş hasta verisinden algoritma tarafından çıkarılır; daha çok değişken ve etkileşim kullanılabilir, sonuç bir olasılıktır.
2. Aşırı öğrenme (overfitting). Model eğitim hastalarını ezberlemiş, yeni hastalara genellenememiştir. Geçerli performans test hastalarındaki değerdir (0,70).
3. Random Forest'ta ağaçlar birbirinden bağımsız, farklı hasta ve değişken alt kümeleriyle eğitilir ve oylanır (bagging). XGBoost'ta ağaçlar sırayla kurulur ve her yeni ağaç öncekilerin hatalarını düzeltir (boosting).
4. GKS 15, 14,5'ten büyük olduğu için kökte “Hayır” dalına gidilir; nabız 98 ≤ 103,5 olduğu için “Evet”; laktat 1,4 ≤ 2,15 olduğu için yine “Evet”. Hasta, hastaların %77,1'inin düştüğü yaprağa düşer; bu yapraktaki sepsis oranı %4'tür ve ağacın kararı “Sepsis yok”tur.
5. Hayır. %35 bir olasılıktır. Uyarı olup olmayacağı seçilen eşiğe bağlıdır (ör. eşik %20 ise uyarı üretir), ve son karar klinik değerlendirmeyle verilir.
6. ML = Machine Learning (makine öğrenmesi); XAI = eXplainable Artificial Intelligence (açıklanabilir yapay zekâ); RF = Random Forest (rastgele orman); XGBoost = eXtreme Gradient Boosting (aşırı gradyan artırma); CV = Cross-Validation (çapraz doğrulama).
7. 5 katlı çapraz doğrulamada veri 5 parçaya bölünür ve her parça sırayla bir kez test olarak kullanılır; sonunda 3000 hastanın tamamı bir kez “sınava girmiş” olur (296 sepsis). Bu nottaki 900 hastalık sonuçlar ise baştan ayrılmış tek bir test setinden gelir (Kart 7).
8. GKS'nin normali 15'tir; 13 hafif bilinç değişikliğidir (qSOFA ölçütü). Laktatın normali <2 mmol/L'dir; 1,6 normaldir. Solunum sayısının normali 12–20/dk'dır; 24 takipnedir (qSOFA eşiği ≥22). Üçünden yalnızca laktat normaldir.
9. “Hastanın bilinci tam mı, yani GKS 15 mi?” sorusunu sorar. GKS tam sayı olduğu için ağaç iki komşu değerin (14 ve 15) ortasından keser: ≤ 14,5 = “15 değil” = en ufak bir bilinç değişikliği var.

Bölüm 2

1. Duyarlılık = 30 / (30 + 10) = %75. PPV = 30 / (30 + 70) = %30.
2. AUC bir sıralama başarısıdır (rastgele bir hastaya sağlam kişiden daha yüksek skor verme olasılığı), doğru sınıflandırılan hasta oranı değildir.
3. Ortopedi servisinde. Duyarlılık ve özgüllük aynı kalsa bile prevalans düştükçe yanlış pozitiflerin payı artar ve PPV düşer.
4. Duyarlılık %82'den %46,1'e düşer; 100 hastadaki uyarı sayısı 23,3'ten 8,7'ye iner. Alarm yükü azalır ama sepsis hastalarının yarısından fazlası kaçırılır.
5. Model iyi sıralıyor ama kötü kalibre: riski yaklaşık 2,5 kat abartıyor. Kalibrasyon grafiğinde (Şekil 2.6) eğri köşegenden sapar; Brier skoru da kötüleşir (0,097).
6. PPV = Positive Predictive Value (pozitif kestirim değeri); NPV = Negative Predictive Value (negatif kestirim değeri). 54/115 = PPV (%47): payda bütün alarmlardır. 750/785 = NPV (%95,5): payda bütün sessizliklerdir, yani modelin “yok” dediği hastalar. Ölçütler farklı yerden başladığı için paydaları farklıdır.
7. ROC = Receiver Operating Characteristic (alıcı işletim karakteristiği). y ekseni duyarlılık (yakalama oranı), x ekseni 1 − özgüllük (yanlış alarm oranı).
8. AP = Average Precision (ortalama kesinlik). Rastgele bir modelin AP'si yaklaşık prevalans kadardır, yani ≈ 0,055: rastgele verilen alarmların gerçek olma oranı olayın sıklığına eşittir. 0,21 rastgeleden belirgin iyidir, ama alarmların çoğu yine yanlıştır.

Ali AKDAĞLI

9. $(0{,}10 - 0)^2 = 0{,}01$. Model %90 deseydi $(0{,}90 - 0)^2 = 0{,}81$ olurdu: emin konuşup yanılan model çok daha fazla cezalandırılır.
10. CA = doğruluk (classification accuracy); Prec = PPV, kesinlik (precision); Recall = duyarlılık.

Bölüm 3

1. Global açıklama modelin genel olarak neye baktığını gösterir (ör. permütasyon önemi, arı kovanı grafiği). Yerel açıklama tek bir hastanın riskinin nedenlerini gösterir (ör. şelale grafiği).
2. %6,7, hiçbir bilgi yokken ortalama hastanın riski (başlangıç); %68 modelin bu hasta için verdiği risk. Aradaki fark değişkenlerin SHAP katkılarının toplamıdır.
3. Düşük sistolik KB değerleri riski artırıyor demektir; bu, hipotansiyonun sepsisteki yeriyle uyumludur.
4. SHAP modelin gerekçesini açıklar, nedenselliği değil. Ateş enfeksiyonun bir belirtisidir; ateşi düşürmek altta yatan süreci değiştirmez.
5. Tedaviye uyum, sağlık okuryazarlığı ve düzenli izlem gibi karıştırıcılar. Eğitim alanlar zaten daha uyumlu hastalar olabilir.
6. SHAP = SHapley Additive exPlanations (Shapley toplamsal açıklamaları). Brüt maaş = başlangıç (ortalama) risk E[f(X)] = %6,7; kalemler = değişkenlerin + / − katkıları (ateş +19, nabız +12…); net maaş = modelin bu hasta için riski f(x) = %68.
7. Kırmızı, yüksek GKS değerini (15, tam bilinç) gösterir; noktaların solda olması bu değerin riski azalttığı anlamına gelir. Renk değerin büyüklüğünü, konum riske etkisini gösterir; GKS'de yüksek değer klinik olarak iyidir, dolayısıyla "kırmızı = kötü" genellemesi yanlıştır.
8. MoM (multiple of the median), ölçülen değerin aynı gebelik haftasındaki ortanca değere oranıdır. 0,5 MoM beklenenin yarısı demektir. PlGF'de düşük değer plasental damar gelişiminin yetersiz olabileceğini düşündürür ve preeklampsi riskini artırır.
9. ABİ'nin normali 0,9–1,3'tür. 0,7 periferik arter hastalığını, yani ayağa giden kanlanmanın azaldığını düşündürür; yara iyileşmesi bozulur ve ülser riski artar.
10. En az bir fenotipik ölçüt (istemsiz kilo kaybı, düşük BKİ, kas kütlesinde azalma; modelde kilo kaybı, BKİ, baldır çevresi) ile en az bir etiyolojik ölçüt (besin alımında azalma ya da hastalık/inflamasyon; modelde besin alımı azalması).

Bölüm 4

1. Raporlama için TRIPOD+AI; yanlılık riski değerlendirmesi için PROBAST veya PROBAST+AI.
2. 4. soru (veri sızıntısı). Kan kültürü istemi, klinisyenin sepsisten zaten şüphelendiğini gösterir; tahmin anında "cevabın" bir kısmını modele vermek performansı yapay olarak yükseltir.
3. Veri kayması: yeni cihaz, yeni protokol, değişen hasta profili ya da kayıt alışkanlıkları. Çözüm: sürekli izleme, yeniden kalibrasyon veya yeniden eğitim, yerel validasyon.
4. Yalnızca 18 hastaya dayandığı için güvenilir değildir; birkaç hastanın farklı sınıflanması yüzdeyi büyük ölçüde değiştirir (1 hasta ≈ 5,6 puan). Güven aralığıyla raporlanmalı, daha büyük örneklemde doğrulanmalıdır.
5. Özel nitelikli kişisel veri. Açık rıza veya kanuni istisna, anonimleştirme, veri minimizasyonu, etik kurul onayı ve kurum izni gözetilmelidir.
6. TRIPOD+AI bir raporlama rehberidir: kendi tahmin modeli makalenizi yazarken neleri raporlayacağınızı söyler. PROBAST(+AI) bir yanlılık riski ve uygulanabilirlik değerlendirme aracıdır: başkasının çalışmasını eleştirel okurken kullanılır.
7. EPV = Events Per Variable (değişken başına olay sayısı). Sepsis verisinde 3000 hastanın yalnızca 296'sında olay vardır; modelin asıl öğrendiği bu 296 olaydır. Örneklem yeterliliğini hasta sayısı değil olay sayısı belirler (Riley ve ark., 2020).
8. RKÇ = randomize kontrollü çalışma (RCT, Randomized Controlled Trial). Yüksek AUC yalnızca modelin hastaları iyi ayırdığını gösterir; hasta sonucunun iyileştiğini (nedenselliği) göstermek için modelin kullanıldığı ve

Ali AKDAĞLI

kullanılmadığı grupların kurayla karşılaştırılması (ya da benzeri bir etki çalışması) gerekir. Böyle bir çalışma CONSORT-AI ile raporlanır.

Ek G. Kaynakça

Kaynaklar Vancouver biçiminde verilmiştir. Metin içinde (Yazar, yıl) biçiminde atıf yapılmıştır.

1. de Dombal FT, Leaper DJ, Staniland JR, McCann AP, Horrocks JC. Computer-aided diagnosis of acute abdominal pain. BMJ. 1972;2(5804):9–13.
2. Shortliffe EH. Computer-Based Medical Consultations: MYCIN. New York: Elsevier; 1976.
3. Knaus WA, Zimmerman JE, Wagner DP, Draper EA, Lawrence DE. APACHE—acute physiology and chronic health evaluation: a physiologically based classification system. Crit Care Med. 1981;9(8):591–597.
4. Royal College of Physicians. National Early Warning Score (NEWS) 2: Standardising the assessment of acute-illness severity in the NHS. London: RCP; 2017.
5. Singer M, Deutschman CS, Seymour CW, et al. The Third International Consensus Definitions for Sepsis and Septic Shock (Sepsis-3). JAMA. 2016;315(8):801–810.
6. Seymour CW, Liu VX, Iwashyna TJ, et al. Assessment of clinical criteria for sepsis. JAMA. 2016;315(8):762–774.
7. Wong A, Otles E, Donnelly JP, et al. External validation of a widely implemented proprietary sepsis prediction model in hospitalized patients. JAMA Intern Med. 2021;181(8):1065–1070.
8. Adams R, Henry KE, Sridharan A, et al. Prospective, multi-site study of patient outcomes after implementation of the TREWS machine learning-based early warning system for sepsis. Nat Med. 2022;28(7):1455–1460.
9. Abràmoff MD, Lavin PT, Birch M, Shah N, Folk JC. Pivotal trial of an autonomous AI-based diagnostic system for detection of diabetic retinopathy in primary care offices. NPJ Digit Med. 2018;1:39.
10. Breiman L. Random forests. Mach Learn. 2001;45(1):5–32.
11. Chen T, Guestrin C. XGBoost: A scalable tree boosting system. In: Proceedings of the 22nd ACM SIGKDD; 2016:785–794.
12. Lundberg SM, Lee SI. A unified approach to interpreting model predictions. Adv Neural Inf Process Syst. 2017;30:4765–4774.
13. Van Calster B, McLernon DJ, van Smeden M, Wynants L, Steyerberg EW. Calibration: the Achilles heel of predictive analytics. BMC Med. 2019;17(1):230.
14. Christodoulou E, Ma J, Collins GS, Steyerberg EW, Verbakel JY, Van Calster B. A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. J Clin Epidemiol. 2019;110:12–22.
15. Obermeyer Z, Powers B, Vogeli C, Mullainathan S. Dissecting racial bias in an algorithm used to manage the health of populations. Science. 2019;366(6464):447–453.
16. Collins GS, Moons KGM, Dhiman P, et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. BMJ. 2024;385:e078378.
17. Wolff RF, Moons KGM, Riley RD, et al. PROBAST: A tool to assess the risk of bias and applicability of prediction model studies. Ann Intern Med. 2019;170(1):51–58.
18. Moons KGM, Damen JAA, Kaul T, et al. PROBAST+AI: an updated quality, risk of bias, and applicability assessment tool for prediction models using regression or artificial intelligence methods. BMJ. 2025;388:e082505.
19. Liu X, Cruz Rivera S, Moher D, Calvert MJ, Denniston AK; SPIRIT-AI and CONSORT-AI Working Group. Reporting guidelines for clinical trial reports for interventions involving artificial intelligence: the CONSORT-AI extension. Nat Med. 2020;26(9):1364–1374.
20. Cruz Rivera S, Liu X, Chan AW, et al. Guidelines for clinical trial protocols for interventions involving artificial intelligence: the SPIRIT-AI extension. Nat Med. 2020;26(9):1351–1363.
21. Vasey B, Nagendran M, Campbell B, et al. Reporting guideline for the early-stage clinical evaluation of decision support systems driven by artificial intelligence: DECIDE-AI. Nat Med. 2022;28(5):924–933.
22. Riley RD, Ensor J, Snell KIE, et al. Calculating the sample size required for developing a clinical prediction model. BMJ. 2020;368:m441.

AI AKDAĞI

23. Vickers AJ, Elkin EB. Decision curve analysis: a novel method for evaluating prediction models. Med Decis Making. 2006;26(6):565–574.

24. Steyerberg EW. Clinical Prediction Models: A Practical Approach to Development, Validation, and Updating. 2nd ed. Cham: Springer; 2019.

25. Rajkomar A, Dean J, Kohane I. Machine learning in medicine. N Engl J Med. 2019;380(14):1347–1358.

26. Topol EJ. High-performance medicine: the convergence of human and artificial intelligence. Nat Med. 2019;25(1):44–56.

27. Kelly CJ, Karthikesalingam A, Suleyman M, Corrado G, King D. Key challenges for delivering clinical impact with artificial intelligence. BMC Med. 2019;17(1):195.

28. Smith JW, Everhart JE, Dickson WC, Knowler WC, Johannes RS. Using the ADAP learning algorithm to forecast the onset of diabetes mellitus. Proc Annu Symp Comput Appl Med Care. 1988:261–265.

29. Demšar J, Curk T, Erjavec A, et al. Orange: Data mining toolbox in Python. J Mach Learn Res. 2013;14:2349–2353.

30. Cederholm T, Jensen GL, Correia MITD, et al. GLIM criteria for the diagnosis of malnutrition: a consensus report from the global clinical nutrition community. Clin Nutr. 2019;38(1):1–9.

31. Kondrup J, Rasmussen HH, Hamberg O, Stanga Z; Ad Hoc ESPEN Working Group. Nutritional risk screening (NRS 2002): a new method based on an analysis of controlled clinical trials. Clin Nutr. 2003;22(3):321–336.

32. Rolnik DL, Wright D, Poon LC, et al. Aspirin versus placebo in pregnancies at high risk for preterm preeclampsia. N Engl J Med. 2017;377(7):613–622.

33. Schaper NC, van Netten JJ, Apelqvist J, et al. Practical guidelines on the prevention and management of diabetic foot disease (IWGDF 2023 update). Diabetes Metab Res Rev. 2024;40(3):e3657.

34. Reyna MA, Josef CS, Jeter R, et al. Early prediction of sepsis from clinical data: the PhysioNet/Computing in Cardiology Challenge 2019. Crit Care Med. 2020;48(2):210–217.

35. Johnson AEW, Bulgarelli L, Shen L, et al. MIMIC-IV, a freely accessible electronic health record dataset. Sci Data. 2023;10(1):1.

36. World Health Organization. Ethics and governance of artificial intelligence for health: WHO guidance. Geneva: WHO; 2021.

37. Regulation (EU) 2024/1689 of the European Parliament and of the Council laying down harmonised rules on artificial intelligence (Artificial Intelligence Act). Off J Eur Union. 2024.

38. 6698 sayılı Kişisel Verilerin Korunması Kanunu. Resmî Gazete. 7 Nisan 2016; Sayı: 29677.

Ali AKDAĞLI