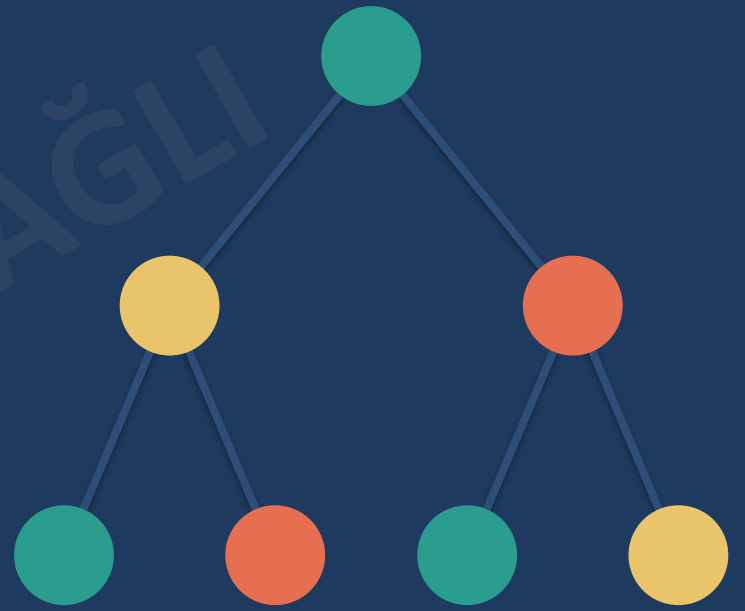
Sağlık Bilimleri Fakültesi

Öğretim Elemanları için Yapay Zekâ Eğitimi



Modül 2

Karar Destek Sistemleri ve Tahminleyici Modelleme

Prof. Dr. Ali AKDAĞLI

12 saat · 4 oturum × 3 saat · Uygulama aracı: Orange Data Mining

Ali AKDAĞLI · 2026

BUGÜNÜN TEK BÜYÜK FİKRİ

Model bir duman dedektörüdür.



Hastanın verisini “koklar”, bir risk sayısı üretir, seçtiğimiz sınırı geçerse öter. Bütün kısaltmalar bu dedektörün karnesidir.

Prof. Dr. Ali AKDAĞLI

1 Sensör

Hastanın verisi: nabız, ateş, laktat… Model bunları okur.

2 Hassasiyet düğmesi

Eşik: risk kaçı geçince ötsün? Düğmeyi biz ayarlarız.

3 Karne

Duyarlılık, özgüllük, PPV, AUC, kalibrasyon: dedektörün **notları**.

4 Ev sahibi

Öttüğünde ne yapılacağına **hemşire ve ebe** karar verir.

Modülün haritası: dört oturum, dört soru

1 Oturum 1

Makine nasıl öğrenir?

Kural mı, deneyim mi?

- KDS'nin kısa tarihi
- 4 algoritma, 4 benzetme
- Orange: ilk karar ağacı

2 Oturum 2

Model çıktısını okumak

Model ne kadar iyi?

- Karışıklık matrisi
- ROC/AUC, PPV, eşik
- Kalibrasyon

3 Oturum 3

Neden bu hasta?

Açıklanabilirlik

- Değişken önemi
- SHAP grafikleri
- 4 klinik vaka

4 Oturum 4

Klinik araştırmaya

Kanıttan uygulamaya

- TRIPOD+AI, PROBAST
- Etik, KVKK, yanlılık
- Araştırma önerisi

Model öneriyor, hemşire/ebe karar veriyor.

Dedektör dili: nasıl yapılır → karnesi → neden öttü → evimize kurmadan önce.

Prof. Dr. Ali AKDAĞLI

Kısaltma kartları nasıl okunur?

Ab

Kısaltma → Türkçe

Önce kısaltma, sonra İngilizce açılımı ve **Türkçesi**, sonra **tek cümlelik** tanım.

⚙

Üç benzetme

⚙ mühendislik · ⌂ günlük hayat · ✚ klinik. **Biri tutmazsa diğeri** tutar.

#

Bizim veriden

Her kavram, kendi sepsis verimizden **bir sayıya** bağlanır.

✚

Hatırlatma kutusu

Tıbbi terimler için kısa **ortak tanım**; zaten bildiğinizi tazeler.

Anlaşılmayan bir kısaltma olursa çekinmeden sorabilirsiniz; kartı birlikte yeniden okuruz.

Prof. Dr. Ali AKDAĞLI

Uygulama veri setlerimiz

Veri seti	n	Tahmin edilen sonuç	Prevalans
Sepsis (sentetik)	3000	Sepsis, 24 saat içinde	%9,9
Diyabet – Pima (gerçek, açık veri)	768	Diyabet var/yok	%34,9
Diyabetik ayak (sentetik)	2000	Ülser, 12 ay içinde	%12
Malnütrisyon (sentetik)	1500	Malnütrisyon (GLIM)	%27,7
Preeklampsi (sentetik)	4000	Preeklampsi, 11–13. hafta taraması	%5,5

Prof. Dr. Ali AKDAĞLI

Sentetik veri gerçek hasta içermez; klinik bilgiyle tasarlanmıştır ve yalnızca öğretim amaçlıdır.

OTURUM 1

1

Makine nasıl “öğrenir”?

Kuraldan veriye: dört algoritma, dört klinik benzetme

Prof. Dr. Ali AYDAĞLI

00:00 Kavram

01:00 Uygulama

02:00 Vaka ve tartışma

Bu oturumun hedefleri

1. Kural tabanlı KDS ile öğrenen sistemi ayırt etmek
2. Eğitim/test ayrımının neden gerektiğini açıklamak
3. LR, karar ağacı, RF ve XGBoost'u birer klinik benzetmeyle anlatmak
4. Orange'da veri setini açıp karar ağacını okumak

Prof. Dr. Ali AKDAĞLI

Bugünün akışı

00:00	Kavramsal anlatım
00:50	Ara
01:00	Orange uygulaması
01:50	Ara
02:00	Vaka, tartışma, özet

KISALTMA KARTI

KDS

Clinical Decision Support System

Karar destek sistemi

Karar anında bilgi ve öneri sunan, ama kararı klinisyenin yerine vermeyen sistem.

Mühendislik

Şerit takip uyarısı: şeritten çıkınca direksiyon titrer; direksiyonu yine sürücü çevirir.

Günlük hayat

Yol tarifi uygulaması: "sağa dönün" der; trafiğe bakıp karar veren sizsiniz.

Klinik

Braden skalası: risk puanı verir; önlemi hemşire planlar.

qSOFA = 3 soru

Bizim veriden: Üç "evet"ten **en az ikisi** varsa uyarı veren, insan yazımı bir KDS.

Dedektör dili: KDS = evdeki duman dedektörü; öter ama yangını söndüren sizsiniz.

Prof. Dr. Ali AKDAĞLI

KDS'yi zaten kullanıyorsunuz

B

Braden · Morse

Basınç yarası ve düşme riski. Puanları insan belirledi.

N

NEWS2 · qSOFA

Yaşamsal bulgulardan uyarı puanı. Eşikler uzman kararı.

A

APGAR · Glasgow

Yenidoğan ve bilinç değerlendirmesi. Sabit kurallar.

ML

Makine öğrenmesi

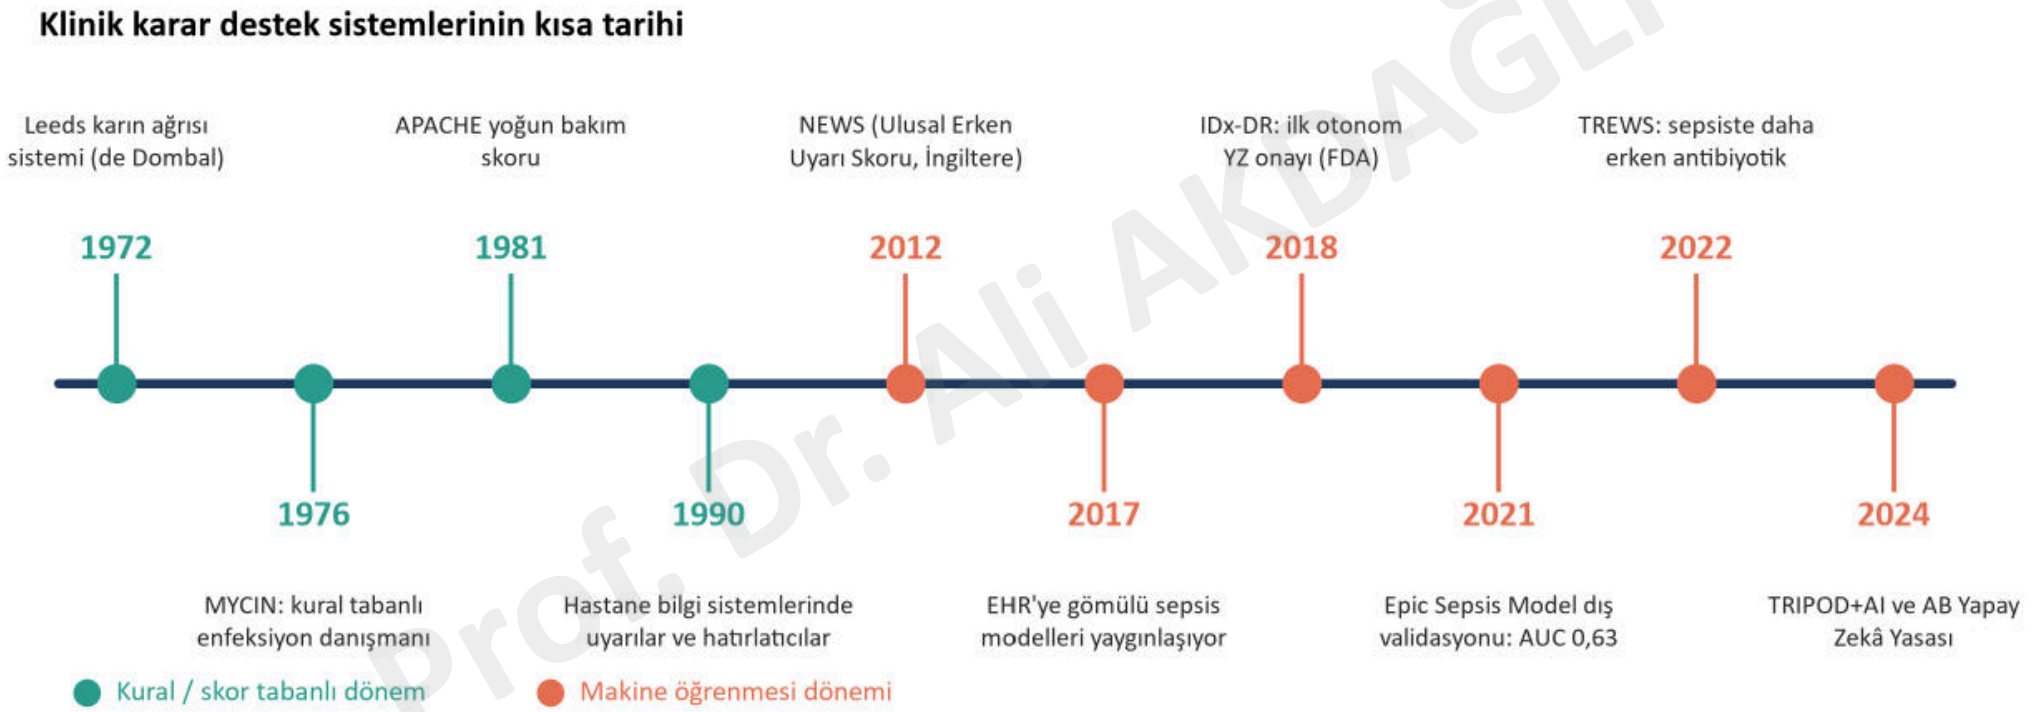
Kuralı insan yazmaz; **kuralı veriden çıkarır.**

Ortak nokta: hepsi bir karar destek aracı. Fark: kuralı kim yazıyor?

Dedektör dili: Braden, qSOFA, NEWS2 de birer dedektör; ama ayarlarını insan yaptı.

Prof. Dr. Ali AKDAĞLI

Klinik KDS'nin kısa tarihi

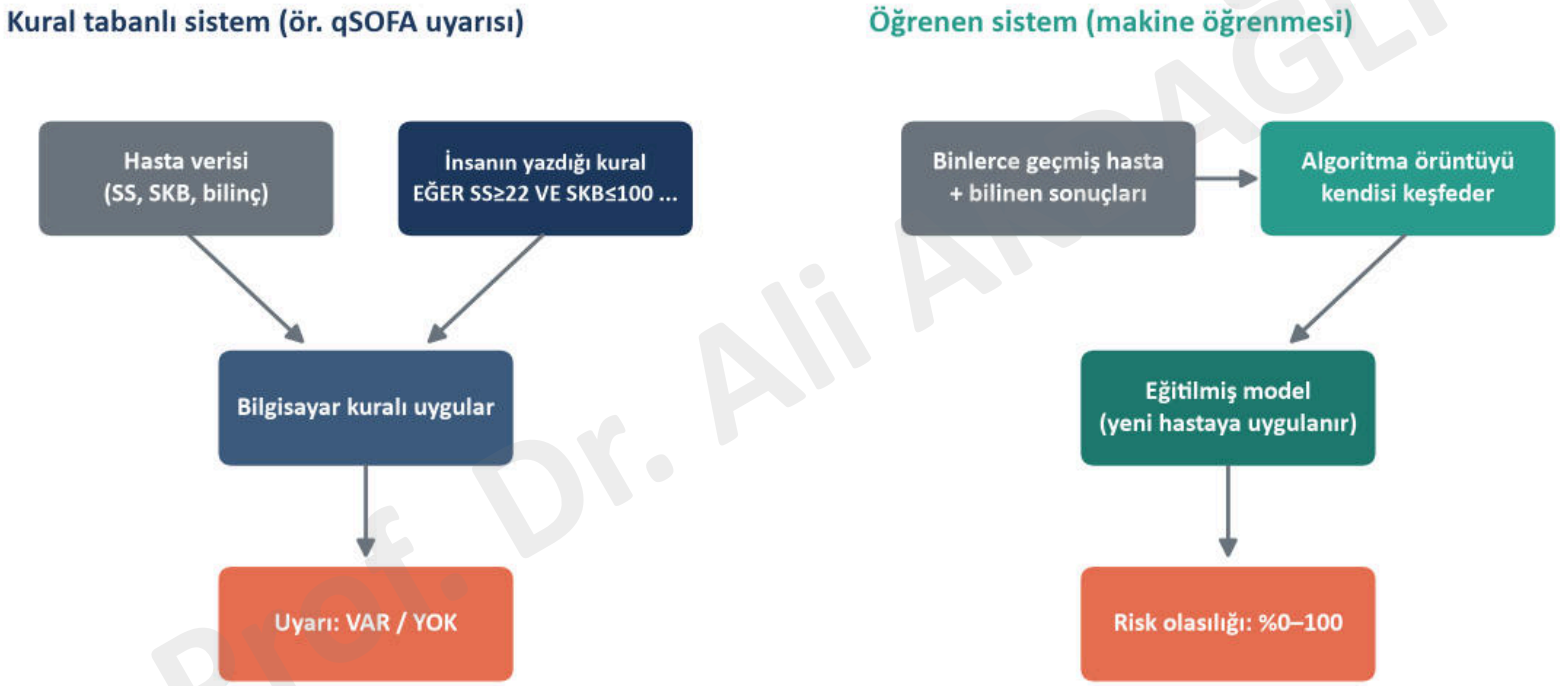


Şekil 1.1 · 1972 Leeds → 2024 TRIPOD+AI ve AB YZ Yasası

1. 1972–1990: **kural ve skor** dönemi
2. 2012 sonrası: **makine öğrenmesi** dönemi
3. 2021 Epic ve 2022 TREWS: ikisine de döneceğiz

Prof. Dr. Ali AKDAĞLI

Kural tabanlı mı, öğrenen mi?



Prof. Dr. Ali ARSAĞLI

Şekil 1.2 · Kural tabanlı sistem ve öğrenen sistem

1. Kural: insan yazar → **Var/Yok** uyarısı
2. Öğrenen: kuralı veriden çıkarır
3. Çıktı: **%0–100 risk olasılığı**

Dedektör dili: öğrenen sistem önce "ne kadar duman var?" der; ötüp ötmemeyi eşik belirler.

Benzetme: öğrenmek = deneyim kazanmak

1

Deneyimli hemşire

Binlerce hasta gördü. “Bu hasta iyi değil” der ve çoğu zaman haklıdır.

2

Model

Binlerce kayıttan örüntü çıkarır. Sonucu bir **risk olasılığı** olarak verir.

!

Önemli fark

Model **yalnızca gösterilen vakalardan** öğrenir. Yeni ortamda deneyimsizdir.

Prof. Dr. Ali AKDAĞLI

Makine öğrenmesinin altı adımı

Sizin rolünüz özellikle 1., 5. ve 6. adımlarda belirleyici: doğru veri, doğru soru, doğru yorum



Prof. Dr. Ali KIDAĞLI

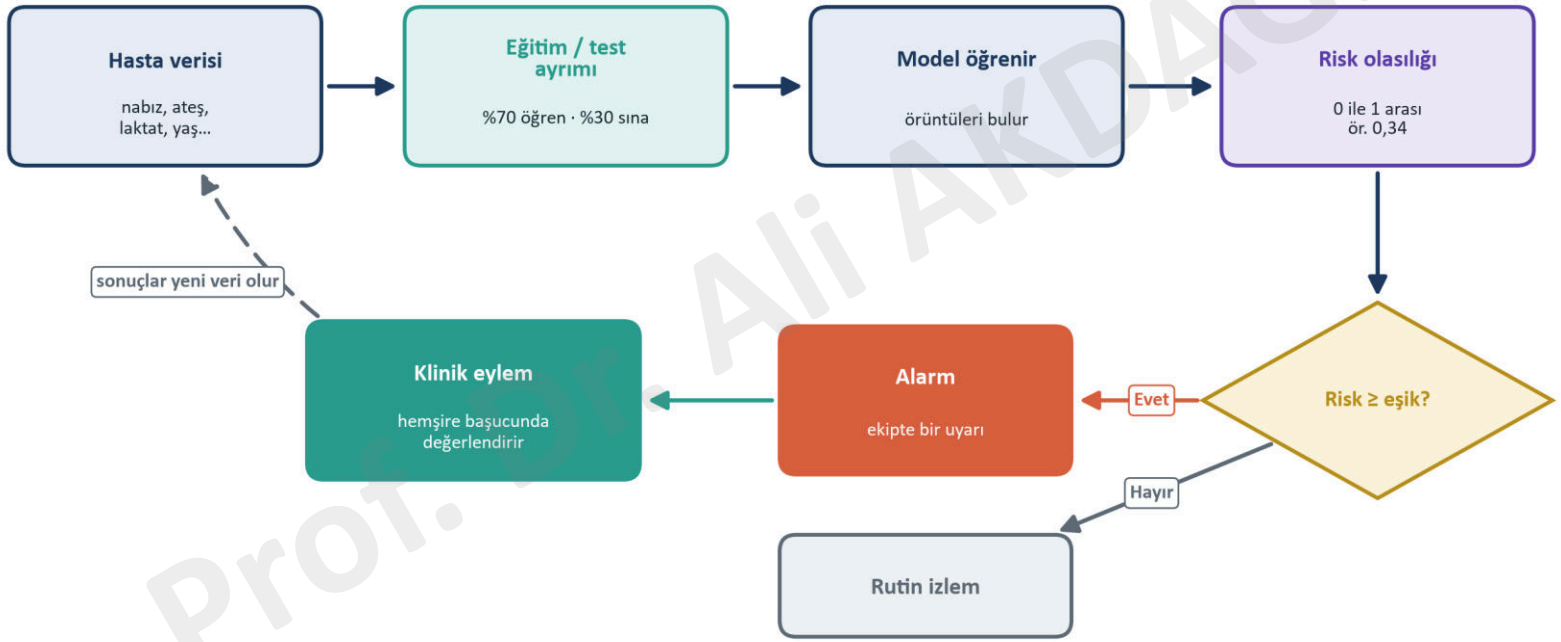
Şekil 1.3 · Veriden klinik yoruma altı adım

1 Teknik adımlar: 2, 3, 4

2 **Sizin rolünüz: 1, 5 ve 6**

3 Doğru veri, doğru soru, doğru yorum

Bir tahminin yolculuğu



Akış 1.1 · Veri → model → olasılık → eşik → karar → klinik eylem

1. Model bir **olasılık** üretir; karar **eşikte** verilir

2. Eşik bir **klinik tercih**tir

3. Son söz her zaman **klinisyenin**

Prof. Dr. Ali AKDAĞLI

KAVRAM KARTI

Değişken · Hedef

Feature (variable) · Target (outcome)

Modelin girişleri · tahmin edilen sonuç

Değişkenler modele giren bilgilerdir; hedef, modelin tahmin etmeye çalıştığı sonuçtur.

Mühendislik

Sensör kanalları ve sistem çıkışı: girişler x, çıkış y; model y = f(x) ilişkisini öğrenir.

Günlük hayat

İkinci el araba: kilometre, yıl, hasar kaydı → "iki yılda arıza yapar mı?"

Klinik

Vital bulgular → sonuç: nabız, ateş, laktat → "24 saatte sepsis gelişecek mi?"

15 değişken · 1 hedef

Bizim veriden: 3000 hasta; hedef "Sepsis (24 saat)": **Evet / Hayır**. Orange'da Role = target.

Prof. Dr. Ali AKDAĞLI

Sepsis nedir? Savunmanın kendisi zarar verir

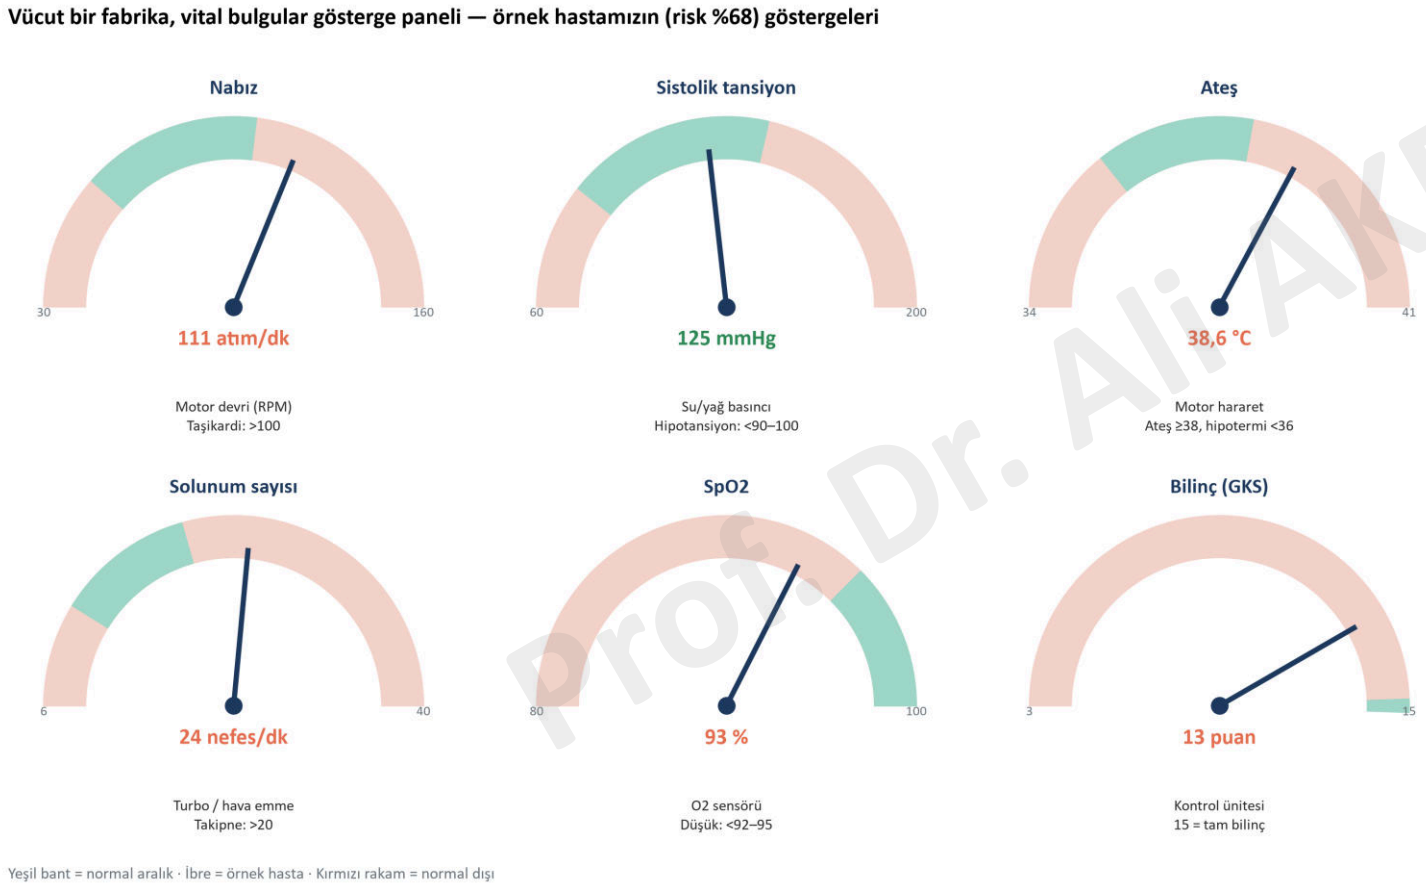


Şekil · Sepsisin basitleştirilmiş zinciri (ev benzetmesi)

1. Mikrop girer: **hırsız**
2. Bağışıklık aşırı tepki: **fıskiyeler evi su basar**
3. Erken fark etmek **hayat kurtarır**

Dedektör dili: sepsis = yangın. Modelin işi yangını erken koklamak.

Vücut bir fabrika: vital bulgular göstergedir



Şekil · Örnek hastamızın (risk %68) gösterge paneli

1. Nabız = **motor devri**
2. Ateş = **hararet** · SpO2 = **oksijen sensörü**
3. GKS = **kontrol ünitesi** (15 tam bilinç)
4. Yeşil bant = normal aralık

Prof. Dr. Ali AKDAĞLI

HATIRLATMA KUTUSU

Bu kelimeler ne demek? · Sepsis verisi (1)

Nabız · taşikardi
Dakikadaki kalp atımı; normal 60–100. Taşikardi: 100'ün üstü.
≈ motor devri (RPM)

Solunum sayısı · takipne
Dakikadaki nefes; normal 12–20. qSOFA: ≥22 → 1 puan.
≈ turbonun dönüş hızı

Ateş · hipotermi
≥38 °C ateş, <36 °C hipotermi. Sepsiste **iki yön de** tehlikeli.
≈ hararet göstergesi

Sistolik KB · hipotansiyon
Büyük tansiyon (120/80'deki 120). qSOFA: ≤100 mmHg → 1 puan.
≈ su şebekesinin basıncı

SpO2
Kandaki oksijen doygunluğu, parmak mandalıyla. Normal %95–100.
≈ kamyonların yüzde kaçı dolu gidiyor

GKS (Glasgow Koma Skalası)
Bilinç puanı 3–15. 15 = tam bilinç; 13–14 = hafif bulanıklık.
≈ sistemin durum kodu

Prof. Dr. Ali AKDAĞLI

HATIRLATMA KUTUSU

Bu kelimeler ne demek? · Sepsis verisi (2)

Laktat
Oksijen yetmeyince oluşan atık. Normal <2 mmol/L; 2–4 dikkat; >4 ciddi.
≈ egzozdan çıkan kara duman

Lökosit
Savunma hücreleri; normal 4–11 bin. Enfeksiyonda artar, ağır sepsiste düşebilir.
≈ güvenlik ekibi

Kreatinin
Kas atığı; böbrek süzer. Yüksekse böbrek iyi süzmüyor (~0,6–1,2 mg/dL).
≈ arıtma filtresindeki kir

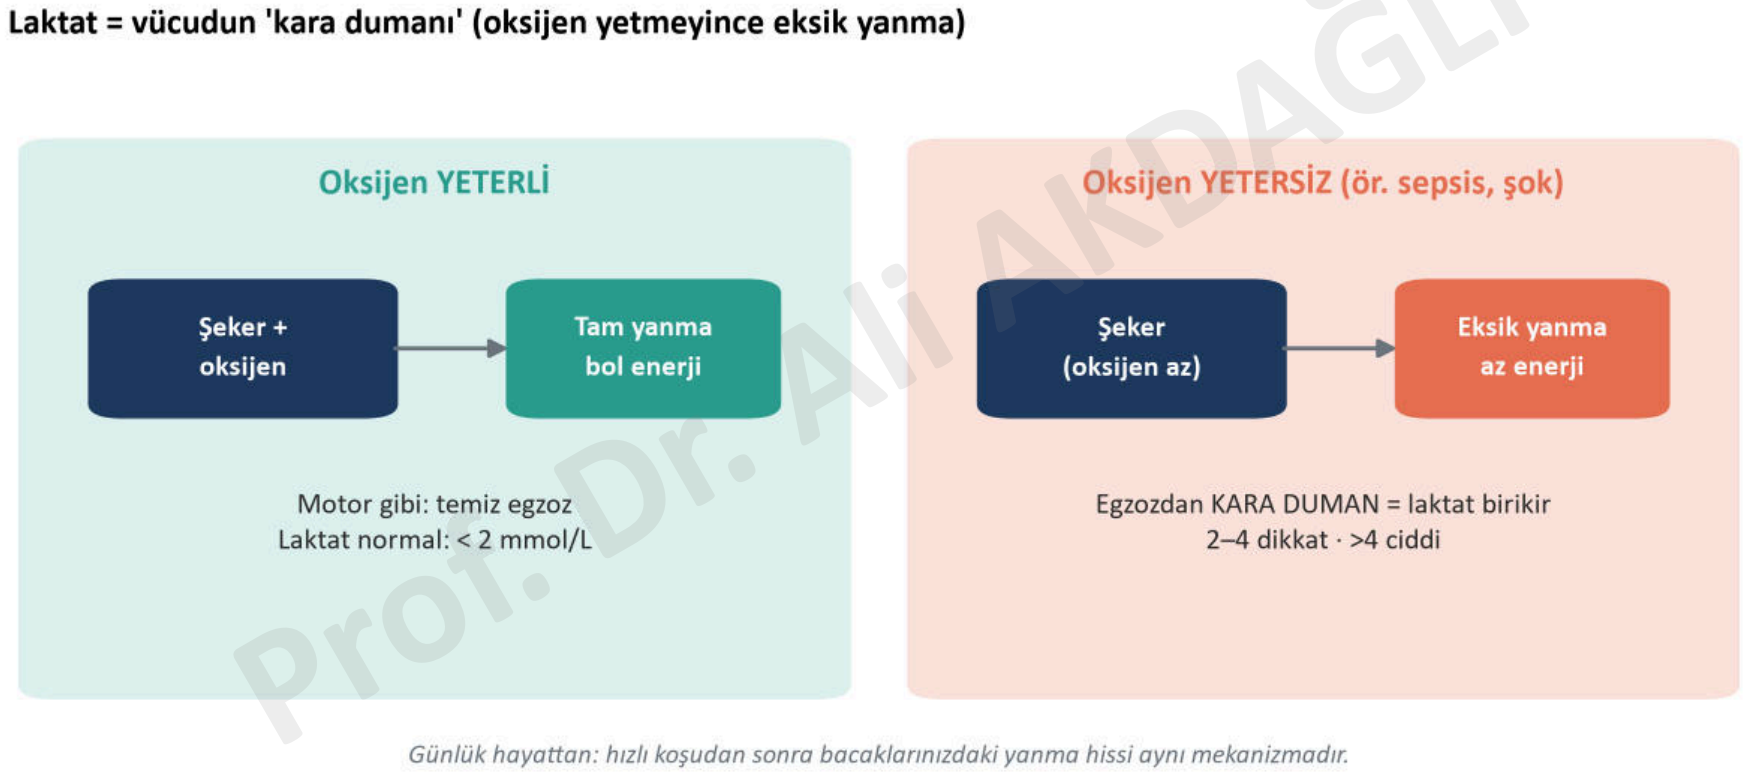
Trombosit
Kanamayı durduran hücreler; normal 150–400 bin. Sepsiste düşebilir.
≈ yol tamir ekibi

İmmünsupresyon
Bağışıklığın ilaç ya da hastalıkla baskılanması (kemoterapi, nakil).
≈ güvenlik ekibinin yarısı izinde

Üriner kateter
Mesaneye takılan idrar sondası; mikroplar için bir giriş yolu.
≈ dış dünyaya açık kapı

Prof. Dr. Ali AKDAĞLI

Laktat = vücudun “kara dumanı”



Prof. Dr. Ali AKDAĞLI

Şekil · Oksijen yetmeyince eksik yanma: laktat

1. Oksijen yeterli: **temiz egzoz**, laktat <2
2. Oksijen az: **kara duman**, laktat birikir
3. 2–4 mmol/L dikkat · >4 ciddi

Dedektör dili: laktat, gerçek bir duman sensörü gibidir; ama tek başına yetmez.

Eğitim ve test: soruyu önceden vermemek

Ezberleyen öğrenci = aşırı öğrenme

- Soruları önceden gördü, **100 aldı**
- Yeni soruda başarısız olur
- Model eğitim verisinde mükemmel görünür

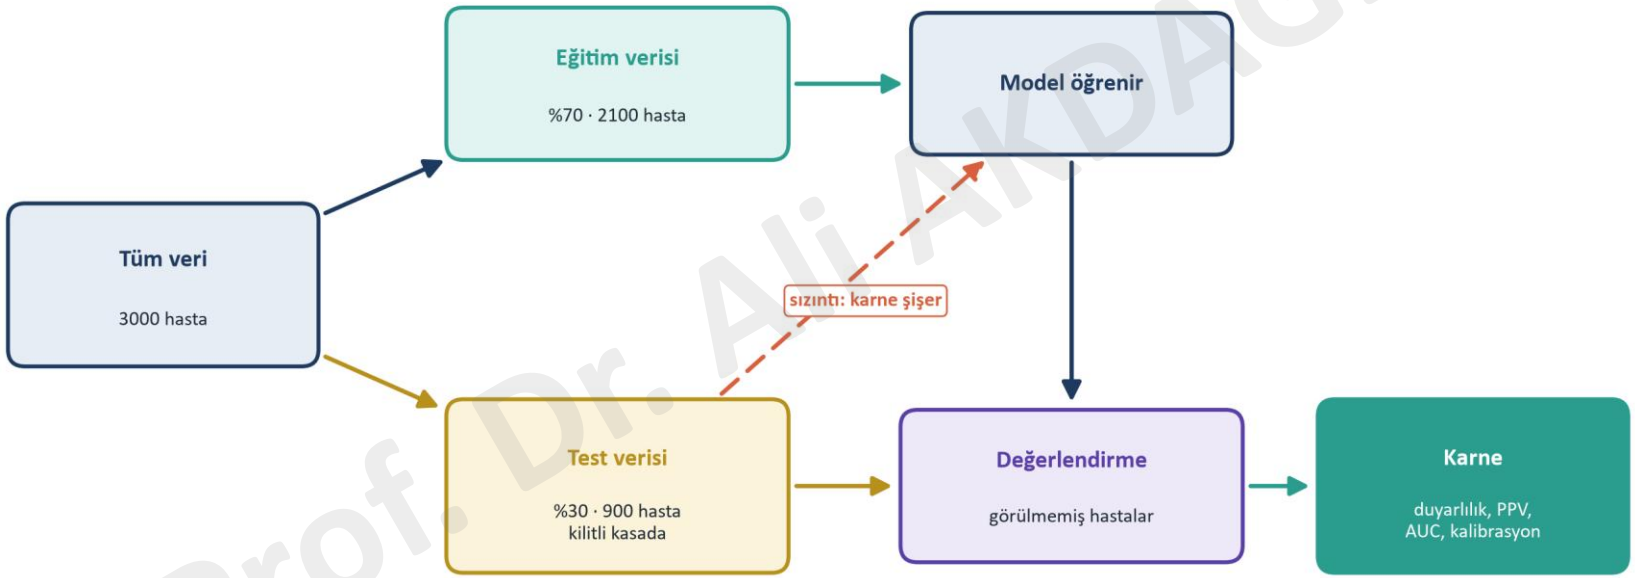
Öğrenen öğrenci = iyi model

- Eğitim verisi = ders kitabı
- Test verisi = **hiç görülmemiş** sorular
- Çapraz doğrulama = 5 ayrı sınavın ortalaması

Prof. Dr. Ali AKBAĞLI

Modelin gerçek başarısını yalnızca görmediği veri söyler.

Eğitim/test ayrımı adım adım



Prof. Dr. Ali AKDAĞLI

Akış 1.2 · 3000 hasta → 2100 eğitim + 900 test → karne

1. Test verisi **kilitli kasada** bekler
2. Karne yalnızca **görülmemiş** hastalarla çıkarılır
3. Sızıntı karneyi **haksız yere şişirir**

KAVRAM KARTI

Aşırı öğrenme

Overfitting

Ezberleme

Model konuyu öğrenmek yerine eğitim verisini gürültüsüyle ezberler: eğitimde mükemmel, yeni hastada kötü.

Mühendislik

Eğri uydurma: 12 gürültülü noktaya 11. derece polinom: her noktadan geçer, aralarda çılgınca salınır.

Günlük hayat

Garaj sürücüsü: yalnızca kendi garajına park edebilir; başka otoparkta duvara çarpar.

Klinik

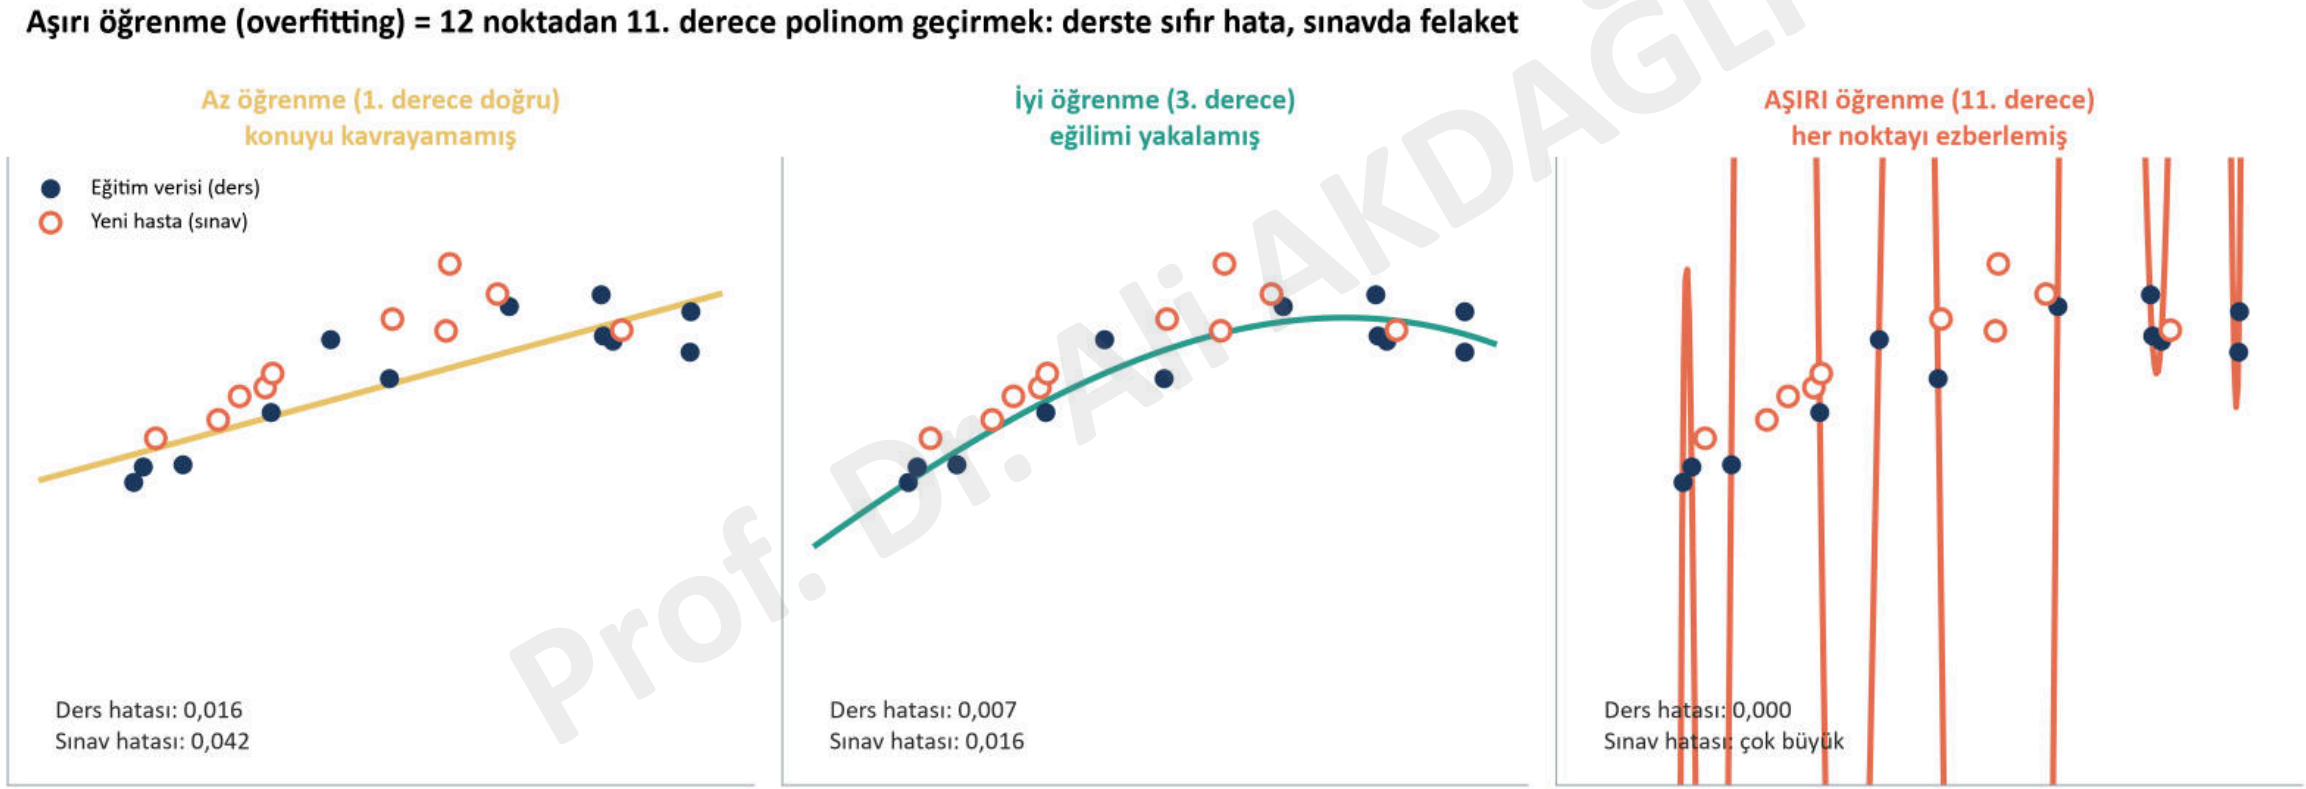
Tek servis deneyimi: yalnız kendi servisini tanıyan çalışan, başka hastanede şaşırır.

2100 / 900

Bizim veriden: Hastaların 2100'ü eğitime, **900'ü teste**: bütün başarı sayılarımız modelin görmediği 900 kişiden.

Prof. Dr. Ali AKDAĞLI

Aşırı öğrenme = eğriyi noktalara zorlamak

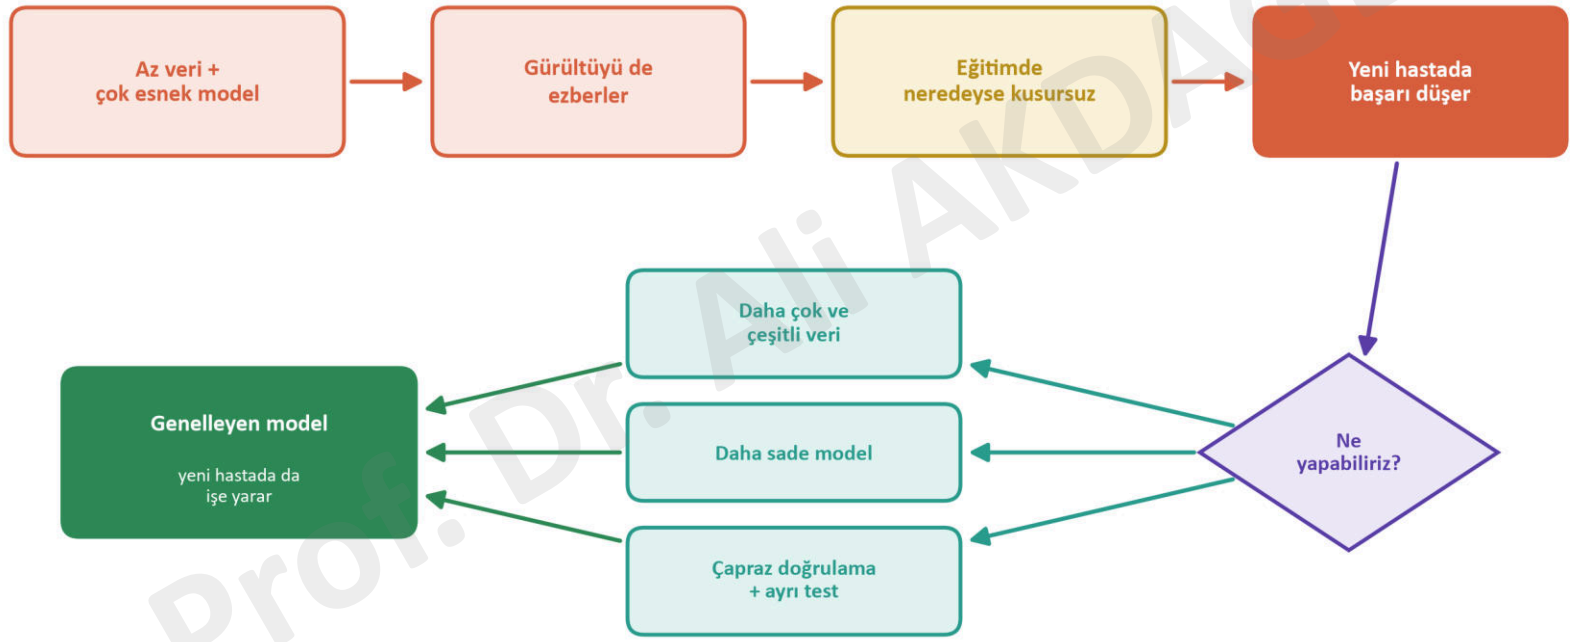


Şekil · Aynı veriye üç eğri: az, iyi ve aşırı öğrenme

1. Az öğrenme: **konuyu kaçırır**
2. İyi öğrenme: **eğilimi yakalar**
3. Aşırı öğrenme: derste 0 hata, **sınavda felaket**

Prof. Dr. Ali AKDAĞLI

Ezberden genellemeye



Akış 1.3 · Sorunun zinciri ve üç çözüm yolu

1. Eğitimde kusursuz, yeni hastada **zayıf**: ezber işareti

2. Çözüm: **veri**, **sadelik**, **dürüst sınama**

3. Hedef: **genelleyen** model

Prof. Dr. Ali AKDAĞLI

KAVRAM KARTI

Çapraz doğrulama

Cross-validation (k-fold)

Beş ayrı sınavın ortalaması

Veri 5 parçaya bölünür; her turda bir parça sınav, dördü ders olur; 5 sınavın ortalaması alınır.

Mühendislik

Tekrarlı ölçüm: bir ölçümü 5 kez yapıp ortalamak; tek ölçüme güvenmemek.

Günlük hayat

Beş sınav: öğrenciyi tek sınavla değil, beş farklı sınavla değerlendirmek.

Klinik

Beş nöbet: bir hemşirenin becerisini tek nöbette değil, beş nöbette gözlemek.

5 kat

Bizim veriden: Orange'daki **Test and Score** = 5 katlı çapraz doğrulama. Sayılar slayttakilerden **biraz farklı** çıkabilir.

Prof. Dr. Ali AKDAĞLI

KISALTMA KARTI

LR

Logistic Regression

Lojistik regresyon

Her değişkene bir ağırlık verilir, toplanır; toplam S eğrisiyle 0–1 arası bir olasılığa çevrilir.

Mühendislik

Doyumlu yükselteç / dimmer: ağırlıklı toplam, çıkış 0 ile 1 arasında doyar (S eğrisi).

Günlük hayat

Kredi notu: gelir +puan, borç −puan; toplam puan "onay olasılığına" çevrilir.

Klinik

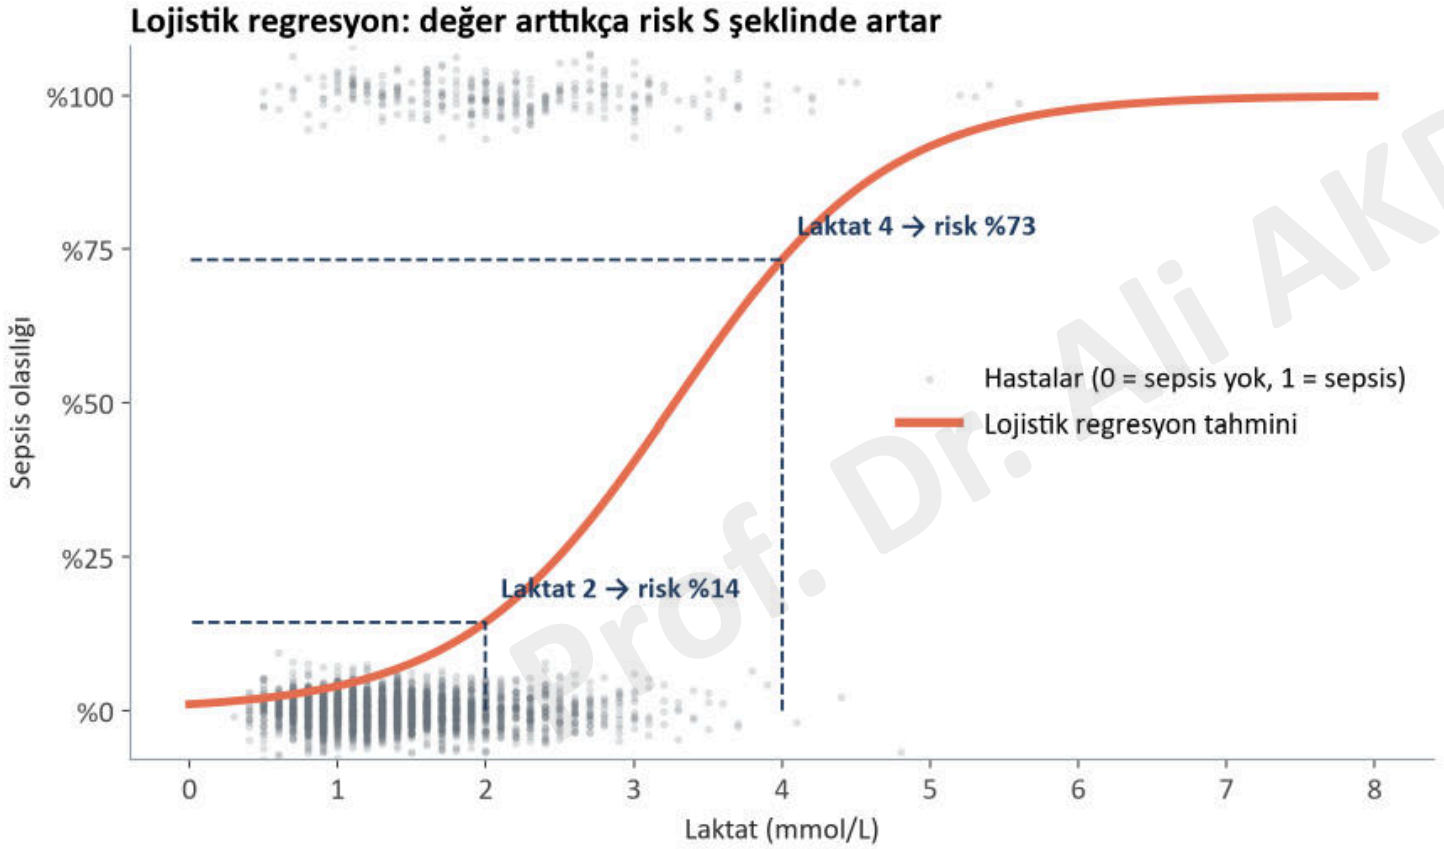
Braden skalası: maddeler puanlanıp toplanır; farkı, puanlar **veriden** öğrenilir.

%14 → %73

Bizim veriden: Yalnız laktatla: laktat **2** mmol/L'de risk %14, laktat **4**'te risk %73.

Prof. Dr. Ali AKDAĞLI

Lojistik regresyon = Braden skalası



Şekil 1.4 · Laktata göre sepsis riski (S eğrisi)

%14

Laktat 2 mmol/L'de risk

%73

Laktat 4 mmol/L'de risk

Ağırlıklı toplam → S eğrisi → olasılık

Şeffaf, iyi kalibre, güçlü kıyas noktası

Prof. Dr. Ali AKDAĞLI

KAVRAM KARTI

Karar ağacı

Decision tree

Evet/hayır soruları zinciri

Hastaları her adımda bir evet/hayır sorusuyla ikiye ayıran, sonunda karar veren soru zinciri.

Mühendislik

İç içe if-else / arıza akış şeması: "Güç ışığı yanıyor mu? Hayır → sigortaya bak."

Günlük hayat

Yirmi soru oyunu: her soru olasılıkları yarıya indirir.

Klinik

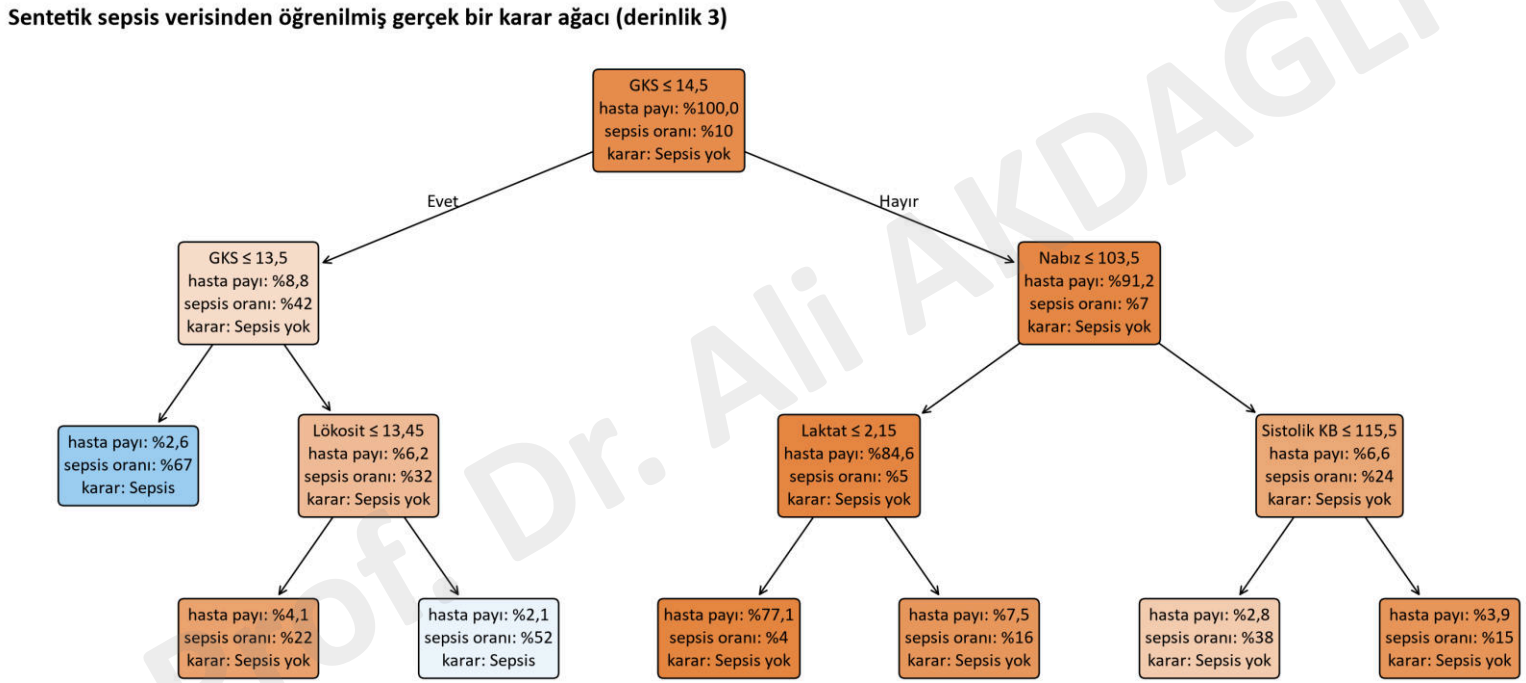
Triaj akış şeması: acil serviste adım adım sorularla öncelik belirlemek.

GKS ≤ 14,5 ?

Bizim veriden: Ağacımızın **ilk sorusu**: bilinçte en ufak değişiklik var mı? Model bunu kendisi seçti.

Prof. Dr. Ali AKDAĞLI

Karar ağacı = triaj akış şeması



Prof. Dr. Ali AKDAĞLI

Şekil 1.5 · Sentetik sepsis verisinden öğrenilmiş karar ağacı (derinlik 3)

1 Kök: **GKS ≤ 14,5** (bilinç değişikliği)

2 Sonra: nabız ≤ 103,5 ve laktat ≤ 2,15

3 Okunması kolay ama tek başına **kararsız**

KISALTMA KARTI

RF

Random Forest

Rastgele orman

Her biri farklı hastaları ve değişkenleri gören yüzlerce karar ağacının oylaması.

Mühendislik

Üçlü yedekli sensör: biri saçmalarsa çoğunluk onu bastırır; ortalama gürültüyü azaltır.

Günlük hayat

Kalabalığın bilgeliği: kavanozdaki şekerleri tahmin eden kalabalığın ortalaması isabetlidir.

Klinik

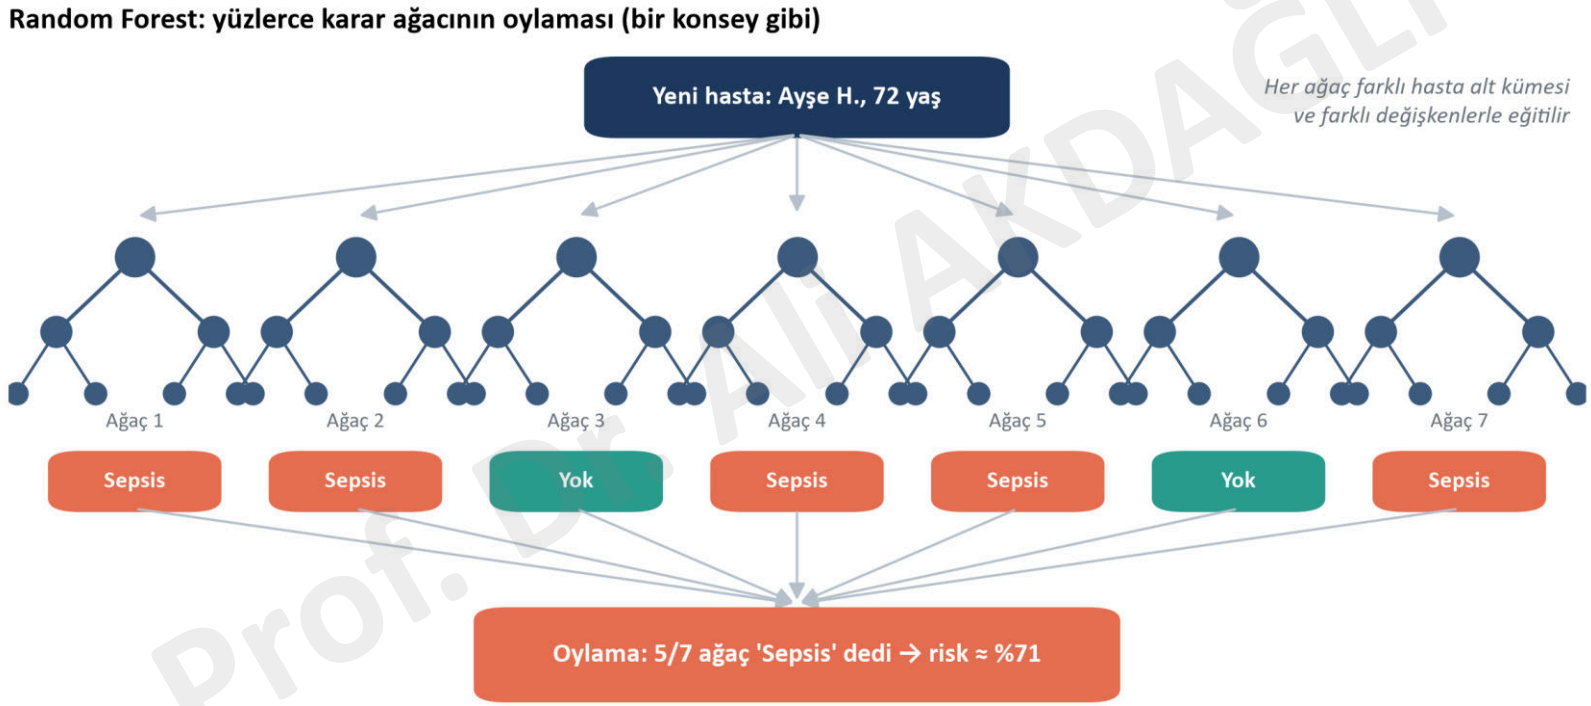
Konsey kararı: tek uzman yerine birçok uzmanın oyu; “500 hemşirenin oylaması”.

AUC 0,88

Bizim veriden: Sepsis verisinde Random Forest'ın ayırma gücü (Oturum 2'de AUC'yi açacağız).

Prof. Dr. Ali AKDAĞLI

Random Forest = konsey oylaması



Prof. Dr. Ali AKDAĞLI

Şekil 1.6 · Random Forest: 7 ağaçtan 5'i "sepsis" diyor

1. Her ağaç farklı hastaları ve değişkenleri görür
2. **5/7 ağaç "sepsis" → risk ≈ %71**
3. Bagging = kalabalığın bilgeliği

KISALTMA KARTI

XGBoost

eXtreme Gradient Boosting

Aşırı gradyan artırma

Ağaçlar sırayla kurulur; her yeni ağaç öncekilerin toplam hatasını küçültmeye çalışır.

Mühendislik

Kapalı çevrim / ardışık yaklaşım: her adımda hatayı ölç, düzelt; Newton-Raphson gibi köke yaklaş.

Günlük hayat

Golf: ilk vuruş yeşile getirir, kısa vuruşlar deliğe adım adım yaklaştırır.

Klinik

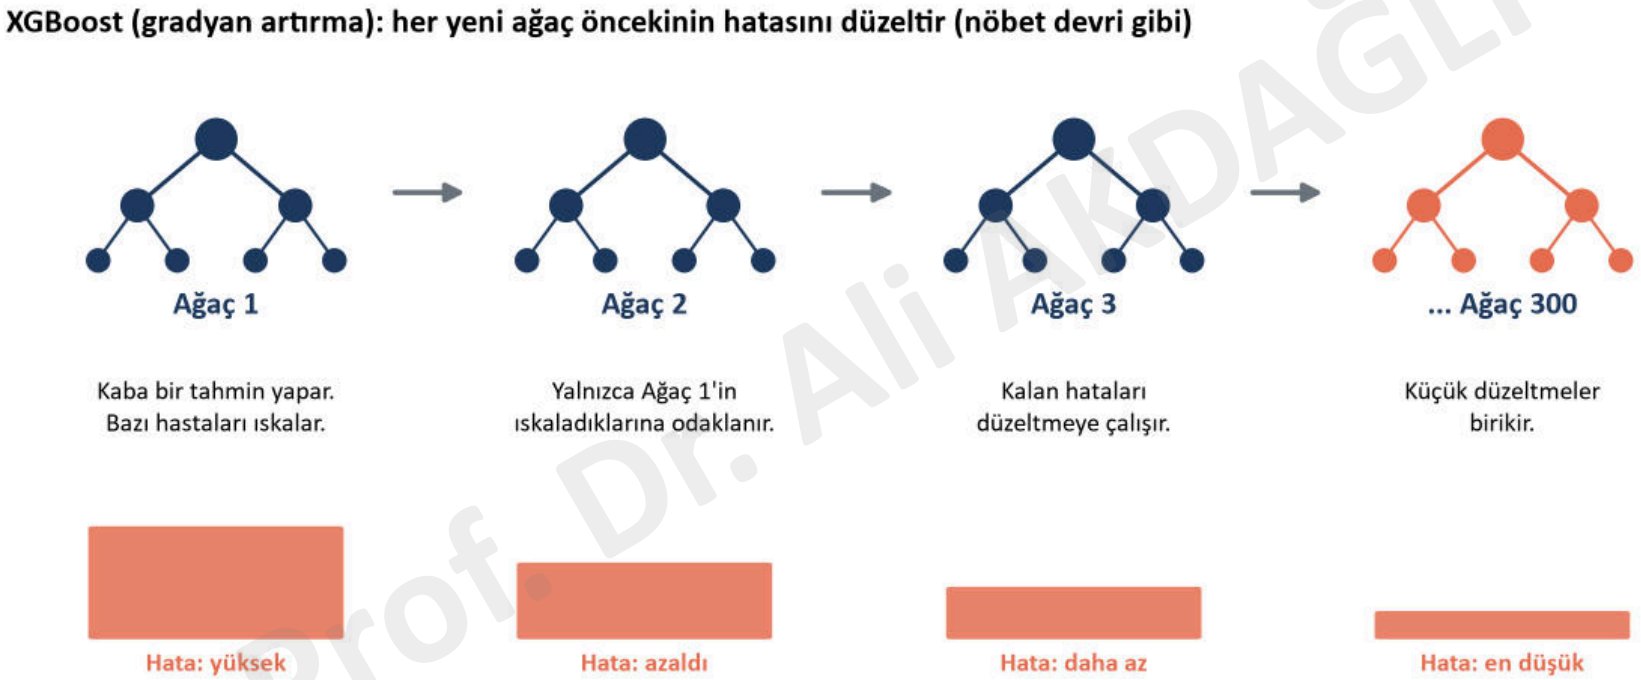
Nöbet devri zinciri: her ekip öncekinin kaçırdığına odaklanır.

AUC 0,89

Bizim veriden: Sepsiste en yüksek AUC; ama LR 0,86 ile **çok yakın**. Orange'daki adı: Gradient Boosting.

Prof. Dr. Ali AKDAĞLI

XGBoost = nöbet devri zinciri



Prof. Dr. Ali AKDAĞLI

Şekil 1.7 · Boosting: her yeni ağaç öncekinin hatasını düzeltir

1. Ağaçlar **sırayla** çalışır
2. Her ağaç öncekinin ıskaladığına odaklanır
3. Orange'daki adı: **Gradient Boosting**

Dört algoritma yan yana

Algoritma	Benzetme	Güçlü yanı	Zayıf yanı	Sepsis AUC
Lojistik regresyon	Braden skalası	Şeffaf, iyi kalibre	Karmaşık ilişkileri kaçırabilir	0,86
Karar ağacı	Triaj şeması	Okuması çok kolay	Kararsız, veriye duyarlı	0,84
Random Forest	Konsey oylaması	Sağlam, güçlü	Açıklaması zor	0,88
XGBoost	Nöbet devri	Tablo verisinde güçlü	Açıklaması zor, ayar ister	0,89

Prof. Dr. Ali AKDAĞLI

Fark küçük: **karmaşık her zaman kazanmaz** (Oturum 2'de beş veri setinde göreceğiz).

Hepsi bir risk olasılığı üretir

0–1

Her model bir **risk olasılığı** verir

Eşik

Evet/hayır kararı **sizin seçtiğiniz eşikte** verilir

Prof. Dr. Ali AKDAĞLI

Model termometredir; “ateş var” kararını eşik verir.

Dedektör dili: model duman yoğunluğunu ölçer; ötme sınırını biz koyarız.

KAVRAM KARTI

Eşik

Threshold (cut-off)

Alarm sınırı

Risk kaçı geçince alarm çalsın? Bu sınırı model değil, klinik ekip seçer.

Mühendislik

Termostat / sigorta: 6 A'lik sigorta en ufak yükte atar, 32 A'lik çok geç atar.

Günlük hayat

Dedektör hassasiyeti: çok hassas → tostta öter; kaba → gerçek yangını geç fark eder.

Klinik

Bildirim kuralı: "Riski %20'yi geçen hastayı hekime bildir."

%5 ↔ %50

Bizim veriden: Eşik %5: **38,6 uyarı / 100 hasta**, sepsislerin %91'i yakalanır. Eşik %50: 4,9 uyarı, yalnızca %34,8'i.

Dedektör dili: eşik = dedektörün hassasiyet düğmesi.

Prof. Dr. Ali AKDAĞLI

HATIRLATMA KUTUSU

Bu kelimeler ne demek? · Pima diyabet verisi

Diyabet (Tip 1 · Tip 2)
Kan şekerinin yüksek kalması. Tip 1: insülin yok. Tip 2: insülin var, etkisi azalmış.
≈ kapıyı açan anahtar yok / kilit paslı

Glukoz (OGTT 2. saat)
Şekerli sudan 2 saat sonra kan şekeri. <140 normal, ≥200 diyabet.
≈ sisteme basamak girişi verip yanıtı ölçmek

HbA1c
Son 2–3 ayın ortalama şekeri. <%5,7 normal, %5,7–6,4 prediyabet, ≥%6,5 diyabet.
≈ mevsimin ortalama sıcaklığı

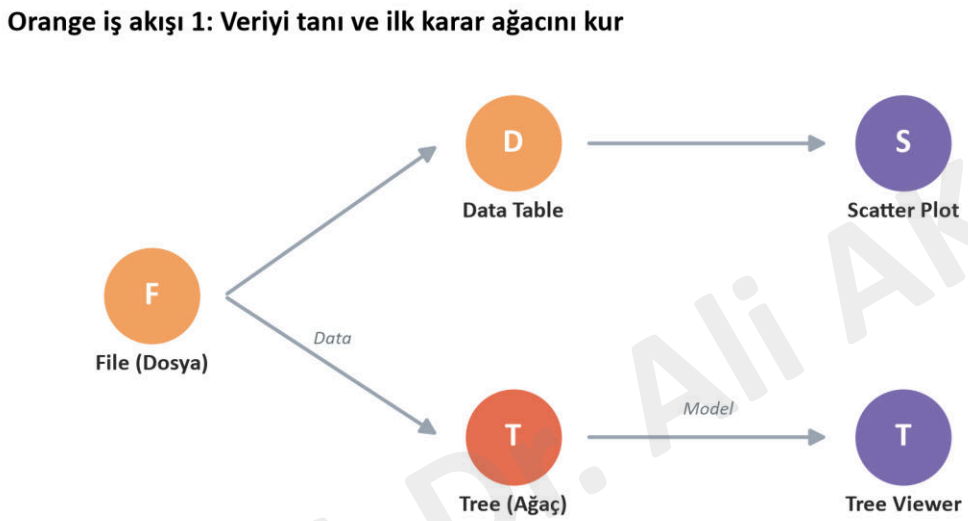
BKİ
Kilo / boy². 18,5–24,9 normal, 25–29,9 fazla kilolu, ≥30 obez.
≈ 70 kg, 1,75 m → 22,9

Aile öyküsü skoru
Ailedeki diyabet yükünü özetleyen puan (diabetes pedigree function).
≈ genetik yatkınlık göstergesi

Pima veri seti
Arizona'daki Pima yerlisi kadınlar; **gerçek** açık veri (Smith 1988), n = 768.
≈ ders kitabı veri seti

Prof. Dr. Ali AKDAĞLI

Orange 1: veriyi tanı, ilk ağacını kur

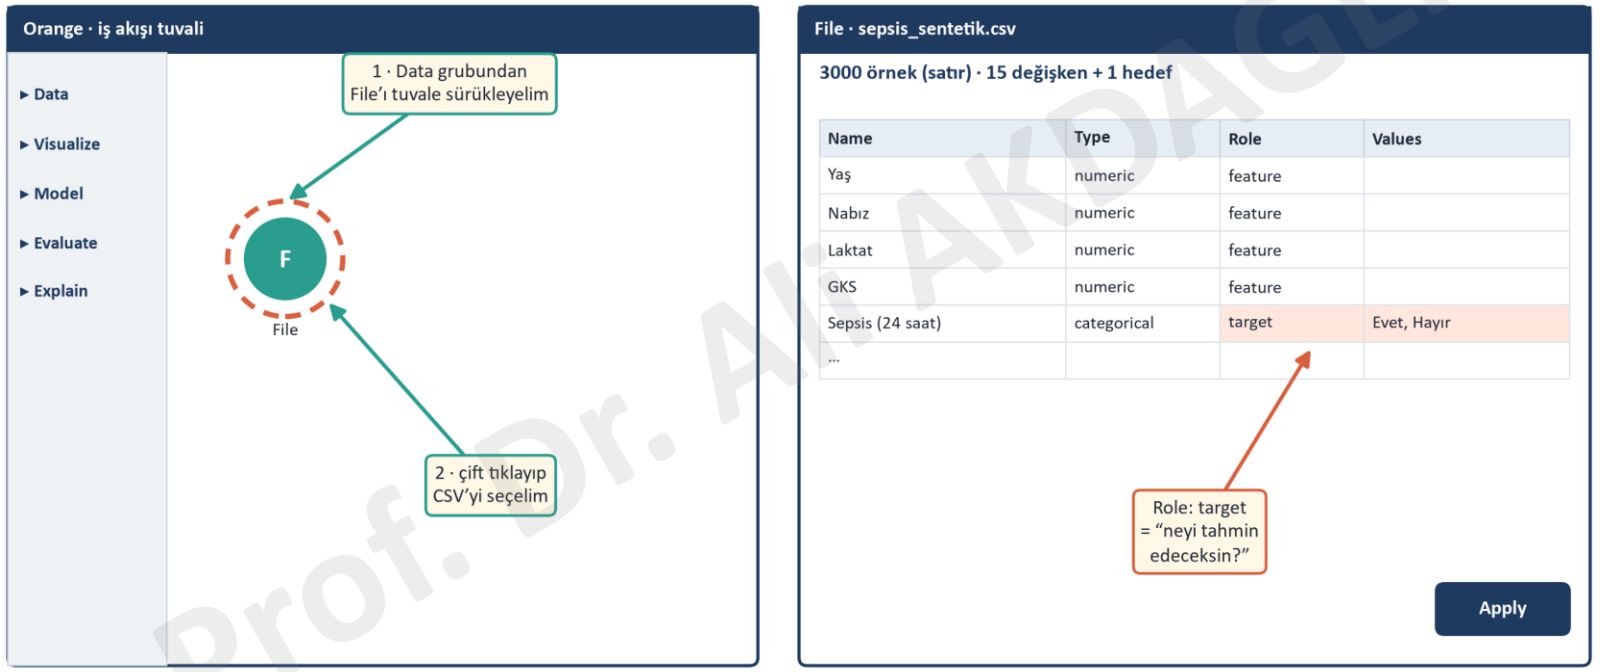


Şekil 1.8 · Orange iş akışı 1

1. **File** → sepsis_sentetik.csv dosyasını açıyoruz
2. "Sepsis (24 saat)" satırında **Role = target** seçiyoruz
3. File → **Data Table** (ve Scatter Plot) ile veriyi inceliyoruz
4. File → **Tree**; derinliği **3** yapıyoruz
5. Tree → **Tree Viewer**: kökü okuyoruz
6. Aynısını **diyabet_pima.csv** ile tekrarlıyoruz

Prof. Dr. Ali AKDAĞLI

Adım 1 · Veriyi açıyoruz ve hedefi seçiyoruz



Temsilî ekran çizimi

Temsilî ekran çizimi · Orange 1 · Veriyi tanımak ve ilk ağaç · Adım 1

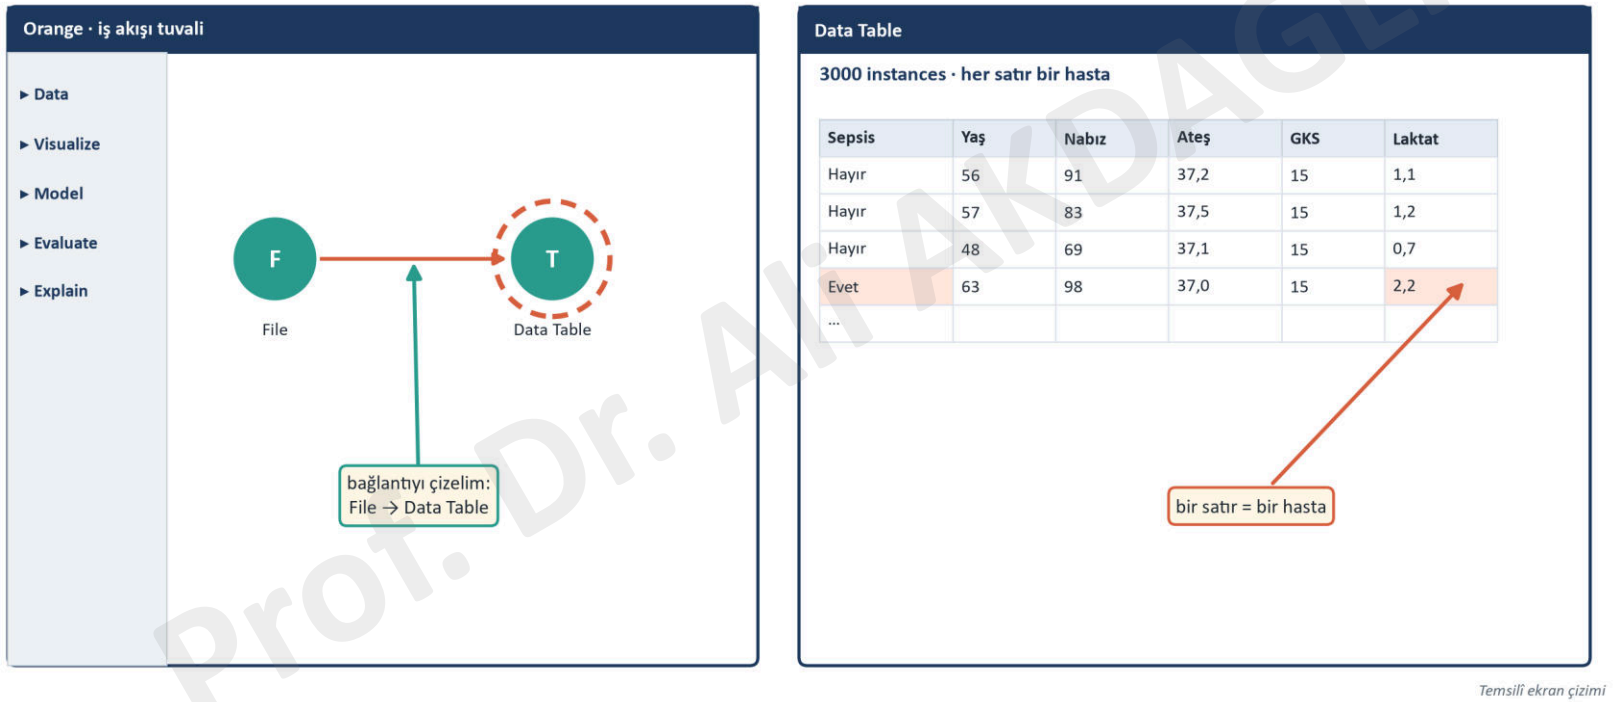
1 **Yapacağımız:** File → CSV → hedef = target

2 **Ekranda:** 3000 örnek, değişken listesi

3 **Anlamı:** hasta oranı %9,9; soru = sepsis

Prof. Dr. Ali AKDAĞLI

Adım 2 · Hastaları tabloda görüyoruz



Temsilî ekran çizimi

Temsilî ekran çizimi · Orange 1 · Veriyi tanımak ve ilk ağaç · Adım 2

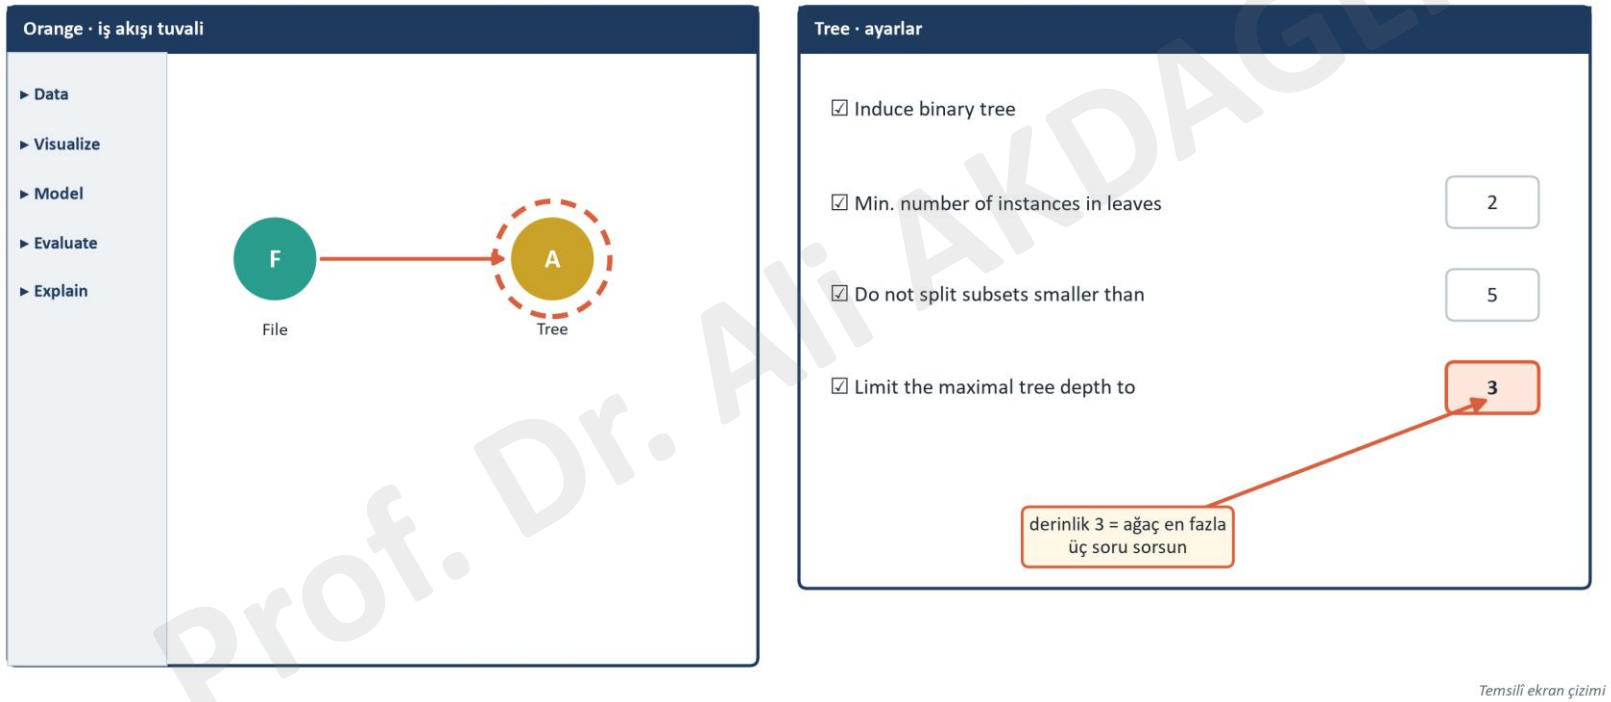
1 **Yapacağımız:** File → Data Table bağlantısı

2 **Ekranda:** satır = hasta, sütun = ölçüm

3 **Anlamı:** model yalnızca tablodakini bilir

Prof. Dr. Ali AKDAĞLI

Adım 3 · Ağacı ekliyoruz, derinliği sınırlıyoruz



Temsilî ekran çizimi

Prof. Dr. Ali AKDAĞLI

Temsilî ekran çizimi · Orange 1 · Veriyi tanımak ve ilk ağaç · Adım 3

1 **Yapacağımız:** Tree → derinlik = 3

2 **Ekranda:** dört ayar kutusu

3 **Anlamı:** az soru = okunur ve ezberlemeyen ağaç

Ağacı okumak: model neye baktı?

GKS ≤ 14,5

Kök: **bilinç değişikliği**

Nabız ≤ 103,5

İkinci soru: taşikardi

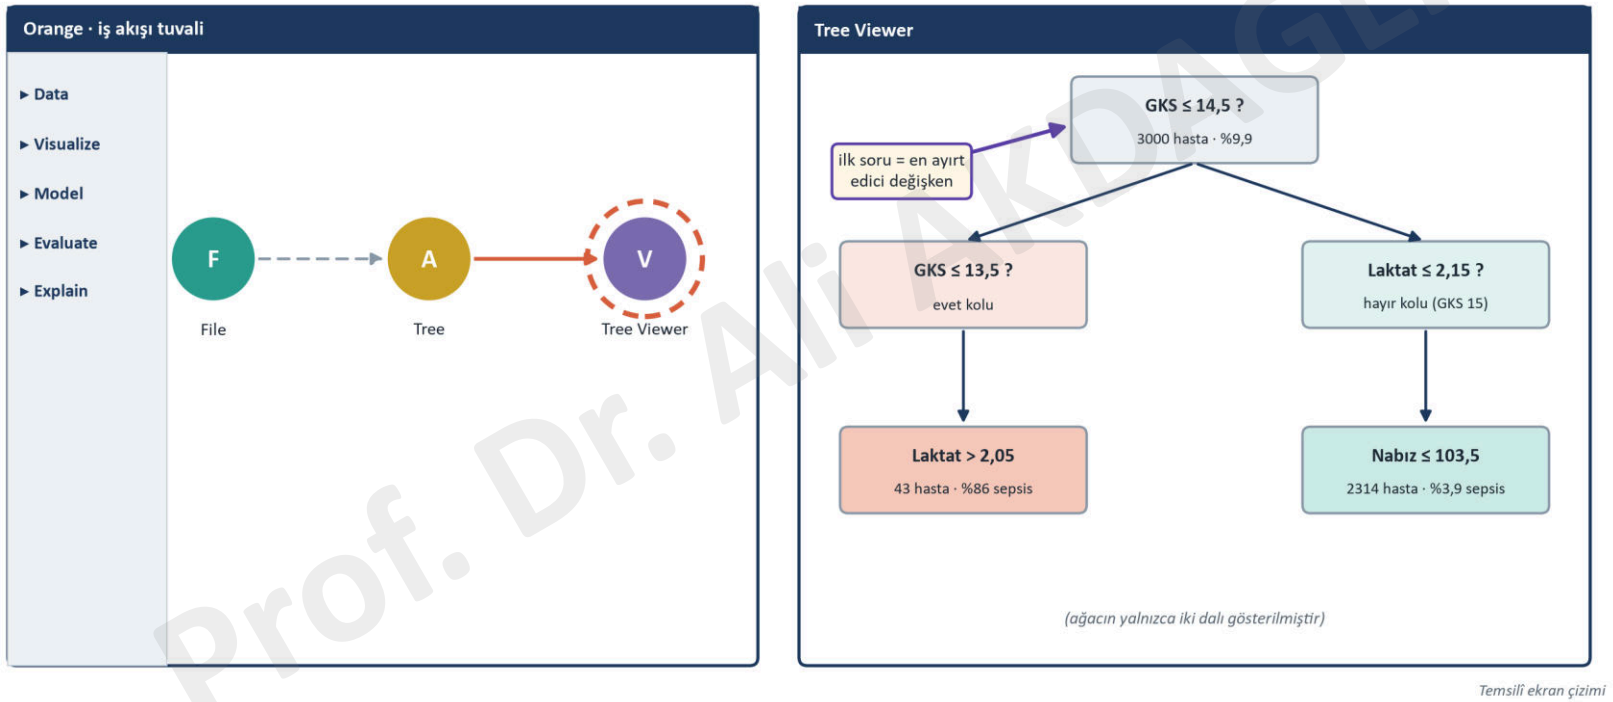
Laktat ≤ 2,15

Üçüncü soru: perfüzyon

Model, klinisyenlerin bildiğini veriden yeniden keşfetti.

Prof. Dr. Ali AKDAĞLI

Adım 4 · Ağacı okuyoruz: model neye baktı?



Temsilî ekran çizimi

Prof. Dr. Ali AKDAĞLI

Temsilî ekran çizimi · Orange 1 · Veriyi tanımak ve ilk ağaç · Adım 4

1 **Yapacağımız:** Tree → Tree Viewer

2 **Ekranda:** ilk soru GKS ≤ 14,5

3 **Anlamı:** GKS ≤ 13 + laktat > 2 → %86 sepsis

düşünüyoruz: servisinizde hangi karar?

G

Düşünme soruları

Servisinizde bir modelin **destekleyebileceği 3 karar** buluyoruz.

Her biri için yanıtlıyoruz:

- **Hangi karar?** (ör. düşme önlemi)
- **Hangi anda?** (ör. yatışın ilk 24 saati)
- **Hangi veriyle?** (ör. kabul formu, yaşam bulguları)
- **Yanılırsa ne olur?**

?

Paylaşım

1. Dileyen katılımcılar **en sevdiği fikri** paylaşabilir
2. Fikirleri saklıyoruz: Oturum 4'te **araştırma önerisinin tohumu** olacak
3. En zor soru hangisiydi: karar mı, an mı, veri mi?

Prof. Dr. Ali AKDAĞLI

Oturum 1 özeti

- ✓ KDS'yi zaten kullanıyorsunuz; fark **kuralı kimin yazdığı**
- ✓ Model yalnızca gösterilen vakalardan öğrenir; **görmediği veriyle** sınanır
- ✓ LR = Braden · Ağaç = triaj · RF = konsey · XGBoost = nöbet devri
- ✓ Çıktı bir **olasılık**; karar **eşikte** verilir

? Düşünmeye değer

1. Bugün öğrendiğim en önemli şey…
2. Hâlâ kafamı karıştıran bir şey…
3. Servisimde modelin destekleyebileceği bir karar…

Prof. Dr. Ali AKDAĞLI

Bugünün kısaltmaları · Oturum 1

KDS	Karar destek sistemi: öneri verir, kararı klinisyen verir
Değişken · hedef	Modelin girişleri · tahmin edilen sonuç (target)
Aşırı öğrenme	Overfitting: eğitim verisini ezberlemek
Çapraz doğrulama	Veriyi 5 parçaya bölüp 5 sınavın ortalaması
LR	Lojistik regresyon: ağırlıklı toplam + S eğrisi (Braden)
Karar ağacı	Evet/hayır soruları zinciri (triaj şeması)
RF	Random Forest: yüzlerce ağacın oylaması (konsey)
XGBoost	Sırayla hata düzelten ağaçlar (nöbet devri)
Eşik	Alarm sınırı: risk kaçı geçince ötsün?
GKS	Glasgow Koma Skalası: bilinç puanı, 15 = tam
qSOFA · NEWS2	İnsan yazımı uyarı skorları
OGTT · BKİ	Şekerli su testi (2. saat) · kilo/boy²

Prof. Dr. Ali AKDAĞLI

OTURUM 2

2

Model çıktısını okumak

Karışıklık matrisi, ROC/AUC, PPV, eşik ve kalibrasyon

Prof. Dr. Ali AKDAĞLI

00:00 Kavram

01:00 Uygulama

02:00 Epic vakası ve hesap

Bu oturumun hedefleri

1. Karışıklık matrisinden duyarlılık, özgüllük, PPV ve NPV hesaplamak
2. ROC/AUC'yi yorumlamak ve sınırlılığını bilmek
3. Prevalansın PPV üzerindeki etkisini açıklamak
4. Eşik seçimini klinik bedel üzerinden gerekçelendirmek
5. Kalibrasyonu tanımlamak

Bugünün akışı

00:00	Matris, ROC, PPV, eşik
00:50	Ara
01:00	Orange + kalibrasyon
01:50	Ara
02:00	Epic vakası, hesap

Prof. Dr. Ali AKDAĞLI

İnsan duman dedektörü

1. Ekranda **10 hasta kartı**: önde risk puanı, arkada gerçek durum (sepsis / sağlam).
2. **Eşik %20**: riski eşiğin üstünde olan kartlar **alarm** alır (vurgulanır).
3. Arka yüzleri açıyoruz: alarm + sepsis = **doğru alarm**; alarm + sağlam = **boşa alarm**.
4. Alarmsız + sepsis = **kaçırma**; alarmsız + sağlam = **doğru sessizlik**.
5. Eşiği **%5**'e indiriyoruz: kaç kart daha alarm aldı? Kutular nasıl değişti?

Neye ihtiyacımız var?

- Ekranda on hasta kartı
- Kendi cihazınızda ders notu: Şekil 2.A

Ne öğreniyoruz?

Eşik düşünce **daha çok yakalarız** ama **boşa alarm da artar**. Bugünkü bütün sayılar bu dört kutudan çıkacak.

Dedektör dili: alarm almak = ötmek. Bugün dört kutunun karnesini okuyacağız.

Prof. Dr. Ali AKDAĞLI

Model de bir tanı testidir

T

Tanı testi

Gebelik testi, mamografi…
Sonucu **altın standartla** karşılaştırırız.

M

Model

Altın standart: hasta gerçekten sepsis oldu mu? Pozitif sonuç: **uyarı**.

=

Aynı dil

Duyarlılık, özgüllük, PPV, NPV modeller için de **aynen** geçerlidir.

Prof. Dr. Ali AKDAĞLI

KISALTMA KARTI

DP · YP · YN · DN

Confusion matrix: TP · FP · FN · TN

Karışıklık matrisi: modelin karnesi

Alarmın dört olası sonucunu sayan 2×2 tablo. İkinci kelime modelin cevabı, birincisi haklı mıydı?

Mühendislik

Kalite kontrol kamerası: kusurluyu ayırdı / sağlamı boşuna ayırdı / kusurluyu kaçırdı / sağlamı geçirdi.

Günlük hayat

Gebelik testi: pozitif ve gebe · pozitif ama gebe değil · negatif ama gebe · negatif ve değil.

Klinik

Sepsis modeli: uyardı-oldu · uyardı-olmadı · sustu-oldu (**kaçırma**) · sustu-olmadı.

54 · 61 · 35 · 750

Bizim veriden: XGBoost, 900 hasta, eşik %20. **En tehlikeli kutu: YN = 35** (kaçırılan sepsis).

Dedektör dili: YP = tost yandı, öttü · YN = yangın var, sustu.

Prof. Dr. Ali AKDAĞLI

Bir alarmın dört olası sonucu

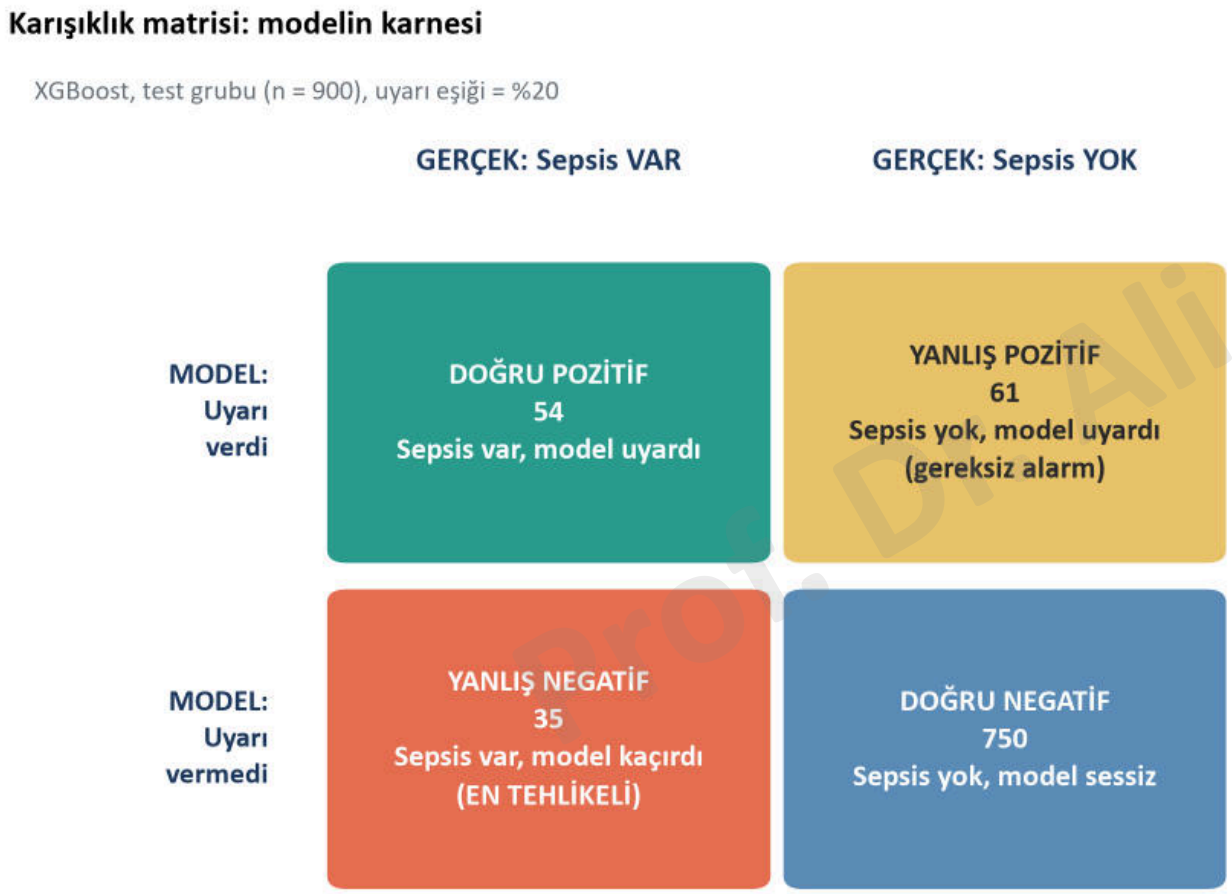


Şekil · Aynı tablo, dört farklı alarm: dedektör, metal dedektörü, spam filtresi, sepsis modeli

1. Sütun = **gerçek** · satır = **alarm**
2. Yeşil: doğru alarm · sarı: **boşa alarm**
3. Turuncu: **kaçırma** (en tehlikeli)
4. Mavi: doğru sessizlik

Prof. Dr. Ali AKDAĞLI

Karışıklık matrisi: modelin karnesi



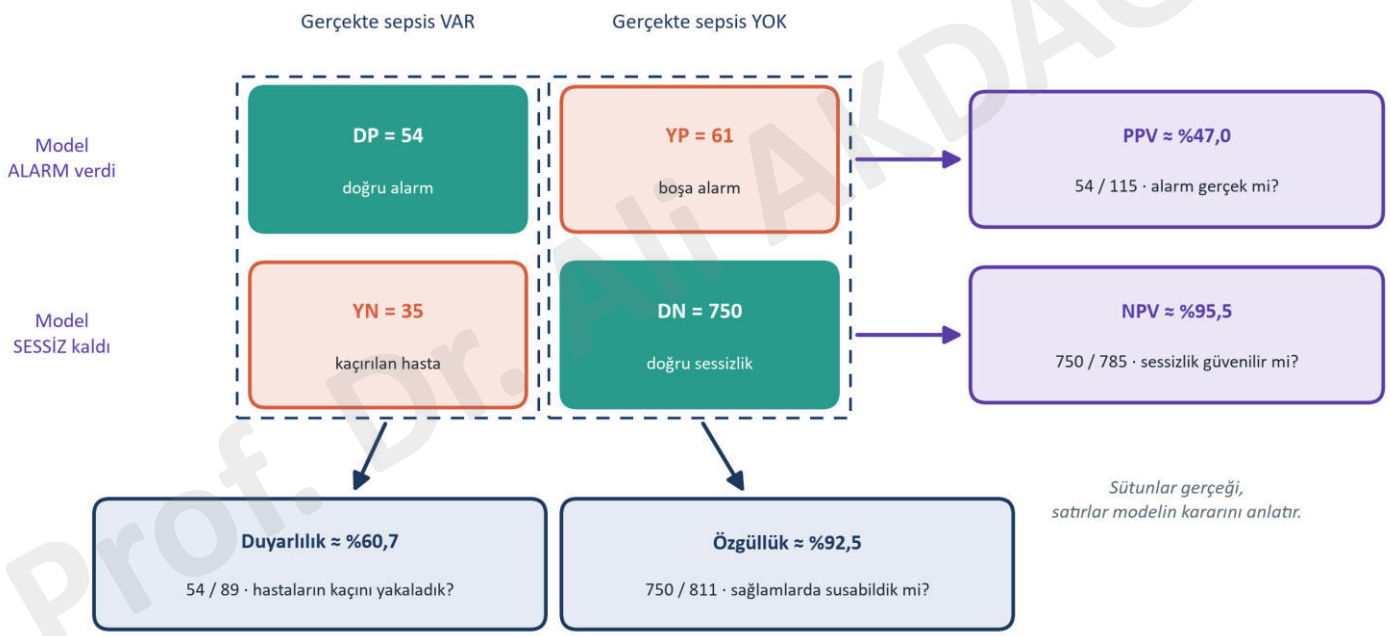
Şekil 2.1 · XGBoost, test grubu n = 900, eşik %20

1. Sütun = **gerçek**, satır = **model**
2. En tehlikeli hücre: **yanlış negatif** (35)
3. 61 gereksiz alarm
4. 900 hasta, 89'u sepsis

Dedektör dili: 54 doğru ötüş · 61 tost ötüşü · 35 sessiz yangın · 750 sessiz huzur.

Prof. Dr. Ali AKDAĞLI

Dört hücreden dört ölçüte



Akış 2.1 · Sütunlar → duyarlılık, özgüllük · Satırlar → PPV, NPV

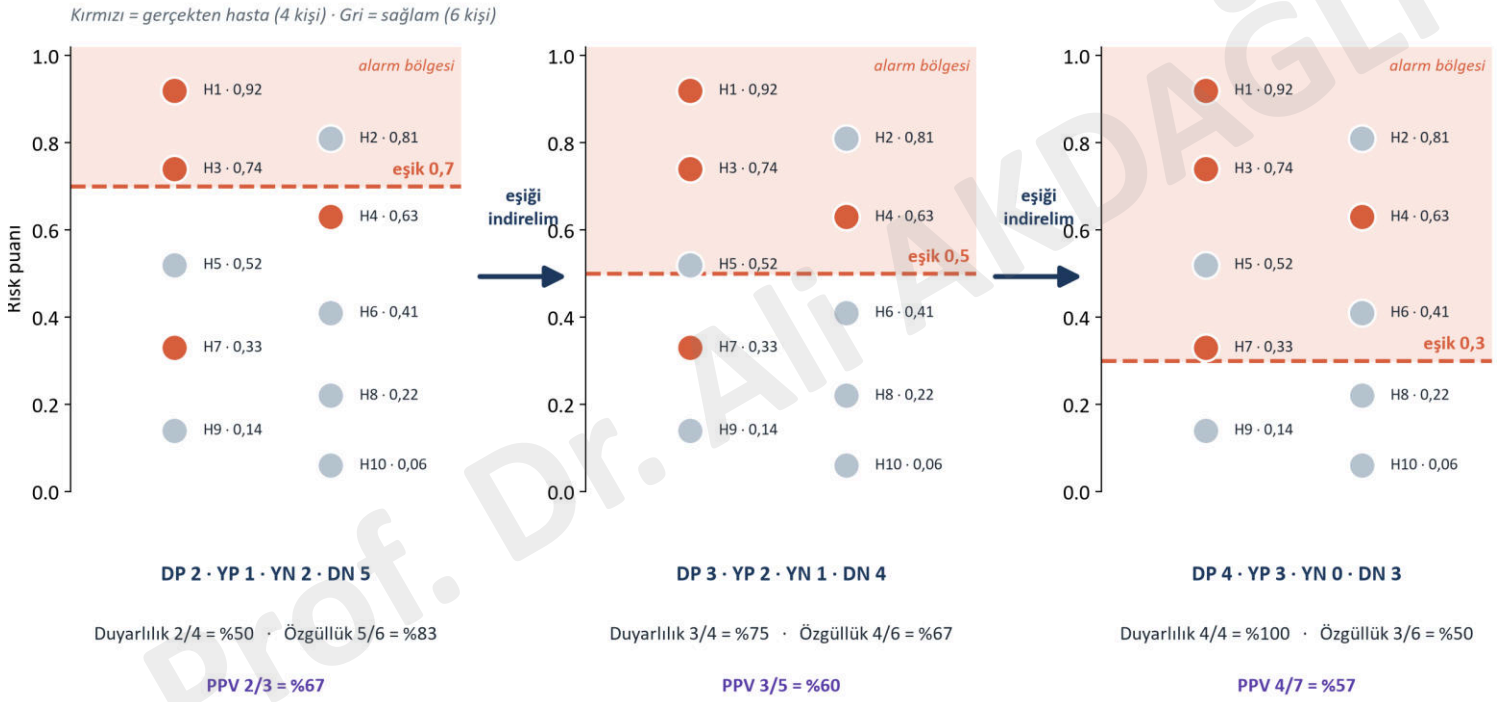
1 **Sütun** = gerçek durum → duyarlılık, özgüllük

2 **Satır** = modelin kararı → PPV, NPV

3 Aynı dört sayı, dört farklı soru

Prof. Dr. Ali AKDAĞLI

On hasta, üç eşik



Şekil 2.A · Eşik 0,70 → 0,50 → 0,30: sayılar nasıl değişiyor?

1. Eşik inince **duyarlılık artar**: 2/4 → 3/4 → 4/4
2. Ama **özgüllük düşer**: 5/6 → 4/6 → 3/6
3. Matris, **seçilen eşiğin** karnesidir

Prof. Dr. Ali AKDAĞLI

KAVRAM KARTI

Duyarlılık

Sensitivity · Recall · True positive rate

Hastaların yüzde kaçını yakaladık?

Gerçekten hasta olanların içinde modelin “alarm” verdiklerinin oranı. Hastalardan başlar.

Mühendislik

Radarın algılama olasılığı: gerçek uçakların yüzde kaçı ekranda göründü?

Günlük hayat

Balık ağı: gözleri küçük ağ bütün balıkları yakalar (ama çöp de toplar).

Klinik

Tarama testi: hastayı kaçırmamak; “D” = **D**oğru hastayı bulma.

54 / 89 = %60,7

Bizim veriden: 89 gerçek sepsisin **54'ü** yakalandı; 35'i kaçırıldı.

Dedektör dili: duyarlılık = gerçek yangınların yüzde kaçında öttü?

Prof. Dr. Ali AKDAĞLI

ADIM ADIM HESAP

Duyarlılık adım adım: 54 / 89

	Gerçekte hasta	Gerçekte sağlam
Alarm öttü	DP **54**	YP 61
Alarm sustu	YN **35**	DN 750

pay (üstte) paydaya eklenen

Soru: hastaların kaçını yakaladık?
Yalnızca **sol sütun** (gerçek hastalar).

1. Sadece gerçekten hasta olanlara bak (sol sütun)
2. Gerçek hastalar: 54 + 35 → **89**
3. Yakalananlar (öttü ve hasta) → **54**
4. 54 ÷ 89 → **%60,7**

10 sepsis hastasının ≈ 6'sı yakalanıyor, ≈ 4'ü kaçıyor.

Prof. Dr. Ali AKDAĞLI

KAVRAM KARTI

Özgüllük

Specificity · True negative rate

Sağlamların yüzde kaçına sustuk?

Gerçekten sağlam olanların içinde modelin “sorun yok” dediklerinin oranı. Sağlamlardan başlar.

Mühendislik

Radar: kuş sürüsüne “uçak” dememe becerisi; 1 − yanlış alarm oranı.

Günlük hayat

Akıllı dedektör / köpek: tostta susar; hırsıza havlar, postacıya havlamaz.

Klinik

Boşuna korkutmamak: sağlam kişiye gereksiz tetkik ve kaygı yaşatmamak; “Ö” = **Ö**tmemek.

750 / 811 = %92,5

Bizim veriden: 811 sağlam kişinin **750'sinde** doğru sustuk; **61'ine** boşa alarm verdik.

Dedektör dili: özgüllük = yangın yokken susabilmek (tostta ötmemek).

Prof. Dr. Ali AKDAĞLI

ADIM ADIM HESAP

Özgüllük adım adım: 750 / 811

	Gerçekte hasta	Gerçekte sağlam
Alarm öttü	DP 54	YP 61
Alarm sustu	YN 35	DN 750

pay (üstte) paydaya eklenen

Soru: sağlamların kaçına doğru sustuk?
Yalnızca **sağ sütun** (gerçek sağlamlar).

1. Sadece gerçekten sağlam olanlara bak (sağ sütun)
2. Gerçek sağlamlar: 61 + 750 → **811**
3. Doğru sessizlik (sustu ve sağlam) → **750**
4. 750 ÷ 811 → **%92,5**

100 sağlam kişinin ≈ 92'sinde sessiz, ≈ 7–8'ine boşa alarm.

Prof. Dr. Ali AKDAĞLI

KISALTMA KARTI

PPV

Positive Predictive Value · Precision

Pozitif kestirim değeri (kesinlik)

Model “ALARM!” dediğinde hastanın gerçekten hasta olma olasılığı: öttüğünde koşmaya değer mi?

Mühendislik

Arıza tespit sistemi: “arıza var” dediği seferlerin yüzde kaçında gerçekten arıza çıktı?

Günlük hayat

Kurt geldi çobanı: 10 bağırışın 9'u yalansa köylü koşmaz: PPV %10'luk alarm.

Klinik

Pozitif sonuç: “Test pozitif; hasta gerçekten hasta mı?” Hastanın asıl sorusu.

54 / 115 = %47

Bizim veriden: Model **115 kez öttü**; 54'ü gerçek sepsis, 61'i boşa. Her iki alarmdan ≈ biri doğru.

Dedektör dili: PPV = dedektör öttüğünde gerçekten yangın olma olasılığı.

Prof. Dr. Ali AKDAĞLI

PPV adım adım: 54 / 115

	Gerçekte hasta	Gerçekte sağlam
Alarm öttü	DP **54**	YP **61**
Alarm sustu	YN **35**	DN **750**

pay (üstte) — paydaya eklenen

Soru: alarmların kaçı haklıydı?

Yalnızca **üst satır** (modelin öttüğü durumlar).

1. Sadece modelin öttüğü durumlara bak (üst satır)
2. Bütün alarmlar: 54 + 61 → **115**
3. Haklı alarmlar (öttü ve hasta) → **54**
4. 54 ÷ 115 → **%47**

Her iki alarmdan ≈ biri gerçek sepsis.

Prof. Dr. Ali AKDAĞLI

KISALTMA KARTI

NPV

Negative Predictive Value

Negatif kestirim değeri

Model “sorun yok” dediğinde gerçekten sorun olmama olasılığı: sessizken rahat olabilir miyiz?

Mühendislik

İzleme sistemi: “her şey yolunda” dediğinde gerçekten yolunda olma oranı.

Günlük hayat

Sessiz dedektör: dedektör susarken gerçekten güvende miyiz? Rahat uyuyabilir miyiz?

Klinik

Temiz sonuç: hasta “temiz” çıktı; izlemi gevşetebilir miyiz?

750 / 785 = %95,5

Bizim veriden: Model **785 kez sustu**; 750'si gerçekten sağlam, **35'i** sepsis oldu.

Prof. Dr. Ali AKDAĞLI

Duyarlılık mı, PPV mi? Aynı pastanın iki dilimi

Duyarlılık: hastalardan başla

- "Hastaların kaçını **yakaladım**?"
- Payda: **gerçek hastalar** (89)
- 54 / 89 = **%60,7**
- Yöneticinin sorusu: kaç kişiyi kaçırıyoruz?

PPV: alarmlardan başla

- "Alarmlarımın kaçı **haklıydı**?"
- Payda: **bütün alarmlar** (115)
- 54 / 115 = **%47**
- Hemşirenin sorusu: bu alarm gerçek mi?

Prof. Dr. Ali AKDAĞLI

Pay aynı (54 doğru alarm); değişen, baktığınız kalabalık.

Dedektör dili: duyarlılık yangınlardan, PPV ötüşlerden başlar.

Dört oran, dört basit bölme

%60,7

Duyarlılık

54 / 89

%92,5

Özgüllük

750 / 811

%47

PPV

54 / 115

%95,5

NPV

750 / 785

Duyarlılık ve özgüllük modele; PPV ve NPV servisin prevalansına bağlıdır.

Prof. Dr. Ali AKDAĞLI



Dedektör dili: dört soru: yangını, sessizliği, ötüşü ve sususu ne kadar doğru yaptı?

KAVRAM KARTI

Doğruluk

Accuracy

Doğru tahminlerin oranı (ve tuzağı)

(DP + DN) ÷ hepsi. Nadir olaylarda yanıltır: hiç ötmeyen dedektör de “çoğunlukla haklıdır”.

Mühendislik

Dengesiz sınıflar: “hiç arıza yok” diyen sistem de yüksek doğruluk alır; tek başına anlamsız.

Günlük hayat

Durmuş saat: günde iki kez doğruyu gösterir; pili bitmiş dedektör “%99 haklıdır”.

Klinik

Tembel model: herkese “sepsis yok” der; doğruluk %90,1, yakalanan sepsis **sıfır**.

%89,3 vs %90,1

Bizim veriden: Bizim modelin doğruluğu %89,3; **hiçbir şey yapmayan** tembel model %90,1!

Dedektör dili: pili bitmiş dedektör de yangın nadir olduğu için “hep haklı” görünür.

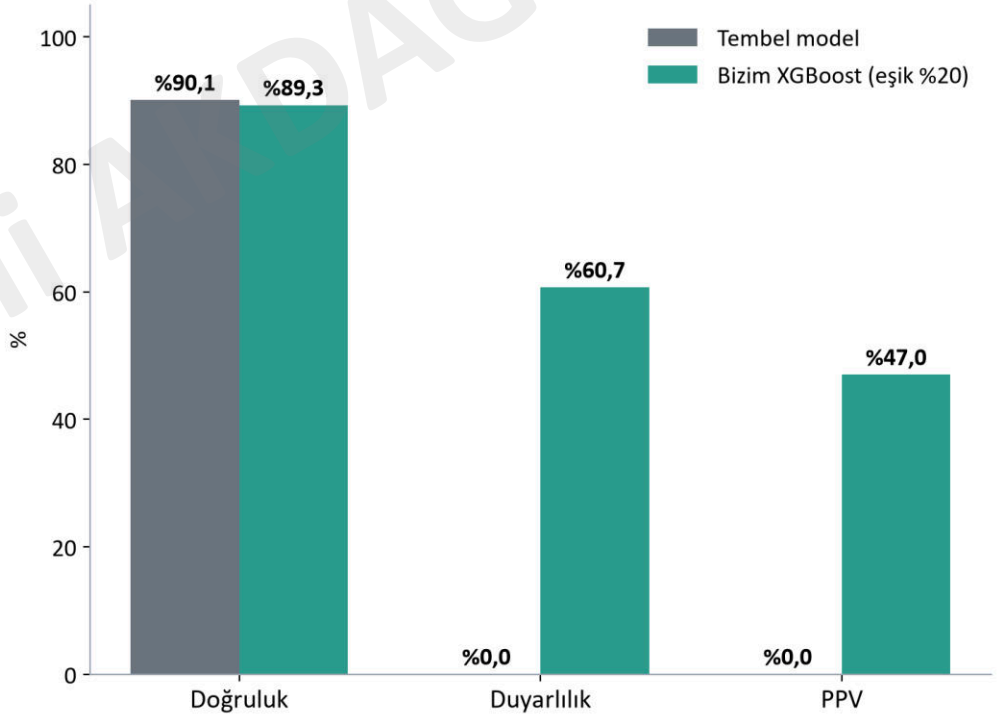
Prof. Dr. Ali AKDAĞLI

Doğruluk tuzağı: hiç ötmeyen dedektör

Doğruluk tuzağı: nadir olayda 'doğruluk %90' hiçbir şey söylemez

Pili bitmiş duman dedektörü
hiç ötmez → yangın nadir olduğu için
"günlerin %99'unda haklı"

Tembel model: herkese "sepsis yok" der
900 hastanın 811'i zaten sağlam
→ doğruluk %90,1 ama 89 sepsisin HİÇBİRİNİ yakalamaz



Şekil · Tembel model ve XGBoost: doğruluk, duyarlılık, PPV

1. Tembel model doğruluğu **%90,1**
2. Ama duyarlılık ve PPV **%0**
3. Nadir olayda doğruluğa değil, **duyarlılık ve PPV**'ye bakıyoruz

Dedektör dili: hiç ötmeyen dedektör "%99 doğru" görünür.

Prof. Dr. Ali AYDAĞLI

KAVRAM KARTI

Prevalans

Prevalence · Base rate

Görülme sıklığı (taban oranı)

Prof. Dr. Ali AKDAĞLI

Bir toplulukta hastalığın ne kadar sık olduğu. Nadir olaylarda alarmların çoğu boşa çıkar.

Mühendislik

Arıza taban oranı: 1000 parçada 2 kusur; nadir arızada alarmların çoğu boş çıkar.

Günlük hayat

Havalimanı x-ray'i: bomba çok nadir; "şüpheli" bavullardan genelde kemer tokası çıkar.

Klinik

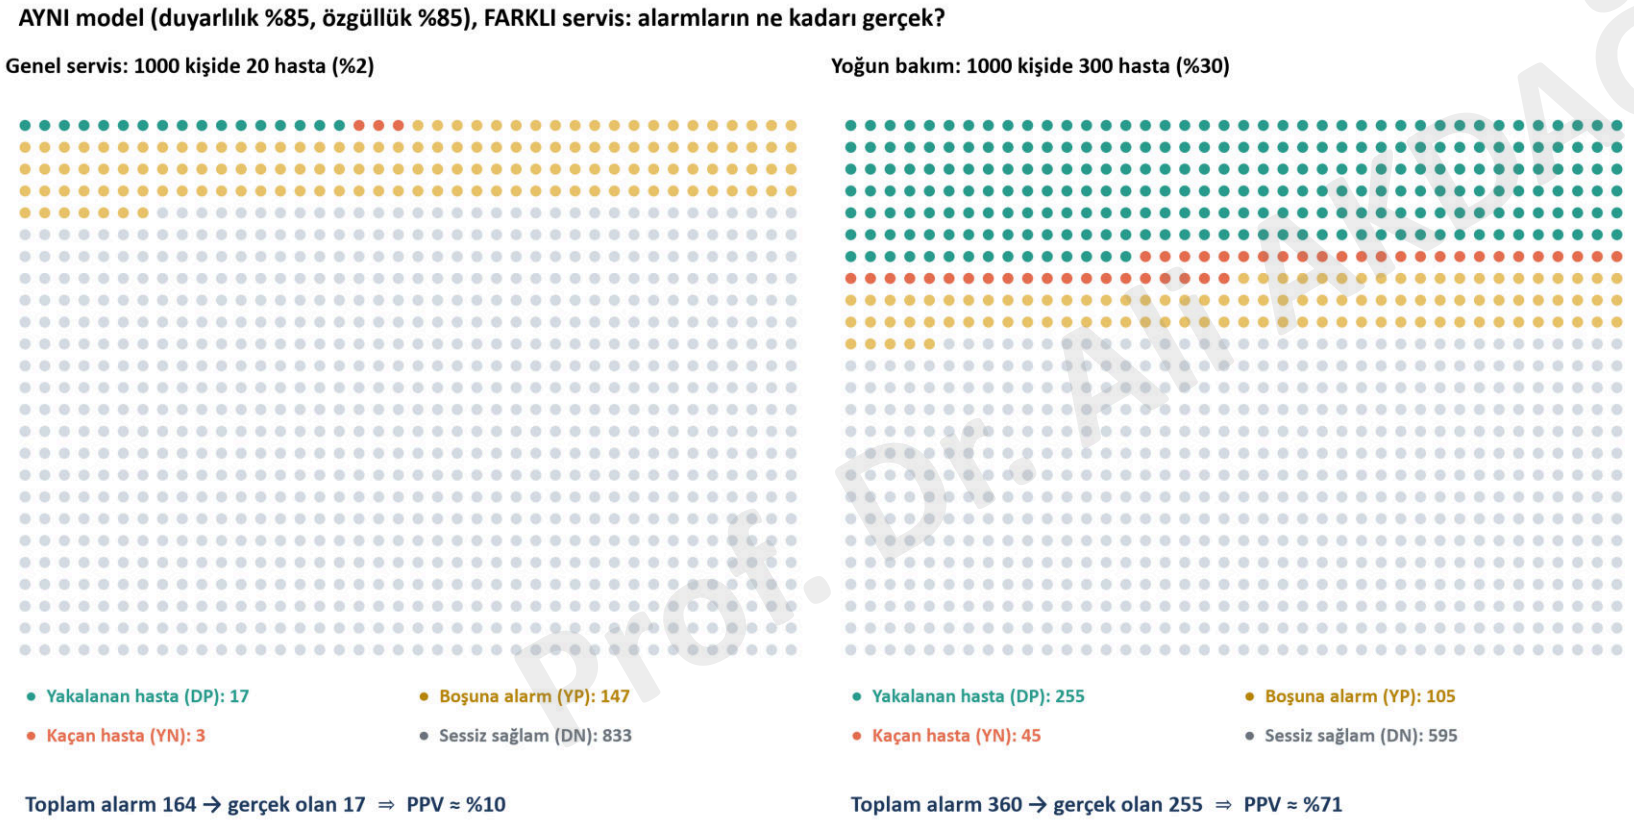
Servis farkı: aynı hastalık yoğun bakımda sık, genel serviste nadir.

%9,9

Bizim veriden: Sepsis verimiz: 100 hastadan ≈ **10**'u. Preeklampsi verimiz: yalnızca **%5,5**.

Dedektör dili: yangının nadir olduğu evde ötüşlerin çoğu tosttandır.

1000 kişi, aynı model, iki farklı servis



Şekil · Duyarlılık ve özgüllük %85: prevalans %2 ve %30'da PPV

1. Genel servis (%2): 164 alarmın **17'si** gerçek → PPV ≈ **%10**
2. Yoğun bakım (%30): 360 alarmın **255'i** gerçek → PPV ≈ **%71**
3. Model **aynı**; değişen yalnızca prevalans

Dedektör dili: aynı dedektör, mutfakta sık; yatak odasında seyrek boşa öter.

Prof. Dr. Ali ERKOÇOĞLU

ADIM ADIM HESAP

PPV %10 adım adım: 1000 kişilik servis

	Gerçekte hasta	Gerçekte sağlam
Alarm öttü	DP 17	YP 147
Alarm sustu	YN 3	DN 833

pay (üstte) · paydaya eklenen

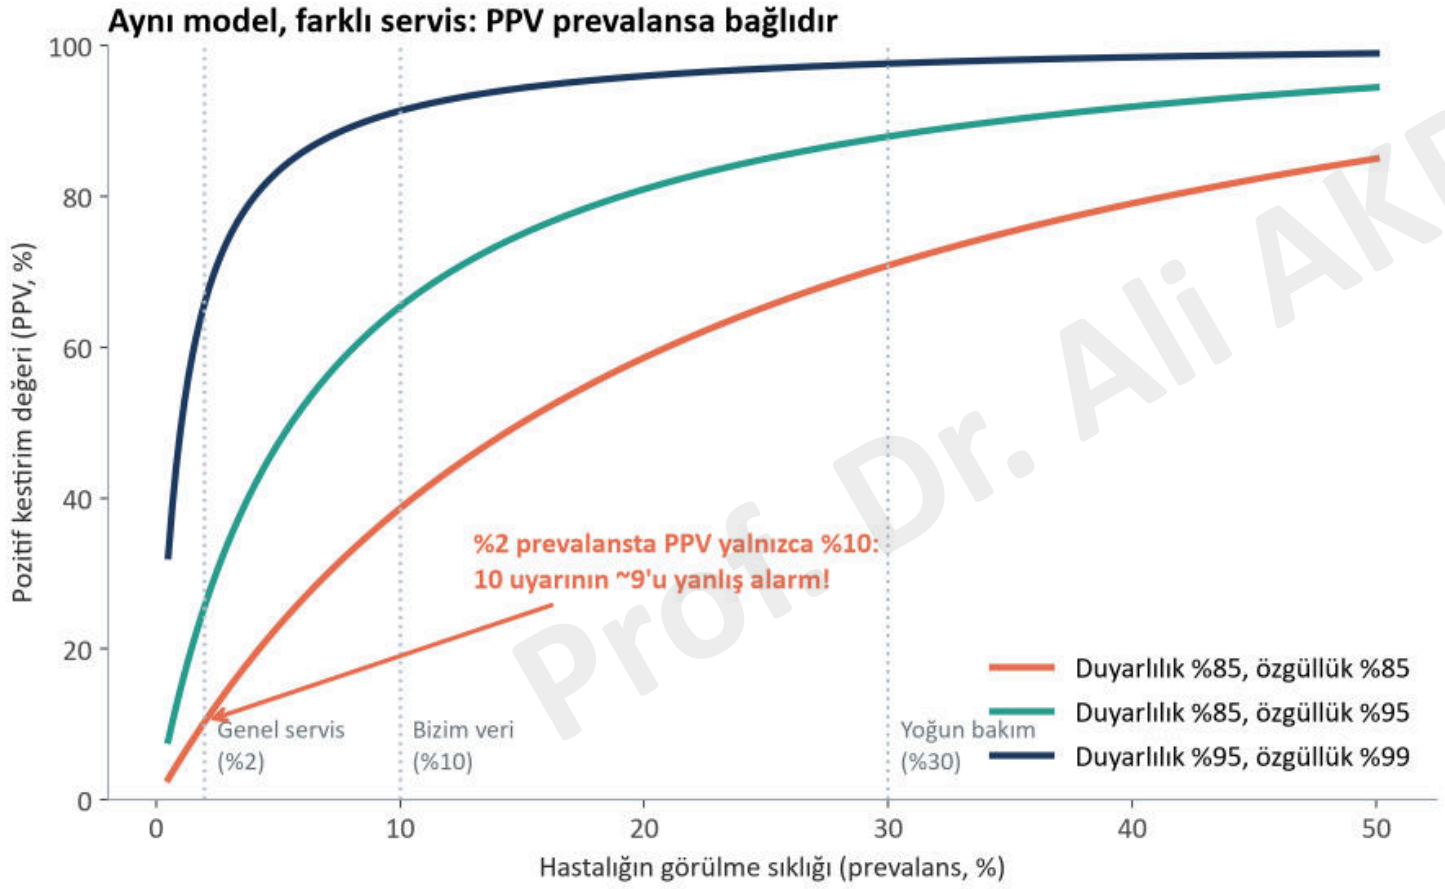
1000 kişi · prevalans **%2**
Duyarlılık **%85** · özgüllük **%85**
Hasta 20 · sağlam 980

1	Hasta: 1000 × 0,02	20
2	Yakalanan: 20 × 0,85	17
3	Boşa alarm: 980 × 0,15	147
4	Bütün alarmlar: 17 + 147	164
5	PPV: 17 ÷ 164	%10,4

10 alarmın ≈ 9'u boşa: bu modelin değil, matematiğin kuralıdır.

Prof. Dr. Ali AKDAĞLI

PPV prevalansa bağlıdır



Şekil 2.4 · Aynı model, farklı servis: PPV ve prevalans

1. Model **değişmiyor**, yalnızca servis değişiyor

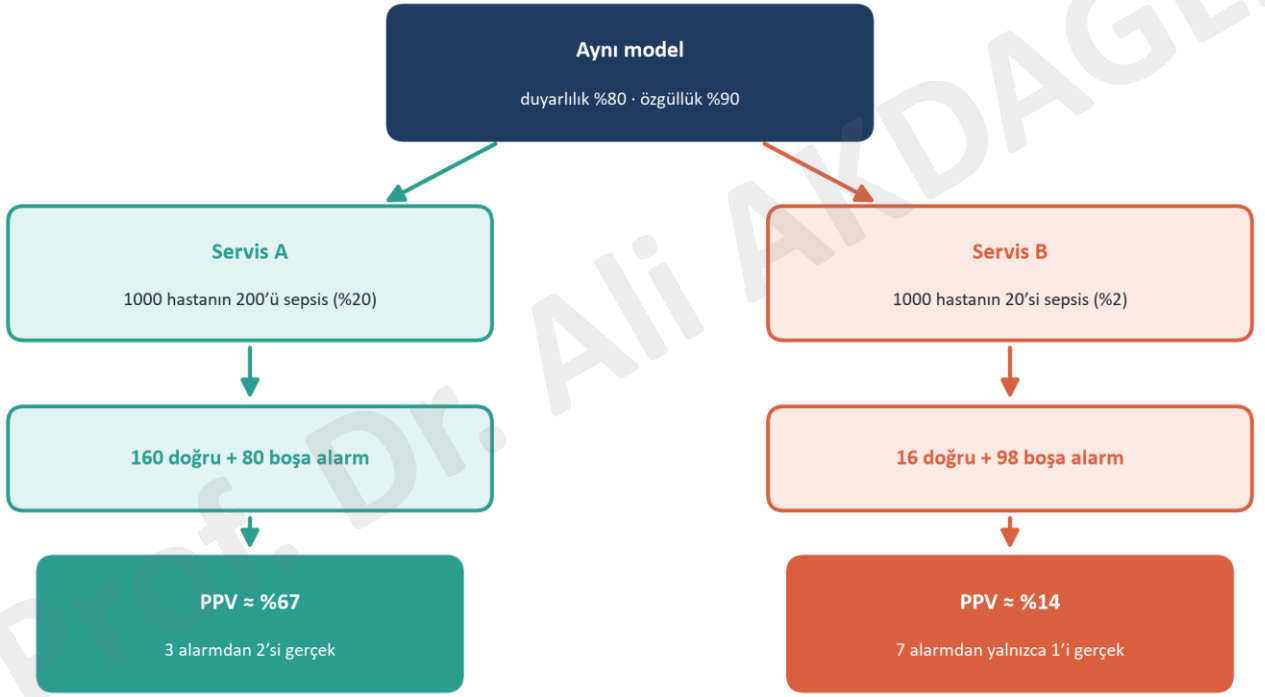
2. Yoğun bakım (%30): PPV yüksek

3. Genel servis (%2): PPV **yalnızca %10**

Dedektör dili: aynı dedektör, yangının nadir olduğu evde çoğunlukla boşa öter.

Prof. Dr. Ali AKDAĞLI

Aynı model, iki servis



Akış 2.2 · Duyarlılık %80, özgüllük %90 · prevalans %20 ve %2

1. Model **değişmedi**, servis değişti
2. Nadir olayda boşa alarm **çoğalır**
3. PPV her zaman **prevalansla birlikte** okunur

Prof. Dr. Ali AKDAĞLI

Kurt geldi çobanı: düşük PPV’nin bedeli

1

Boşa bağırışlar

Çoban “Kurt geldi!” der; köylüler koşar, **kurt yok**. Bir daha, bir daha… PPV çok düşük.

2

Yorgunluk

Onuncu bağırışta köylüler **artık koşmaz**: alarm yorgunluğu.

3

Gerçek kurt

Bir gün kurt **gerçekten** gelir; kimse koşmaz. Asıl alarm gürültüde kaybolur.

Prof. Dr. Ali AKDAĞLI

Klinikte: PPV %10 olan sepsis alarmı → 10 uyarının 9'u boşa → asıl hasta da kaçar.

Dedektör dili: sürekli tostta öten dedektörün pilini sonunda biri çıkarır.

KISALTMA KARTI

ROC

Receiver Operating Characteristic

Alıcı çalışma karakteristiği eğrisi

Eşik düğmesini baştan sona çevirip her ayarda “yakalama” ve “boşa alarm” oranını çizen eğri.

Mühendislik

Sensör karakteristiği: her nokta dedektörün olası bir çalışma noktası (operating point).

Günlük hayat

Balık ağı: göz küçüldükçe hem balık hem çöp artar; ROC bu dengeyi çizer.

Klinik

Tanı testi: farklı kesme değerlerinde duyarlılık–özgüllük dengesi.

4 eğri

Bizim veriden: Sepsiste dört modelin ROC eğrisi **neredeyse üst üste**: hepsi sol üste yakın.

Dedektör dili: ROC = hassasiyet düğmesinin bütün ayarlarının karnesi.

Prof. Dr. Ali AKDAĞLI

ROC eğrisi radar operatörlerinden doğdu

?

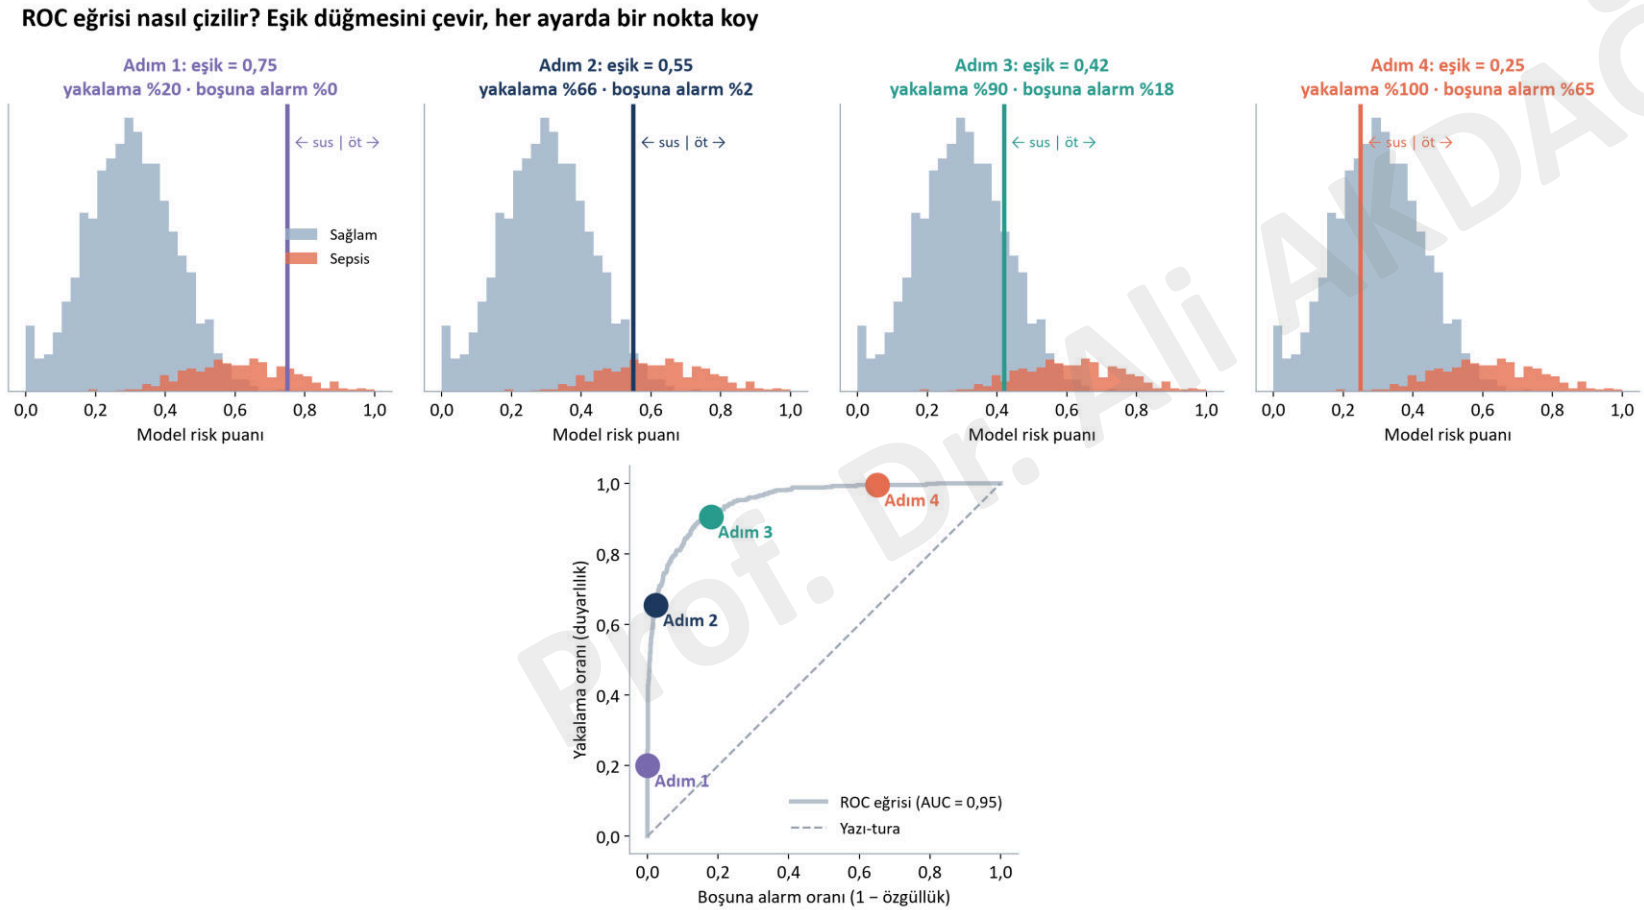
İkinci Dünya Savaşı'nda radar operatörü ekrandaki noktaya bakıp karar verir: **düşman uçağı mı, kuş sürüsü mü?** Hassasiyet düğmesini açtıkça daha çok uçak yakalar ama daha çok kuşa da "uçak" der. ROC, bu ödünleşimin grafiği olarak doğdu ("receiver" = radar alıcısı).

Prof. Dr. Ali AKDAĞLI

Bugünle bağlantısı: Düşman uçağı = **sepsis**, kuş sürüsü = **sağlam hasta**, hassasiyet düğmesi = **eşik**.

Tarihçe notu: sinyal tespit kuramının (signal detection theory) çıkış noktası.

ROC adım adım: düğmeyi çevir, nokta koy



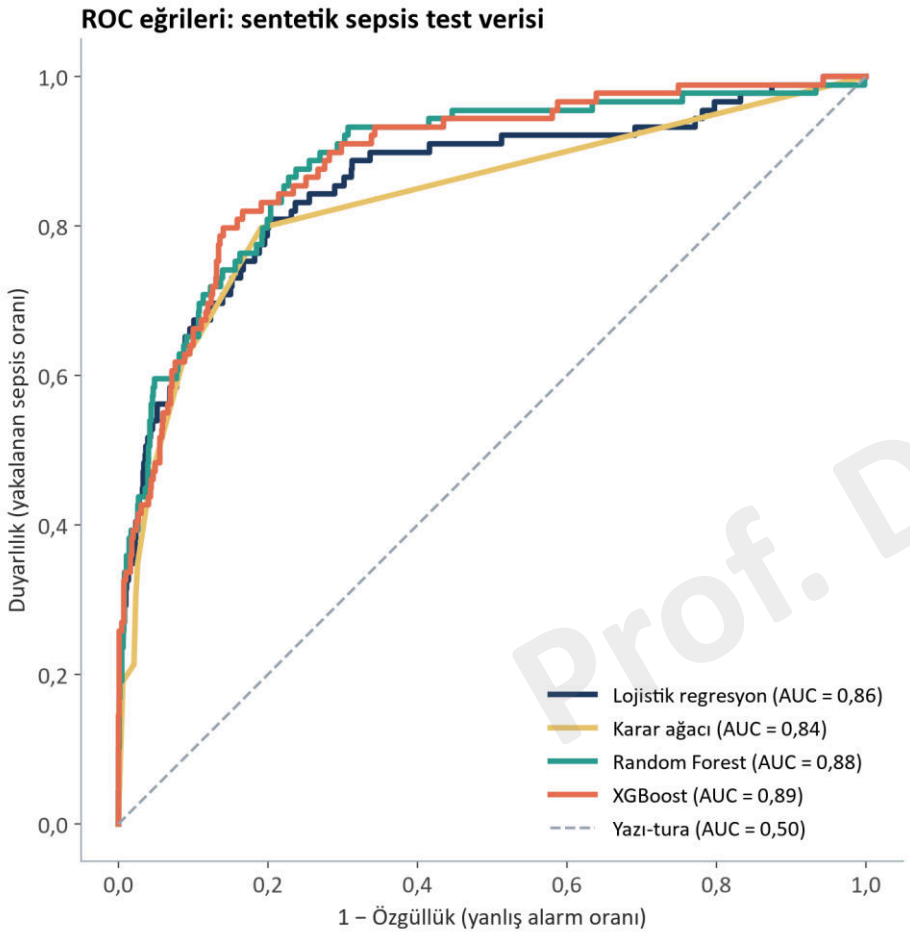
Şekil · Eşik düşürüldükçe ROC üzerinde ilerleyen dört nokta (temsili veri)

1. Eşik **0,75**: yakalama %20, boşa alarm %0
2. Eşik **0,42**: yakalama %90, boşa alarm %18
3. Eşik **0,25**: yakalama %100, boşa alarm %45
4. Noktaları birleştir = **ROC**

Dedektör dili: her nokta, hassasiyet düğmesinin bir ayarı.

Prof. Dr. Ali AKDAĞLI

ROC eğrisi ve AUC



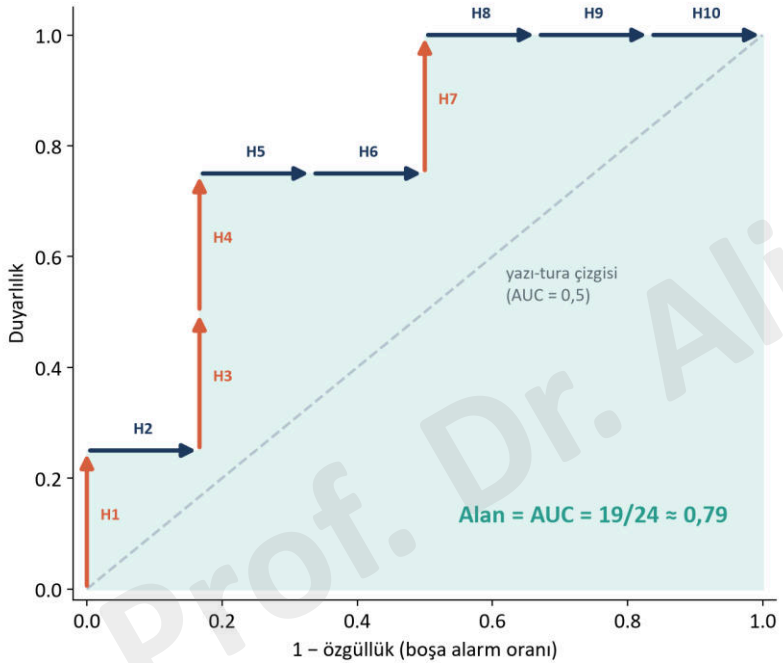
Şekil 2.2 · Dört modelin ROC eğrisi

1. Dikey: **duyarlılık** · Yatay: **yanlış alarm oranı**
2. Her nokta bir **eşik**; köşegen = yazı-tura (0,5)
3. LR 0,86 · Ağaç 0,84 · RF 0,88 · XGB 0,89
4. Eğriler neredeyse üst üste

Dedektör dili: dört dedektörün bütün düğme ayarları üst üste çizildi.

Prof. Dr. Ali AKDAĞLI

ROC eğrisini çiziyoruz



Nasıl çizdik?

Hastaları risk puanına göre yukarıdan aşağı sıraladık.

Eşiği her hastanın hizasına sırayla indirdik.

Gerçekten hasta olan biri alarm bölgesine girince

eğri bir adım YUKARI çıkar (duyarlılık +1/4).

Sağlam biri girince eğri bir adım SAĞA gider

(boşa alarm +1/6).

İyi bir model önce yukarı, sonra sağa gider;

eğri sol üst köşeye yaslanır.

Prof. Dr. Ali AKDAĞLI

Şekil 2.B · Her hasta bir adım yukarı, her sağlam bir adım sağa

1. Hasta girince eğri **yukarı**, sağlam girince **sağa**
2. İyi model önce yukarı tırmanır
3. Eğri altındaki alan = **AUC ≈ 0,79**

KISALTMA KARTI

AUC

Area Under the (ROC) Curve · C statistic

Eğri altındaki alan

Rastgele bir hasta–sağlam çiftinde modelin hastaya daha yüksek risk verme olasılığı (sıralama becerisi).

Mühendislik

Sıralama kalitesi: eşik seçmeden iki dedektörü karşılaştırmanın yolu (0,5 = yazı-tura).

Günlük hayat

Karpuz seçen manav: her olgun–ham çiftinde olgunu seçebiliyor mu?

Klinik

Deneyimli hemşire: iki hastadan hangisinin daha ağır olduğunu sezme oranı.

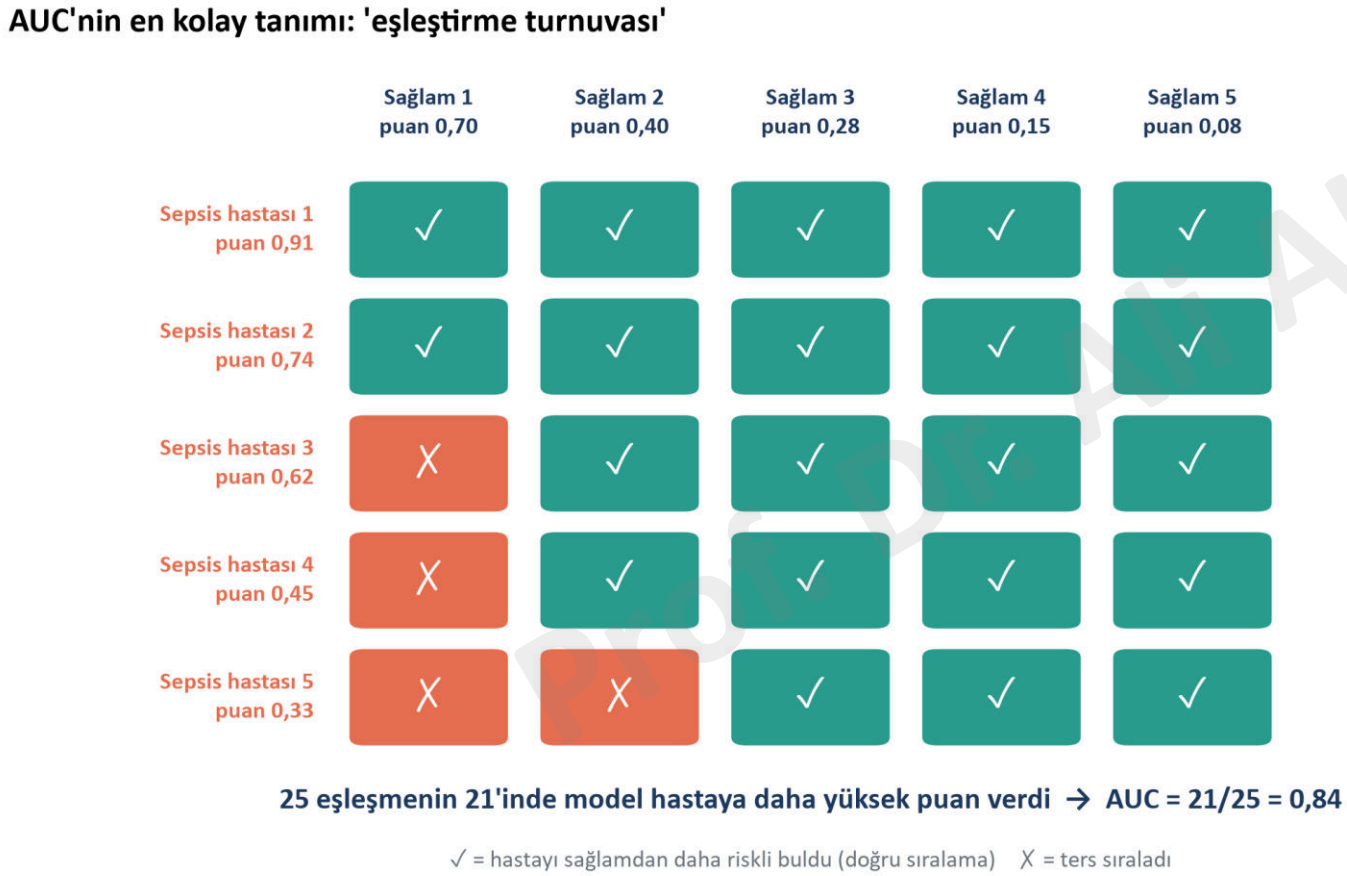
AUC 0,89

Bizim veriden: XGBoost: 100 hasta–sağlam eşleşmesinin ≈ **89'unda** hastayı öne koyuyor. **“%89 doğru” değil!**

Dedektör dili: AUC = dedektörün tehlikeliyi zararsızdan “daha çok koklama” becerisi.

Prof. Dr. Ali AKDAĞLI

AUC = eşleştirme turnuvası



Şekil · 5 hasta × 5 sağlam = 25 eşleşme; 21'inde hasta önde

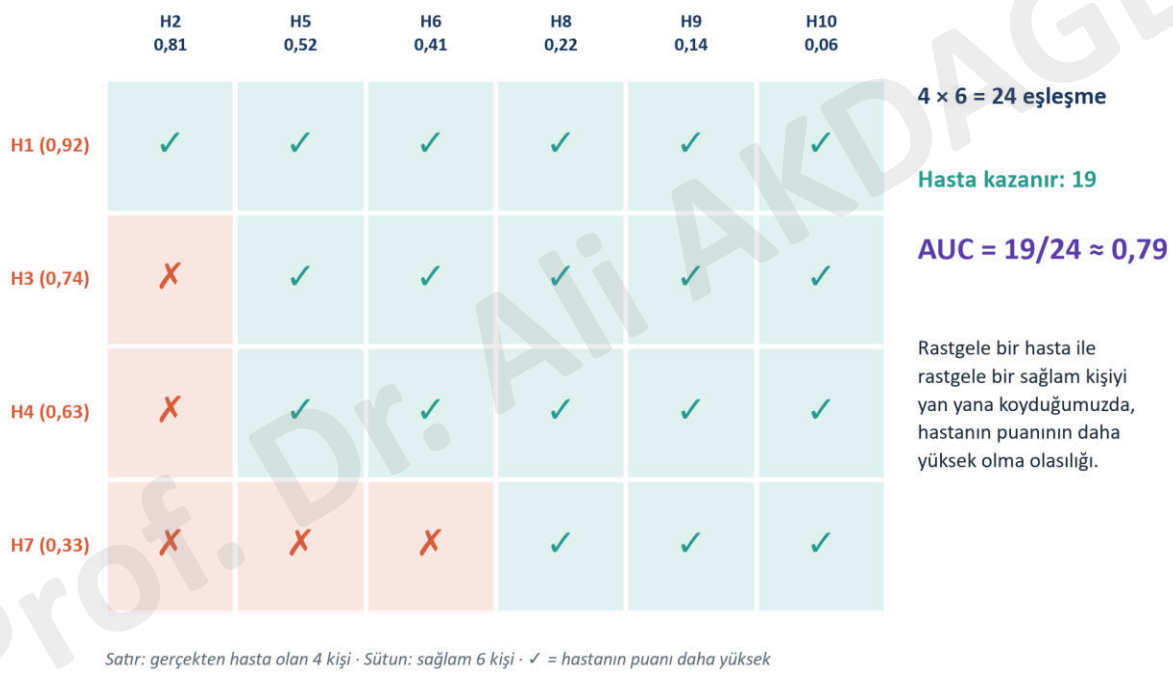
1. Her hücre bir maç: **hasta mı sağlam mı** daha yüksek puan aldı?

2. 25 maçın **21'inde** hasta önde

3. AUC = 21 / 25 = **0,84**

Prof. Dr. Ali AKDAĞLI

AUC = 24 eşleşmede 19 galibiyet



Prof. Dr. Ali AKDAĞLI

Şekil 2.C · Rastgele bir hasta, rastgele bir sağlam: kimin puanı yüksek?

1. Her hasta her sağlamla **eşleşir**: 4 × 6 = 24
2. Hastanın puanı yüksekse ✓: 19 kez
3. AUC = 19/24 ≈ **0,79**

AUC turnuvası: 5 hasta, 5 sağlam

1. Ekranda 5 **“hasta”**, 5 **“sağlam”** kartı; her kartta bir **risk puanı**.
2. Her hasta kartı her sağlam kartla karşılaşır: **puanı yüksek olan** maçı kazanır.
3. Hastaların kazandığı maçları sayıyoruz: **25 maçın kaçı?**
4. Kazanılan maç ÷ 25 = sizin turnuvanızın **AUC'si**.
5. İkinci kart setiyle (karışık puanlar) tekrarlıyoruz: AUC nasıl değişti?

Neye ihtiyacımız var?

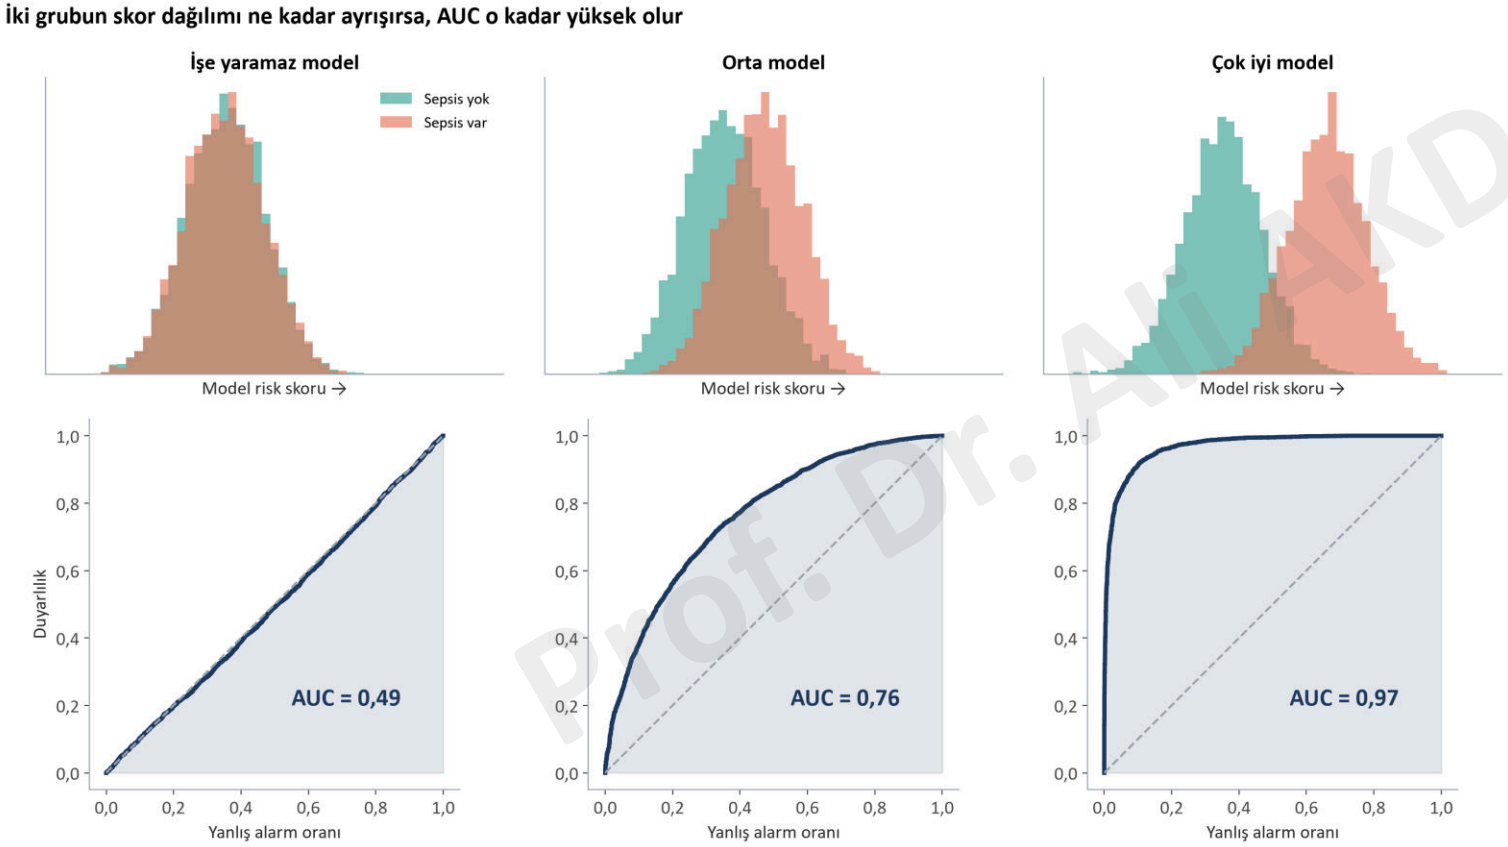
- Ekranda iki kart seti (A: iyi model, B: karışık)
- Kendi cihazınızda ders notu: Şekil 2.C

Ne öğreniyoruz?

AUC = rastgele bir hasta–sağlam çiftinde **hastanın daha yüksek puan alma** oranı. **Eşik kullanılmaz**; yalnızca sıralamaya bakılır.

Prof. Dr. Ali AKDAĞLI

AUC ne demek?



Şekil 2.3 · Skor dağılımlarının örtüşmesi ve AUC

1. Rastgele bir hasta–sağlam çiftinde hastaya **daha yüksek skor** verme olasılığı

2. 0,5 yazı-tura · 0,7–0,8 kabul edilebilir

3. 0,8–0,9 iyi · >0,9 mükemmel (kaba rehber)

Prof. Dr. Ali AKDAĞLI

AUC neyi söyler, neyi söylemez?

AUC söyler

- Hastaları ne kadar iyi **sıraladığını**
- Eşikten bağımsız genel ayırma gücünü
- Modelleri karşılaştırmaya yarar

AUC söylemez

- “%90 doğru tahmin” **değildir**
- Uyarıların kaçı doğru (PPV)
- Risk doğru mu (kalibrasyon)
- Hangi eşikte kullanılacağı

Prof. Dr. Ali AKDAĞLI

AUC 0,90 ≠ “%90 doğru tahmin”

Eşik düğmesi: aynı model, üç ayar

Eşik = duman dedektörünün hassasiyet düğmesi (gerçek sepsis verimizden)



Hangisi doğru? Kaçırmanın bedeli ile boşa koşmanın bedeline siz karar verirsiniz — bu bir klinik karardır.

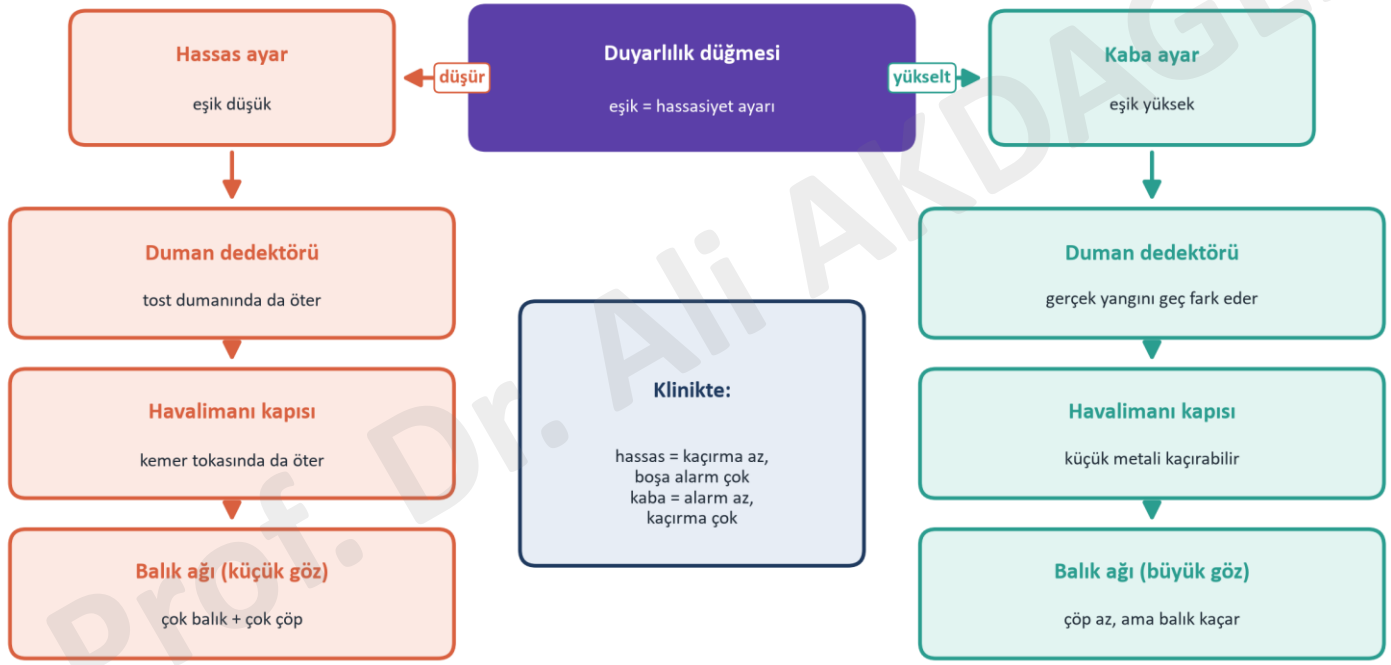
Şekil · Gerçek sepsis verimizde üç eşik: %5, %20, %50

1. Çok hassas (%5): **38,6 alarm**/100, %91 yakalanır
2. Dengeli (%20): 12,8 alarm, %61
3. Kaba (%50): **4,9 alarm**, yalnızca %35

Dedektör dili: düğmeyi çevirmek modeli değil, ötme sıklığını değiştirir.

Prof. Dr. Ali AKDAĞLI

Duyarlılık düğmesi üç yerde



Şekil 2.D · Duman dedektörü · havalimanı kapısı · balık ağı

1. **Hassas ayar:** kaçırma az, boşa alarm çok
2. **Kaba ayar:** alarm az, kaçırma çok
3. Doğru ayarı **kaybın bedeli** belirler

Prof. Dr. Ali AKDAĞLI

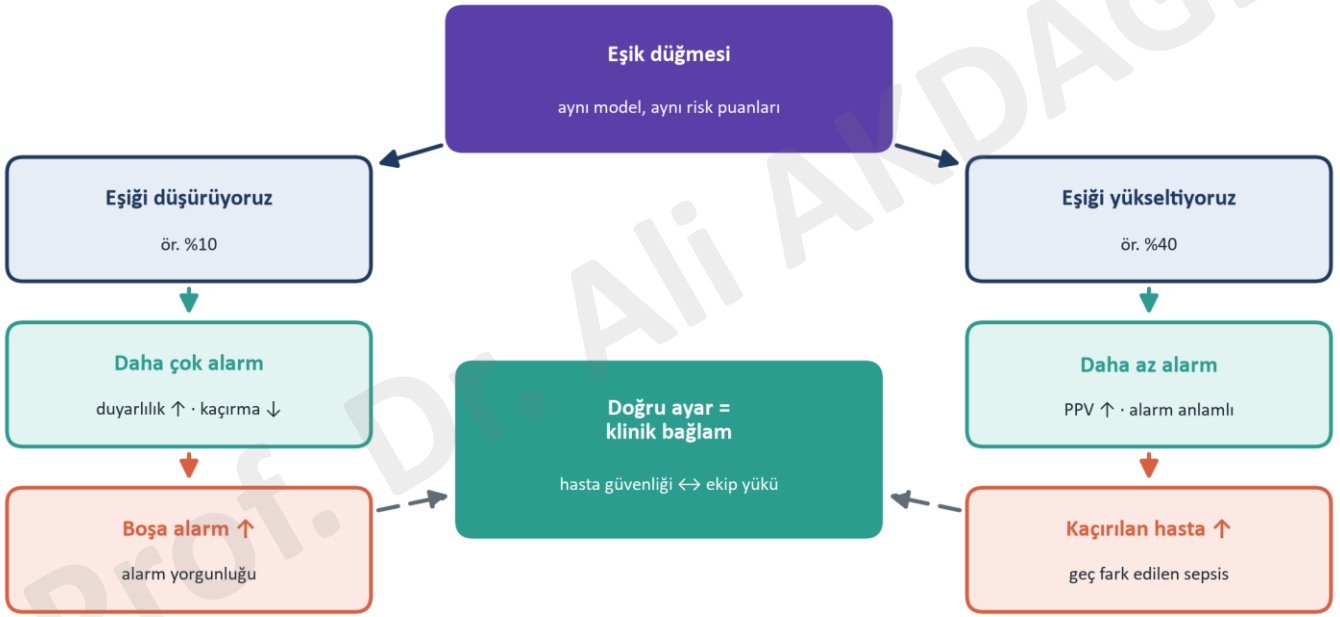
Eşik tablosu: aynı model, beş karar

Eşik	Duyarlılık	Özgüllük	100 hastada uyarı	PPV
%5	%91	%67,2	38,6	%23,3
%10	%82	%83,1	23,3	%34,8
%20	**%60,7**	**%92,5**	**12,8**	**%47**
%30	%46,1	%95,4	8,7	%52,6
%50	%34,8	%98,4	4,9	%70,5

Prof. Dr. Ali AKDAĞLI

Dedektör dili: düğmenin beş ayarı; dedektörün kendisi hiç değişmedi.

Eşiği düşürmek, eşiği yükseltmek



Prof. Dr. Ali AKDAĞLI

Akış 2.3 · İki yön, iki bedel, tek klinik karar

1. Eşiği düşürmek: **kaçırma azalır**, alarm yükü artar
2. Eşiği yükseltmek: **alarm azalır**, kaçırma artar
3. Doğru ayarı **klinik bağlam** belirler

Eşik düğmesini biz ayarlıyoruz

?

Gece 2 hemşire, 30 hasta. Sepsis modeli için hangi eşiği seçersiniz?

A **%5 · çok hassas**

%91 yakalanır · **38,6 uyarı**/100 hasta · uyarıların %23'ü gerçek

B **%20 · dengeli**

%61 yakalanır · **12,8 uyarı** · uyarıların %47'si gerçek

C **%50 · kaba**

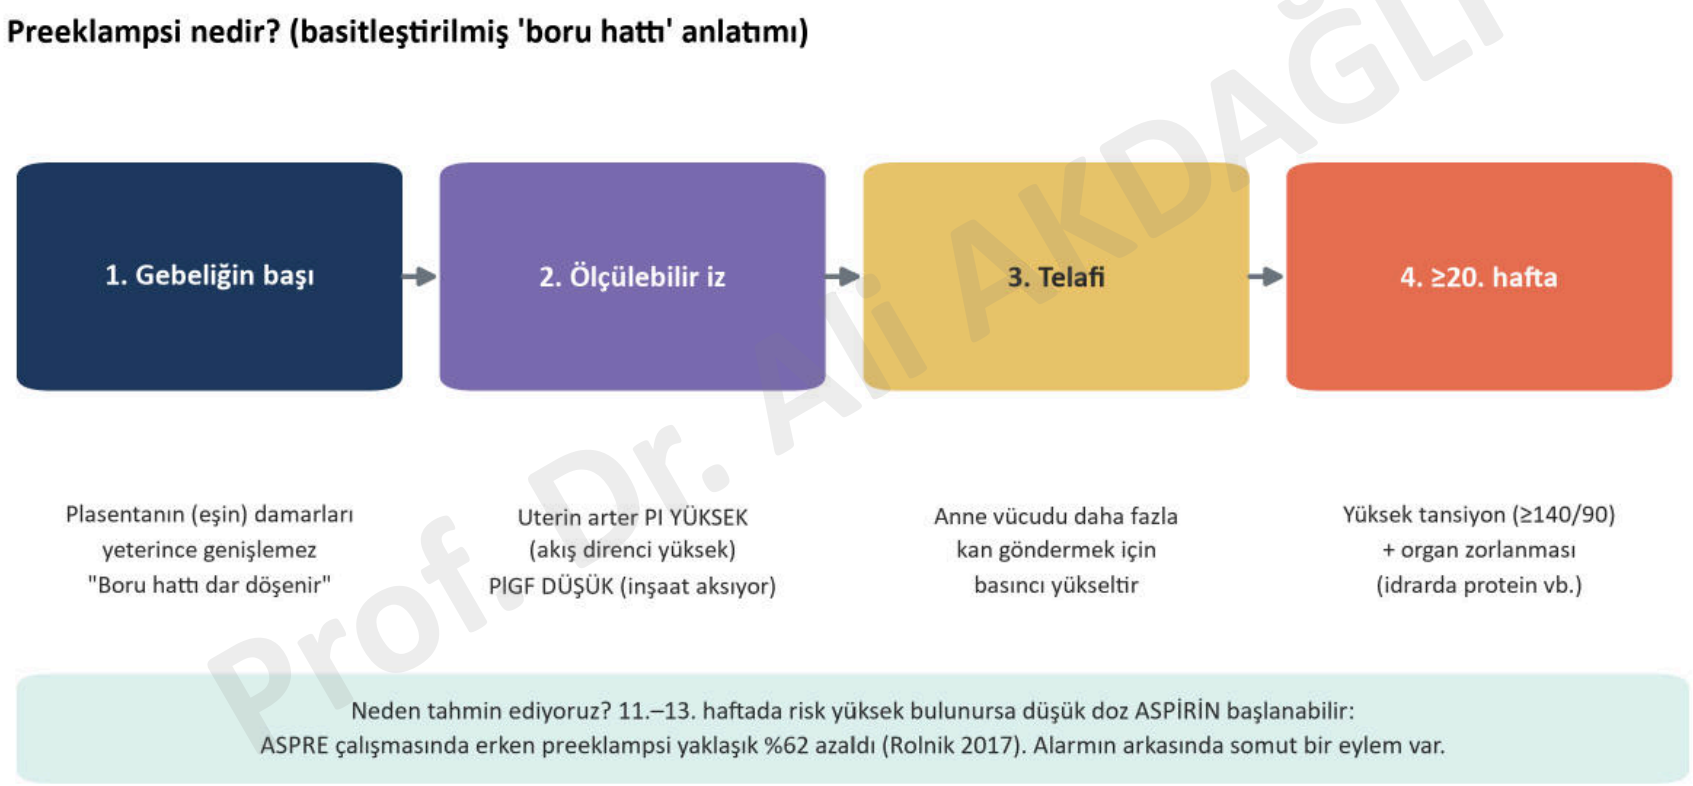
%35 yakalanır · **4,9 uyarı** · uyarıların %71'i gerçek

Doğru cevap yok, gerekçe var: kaçırmanın bedeli mi, boşa koşmanın bedeli mi?

Dedektör dili: düğmeyi kim çeviriyor? İstatistikçi değil, klinik ekip.

Prof. Dr. Ali AKDAĞLI

Preeklampsi nedir? Dar döşenmiş boru hattı



Şekil · Preeklampsinin basitleştirilmiş "boru hattı" anlatımı

1. Plasenta damarları **dar** (boru hattı)
2. Anne vücudu **basıncı artırır** (tansiyon ↑)
3. Erken risk → **aspirin** (ASPRE ≈ %62 azalma)

Prof. Dr. Ali AKDAĞLI

Bu kelimeler ne demek? · Preeklampsi (1)

Preeklampsi
20. haftadan sonra yeni yüksek tansiyon (≥140/90) + organ etkilenmesi.
≈ dar boru hattına karşı basıncı artırmak

Eklampsi
Preeklampsiye nöbet (havale) eklenmesi; çok ağır tablo.

Trimester · 11–13. hafta
Gebeliğin üç aylık dönemleri; 11–13. hafta tarama zamanı.

Nullipar
Hiç doğum yapmamış kadın; ilk gebelik riski artırır.
≈ primipar: 1 doğum · multipar: çok doğum

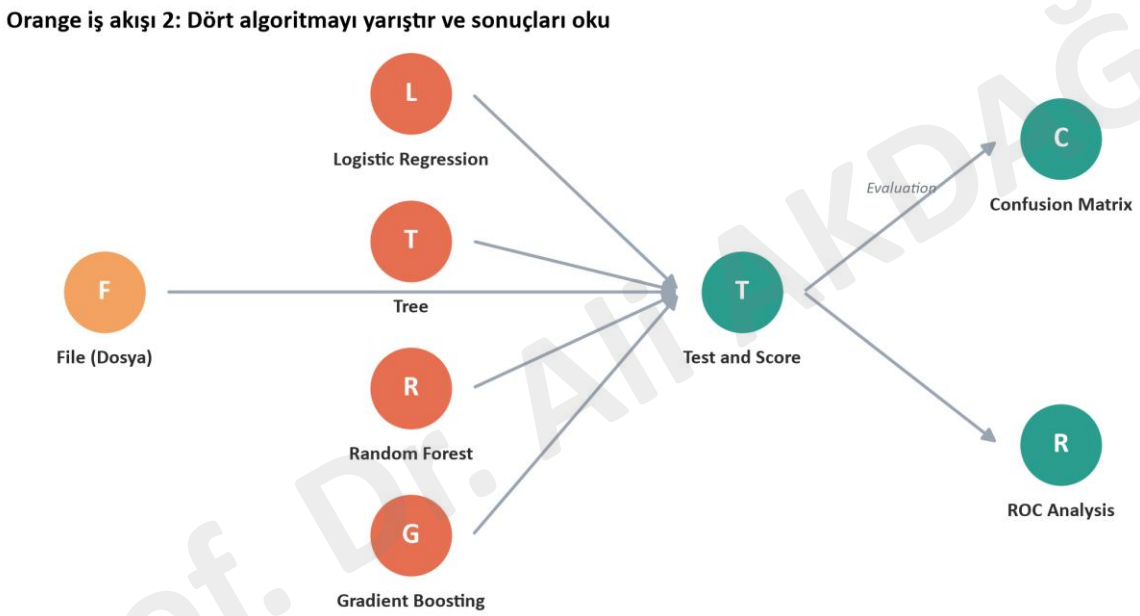
Kronik HT · pregestasyonel diyabet
Gebelikten önce var olan yüksek tansiyon · diyabet.

OAB
Ortalama arter basıncı ≈ (sistolik + 2 × diyastolik) / 3. 120/80 → ≈ 93 mmHg.
≈ zaman ortalamalı basınç

Preeklampsi verimizde prevalans %5,5: nadir olay → düşük PPV bekliyoruz.

Prof. Dr. Ali AKDAĞLI

Orange 2: dört algoritmayı yarıştır

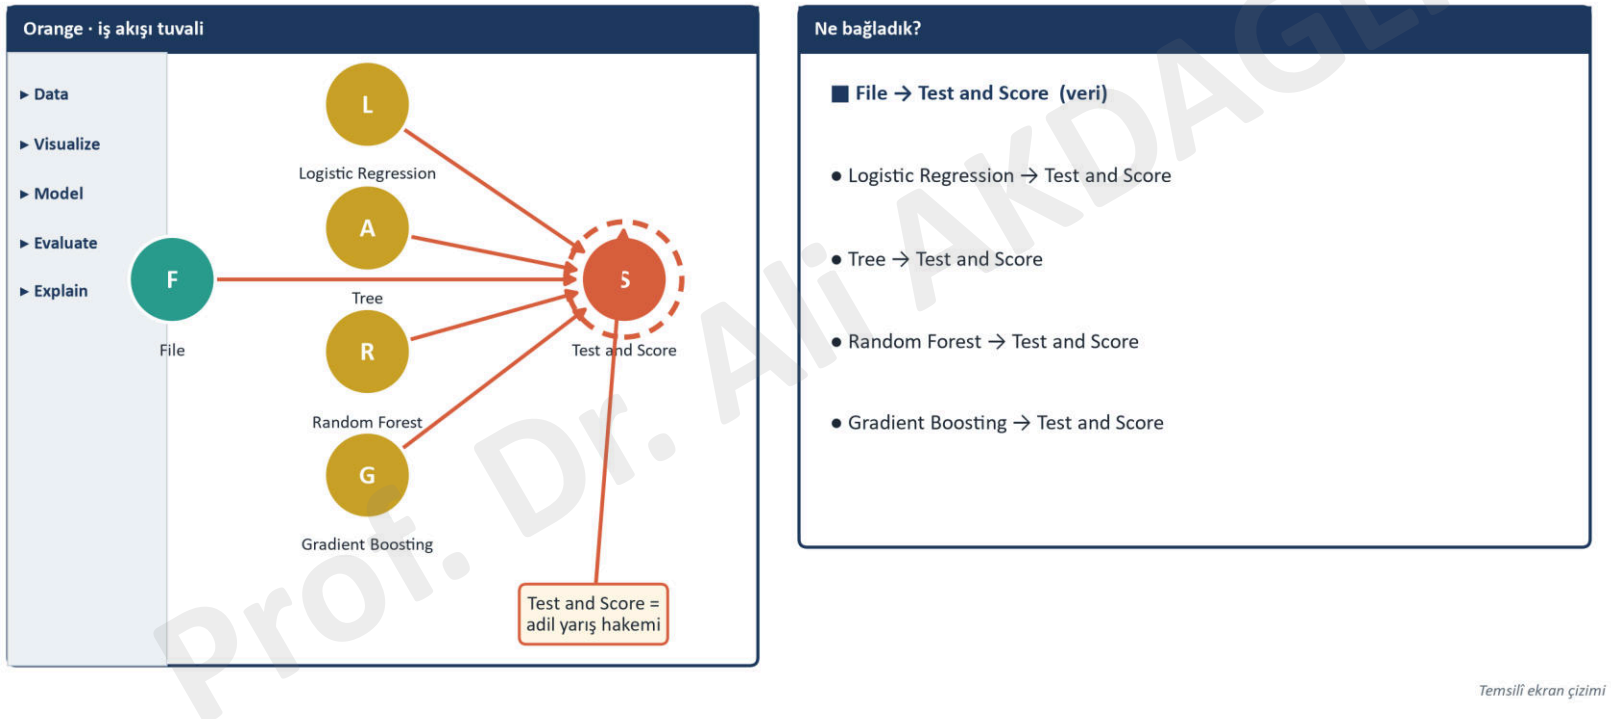


Şekil 2.8 · Orange iş akışı 2

1. **File** → sepsis (Role = target)
2. **Logistic Regression, Tree, Random Forest, Gradient Boosting** ekliyoruz
3. Hepsini **Test and Score**'a bağlıyoruz
4. Cross validation **5 kat**; Target class = **Evet**
5. → **Confusion Matrix** ve **ROC Analysis**
6. Eşiği kaydırıyoruz; **preeklampsi** ile tekrarlıyoruz

Prof. Dr. Ali AKDAĞLI

Adım 1 · Dört öğreniciyi yarışa sokuyoruz



Temsilî ekran çizimi

Temsilî ekran çizimi · Orange 2 · Dört algoritmayı yarıştırmak · Adım 1

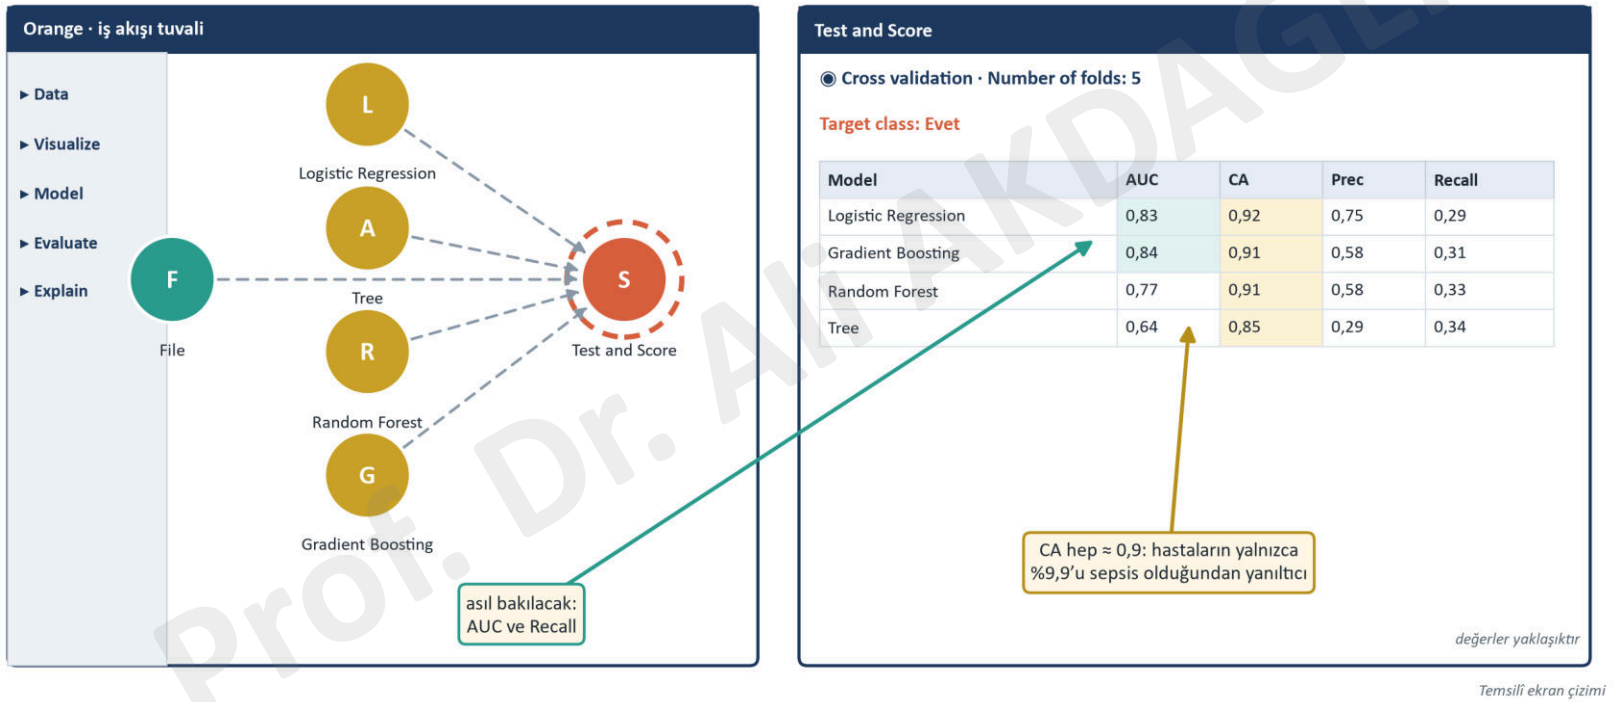
1 **Yapacağımız:** 4 öğrenici + File → Test and Score

2 **Ekranda:** beş bağlantı

3 **Anlamı:** aynı veri, aynı kurallar, adil yarış

Prof. Dr. Ali AKDAĞLI

Adım 2 · Ayarlar ve skor tablosu



Temsilî ekran çizimi

Temsilî ekran çizimi · Orange 2 · Dört algoritmayı yarıştırmak · Adım 2

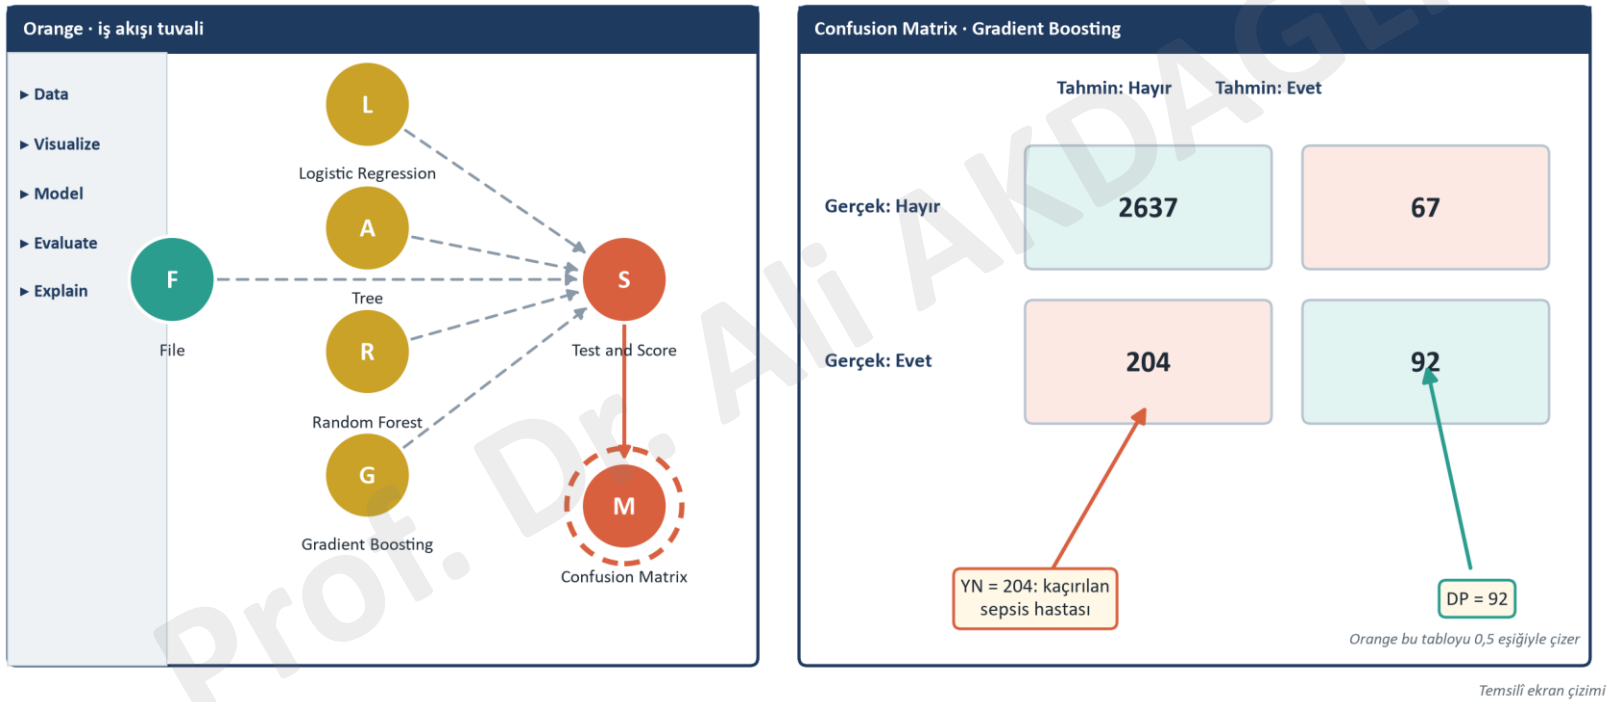
1 **Yapacağımız:** 5 kat çapraz doğrulama, hedef = Evet

2 **Ekranda:** CA hep ≈ 0,9

3 **Anlamı:** AUC: GB ≈ 0,84 · LR ≈ 0,83 · ağaç ≈ 0,64

Prof. Dr. Ali AKDAĞLI

Adım 3 · Karışıklık matrisini okuyoruz



Temsilî ekran çizimi

Temsilî ekran çizimi · Orange 2 · Dört algoritmayı yarıştırmak · Adım 3

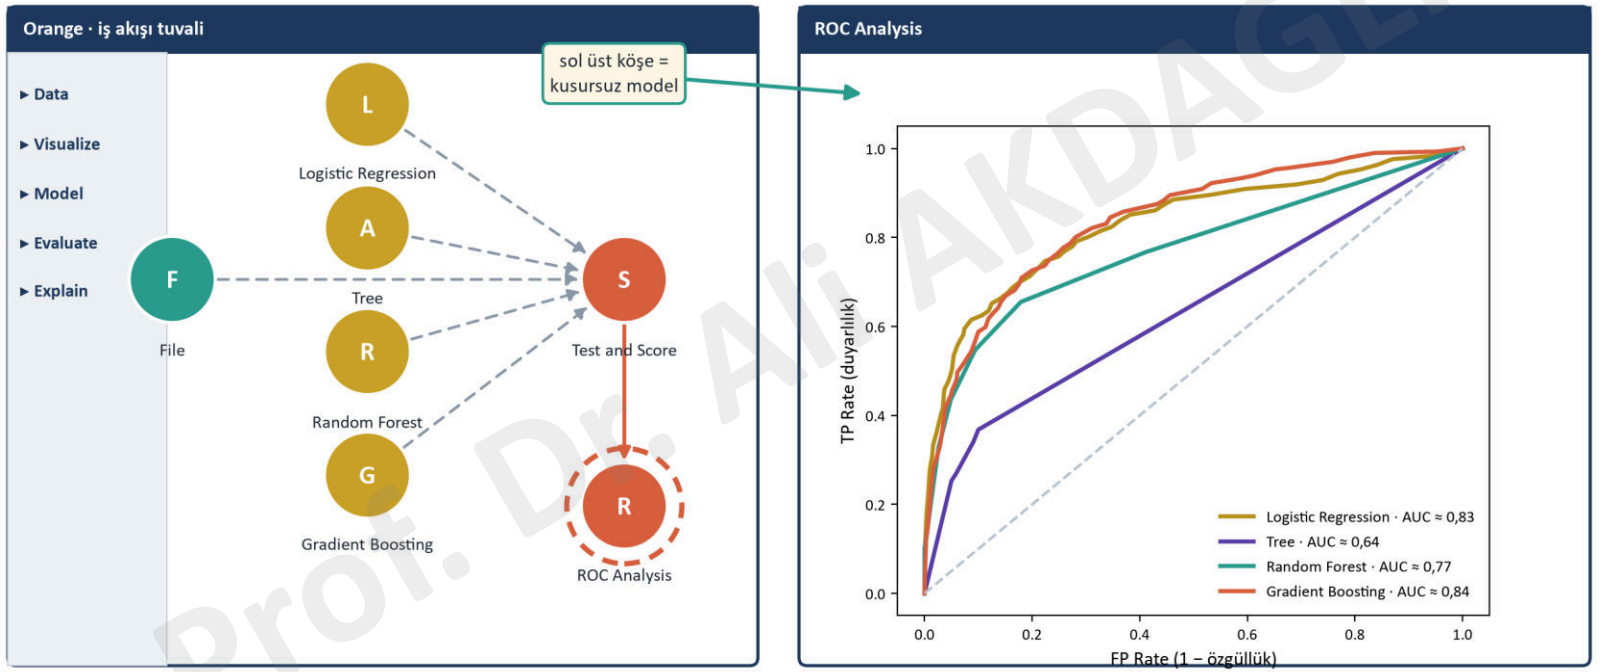
1 **Yapacağımız:** Test and Score → Confusion Matrix

2 **Ekranda:** DP 92 · YN 204 (eşik 0,5)

3 **Anlamı:** duyarlılık ≈ %31; eşik bir tercihtir

Prof. Dr. Ali AKDAĞLI

Adım 4 · ROC eğrilerini karşılaştırıyoruz



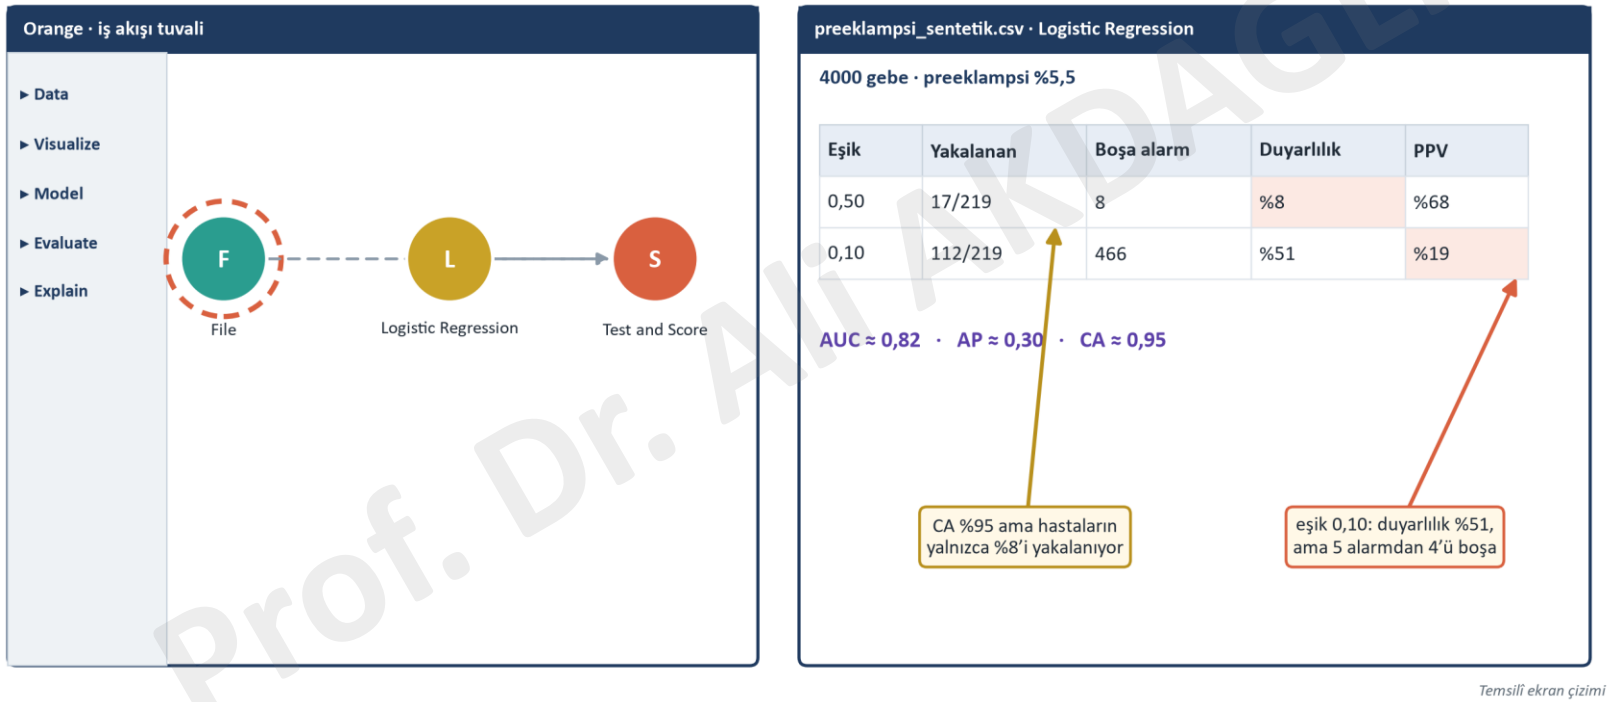
Temsilî ekran çizimi

Prof. Dr. Ali AKDAĞLI

Temsilî ekran çizimi · Orange 2 · Dört algoritmayı yarıştırmak · Adım 4

1. **Yapacağımız:** Test and Score → ROC Analysis
2. **Ekranda:** dört eğri + köşegen
3. **Anlamı:** GB ≈ LR > RF > ağaç

Adım 5 · Nadir olay: preeklampsi verisiyle tekrar



Prof. Dr. Ali AKDAĞLI

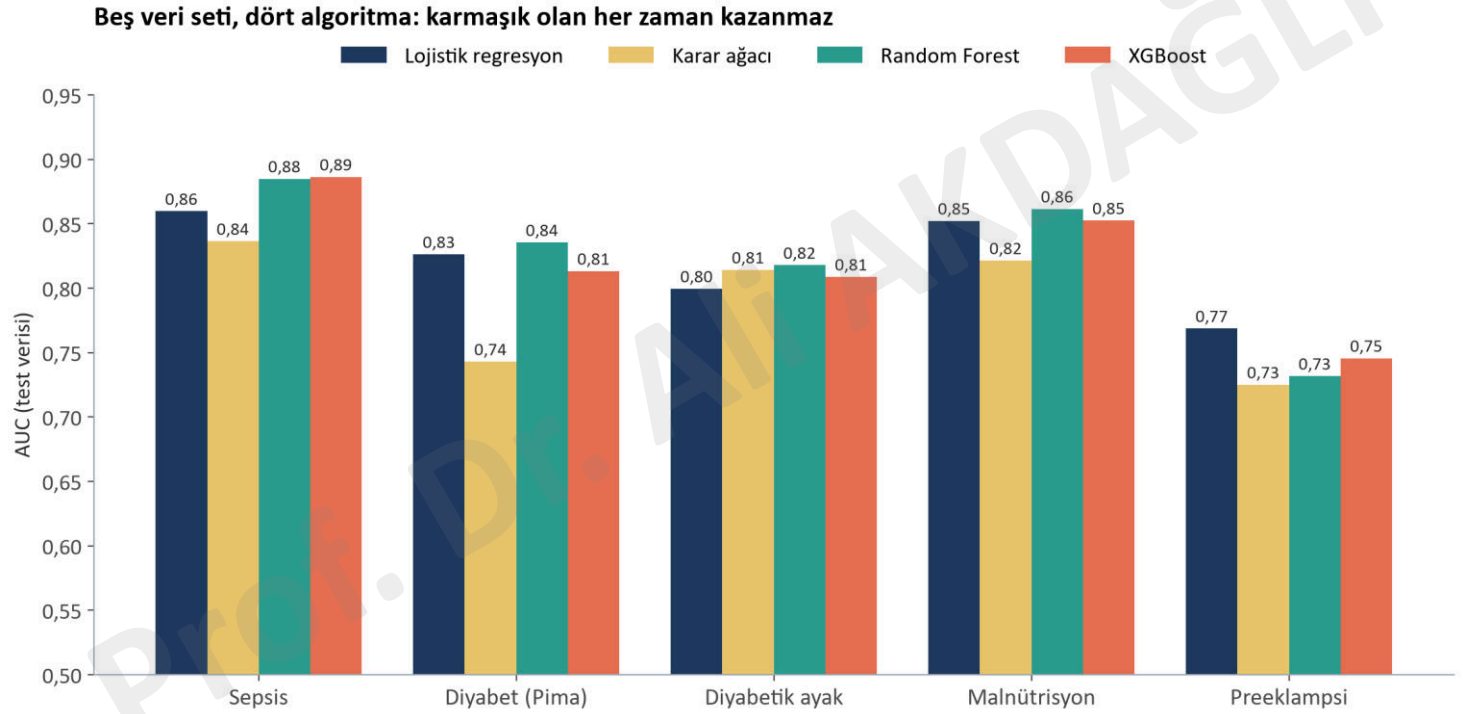
Temsilî ekran çizimi · Orange 2 · Dört algoritmayı yarıştırmak · Adım 5

1 **Yapacağımız:** dosya = preeklampsi, hedef = Gelişti

2 **Ekranda:** CA ≈ 0,95, yakalanan çok az

3 **Anlamı:** eşik 0,10'da duyarlılık %51, PPV ≈ %19

Karmaşık her zaman kazanmaz



Şekil 2.9 · Beş veri seti × dört algoritma, AUC

1 Sepsis: XGB 0,89 · RF 0,88 · **LR 0,86**

2 Preeklampsi: **LR birinci** (0,77)

3 Christodoulou 2019: ML, LR'ye göre üstünlük göstermedi

Prof. Dr. Ali AKDAĞLI

KAVRAM KARTI

Kalibrasyon

Calibration

Söylenen risk = gerçekleşen oran mı?

Model “%30 risk” dediği hastaların gerçekten ≈ %30'u hastalanıyor mu? Sıralama değil, sayının kendisi.

Mühendislik

Terazi: ağırı ağır gösterir (sıralama doğru) ama hep 2 kg fazla tartarsa kalibrasyonu bozuk.

Günlük hayat

Hava durumu: “%30 yağmur” denen 100 günün ≈ 30'unda yağıyor mu?

Klinik

Risk iletişimi: hastaya “riskiniz %68” diyecekseniz sayı gerçek olmalı.

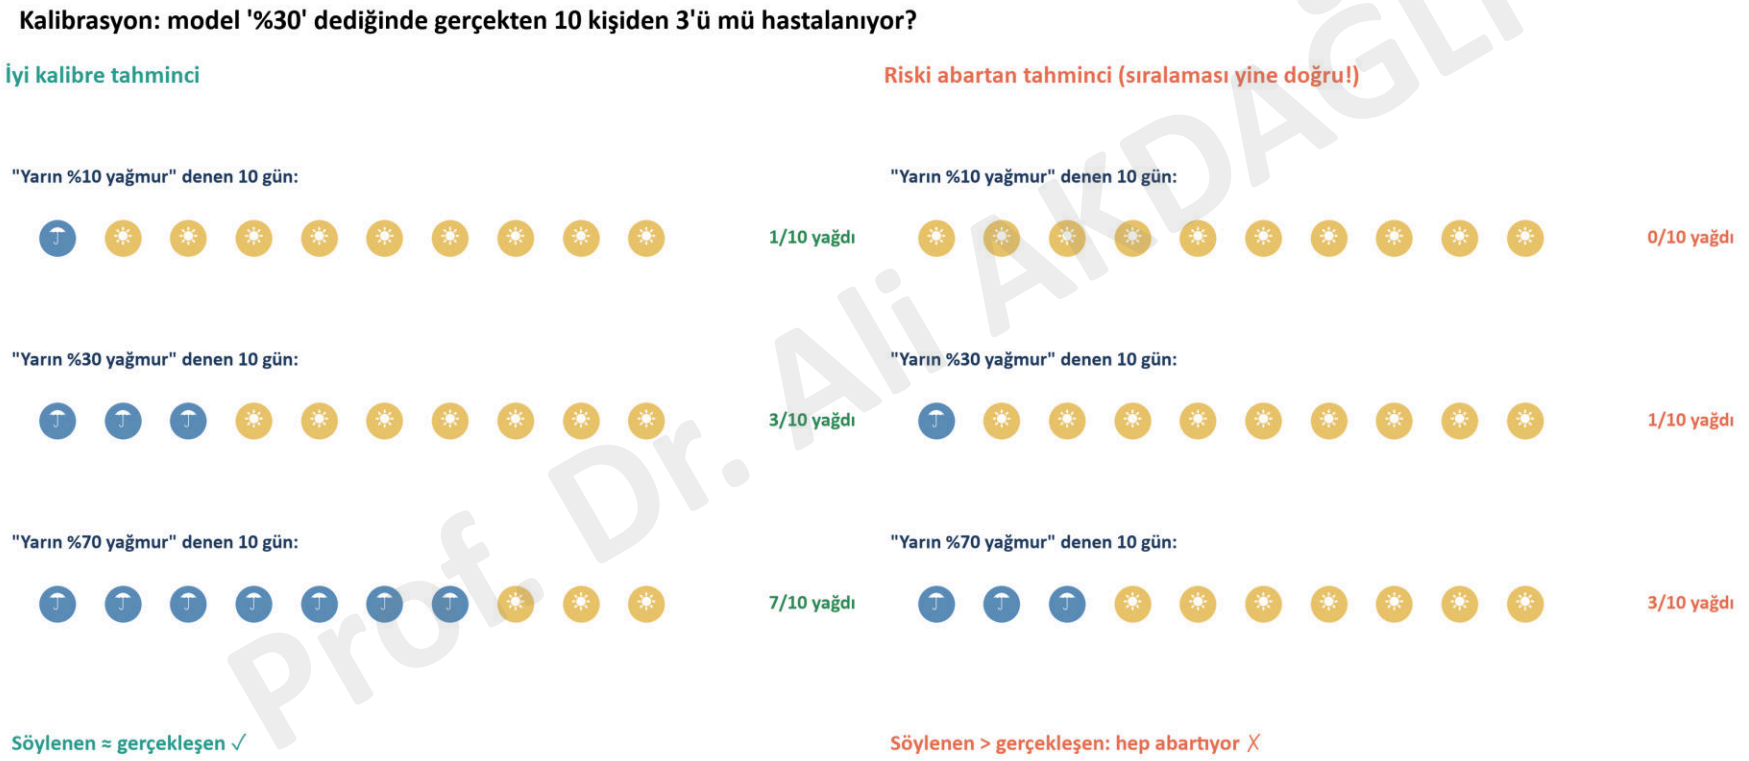
%24,3 vs %9,9

Bizim veriden: Dengelenmiş XGBoost: AUC yine **0,89** ama riski **≈ 2,5 kat** abartıyor.

Dedektör dili: kalibrasyon = dedektörün “duman yoğunluğu” göstergesinin doğruluğu.

Prof. Dr. Ali AKDAĞLI

Kalibrasyon = dürüst hava durumu

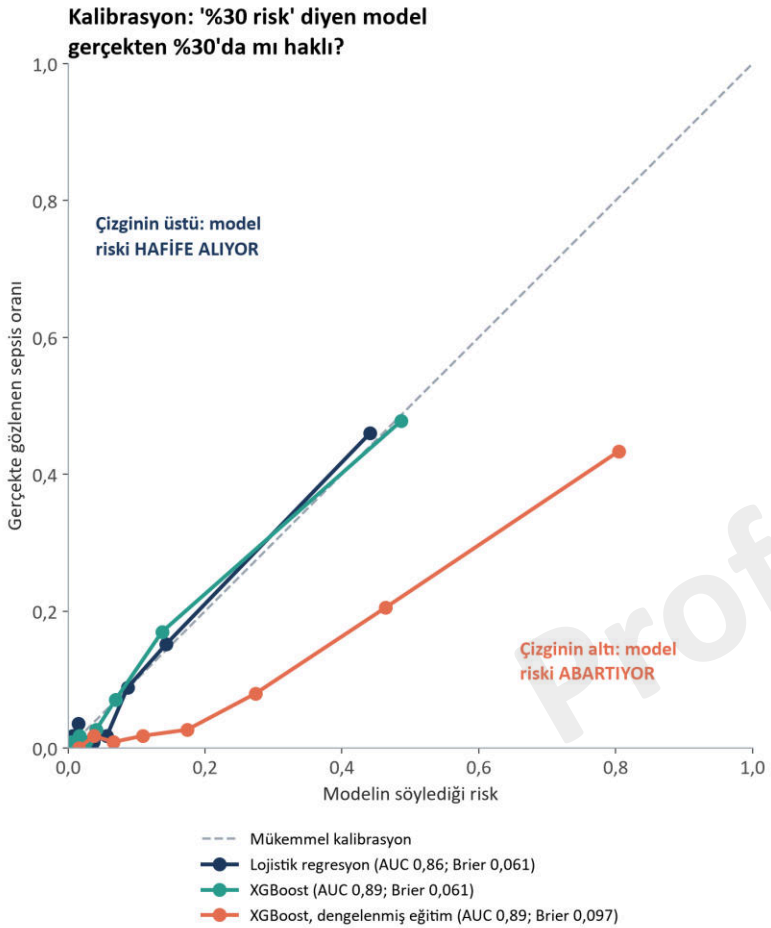


Şekil · "%30 yağmur" denen 10 günün kaçında yağdı?

1. Solda: söylenen = gerçekleşen
2. Sağda: hep **abartıyor**, ama sıralaması doğru
3. AUC sıralamayı, kalibrasyon **sayının kendisini** ölçer

Prof. Dr. Ali AKDAĞLI

Kalibrasyon: “%30” gerçekten %30 mu?



Şekil 2.6 · Kalibrasyon eğrileri

AUC 0,89

Dengelenmiş XGBoost'un AUC'si: **değişmedi**

%24,3 → %9,9

Ortalama tahmin → gerçek oran (**≈2,5 kat abartı**)

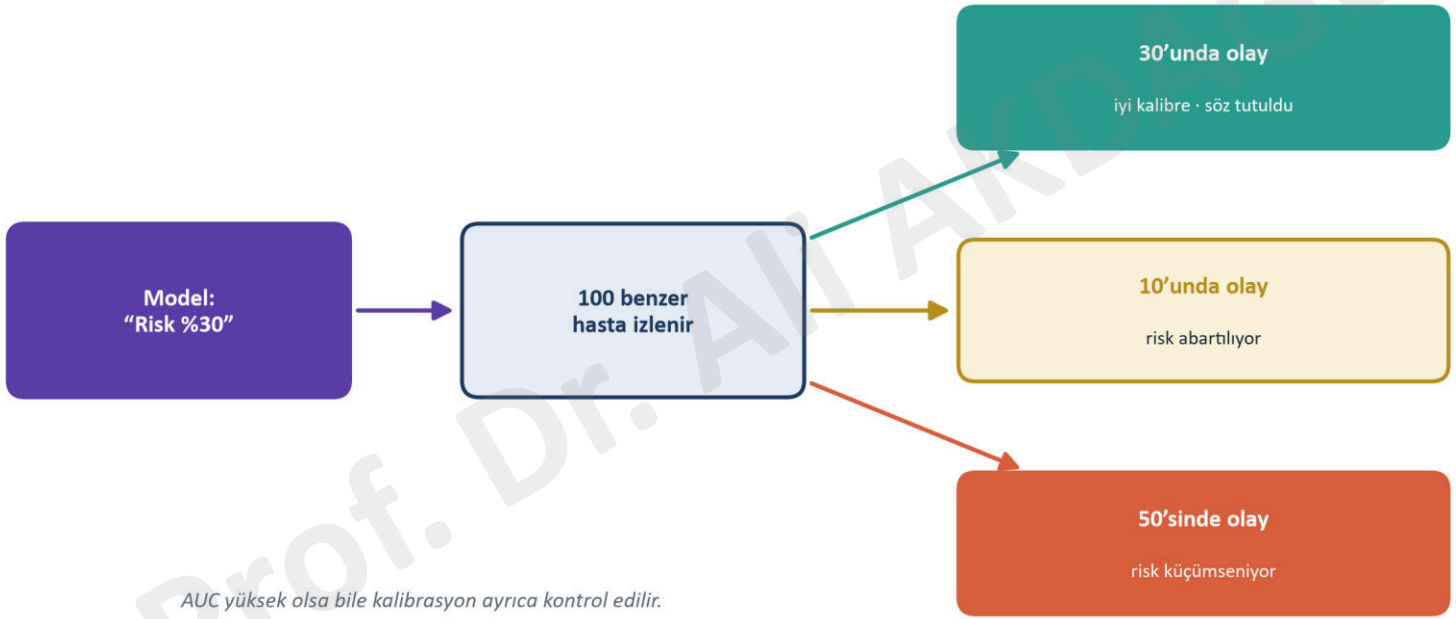
AUC aynı, kalibrasyon bozuk.

“Tahmin modellerinin Aşil topuğu” (Van Calster 2019)

Prof. Dr. Ali AKDAĞLI

Dedektör dili: dedektör hangi odada daha çok duman olduğunu bilir ama miktarı abartır.

“%30” sözünü tutuyor mu?



Akış 2.4 · 100 benzer hasta, üç olası sonuç

1 **30’unda** olay → sözünü tutuyor

2 **10’unda** → riski abartıyor

3 **50’sinde** → riski küçümsüyor

Prof. Dr. Ali AKGÖLLÜ

KISALTMA KARTI

Brier

Brier score

Olasılık tahminlerinin ortalama kare hatası

Söylenen olasılık ile gerçekleşen sonuç (0/1) arasındaki farkların karesinin ortalaması. Küçük = iyi.

Mühendislik

MSE: olasılıklar için ortalama kare hata; hem ayrımı hem kalibrasyonu cezalandırır.

Günlük hayat

Dart: her atışın merkeze uzaklığının karesi; ortalama küçükse iyi atıcı.

Klinik

Risk sözü: “%90” deyip olmazsa büyük ceza (0,81); olursa küçük ceza (0,01).

0,061 vs 0,097

Bizim veriden: İyi kalibre modeller **0,061**; riski abartan dengelenmiş model **0,097**.

Prof. Dr. Ali AKDAĞLI

KISALTMA KARTI

PR · AP

Precision–Recall curve · Average Precision

Kesinlik–duyarlılık eğrisi · ortalama kesinlik

Eşik değiştikçe PPV ile duyarlılığı birlikte çizer; nadir olaylarda ROC'un daha dürüst kardeşi.

Mühendislik

Arama motoru: 10 sonucun kaçı alakalı? Anomali tespitinde standart ölçüt.

Günlük hayat

Samanlıkta iğne: 1000 samandan 50'sine boşa alarm “%5” görünür ama 10 iğneyi boğar.

Klinik

Nadir olay: preeklampside “uyarıların kaçı doğru?” sorusunu görünür kılar.

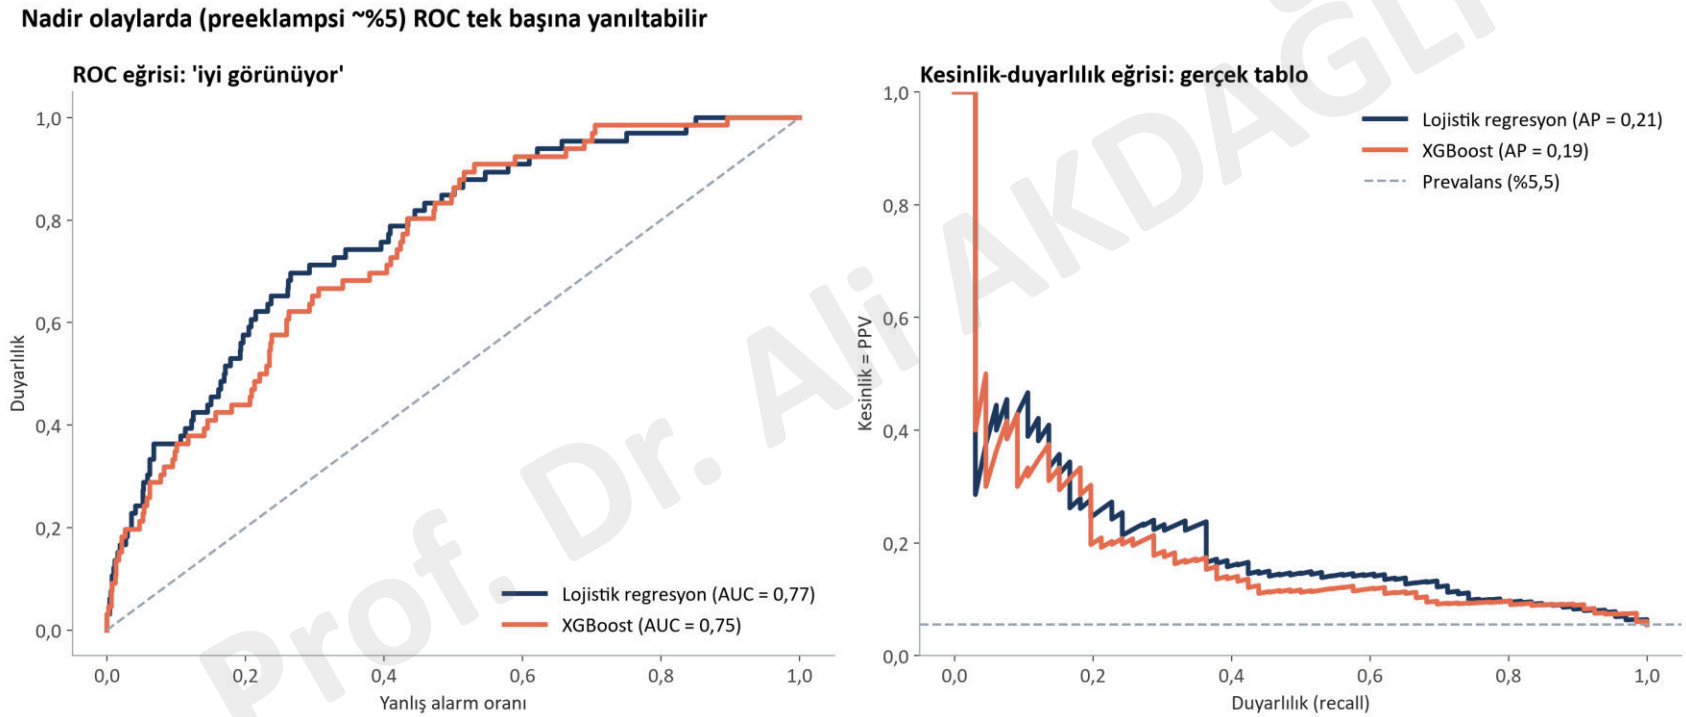
AUC 0,77 · AP 0,21

Bizim veriden: Preeklampsi (%5,5): ROC “iyi” görünür, ama tipik eşikte uyarıların ancak **beşte biri** doğru.

Dedektör dili: nadir yangında ROC iyimser, PR gerçekçidir.

Prof. Dr. Ali AKDAĞLI

Nadir olaylarda ROC yanıltabilir



Prof. Dr. Ali AKDAĞLI

Şekil 2.7 · Preeklampsi (%5,5): ROC ve kesinlik-duyarlılık eğrisi

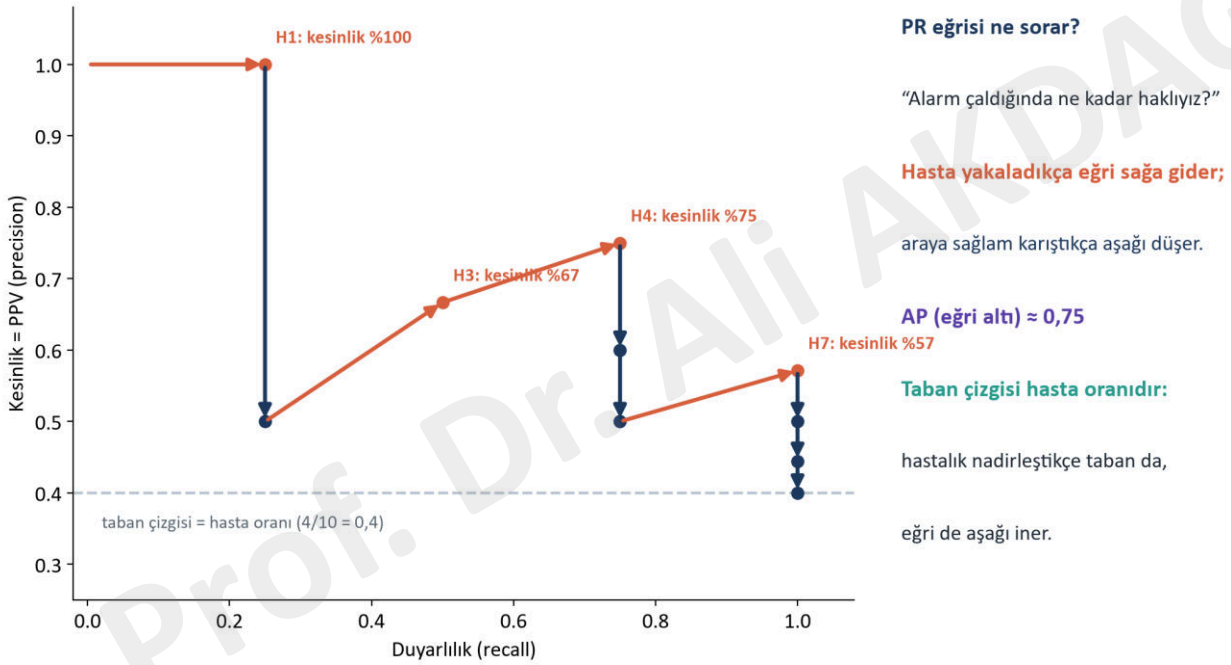
1 Prevalans **%5,5**

2 ROC: AUC 0,77 (LR), 0,75 (XGB): "iyi görünüyor"

3 PR: AP **0,21** ve 0,19: uyarıların çoğu yanlış alarm

Dedektör dili: nadir yangında ROC iyimser, PR gerçekçi konuşur.

PR eğrisi: alarm ne kadar haklı?



PR eğrisi ne sorar?

"Alarm çaldığında ne kadar haklıyız?"

Hasta yakaladıkça eğri sağa gider;

araya sağlam karıştıkça aşağı düşer.

AP (eğri altı) ≈ 0,75

Taban çizgisi hasta oranıdır:

hastalık nadirleştikçe taban da,

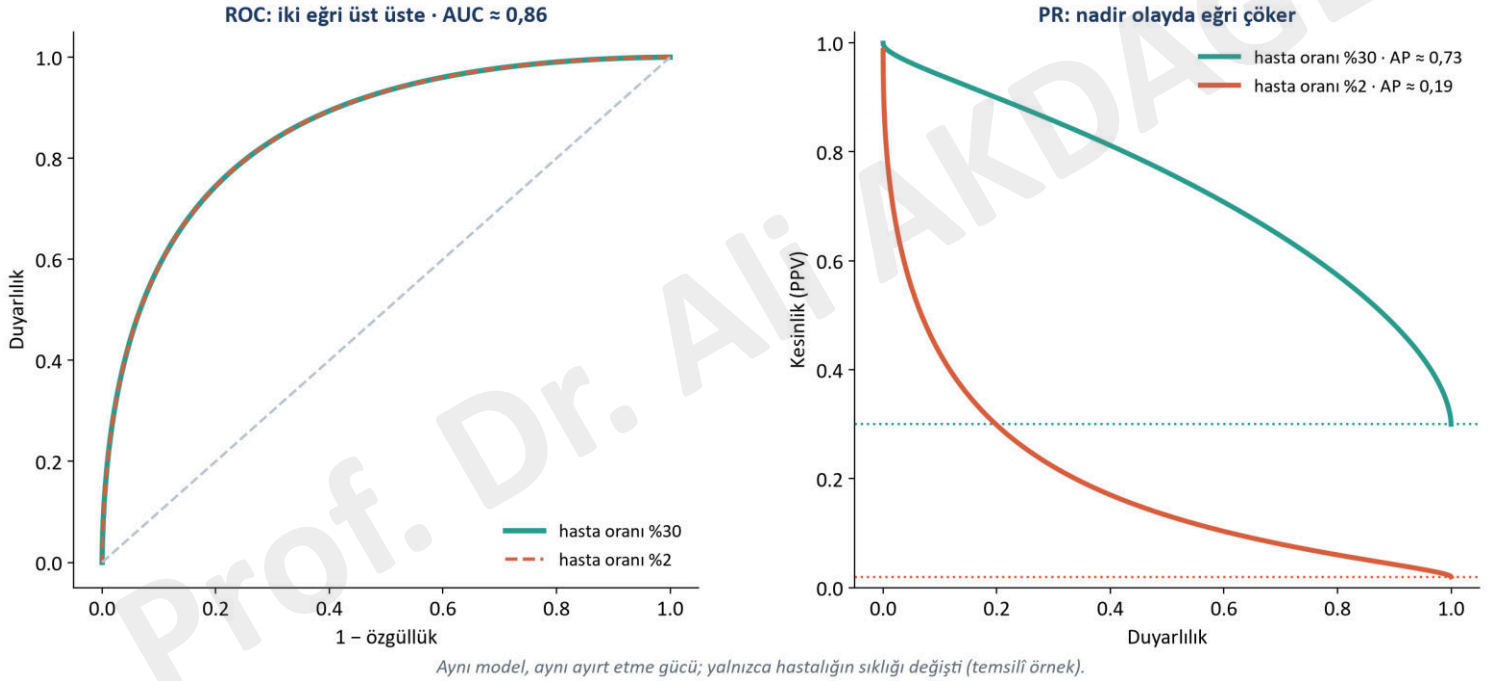
eğri de aşağı iner.

Prof. Dr. Ali AKDAĞLI

Şekil 2.E · Hasta yakaladıkça sağa, sağlam karıştıkça aşağı

1. PR eğrisi **PPV'nin** yolculuğudur
2. Taban çizgisi = **hasta oranı**
3. AP (eğri altı) ≈ **0,75**

Nadir olayda neden PR'ye bakarız?



Prof. Dr. Ali AKDAĞLI

Şekil 2.F · Hasta oranı %30 ve %2: ROC aynı, PR çok farklı

1. ROC/AUC hasta oranından **etkilenmez**
2. PR/AP hasta oranıyla **birlikte düşer**
3. Nadir olayda **AP ve PPV** mutlaka raporlanmalı

KAVRAM KARTI

Dış validasyon

External validation

Başka hastanede, başka dönemde sınamak

Modeli geliştirildiği yerden farklı bir hastanede ya da farklı bir dönemde test etmek.

Mühendislik

Saha testi: rüzgâr tünelinde mükemmel uçak, gerçek fırtınada nasıl uçuyor?

Günlük hayat

Başka şehrin yolları: kendi pistinde test edilen araba, bozuk yolda nasıl gidiyor?

Klinik

Sizin hastaneniz: başka yerde geliştirilen modeli kendi hastalarınızda sınamak.

0,76–0,83 → 0,63

Bizim veriden: Epic Sepsis Model: geliştiricinin AUC'si → **bağımsız dış validasyonda** AUC.

Dedektör dili: dükkânda test edilen dedektör sizin mutfağınızda da çalışıyor mu?

Prof. Dr. Ali AKDAĞLI

Vaka: Epic Sepsis Model

0,76–0,83

Geliştiricinin bildirdiği AUC

0,63

Dış validasyonda AUC (27.697 hasta, 38.455 yatış)

%67

Kaçırılan sepsis vakası

Yatışların %18'inde uyarı · Wong ve ark., JAMA Intern Med, 2021

Dedektör dili: dükkânda iyi çalışan dedektör, sizin evinizde hem sustu hem boşa öttü.

Prof. Dr. Ali AKDAĞLI

Epic vakası: tartışıyoruz

E Olgu özeti

Yaygın kullanılan, **ticari ve kapalı** bir sepsis modeli

Geliştirici AUC'si: **0,76–0,83**

Michigan dış validasyonu: **AUC 0,63**

Sepsislerin **%67'si** kaçırıldı

Yatışların **%18'inde** uyarı

? Tartışıyoruz

1. Geliştirici ile dış validasyon arasındaki fark neden bu kadar büyük?

2. Bu modeli satın alacak olsaydınız **hangi soruları** sorardınız?

3. %18 uyarı oranı **30 yataklı** bir servis için ne demek?

4. Sepsis nasıl tanımlanmış olabilir?

Prof. Dr. Ali AKDAĞLI

Hesap alıştırması: 1000 hastalık servis

Verilenler: **1000 hasta · prevalans %5 · duyarlılık %80 · özgüllük %90**

	Gerçekte hasta (50)	Gerçekte sağlam (950)
Model: uyarı var	DP = ?	YP = ?
Model: uyarı yok	YN = ?	DN = ?

Sonra hesaplıyoruz: **PPV = DP / (DP + YP) = ?** · **NPV = DN / (DN + YN) = ?**

Prof. Dr. Ali AKDAĞLI

Oturum 2 özeti

- ✓ Karışıklık matrisi = karne; en tehlikelisi **yanlış negatif**
- ✓ AUC = sıralama başarısı; **“%90 doğru” değil**
- ✓ PPV **prevalansa** bağlı: aynı model, farklı servis
- ✓ Eşik bir **klinik karar**; alarm yorgunluğu gerçek
- ✓ Ayırma ≠ **kalibrasyon**: ikisine birden bakıyoruz

? Düşünmeye değer

1. Bugün öğrendiğim en önemli şey…
2. Hâlâ kafamı karıştıran bir şey…
3. Servisim için hangi eşiği seçerdim, neden?

Prof. Dr. Ali AKDAĞLI

Bugünün kısaltmaları · Oturum 2

DP·YP·YN·DN	Doğru/yanlış pozitif/negatif: alarmın dört sonucu
Duyarlılık	Hastaların kaçını yakaladık? (recall) 54/89
Özgüllük	Sağlamların kaçına sustuk? 750/811
PPV	Alarm çalınca gerçekten hasta mı? (precision) 54/115
NPV	Model susunca gerçekten sağlam mı? 750/785
Prevalans	Görülme sıklığı; nadirse PPV düşer
Doğruluk	(DP+DN)/hepsi; nadir olayda yanıltır
ROC	Eşik değişirken yakalama–boşa alarm eğrisi
AUC	Hasta–sağlam çiftinde hastayı öne koyma olasılığı
Kalibrasyon	“%30” dediği gerçekten %30 mu?
Brier · AP	Olasılık hatası · PR eğrisi altındaki alan
Dış validasyon	Başka hastanede, başka dönemde test

Prof. Dr. Ali AKDAĞLI

3

OTURUM 3

“Neden bu hasta?”

Açıklanabilirlik, SHAP grafikleri ve dört klinik vaka

Prof. Dr. Ali AKDAĞLI

00:00 Kavram

01:00 Uygulama

02:00 Dört klinik vaka

Bu oturumun hedefleri

1. Global ve yerel açıklamayı ayırt etmek
2. SHAP özet ve şelale grafiklerini yorumlamak
3. Açıklamanın nedensellik olmadığını bilmek
4. Dört klinik vakada model çıktısını eleştirel okumak

Bugünün akışı

00:00	Önem, SHAP, nedensellik
00:50	Ara
01:00	Orange: Explain
01:50	Ara
02:00	Dört klinik vaka

Prof. Dr. Ali AKDAĞLI

Kara kutu sorunu

?

Hemşire sorar: “Neden?”

Gerekçesi görünmeyen alarma güvenilmez; **güvenilmemelidir de.**

G

Global açıklama

Model **genelde** neye bakıyor? → değişken önemi

Y

Yerel açıklama

Model **bu hasta için** neden yüksek risk dedi? → SHAP

Prof. Dr. Ali AKDAĞLI

KAVRAM KARTI

Değişken önemi

Permutation feature importance

Model genelde neye bakıyor?

Bir değişkeni karıştırıp anlamsızlaştırırız; modelin başarısı ne kadar düşerse değişken o kadar önemli.

Mühendislik

Kabloyu çek: bir sensörü sökünce sistem ne kadar bozuluyor? (duyarlılık analizi)

Günlük hayat

Futbolcuyu oyundan al: takım ne kadar kötü oynuyor?

Klinik

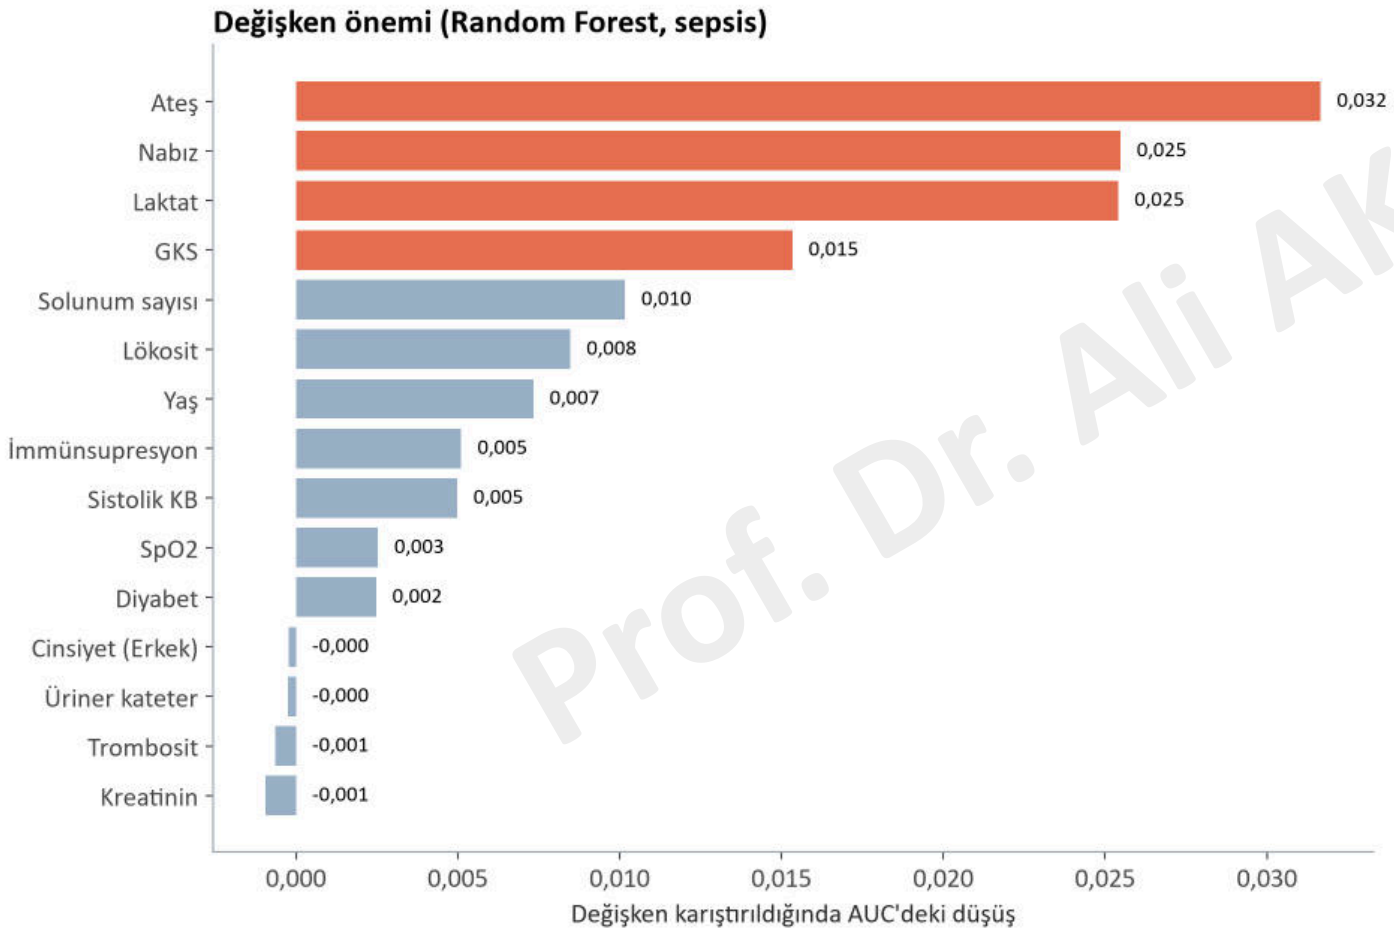
Bilmeseydim: “Nabzı bilmeseydim kararım ne kadar zorlaşırdı?”

İlk 6

Bizim veriden: Ateş, nabız, laktat, GKS, solunum sayısı, lökosit (Random Forest, sepsis).

Prof. Dr. Ali AKDAĞLI

Değişken önemi: model neye bakıyor?



Şekil 3.1 · Permütasyon önemi (Random Forest, sepsis)

1. Değişken karıştırılınca **AUC ne kadar düşüyor?**

2. İlk 6: ateş, nabız, laktat, GKS, SS, lökosit

3. Düşük önem ≠ klinik önemsiz: ilişkili değişkenler **önemi paylaşır**

Prof. Dr. Ali AKDAĞLI

KISALTMA KARTI

SHAP

SHapley Additive exPlanations

Shapley toplamsal açıklamaları

Tek hastanın riskini değişkenlere paylaştırır: ortalama risk + her değişkenin katkısı = model riski.

Mühendislik

Hata bütçesi / süperpozisyon: toplam sapma = bileşen katkılarının toplamı.

Günlük hayat

Maaş bordrosu: brüt maaş + primler − kesintiler = net maaş.

Klinik

Takımda katkı payı: galibiyetin ne kadarı golcünün, ne kadarı savunmanın?

%6,7 → %68

Bizim veriden: Örnek hasta: ortalama risk **%6,7**; ateş +19, nabız +12, solunum +11… → **%68**.

Dedektör dili: SHAP = "dedektör neden öttü?" sorusunun dökümü.

Prof. Dr. Ali AKDAĞLI

SHAP'ın arkasında bir Nobel var

?

SHAP adını **Lloyd Shapley**'den alır. Shapley, oyun kuramında bir takımın kazancını oyuncular arasında **adil paylaştırmanın** yolunu buldu ve bu çalışmalarıyla **2012'de Nobel ekonomi ödülünü** aldı.

Prof. Dr. Ali AKDAĞLI

Bugünle bağlantısı: Takım = **değişkenler**, kazanç = **bu hastanın riski – ortalama risk**. SHAP, kazancı değişkenlere adil paylaştırır.

Makine öğrenmesine uyarlayan: Lundberg ve Lee, 2017.

SHAP: katkı payı ve fatura

1

Takım oyunu

Maçı kazanan takımda her oyuncunun gole **katkı payı**.

2

Hesabın faturası

Başlangıç riski + katkılar = model riski. Her değişken bir kalem.

3

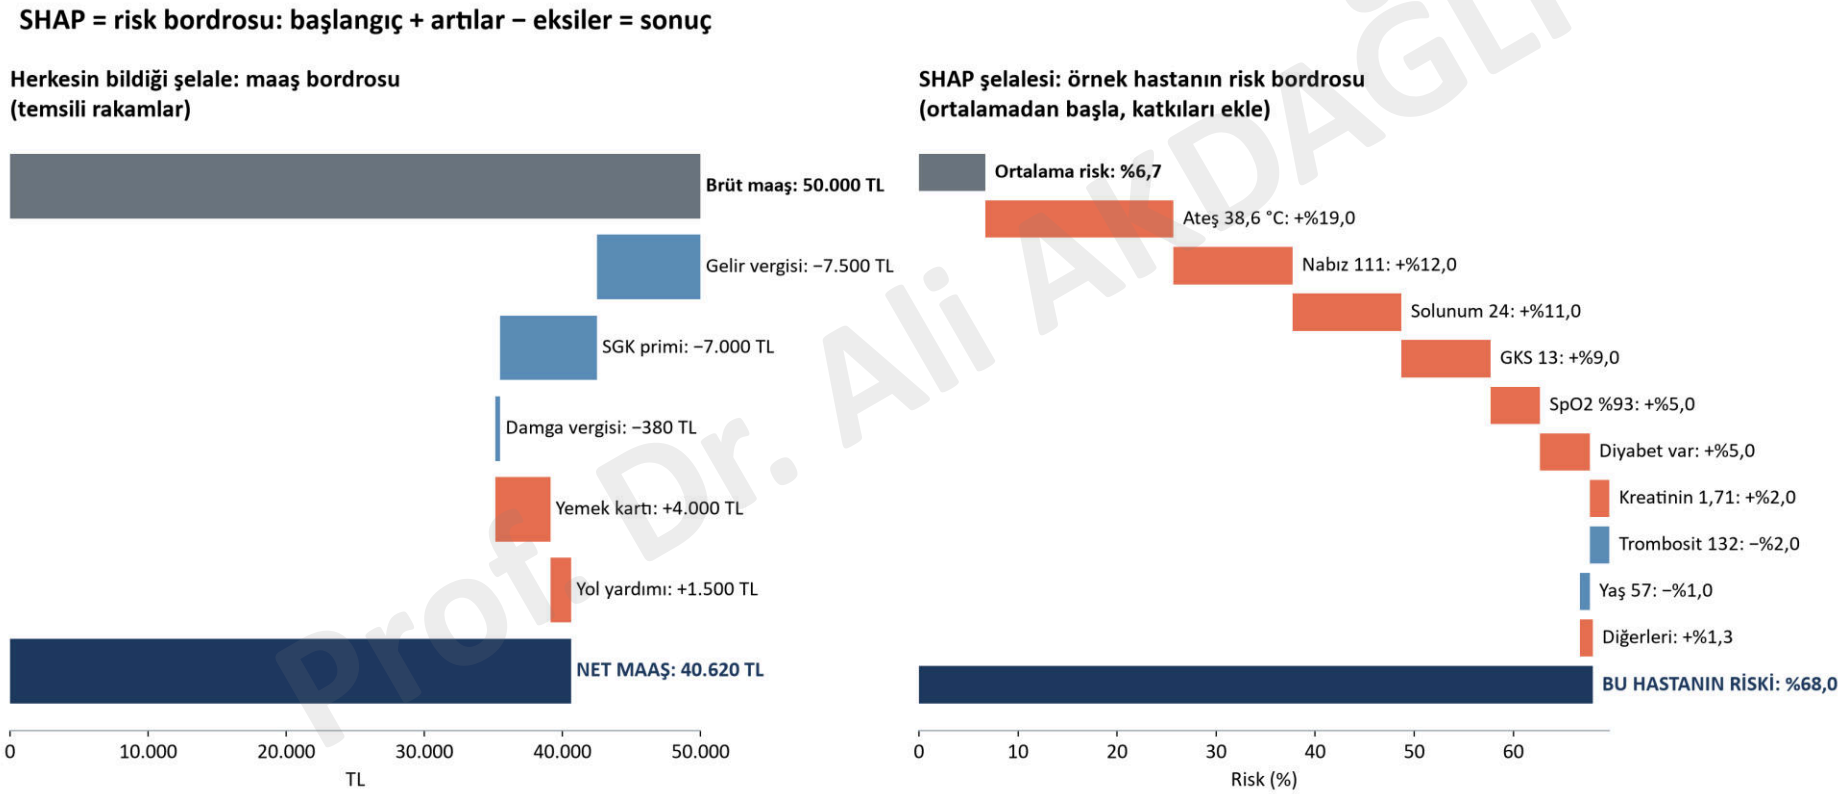
Oyun kuramı

Shapley değerleri; makine öğrenmesine uyarlayan: **Lundberg ve Lee, 2017**.

SHAP, “model bu hasta için neden böyle dedi?” sorusunu yanıtlar.

Prof. Dr. Ali AKDAĞLI

SHAP = risk bordrosu



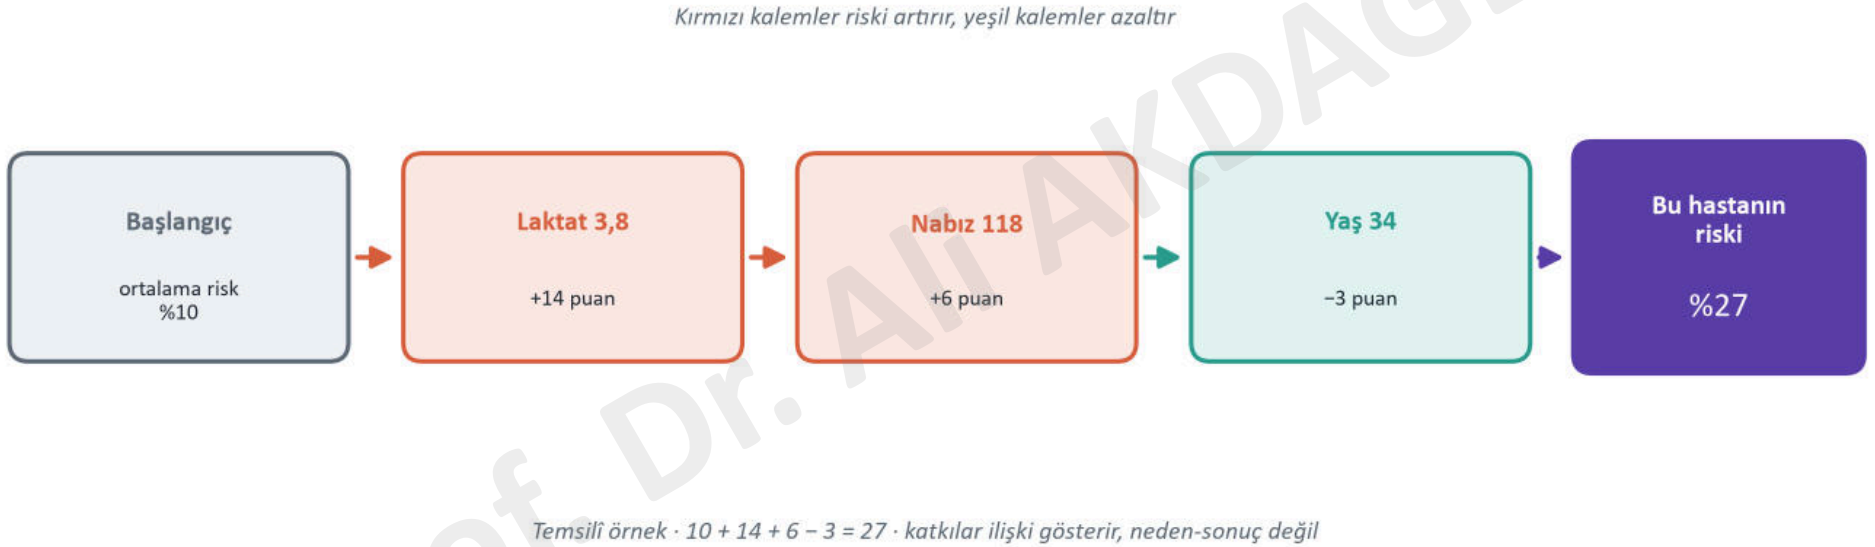
Şekil · Solda temsili maaş bordrosu, sağda örnek hastanın risk bordrosu

1. Brüt maaş ↔ **ortalama risk (%6,7)**
2. Kalemler ↔ **değişkenlerin katkısı**
3. Net maaş ↔ **bu hastanın riski (%68)**

Dedektör dili: bordro, dedektörün neden öttüğünün kalem kalem dökümü.

Prof. Dr. Ali AKDAĞLI

Riskin faturası adım adım



Prof. Dr. Ali AKDAĞLI

Akış 3.1 · Başlangıç riski + katkılar = bu hastanın riski (temsilî örnek)

1. Herkes **ortalama riskle** başlar
2. Her değişken bir **katkı** ekler ya da çıkarır
3. Toplam = **bu hastanın** riski

Örnek hastanın bordrosu adım adım

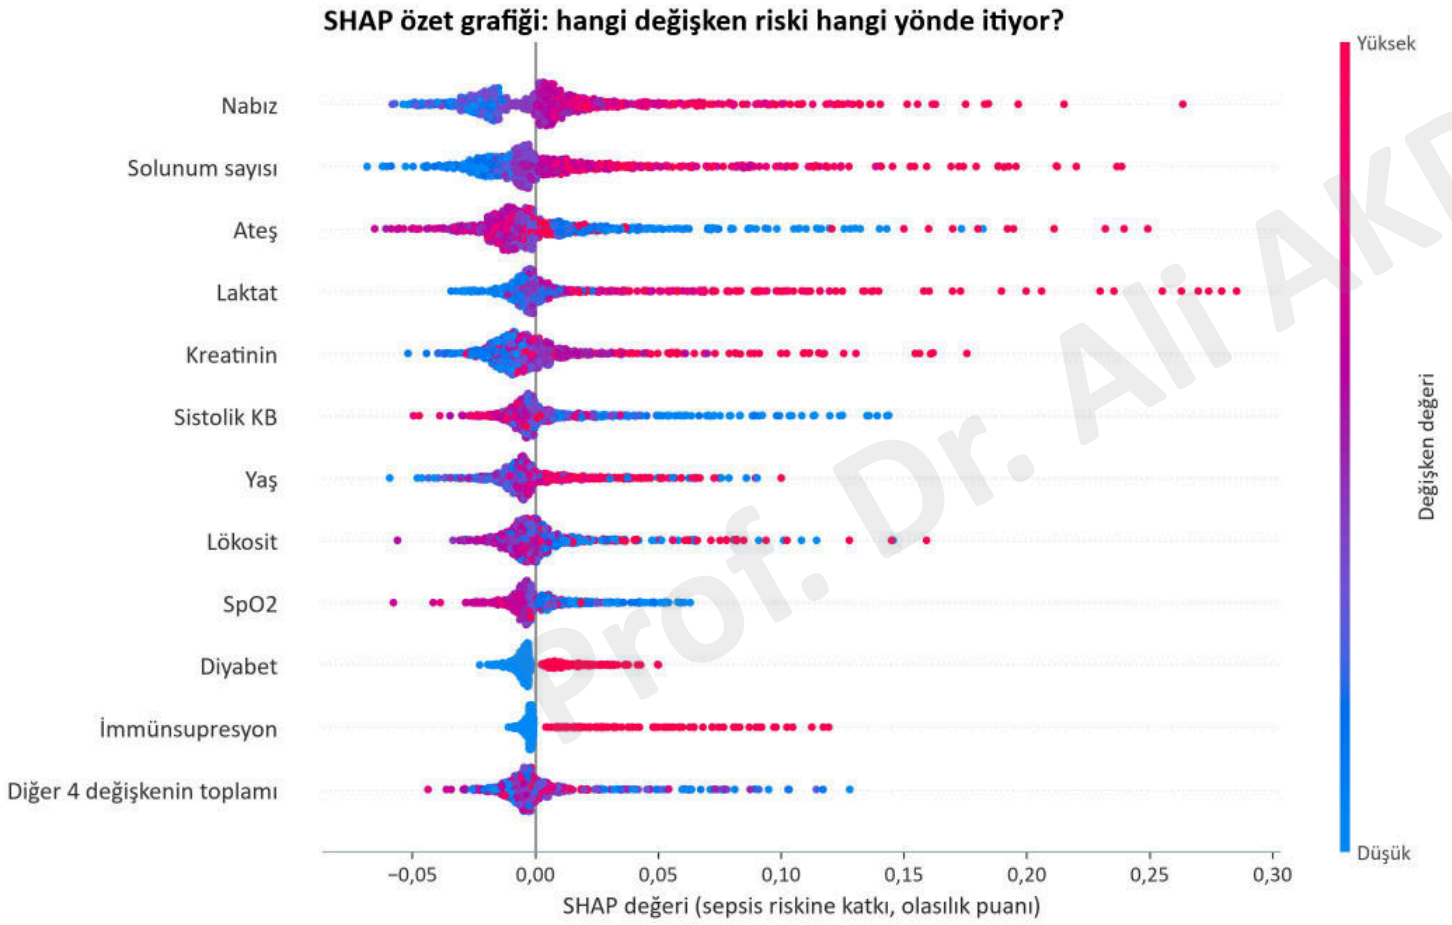
57 yaş, erkek
Ateş 38,6 · nabız 111 · SS 24
GKS 13 · SpO2 %93
Laktat **1,6 (normal)**
Kreatinin 1,71 · trombosit 132
Diyabet var · kateter var

1	Başlangıç: ortalama risk	**%6,7**
2	Ateş +19 · nabız +12 · solunum +11	**+42**
3	GKS +9 · SpO2 +5 · diyabet +5 · kreatinin +2	**+21**
4	Trombosit −2 · yaş −1 · diğerleri +1,3	**−1,7**
5	6,7 + 42 + 21 − 1,7	**%68**

Başlangıç + katkılar = model riski. Bordro her zaman denkleşir.

Prof. Dr. Ali AKDAĞLI

SHAP özet grafiği nasıl okunur?



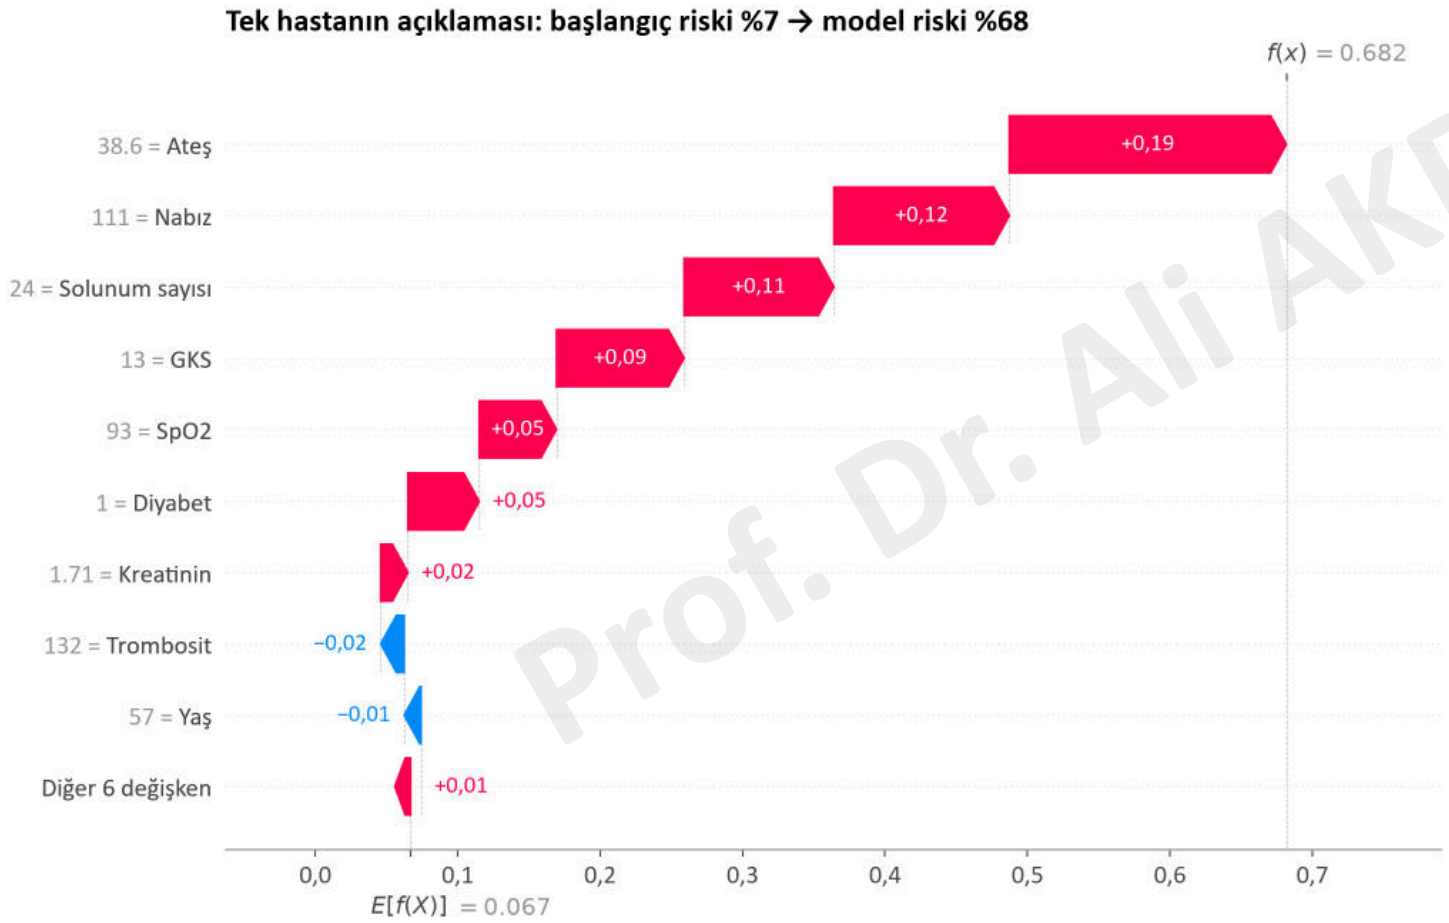
Şekil 3.2 · SHAP özet (arı kovanı) grafiği, sepsis

1. Her nokta **bir hasta**
2. Kırmızı = yüksek değer · mavi = düşük değer
3. Çizginin sağı = **risk artar**
4. Sistolik KB: **düşük (mavi) sağda**

Prof. Dr. Ali AKDAĞLI

Dedektör dili: bütün ötüşlerin dökümü tek grafikte.

Tek hasta: şelale grafiği



Şekil 3.3 · Tek hasta için SHAP şelale grafiği

1. Başlangıç: ortalama risk **%6,7**
2. Ateş +19 · nabız +12 · SS +11 · GKS +9
3. Trombosit −2 · yaş −1
4. Model riski: **%68**

Dedektör dili: bu seferki ötüşün kalem kalem gerekçesi.

Prof. Dr. Ali AKDAĞLI

Örnek hasta: laktat normal, risk yüksek

%6,7

Başlangıç (ortalama) risk

%68

Bu hasta için **model riski**

1,6

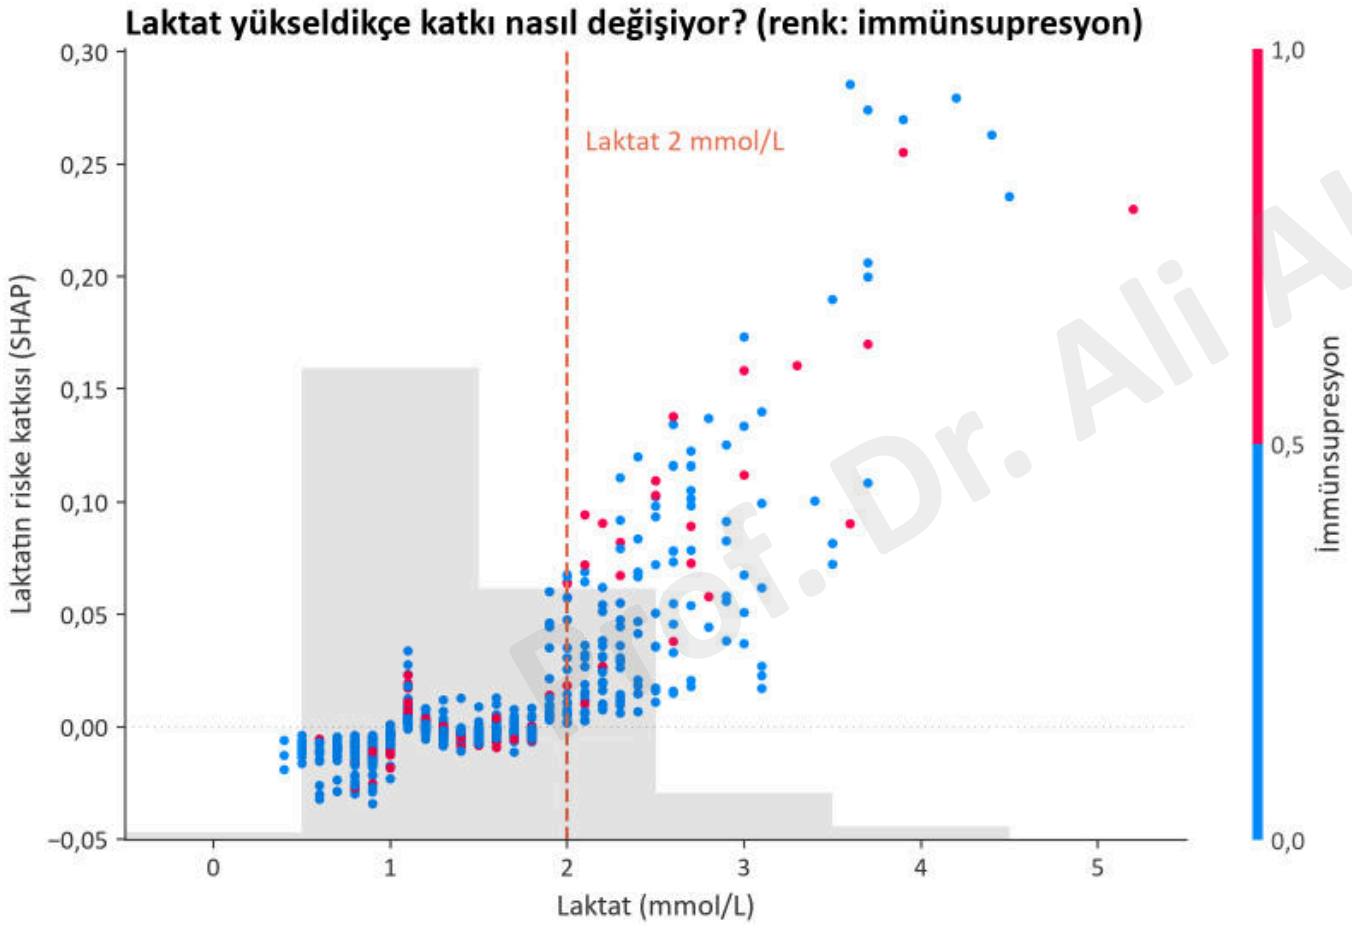
Laktat (mmol/L): **normal**

“Laktat normalse sepsis yoktur” bir yanılgıdır: model bütün tabloya bakar.

Dedektör dili: duman sensörü sakin, ama diğer sensörler bağırıyor.

Prof. Dr. Alp AKDAĞLI

Laktatın katkısı: model kuralı buldu



Şekil 3.4 · Laktatın SHAP bağımlılık grafiği

1. Laktat **2 mmol/L** üstünde katkı belirgin artar
2. Sepsis-3'teki **laktat > 2** ile uyumlu
3. Model kuralı **kendisi buldu**

Prof. Dr. Ali AKDAĞLI

İlişki nedensellik değildir

SHAP “model neden böyle dedi?” sorusunu yanıtlar, “hastalık neden oldu?” sorusunu değil.

✗ Yanlış yorum

“Ateşi düşürürsek sepsis riski azalır.”

✓ Doğru yorum

“Model bu hastada riski en çok **ateşe bakarak** yükseltti.”

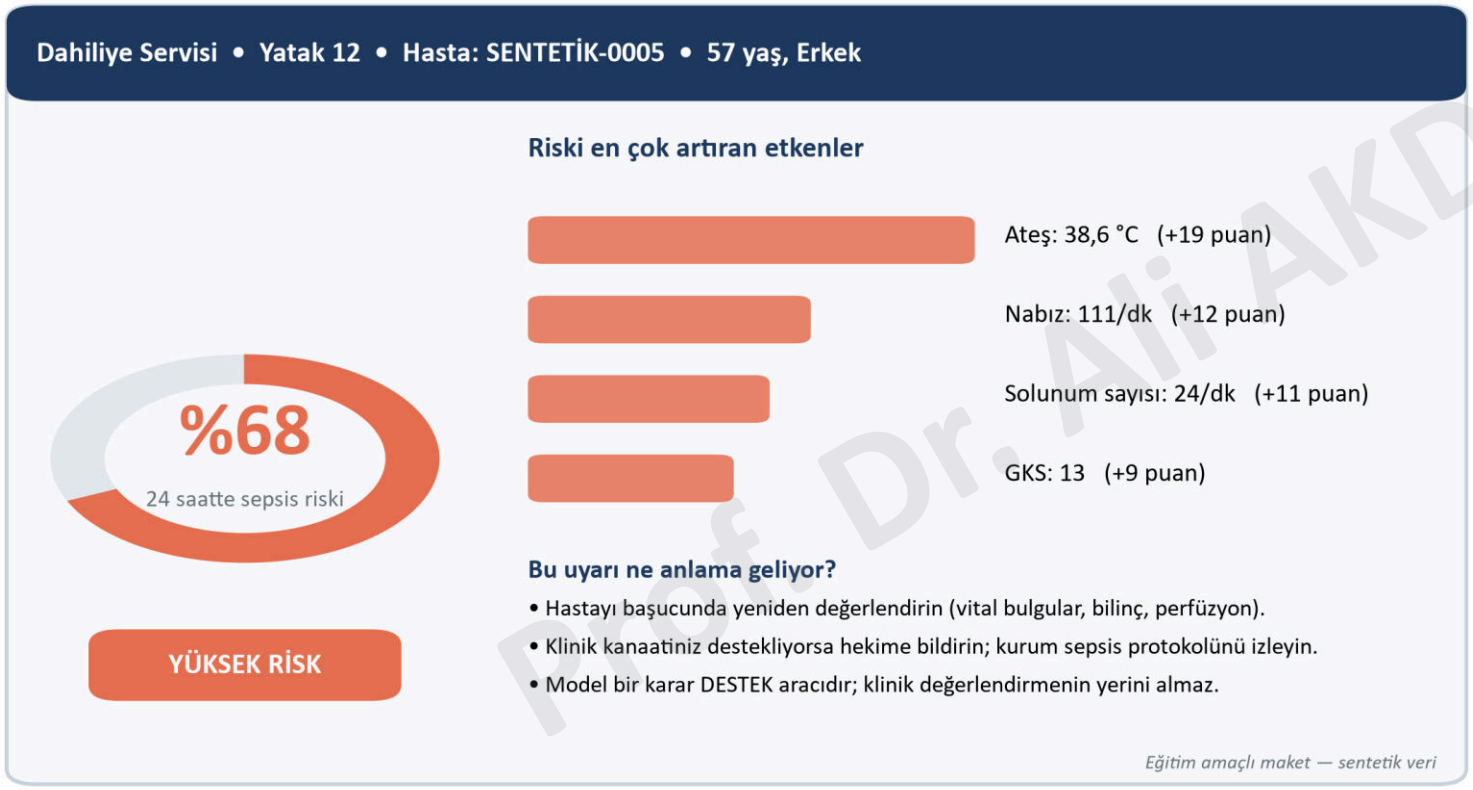
! Karar

Müdahale kararı **klinik bilgiyle** verilir.

Dedektör dili: dedektörü susturmak yangını söndürmez.

Prof. Dr. Ali AKDAĞLI

İyi bir KDS ekranı nasıl görünür?



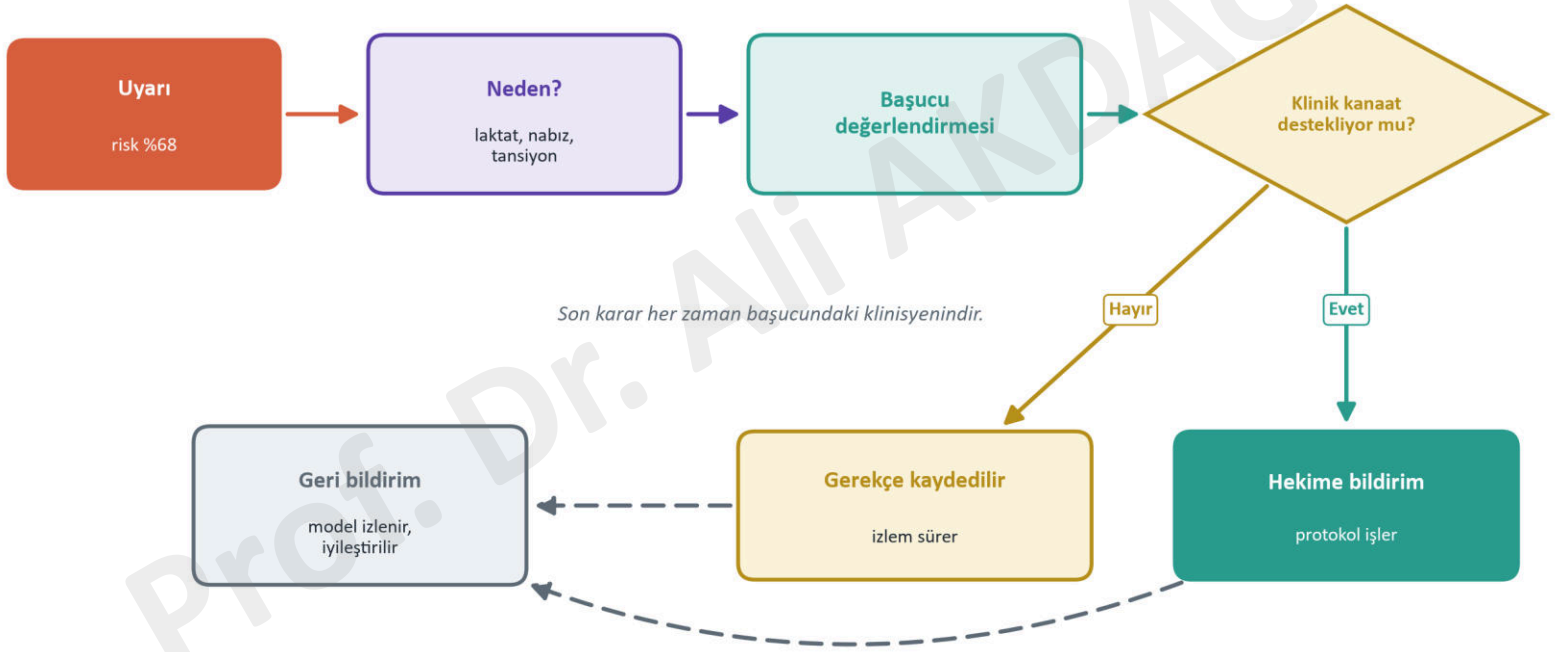
Şekil 3.5 · Klinik karar destek ekranı maketi (eğitim amaçlı)

1. Risk + **ana etkenler** + önerilen eylem
2. "Karar desteğidir" uyarısı
3. Sayı tek başına değil, **gerekçesiyle**

Dedektör dili: iyi dedektör hem öter hem de "mutfakta, yoğun duman" der.

Prof. Dr. Ali AKDAĞLI

Uyarıdan eyleme: insan döngüde

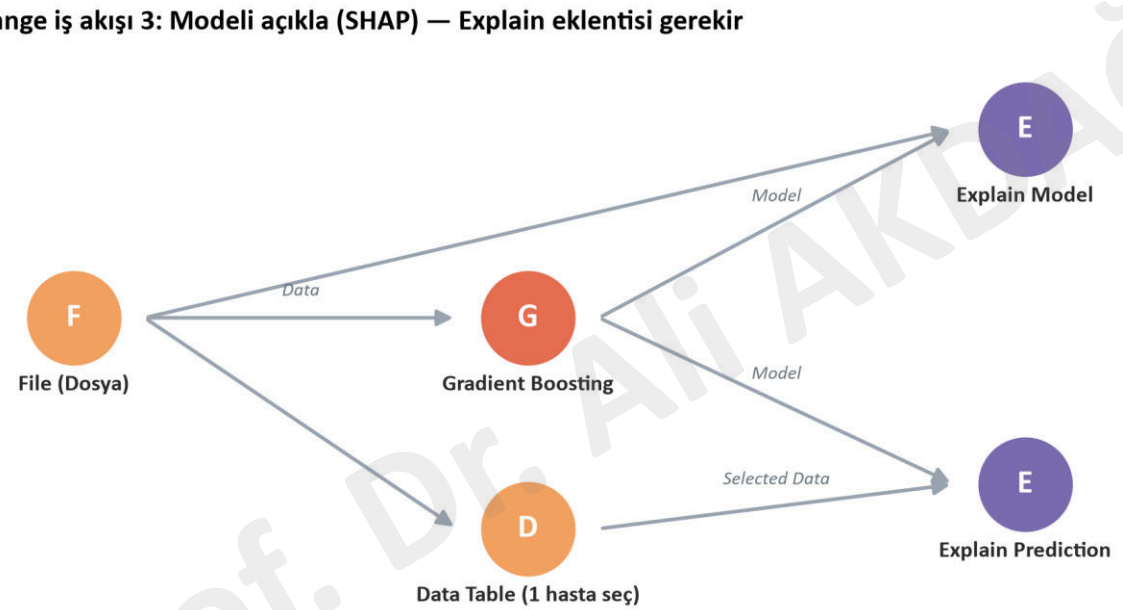


Prof. Dr. Ali AKDAĞLI

Akış 3.2 · Uyarı → neden → başucu → klinik kanaat → eylem → geri bildirim

1. Uyarı **nedenleriyle** birlikte gelir
2. Kararı **başucu değerlendirmesi** verir
3. Her karar **geri bildirim** olur

Orange 3: modeli açıkla

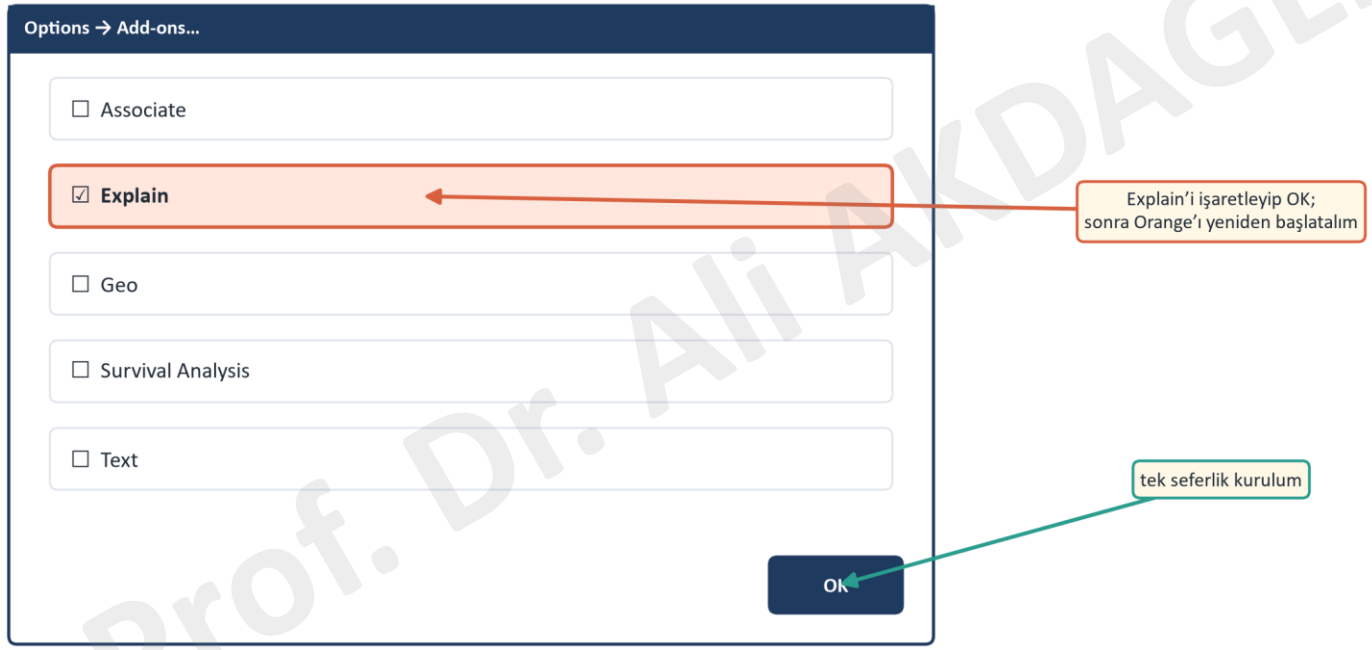


Şekil 3.10 · Orange iş akışı 3 (Explain eklentisi gerekir)

1. Options → Add-ons → **Explain**; Orange'ı yeniden başlatıyoruz
2. **File** → sepsis (Role = target)
3. File → **Gradient Boosting**
4. File + model → **Explain Model** (SHAP özet)
5. File → **Data Table**: tek hasta seçiyoruz
6. Seçili hasta + model → **Explain Prediction**

Prof. Dr. Ali AKDAĞLI

Adım 1 · Explain eklentisini kuruyoruz



Temsilî ekran çizimi

Prof. Dr. Ali AKDAĞLI

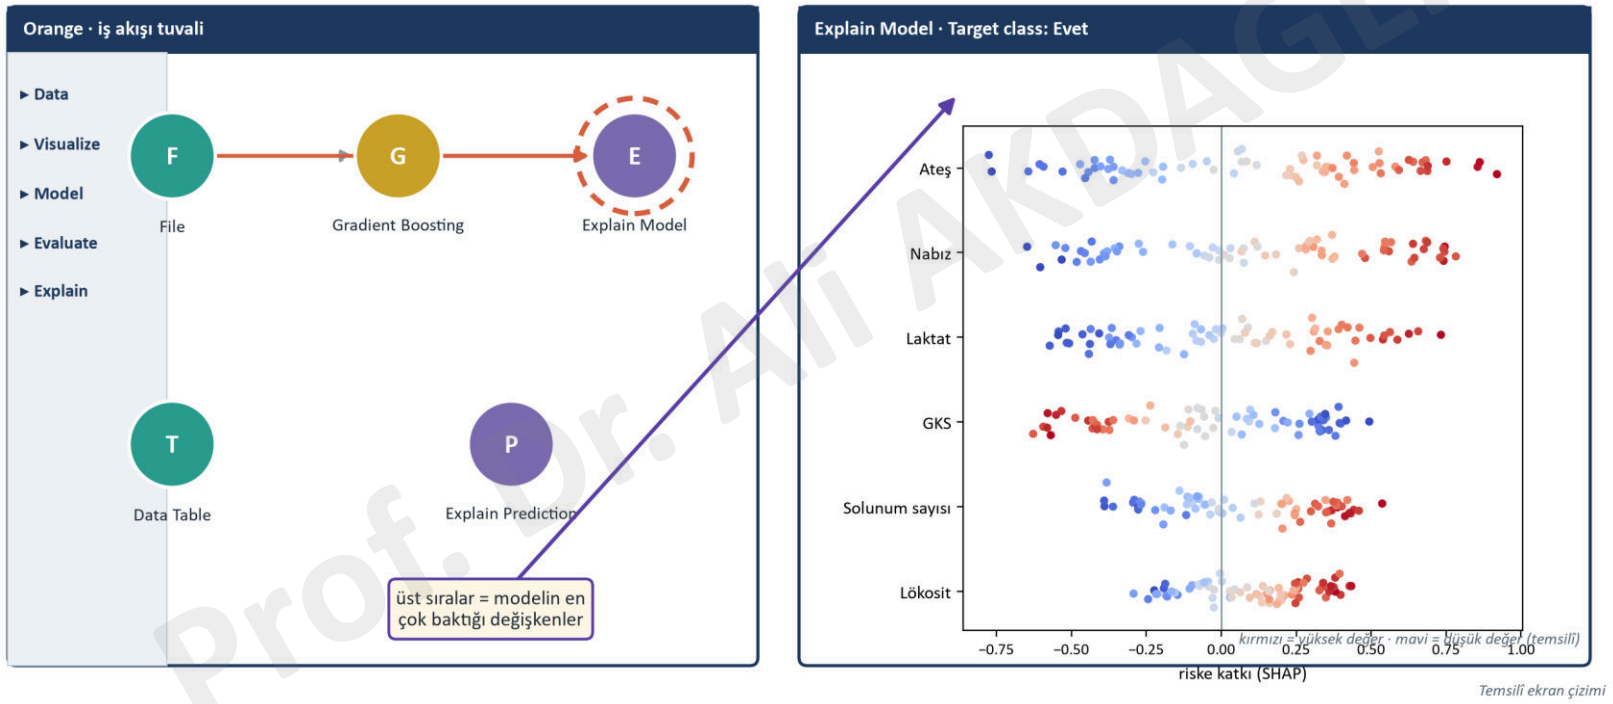
Temsilî ekran çizimi · Orange 3 · Modeli açıklamak (SHAP) · Adım 1

1 **Yapacağımız:** Options → Add-ons → Explain

2 **Ekranda:** sol panelde Explain grubu

3 **Anlamı:** SHAP araçları hazır

Adım 2 · Genel resim: model neye bakıyor?



Temsilî ekran çizimi · Orange 3 · Modeli açıklamak (SHAP) · Adım 2

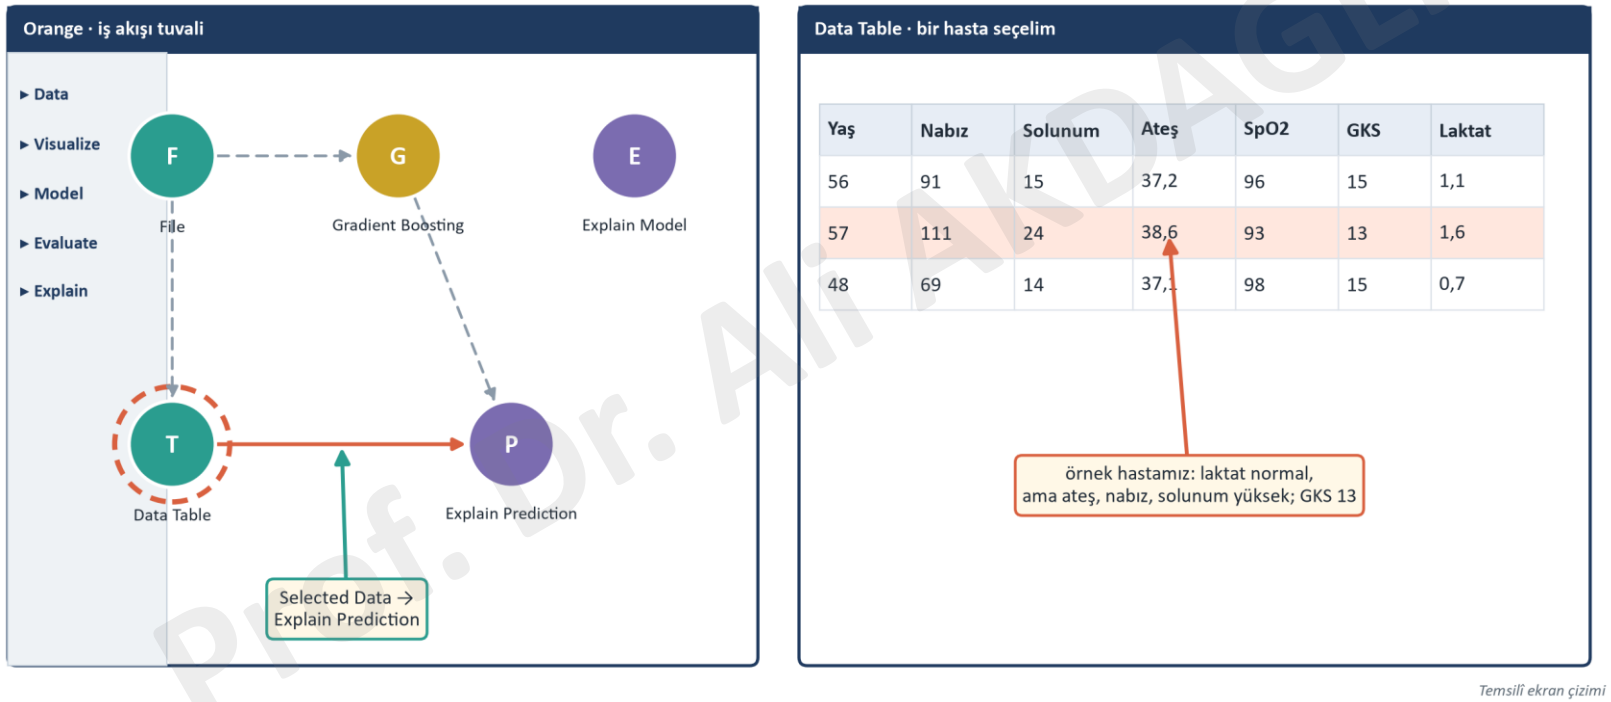
1 **Yapacağımız:** File + GB → Explain Model

2 **Ekranda:** arı kovanı; üstte ateş, nabız

3 **Anlamı:** yönler klinik bilgiyle uyumlu mu?

Prof. Dr. Ali AKDAĞLI

Adım 3 · Tek bir hasta seçiyoruz



Temsilî ekran çizimi · Orange 3 · Modeli açıklamak (SHAP) · Adım 3

1 **Yapacağımız:** Data Table → bir satır seç

2 **Ekranda:** seçili satır vurgulu

3 **Anlamı:** laktat normal, diğer bulgular yüksek

Prof. Dr. Ali AKDAĞLI

Explain Prediction'ı okumak: dört soru

1

Başlangıç kaç?

Ortalama risk **nereden** başlıyor?

2

Kim itti?

Riski en çok **artıran** ve **azaltan** üç değişken

3

Mantıklı mı?

Gerekçe klinik değerlendirmenizle **uyumlu mu?**

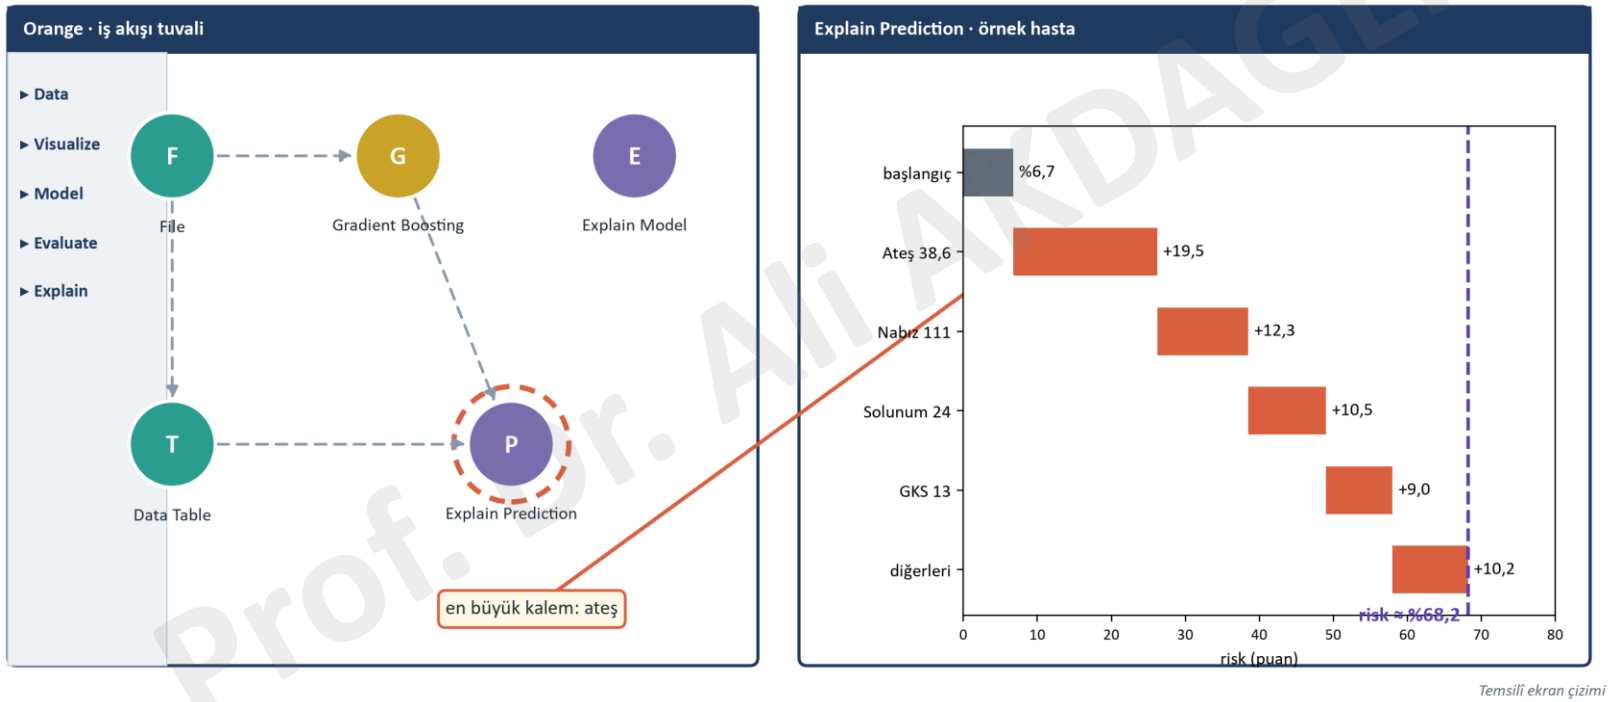
4

Ne yapardınız?

Hemşirelik/ebelik **eylemi** ne olurdu?

Prof. Dr. Ali AKDAĞLI

Adım 4 · Riskin faturasını okuyoruz



Temsilî ekran çizimi

Temsilî ekran çizimi · Orange 3 · Modeli açıklamak (SHAP) · Adım 4

1 **Yapacağımız:** Explain Prediction'ı açıyoruz

2 **Ekranda:** başlangıç %6,7 → risk ≈ %68

3 **Anlamı:** en büyük kalem ateş, sonra nabız

Prof. Dr. Ali AKDAĞLI

Dört vaka, dört klinik alan

S

Sepsis

Hemşirelik · Şekil 3.3 ve 3.5

A

Diyabetik ayak

Hemşirelik/podiatri · Şekil 3.6

M

Malnütrisyon

Beslenme/hemşirelik · Şekil 3.7

P

Preeklampsi

Ebelik · Şekil 3.8

Kendi alanınıza en yakın vakayla başlayabilirsiniz · Ek vaka: Pima (Şekil 3.9)

Prof. Dr. Ali AKDAĞLI

Vaka 1 · Sepsis: laktat normal, risk %68

S

57 yaş, erkek

Ateş **38,6** · nabız **111** · SS **24**

SKB **125** · SpO2 **%93** · GKS **13**

Laktat **1,6** (normal) · kreatinin 1,71

Diyabet var · üriner kateter var

Model riski: **%68**

TREWS (Adams 2022): uyarıya 3 saatte yanıt → mortalitede düzeltilmiş mutlak **%3,3** azalma

?

Tartışıyoruz

1. Bu hastanın **qSOFA** puanı kaç? (SS ≥ 22, SKB ≤ 100, GKS < 15)
2. Model ile skor **uyumlu mu?**
3. Hemşirelik **eylemi** ne olmalı?
4. “Laktat normal” bilgisi kararınızı değiştirir mi?

Prof. Dr. Ali AKDAĞLI

HATIRLATMA KUTUSU

Bu kelimeler ne demek? · Diyabetik ayak

Diyabetik ayak ülseri
Diyabetlinin ayağında iyileşmeyen açık yara; ampütasyona gidebilir.

Nöropati
Şeker sinirleri bozar; ayak acıyı hissetmez.
≈ sensör kablosu kopmuş

Monofilament testi
İnce telle tabana dokunma; hissetmiyorsa nöropati.
≈ süreklilik testi

ABİ
Ayak bileği / kol tansiyonu. Normal 0,9–1,3; <0,9 damar daralması.
≈ iki musluğun basınç oranı

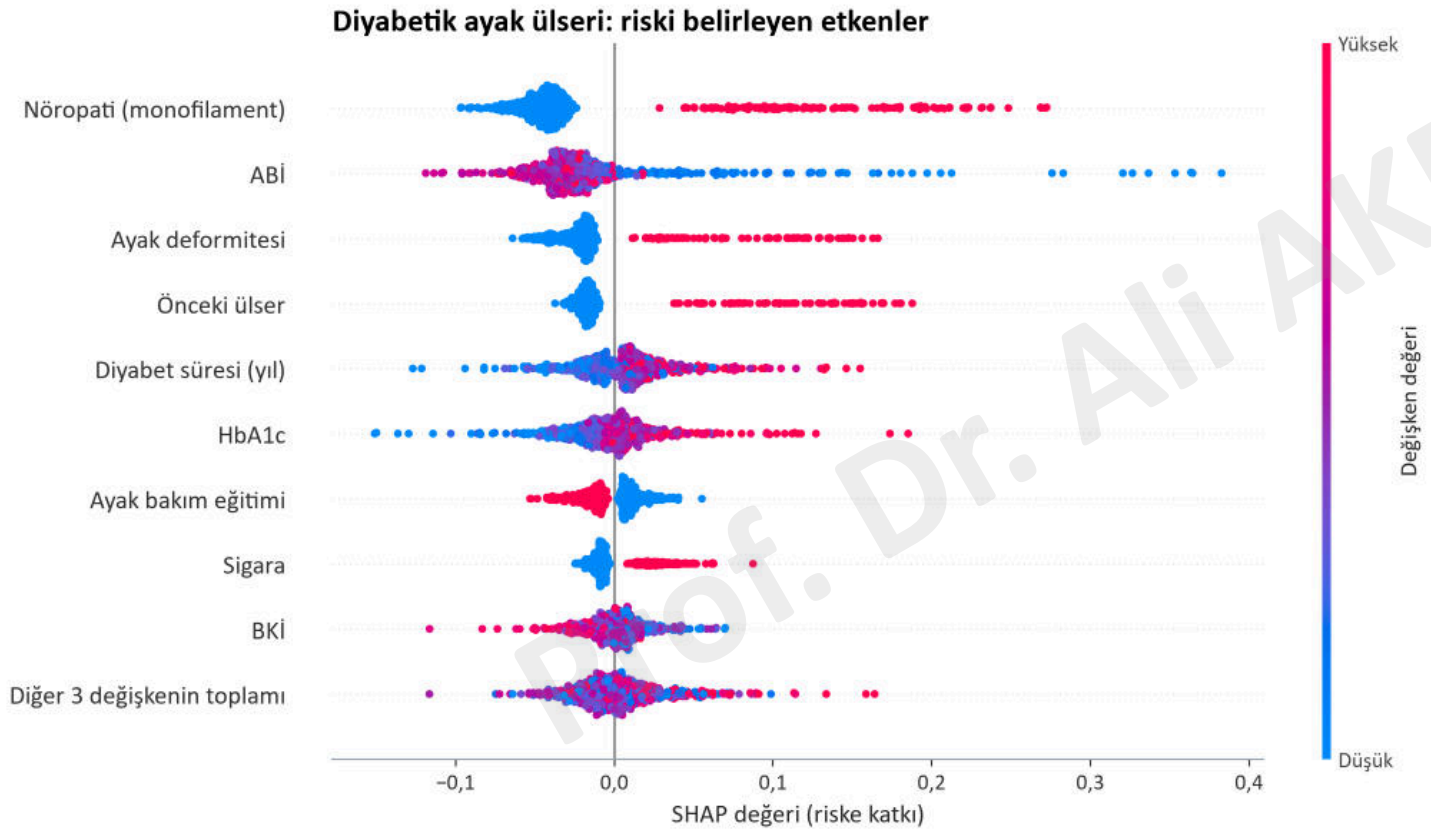
Deformite · offloading
Ayak şekil bozukluğu · yaralı yerden yükü almak (özel terlik).
≈ gerilme yığılmasını gidermek

Wagner evresi · IWGDF
Yara derinliği 0–5 · uluslararası diyabetik ayak rehberi grubu.

Diyabetik ayak verimizde 12 ayda ülser sıklığı: %12.

Prof. Dr. Ali AKDAĞLI

Vaka 2 · Diyabetik ayak ülseri



Şekil 3.6 · Diyabetik ayak, SHAP özet

Tartışıyoruz

1. İlk beş değişken **IWGDF** risk sınıflamasıyla örtüşüyor mu?
2. "Ayak bakım eğitimi" **koruyucu** çıktı. Bu nedensellik mi? (Karıştırıcı?)
3. Bu modelle hemşirelik izlemini nasıl planlarsınız?

Prof. Dr. Ali AKDAĞLI

Bu kelimeler ne demek? · Malnütrisyon

Malnütrisyon
İhtiyaca göre yetersiz/dengesiz beslenme; yatan yaşlılarda çok sık.

GLIM kriterleri
Fenotipik (kilo kaybı, düşük BKİ, kas kaybı) + etiyolojik (az yeme, inflamasyon).

Baldır çevresi
Kas kütlesinin pratik ölçüsü; yaşlıda <31 cm düşük kas.

Albümin
Ana kan proteini (~3,5–5,0 g/dL); bugün daha çok inflamasyon göstergesi.

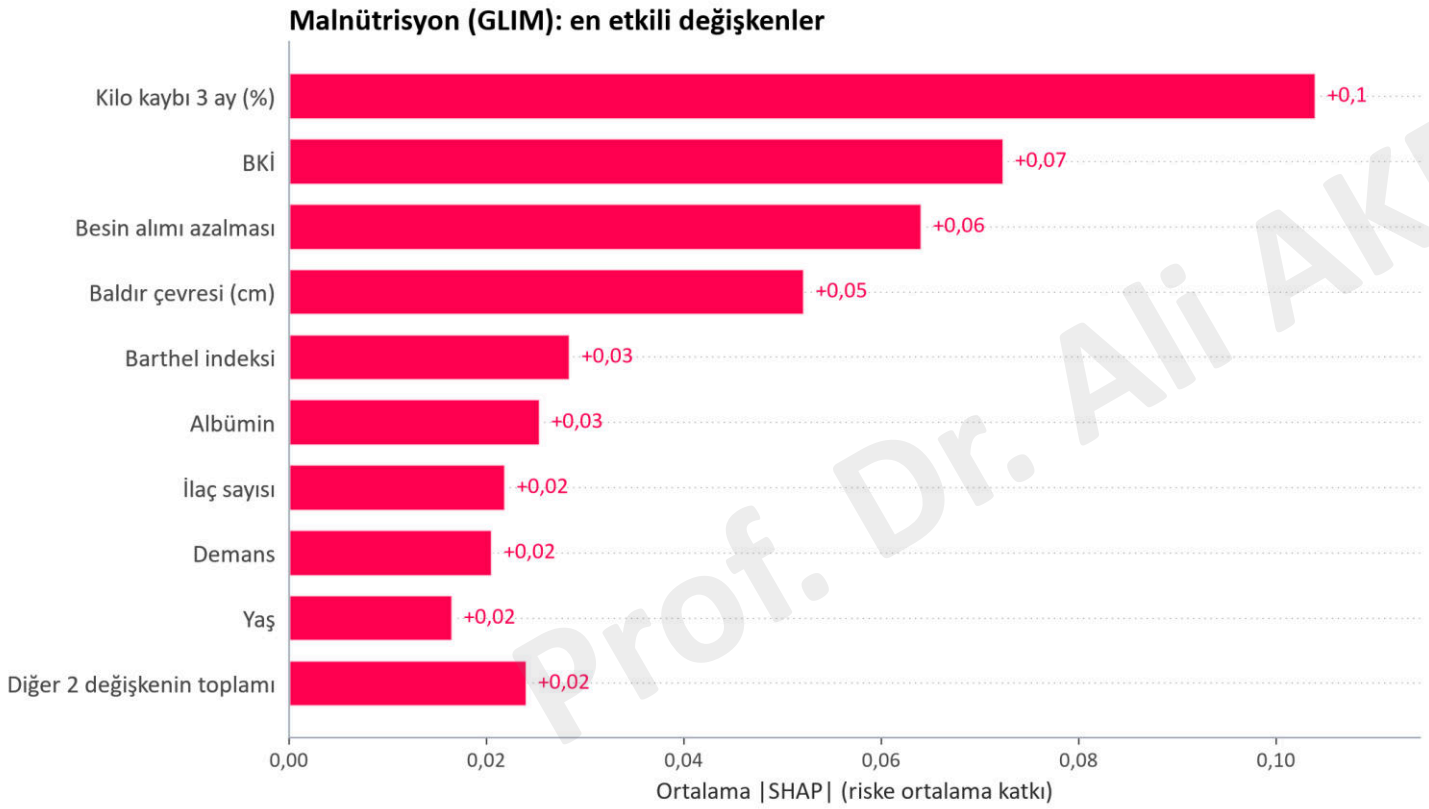
Disfaji · demans · Barthel
Yutma güçlüğü · bilişsel gerileme · bağımsızlık puanı 0–100.

NRS-2002 · MUST
Hastanede beslenme riski tarama ölçekleri (kural tabanlı skorlar).
≈ insan yazımı KDS

Malnütrisyon verimiz: ≥65 yaş yatan hasta, GLIM'e göre sıklık %27,7.

Prof. Dr. Ali AKDAĞLI

Vaka 3 · Malnütrisyon (GLIM)



Şekil 3.7 · Malnütrisyon, ortalama |SHAP|

Tartışıyoruz

1. İlk sıralar **GLIM** fenotipik ve etiyolojik kriterleriyle örtüşüyor mu?
2. Model **NRS-2002** veya **MUST**'tan daha mı iyi? Nasıl anlarız?
3. Albümin neden geride? Hangi **ek veriyi** toplardınız?

Prof. Dr. Ali AKDAĞLI

Bu kelimeler ne demek? · Preeklampsi taraması (2)

Uterin arter PI
Rahim atardamarında akış direnci (Doppler). **Yüksek = dar boru = risk.**
≈ borudaki akış direnci

PlGF
Plasental büyüme faktörü. **Düşük = plasenta inşaatı aksıyor = risk.**

PAPP-A
İlk trimester taramasındaki başka bir plasenta proteini; düşük değer riskle ilişkili.

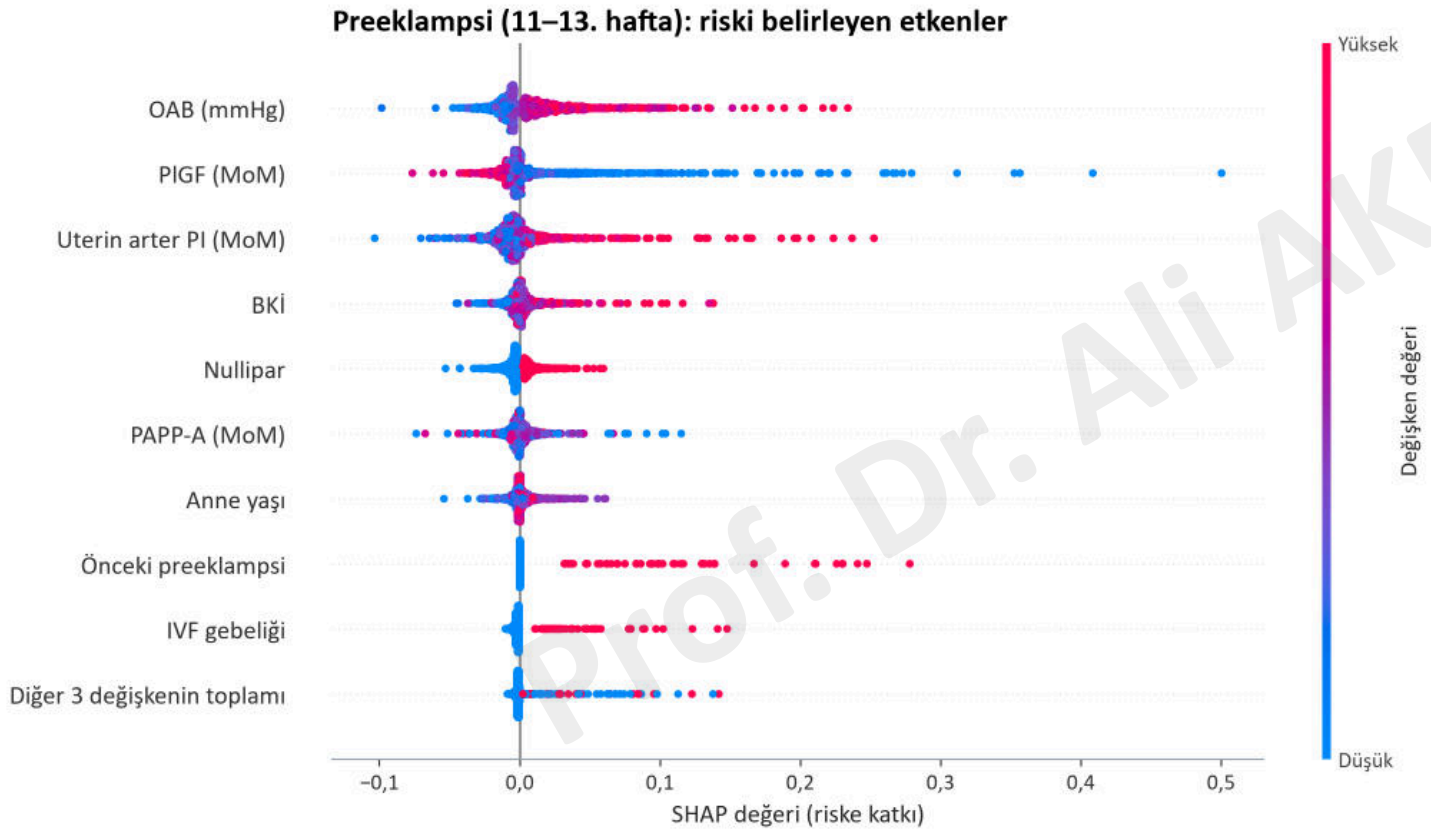
MoM
Değer ÷ aynı haftadaki ortanca. 1,0 ortalama · 0,5 yarısı · 2,0 iki katı.
≈ normalize edilmiş, birimsiz değer

FMF
Fetal Medicine Foundation: ilk trimester preeklampsi risk algoritması.

ASPRE · aspirin
Yüksek riskli gebede aspirin, preterm preeklampsiyi ≈ %62 azalttı (Rolnik 2017).

Prof. Dr. Ali AKDAĞLI

Vaka 4 · Preeklampsi (11–13. hafta)



Şekil 3.8 · Preeklampsi, SHAP özet

? Tartışıyoruz

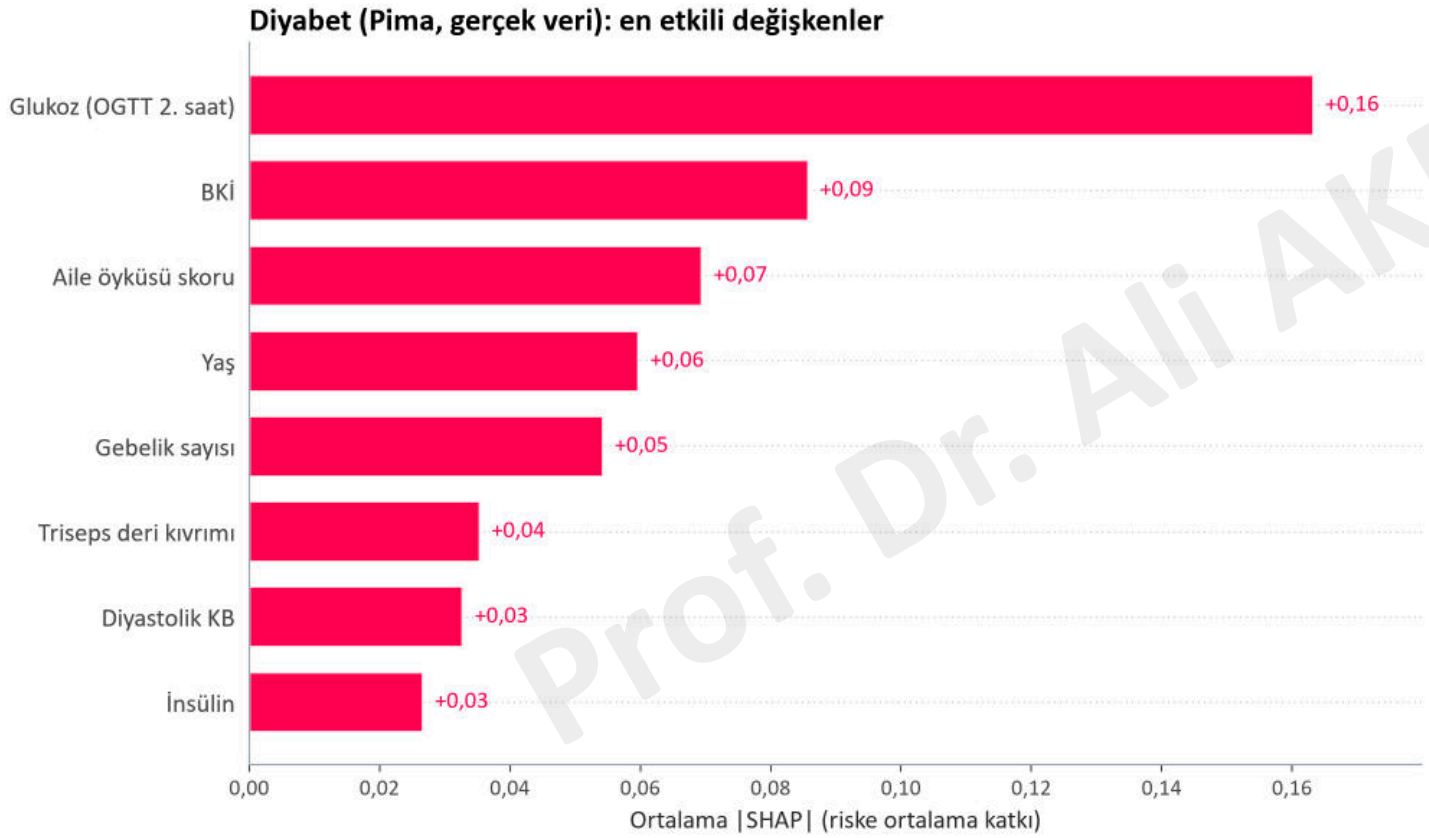
1. OAB, **PlGF** (düşük → risk artar) ve uterin arter PI: FMF taramasıyla uyumlu mu?

2. ASPRE (Rolnik 2017): aspirin preterm preeklampsiyi **≈ %62** azalttı

3. Prevalans **%5,5**: yanlış pozitif yükü yüksek. Gebeyle **nasıl konuşursunuz?**

Prof. Dr. Ali AKDAĞLI

Ek vaka · Pima diyabet (gerçek veri)



Şekil 3.9 · Pima diyabet, ortalama |SHAP|

? Tartışıyoruz

1. Baskın değişken **glukoz**: klinik olarak beklenen mi?

2. Model yalnızca **Pima kadınlarında** eğitildi.

3. Mersinli bir gebe için kullanılabilir mi? (**genellenebilirlik**)

Prof. Dr. Ali AKDAĞLI

Oturum 3 özeti

- ✓ Değişken önemi **global**; SHAP **yerel** açıklama
- ✓ SHAP = fatura: **başlangıç + katkılar = model riski**
- ✓ Açıklama **nedensellik değildir**
- ✓ Gerekçe klinik bilgiyle örtüşmüyorsa **sorguluyoruz**

Prof. Dr. Ali AKDAĞLI

? Düşünmeye değer

1. Bugün öğrendiğim en önemli şey…
2. Hâlâ kafamı karıştıran bir şey…
3. Bir SHAP grafiğini öğrencime nasıl anlatırdım?

Bugünün kısaltmaları · Oturum 3

Değişken önemi	Karıştırınca başarı ne kadar düşüyor? (global)
SHAP	Tek hastanın risk bordrosu: başlangıç + katkılar
Arı kovanı	Bütün hastaların SHAP noktaları (beeswarm)
Şelale	Tek hastanın SHAP grafiği (waterfall)
Global · yerel	Model genelde ne yapar · bu hasta için neden
Nedensellik	SHAP söylemez; termometreyi soğutmak iyileştirmez
ABİ	Ayak bileği / kol tansiyonu; <0,9 damar daralması
IWGDF	Uluslararası diyabetik ayak rehber grubu
GLIM	Malnütrisyon tanı ölçütleri (fenotip + etiyoloji)
NRS-2002 · MUST	Beslenme riski tarama ölçekleri
PI · PlGF	Akış direnci (yüksek kötü) · plasenta proteini (düşük kötü)
MoM · FMF	Ortancanın katı · ilk trimester tarama algoritması

Prof. Dr. Ali AKDAĞLI

OTURUM 4

4

Klinik araştırmaya entegrasyon

Yaşam döngüsü, raporlama rehberleri, etik ve araştırma önerisi

Prof. Dr. Ali AKDAĞLI

00:00 Kavram

01:00 Uygulama

02:00 Atölye sunumları

Bu oturumun hedefleri

1. Model yaşam döngüsünü ve kanıt basamaklarını açıklamak
2. TRIPOD+AI, PROBAST(+AI), CONSORT-AI, SPIRIT-AI, DECIDE-AI'yi eşleştirmek
3. Bir tahmin modeli makalesini kontrol listesiyle okumak
4. Etik, KVKK, yanlılık ve sorumluluğu tartışmak
5. Kendi araştırma önerinizin taslağını yazmak

Bugünün akışı

00:00	Döngü, rehber, etik
00:50	Ara
01:00	Tasarım ve atölye
01:50	Ara
02:00	Sunumlar, kapanış

Prof. Dr. Ali AKDAĞLI

Bir modelin yaşam döngüsü

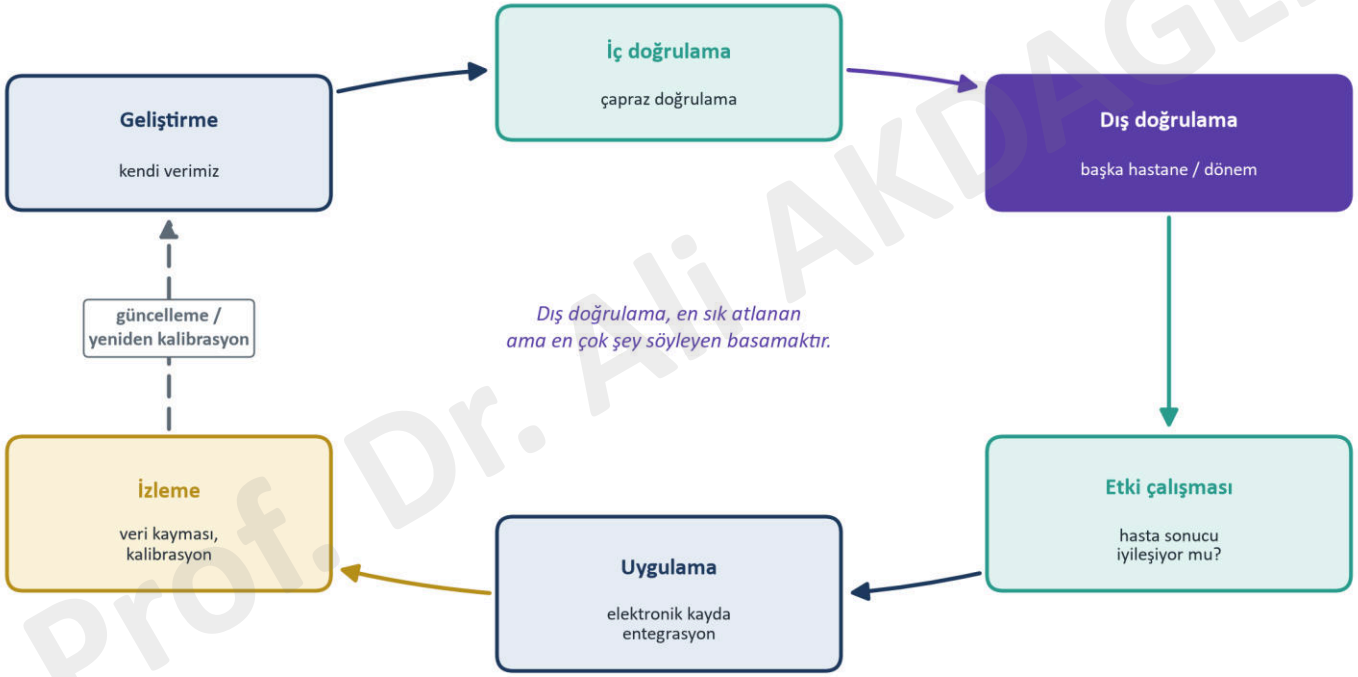


Şekil 4.1 · Modelin sekiz evreli yaşam döngüsü

1. Sekiz evre: **klinik sorudan izlemeye**
2. Modellerin **çoğu 4. adımda** kalıyor
3. Asıl soru: **hasta sonucu değişiyor mu?**

Prof. Dr. Ali AKDAĞLI

Geliştirmeden izlemeye



Prof. Dr. Ali AKDAĞLI

Akış 4.1 · Altı basamak, bir döngü: model hiç 'bitmez'

1. **Dış doğrulama** olmadan klinik kullanım erken olur
2. **Etki çalışması**: hastaya yarar var mı?
3. Uygulamadan sonra **izleme** sürer

KISALTMA KARTI

RKÇ

Randomized Controlled Trial (RCT)

Randomize kontrollü çalışma

Katılımcılar kurayla iki gruba ayrılır; biri yeni uygulamayı, diğeri eskisini alır; sonuçlar kıyaslanır.

Mühendislik

A/B testi: iki tasarım rastgele kullanıcılara gösterilir; hangisi daha iyi?

Günlük hayat

Yazı-turayla tarla: gübreyi hangi tarlaya koyacağınıza kura karar verir.

Klinik

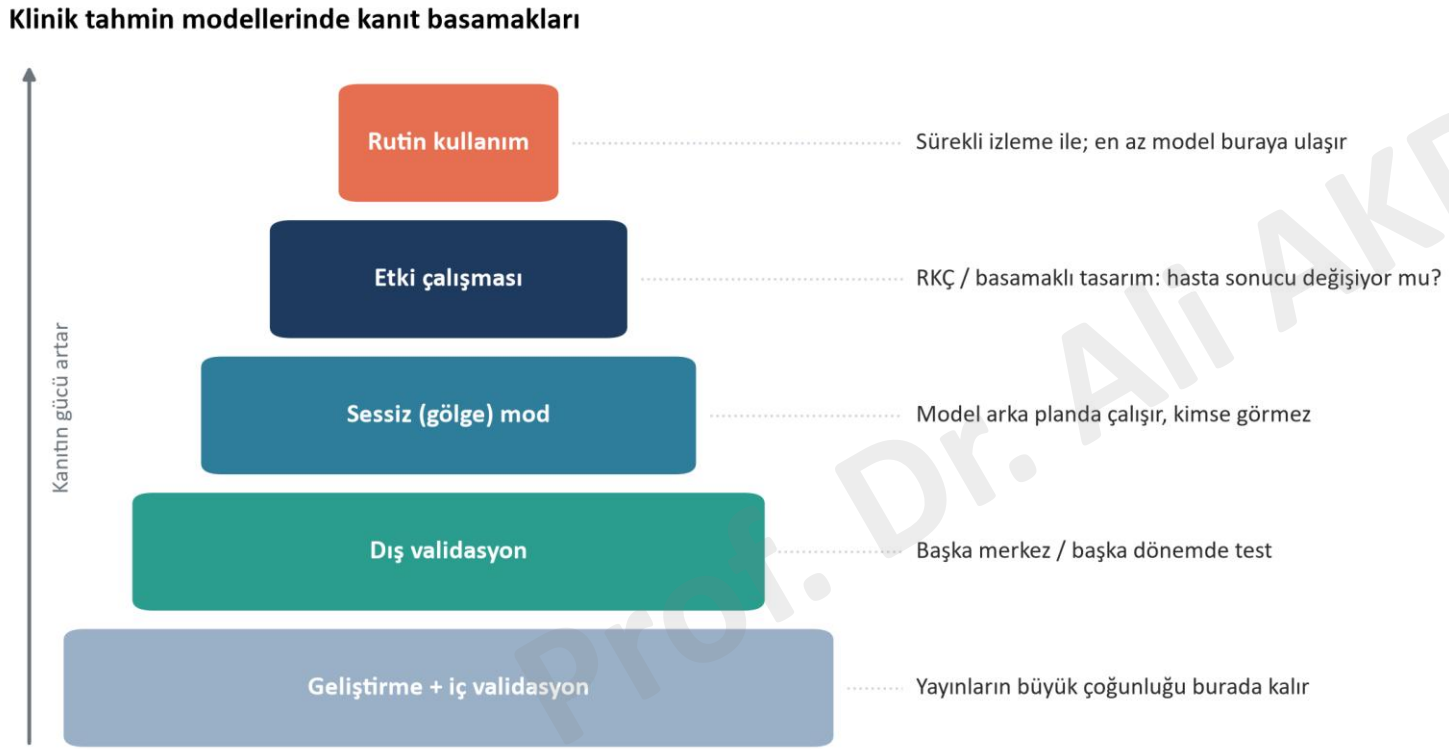
Model uyarısı: uyarıyı alan ve almayan servislerde hasta sonucunu kıyaslamak.

SPIRIT · CONSORT

Bizim veriden: YZ'li RKÇ'nin **protokol** (SPIRIT-AI) ve **sonuç makalesi** (CONSORT-AI) rehberleri, 2020.

Prof. Dr. Ali AKDAĞLI

Kanıt basamakları



Şekil 4.4 · Klinik tahmin modellerinde kanıt basamakları

1. Yayınların çoğu **en alt basamakta**
2. Sessiz (gölge) mod: arka planda, kimse görmez
3. Etki çalışması: **hasta sonucu değişiyor mu?**

Prof. Dr. Ali AKDAĞLI

KISALTMA KARTI

TRIPOD+AI · PROBAST+AI

Reporting guideline · Risk of bias assessment tool

Raporlama rehberi · yanlılık riski aracı

Tahmin modeli makalesini yazarken (TRIPOD+AI) ve okurken (PROBAST+AI) kullanılan kontrol listeleri.

Mühendislik

ISO / uçuş öncesi listesi: ne kadar deneyimli olunursa olsun her madde tek tek işaretlenir.

Günlük hayat

Araç muayene formu: fren, far, lastik; eksik madde varsa geçemez.

Klinik

Cerrahi güvenlik listesi: ameliyattan önce herkesin birlikte kontrol ettiği maddeler.

2024 · 2025

Bizim veriden: TRIPOD+AI (Collins 2024) **yazarken**; PROBAST+AI (Moons 2025) **okurken**.

Prof. Dr. Ali AKDAĞLI

Hangi çalışma, hangi rehber?

Çalışma türü	Raporlama rehberi	Yanlılık riski aracı
Tahmin modeli geliştirme / validasyon	**TRIPOD+AI (2024)**	**PROBAST / PROBAST+AI (2025)**
YZ müdahalesi içeren RKÇ protokolü	**SPIRIT-AI** (2020)	—
YZ müdahalesi içeren RKÇ raporu	**CONSORT-AI** (2020)	RoB 2
Erken evre klinik değerlendirme (canlı kullanım)	**DECIDE-AI** (2022)	—

Tahmin modeli **yazıyorsanız TRIPOD+AI**, **okuyup değerlendiriyorsanız PROBAST+AI**.

Prof. Dr. Ali AKDAĞLI

KAVRAM KARTI

Veri sızıntısı

Data leakage

Sınav cevaplarını önceden görmek

Model, tahmin anında aslında elde olmayacak bir bilgiyi kullanır: iç testte harika, gerçekte işe yaramaz.

Mühendislik

Nedensel olmayan filtre: çıktıyı hesaplarken henüz gelmemiş girişleri kullanmak.

Günlük hayat

Kopya kâğıdı: sınav cevaplarını önceden gören öğrenci; not harika, bilgi yok.

Klinik

Antibiyotik bilgisi: “antibiyotik başlandı mı?” ile sepsisi “tahmin etmek”.

24 saat önce?

Bizim veriden: Her değişken için soruyoruz: tahmin anında bu bilgi **gerçekten elimizde** olur muydu?

Dedektör dili: yangın çıktıktan sonra öten dedektör “kusursuz” görünür.

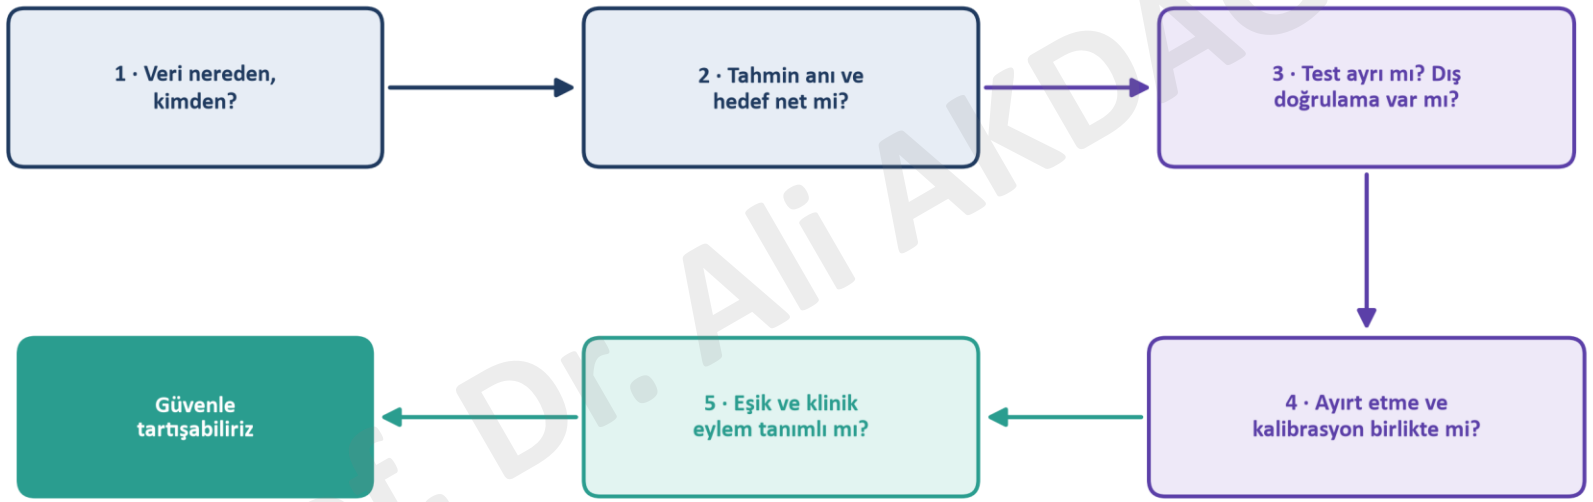
Prof. Dr. Ali AKDAĞLI

Eleştirel okuma için 10 soru

1. Klinik soru ve **kullanım anı** net mi?
2. Veri kaynağı, dönemi, hasta seçimi uygun mu?
3. Sonuç **nasıl ve ne zaman** tanımlandı?
4. Tahmin anında olmayan veri var mı? (**veri sızıntısı**)
5. Eksik veriler nasıl ele alındı?
6. Örneklem ve **olay sayısı** yeterli mi? (Riley 2020)
7. Ayrım **ve kalibrasyon** raporlanmış mı?
8. **Dış validasyon** yapılmış mı?
9. **Alt gruplarda** performans incelenmiş mi?
10. Klinik fayda (karar eğrisi) ve **iş akışı**?

Prof. Dr. Ali AKDAĞLI

Makaleyi beş soruyla okumak



Prof. Dr. Ali AKDAĞLI

Akış 4.2 · Beş soru, sırayla; yanıtı eksik olan yere not düşüyoruz

1 Önce **veri ve tahmin anı**

2 Sonra **test düzeni ve dış doğrulama**

3 En son **eşik ve klinik eylem**

KAVRAM KARTI

Veri kayması

Dataset shift · Drift

Dünya değişir, model eskir

Modelin eğitildiği dönemin koşulları değişince (cihaz, protokol, hasta profili) performansın bozulması.

Mühendislik

Sensör kayması: termokupl yaşlanır, okuma kayar; periyodik kalibrasyon gerekir.

Günlük hayat

Yazıyoruz ayarlanan klima: kışın işe yaramaz; eski harita yeni otoyolu bilmez.

Klinik

Yeni laboratuvar cihazı: laktat farklı ölçülür; model eski cihaza göre öğrenmişti.

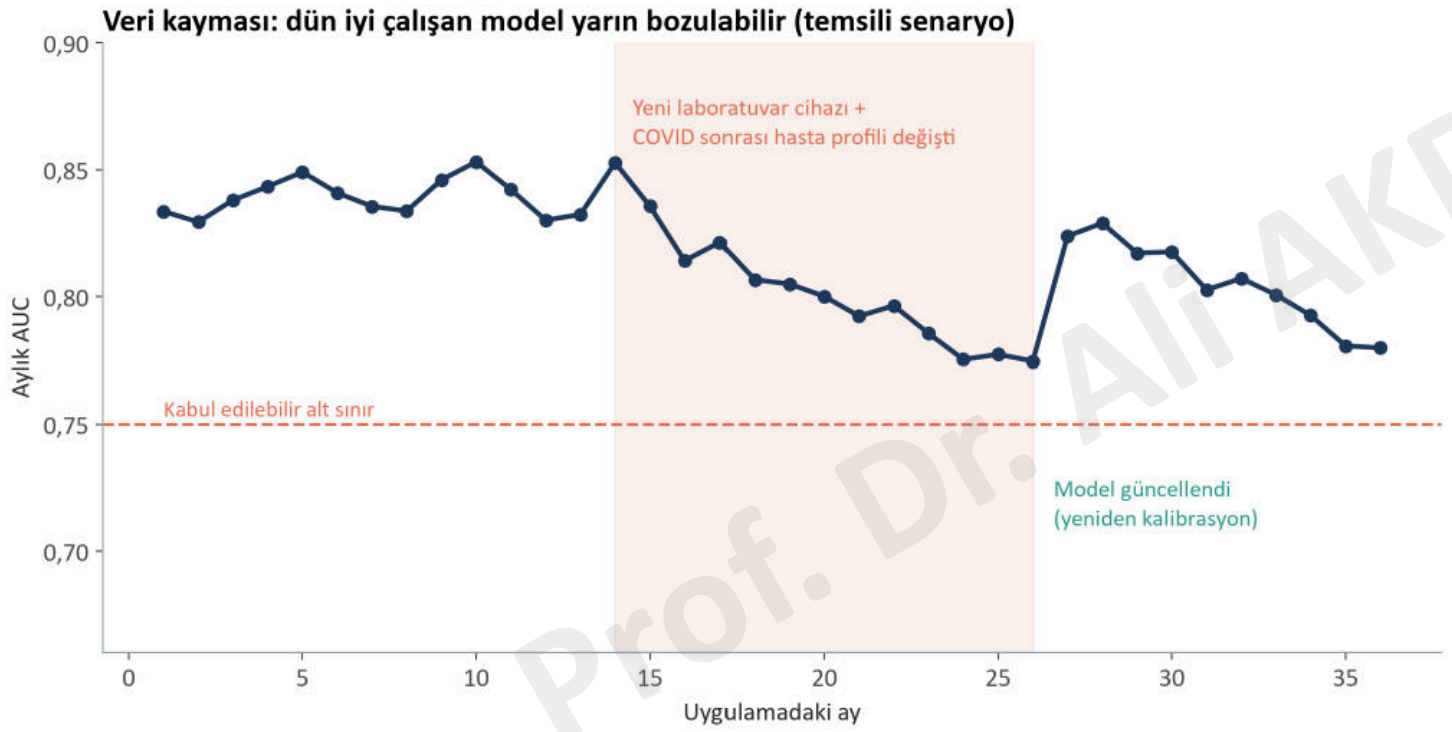
0,85 → sınır

Bizim veriden: Temsili senaryo: AUC aylar içinde **kabul edilebilir sınıra** iner; güncelleme toparlar.

Dedektör dili: dedektör de yıllar içinde tozlanır; düzenli test düğmesine basılır.

Prof. Dr. Ali AKDAĞLI

Veri kayması: dün iyi, yarın kötü



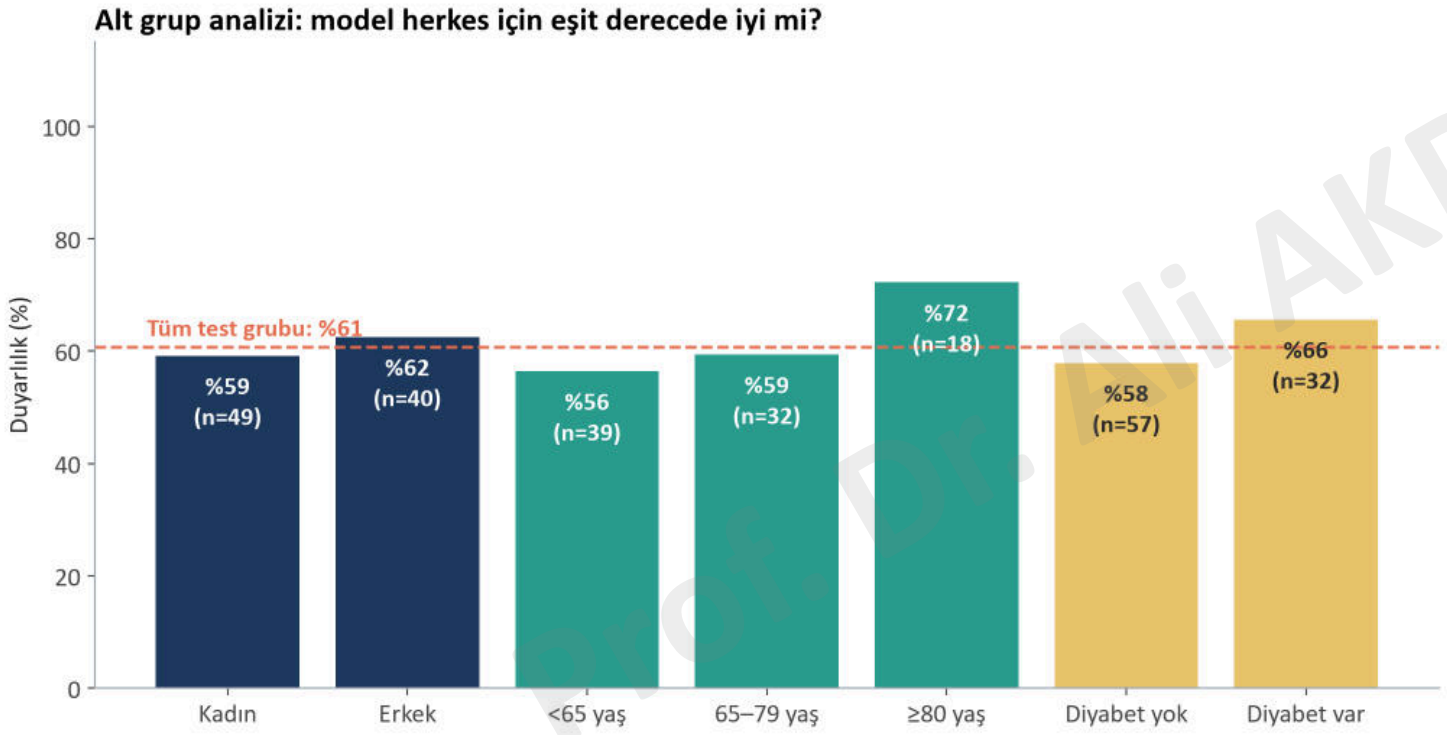
Şekil 4.2 · Veri kayması (temsili senaryo)

1. Yeni cihaz, protokol, hasta profili → **performans düşer**
2. Güncelleme (yeniden kalibrasyon) toparlar
3. Çözüm: **sürekli izleme**

Dedektör dili: dedektörün pilini ve sensörünü düzenli test ediyoruz.

Prof. Dr. Ali AKDAĞLI

Alt grup analizi: herkes için eşit mi?



Şekil 4.3 · Alt grup duyarlılığı (eşik %20)

1. Genel duyarlılık **%61**
2. ≥80 yaş %72, ama **n = 18**
3. Küçük alt grupta farklar **güvenilir değil**

Prof. Dr. Ali AKDAĞLI

Yanlılık: yanlış hedef değişken

Yanlış hedef değişken seçmek yanlılık doğurur (Obermeyer ve ark., Science, 2019).

Prof. Dr. Ali AKDAĞLI

1 Algoritma

Sağlık **harcamasını**, gereksinimin vekili olarak tahmin etti.

2 Sonuç

Siyahi hastaların gereksinimini **sistematik olarak düşük** tahmin etti.

3 Ders

Hedefi **klinik gereksinime** göre seçiyoruz; alt grupları inceliyoruz.

Etik ve hukuk çerçevesi

K

KVKK (6698)

Sağlık verisi **özel nitelikli**: açık rıza veya kanuni istisna, anonimleştirme, veri minimizasyonu.

E

Etik kurul

Geriye dönük kayıt çalışmaları dahil **onay** ve kurum izni.

AB

AB YZ Yasası

2024/1689: tıbbi YZ çoğunlukla **yüksek riskli** sınıfta.

Prof. Dr. Ali AKDAĞLI

DSÖ'nün altı ilkesi ve sorumluluk

1 Özerklik

İnsan kontrolü ve karar yetkisi korunur.

2 İyilik, zarar vermeme

Hasta güvenliği ve yararı önce gelir.

3 Şeffaflık

Model anlaşılabilir ve açıklanabilir olmalı.

4 Sorumluluk

Hesap verebilirlik net olmalı.

5 Hakkaniyet

Hiçbir grup sistematik olarak dezavantajlı olmamalı.

6 Sürdürülebilirlik

Model izlenir ve güncellenir.

Sorumluluk klinisyende kalır. Modeli sorgulamak mesleki görevdir (otomasyon yanlılığı).

Prof. Dr. Ali AKDAĞLI

Açık veri kaynakları

PhysioNet

MIMIC-IV; 2019 PhysioNet sepsis yarışması

UCI ML Repository

Klasik ve belgelenmiş veri setleri (ör. Pima)

OpenML

Açık, karşılaştırmalı veri setleri

Kaggle

Çok veri, **dikkatli kullanıyoruz**: kaynak ve kalite belirsiz olabilir

Kurumsal veri

Türkiye'de **etik kurul ve kurum izniyle**

Önce kontrol ediyoruz

Kaynak, dönem, sonuç tanımı, lisans

Prof. Dr. Ali AKDAĞLI

Araştırma tasarım türleri

A Dış validasyon

Var olan modeli kendi verinizde test ediyoruz. **En uygulanabilir başlangıç.**

B Yeni model

Yeterli **olay sayısı** gerekir (Riley 2020).

C Model ve skor

Ör. **NEWS2 ve ML** aynı hastalarda.

D Nitel / karma

Hemşire/ebe ve model: **kabul, güven, iş yükü**.

E Eğitim araştırması

Öğrencilere model çıktısı okumayı öğretmek.

★ Öneri

1. oturumdaki fikrinizi bu tasarımlardan birine yerleştiriyoruz.

Prof. Dr. Ali AKDAĞLI

Atölye: tek sayfalık araştırma önerisi

1. Başlık
2. Klinik problem
3. Hedef popülasyon ve ortam
4. Sonuç ve **zaman ufku**
5. Aday değişkenler ve veri kaynağı
6. Tasarım (dış validasyon / geliştirme / karşılaştırma)
7. Örneklem ve **olay sayısı**
8. Performans: AUC, **kalibrasyon**, duyarlılık/PPV, **eşik**
9. Açıklanabilirlik planı
10. Etik ve KVKK
11. Rehber (**TRIPOD+AI**)
12. Klinik etki planı

1. oturumdaki fikrinizden başlayabilirsiniz · form bilgisayar, tablet ve telefonda doldurulabilir

Prof. Dr. Ali AKDAĞLI

Önerilerimizi paylaşıyoruz

1

Problem

Klinik problem, popülasyon, sonuç ve zaman ufku

2

Tasarım

Veri kaynağı, tasarım, performans ölçütleri ve eşik

3

Riskler

Etik ve KVKK, yanlılık, iş akışı

Dileyen katılımcılar 10 sorudan biriyle katkı verebilir.

Prof. Dr. Ali AKDAĞLI

Oturum 4 özeti

- ✓ Modellerin çoğu **iç validasyonda** kalır
- ✓ Yazarken **TRIPOD+AI**, okurken **PROBAST+AI**
- ✓ Dış validasyon, kalibrasyon ve alt gruplar **şart**
- ✓ KVKK, etik kurul ve **sorumluluk klinisyende**

Prof. Dr. Ali AKDAĞLI

? Düşünmeye değer

1. Modülde en çok işime yarayacak şey…
2. Önümüzdeki 6 ayda yapmayı planladığım…
3. Bu konuda hâlâ öğrenmek istediğim…

Bugünün kısaltmaları · Oturum 4

RKÇ	Randomize kontrollü çalışma (A/B testi)
TRIPOD+AI	Tahmin modeli makalesini yazarken
PROBAST+AI	Tahmin modeli makalesini okurken (yanlılık)
SPIRIT · CONSORT	YZ'li deneme protokolü · raporu (-AI)
DECIDE-AI	Modelin ilk canlı klinik kullanımı
Veri sızıntısı	Tahmin anında olmayan bilgiyi kullanmak

Veri kayması	Koşullar değişince performansın bozulması
Dış validasyon	Başka yer veya dönemde test
Sessiz mod	Model arka planda çalışır, kimse görmez
KVKK	6698: sağlık verisi özel nitelikli
AB YZ Yasası	2024/1689: tıbbi YZ çoğunlukla yüksek riskli
DSÖ	2021 rehberi: 6 etik ilke

Prof. Dr. Ali AKDAĞLI

Model öneriyor, hemşire/ebe karar veriyor.

Sorumluluk klinisyende kalır. Modelin önerisini sorgulamak mesleki görevdir.

Prof. Dr. Ali AKDAĞLI

Dedektörün karnesi: modül tek sayfada

1 Duyarlılık

Yangınların kaçında **öttü**?

2 Özgüllük

Tost yanınca **sustu** mu?

3 PPV

Öttüğünde gerçekten **yangın var** mı?

4 Eşik

Hassasiyet düğmesi; onu biz çeviririz.

5 AUC

Tehlikeliyi zararsızdan **ayırma** becerisi.

6 Kalibrasyon

Duman göstergesinin **sayısı** doğru mu?

7 SHAP

Dedektör **neden** öttü? Kalem kalem döküm.

8 Dış validasyon

Sizin evinizde de çalışıyor mu?

Öttüğünde ne yapılacağına evin sahibi karar verir: model öneriyor, hemşire/ebe karar veriyor.

Prof. Dr. Ali AKDAĞLI

Kısaltmalar sözlüğü (1/2)

YZ · ML	Yapay zekâ · makine öğrenmesi (kuralı veriden çıkarır)
KDS	Karar destek sistemi: öneri verir, karar klinisyende
LR	Lojistik regresyon: ağırlıklı toplam + S eğrisi
RF	Random Forest: yüzlerce ağacın oylaması
XGBoost	Sırayla hata düzelten ağaçlar (Gradient Boosting)
Çapraz doğrulama	5 parçalı sınav; 5 sonucun ortalaması
DP · YP	Doğru pozitif (doğru alarm) · yanlış pozitif (boşa alarm)
YN · DN	Yanlış negatif (kaçırma) · doğru negatif (doğru sessizlik)
Duyarlılık	Hastaların kaçını yakaladık? (sensitivity, recall)
Özgüllük	Sağlamların kaçına sustuk? (specificity)
PPV	Pozitif kestirim değeri: alarm çalınca gerçekten hasta mı?
NPV	Negatif kestirim değeri: susunca gerçekten sağlam mı?

Prof. Dr. Ali AKDAĞLI

Kısaltmalar sözlüğü (2/2)

Doğruluk	(DP + DN) ÷ hepsi; nadir olayda yanıltır (accuracy)
Prevalans	Görülme sıklığı; düşükse PPV düşer
ROC	Alıcı çalışma karakteristiği: eşik boyunca yakalama–boşa alarm
AUC	Eğri altındaki alan: hasta–sağlam çiftini doğru sıralama olasılığı
PR · AP	Kesinlik–duyarlılık eğrisi · ortalama kesinlik
Kalibrasyon · Brier	Söylenen = gerçekleşen mi? · olasılık hatası
SHAP	Shapley toplamsal açıklamaları: risk bordrosu
RKÇ	Randomize kontrollü çalışma (A/B testi)
TRIPOD+AI · PROBAST+AI	Tahmin modeli: yazarken · okurken
SPIRIT · CONSORT · DECIDE	YZ'li deneme protokolü · raporu · ilk canlı kullanım
KVKK	Kişisel Verilerin Korunması Kanunu (6698)
EHR · HBYS	Elektronik hasta kaydı · hastane bilgi yönetim sistemi

Prof. Dr. Ali AKDAĞLI

Tıbbi terimler sözlüğü (1/2)

Sepsis	Enfeksiyona aşırı tepki; organlara zarar verir
Taşikardi	Nabız >100/dk (normal 60–100)
Takipne	Hızlı soluma; >20/dk (qSOFA'da ≥22)
Ateş · hipotermi	≥38 °C · <36 °C; ikisi de tehlikeli
SKB · OAB	Büyük tansiyon · ortalama arter basıncı
SpO2	Oksijen doygunluğu; normal %95–100
GKS	Glasgow Koma Skalası 3–15; 15 tam bilinç
Laktat	Oksijensizlik atığı; <2 normal, >4 ciddi (mmol/L)
Lökosit · trombosit	Savunma hücresi (4–11 bin) · pıhtı hücresi (150–400 bin)
Kreatinin · eGFR	Böbrek atık göstergesi · süzme hızı (≥90 normal)
qSOFA	SS ≥22, SKB ≤100, GKS <15; ≥2 puan pozitif
NEWS2	Vital bulgulara puan veren erken uyarı skoru

Prof. Dr. Ali AKDAĞLI

Tıbbi terimler sözlüğü (2/2)

OGTT · HbA1c	Şekerli su testi (≥200 diyabet) · 3 aylık şeker (≥%6,5)
BKİ	Kilo / boy²; ≥30 obez, <18,5 zayıf
Nöropati	Sinir hasarı; ayak acıyı hissetmez (monofilament)
ABİ	Ayak bileği / kol tansiyonu; <0,9 damar daralması
Wagner	Diyabetik ayak yarası derinliği 0–5
GLIM	Malnütrisyon: fenotipik + etiyolojik kriter
NRS-2002 · MUST	Beslenme riski tarama ölçekleri
Barthel	Günlük yaşam bağımsızlığı 0–100
Preeklampsi	20. hafta sonrası yeni yüksek tansiyon + organ etkisi
Uterin arter PI	Rahim damarında akış direnci; yüksek = risk
PlGF · PAPP-A	Plasenta proteinleri; düşük = risk
MoM · nullipar	Ortancanın katı · hiç doğum yapmamış

Prof. Dr. Ali AKDAĞLI

Kaynaklar (seçki) · 1

de Dombal ve ark., 1972
Computer-aided diagnosis of acute abdominal pain. BMJ. 1972;2(5804):9–13.

Singer ve ark., 2016
Sepsis-3 consensus definitions. JAMA. 2016;315(8):801–810.

Seymour ve ark., 2016
Assessment of clinical criteria for sepsis. JAMA. 2016;315(8):762–774.

Royal College of Physicians, 2017
National Early Warning Score (NEWS) 2. London: RCP; 2017.

Wong ve ark., 2021
External validation of a proprietary sepsis prediction model. JAMA Intern Med. 2021;181(8):1065–1070.

Adams ve ark., 2022
Outcomes after implementation of the TREWS early warning system. Nat Med. 2022;28(7):1455–1460.

Rolnik ve ark., 2017
Aspirin versus placebo in pregnancies at high risk for preterm preeclampsia. N Engl J Med. 2017;377(7):613–622.

Cederholm ve ark., 2019
GLIM criteria for the diagnosis of malnutrition. Clin Nutr. 2019;38(1):1–9.

Schaper ve ark., 2024
IWGDF 2023 practical guidelines on diabetic foot disease. Diabetes Metab Res Rev. 2024;40(3):e3657.

Smith ve ark., 1988
ADAP learning algorithm to forecast the onset of diabetes mellitus. Proc Annu Symp Comput Appl Med Care. 1988:261–265.

Rajkomar, Dean, Kohane, 2019
Machine learning in medicine. N Engl J Med. 2019;380(14):1347–1358.

Kelly ve ark., 2019
Key challenges for delivering clinical impact with AI. BMC Med. 2019;17(1):195.

Tam kaynakça ders notundadır.

Prof. Dr. Ali AKDAĞLI

Kaynaklar (seçki) · 2

Breiman, 2001
Random forests. Mach Learn. 2001;45(1):5–32.

Chen ve Guestrin, 2016
XGBoost: a scalable tree boosting system. Proc 22nd ACM SIGKDD; 2016:785–794.

Lundberg ve Lee, 2017
A unified approach to interpreting model predictions. Adv Neural Inf Process Syst. 2017;30:4765–4774.

Van Calster ve ark., 2019
Calibration: the Achilles heel of predictive analytics. BMC Med. 2019;17(1):230.

Christodoulou ve ark., 2019
No performance benefit of machine learning over logistic regression. J Clin Epidemiol. 2019;110:12–22.

Obermeyer ve ark., 2019
Dissecting racial bias in an algorithm. Science. 2019;366(6464):447–453.

Collins ve ark., 2024
TRIPOD+AI statement. BMJ. 2024;385:e078378.

Moons ve ark., 2025
PROBAST+AI. BMJ. 2025;388:e082505.

Riley ve ark., 2020
Sample size for developing a clinical prediction model. BMJ. 2020;368:m441.

Vickers ve Elkin, 2006
Decision curve analysis. Med Decis Making. 2006;26(6):565–574.

Vasey ve ark., 2022
DECIDE-AI reporting guideline. Nat Med. 2022;28(5):924–933.

Demšar ve ark., 2013
Orange: data mining toolbox in Python. J Mach Learn Res. 2013;14:2349–2353.

Tam kaynakça ders notundadır.

Prof. Dr. Ali AKDAĞLI



Teşekkürler

Sorular ve tartışma

Prof. Dr. Ali AKDAĞLI

Ali AKDAĞLI · Sağlık Bilimleri Fakültesi · 2026